

基于图深度学习的天线阵列优化设计

Antenna Array Optimization Design Based on Graph Deep Learning

专业类别：_____电子信息_____

研究方向（领域）：_____图神经网络_____

作者姓名：_____苏倩_____

导师姓名：_____徐岩_____

合作导师：_____郝禄国_____

答辩日期	2022 年 12 月 7 日		
答辩委员会	姓名	职称	工作单位
主席	毛旭瑞	副研究员	中科院半导体所
委员	高镇	副教授	天津大学
	冯人海	副教授	天津大学

天津大学电气自动化与信息工程学院

二〇二二年十二月

摘要

随着现代通信系统的不断进步与发展，天线的需求量日益增多，如何更高效地完成天线设计成为了广泛关注的问题。目前，大多数的天线设计都依赖于全波仿真软件，但这种方法不仅需要设计者掌握夯实的理论知识，还会耗费大量的计算资源和时间。为解决这一问题，人工智能和深度学习等新兴技术逐渐被应用于天线设计领域，但目前使用最广泛的人工神经网络和深度神经网络因其只能处理单一结构的天线或天线阵列也存在一定弊端。近年来，随着图神经网络的快速发展，实现了对非欧式空间数据的端到端处理，这为天线阵列的优化设计提供了另一种可能。本文将图深度学习与天线阵列设计相结合，实现了对多种不同拓扑结构天线阵列的分析和综合，提高了天线优化设计效率，降低了计算成本。

本文首先提出了基于图深度学习的天线阵列分析方法。在该方法中，提出了一种天线阵列的图表示方法，能够将任意结构的天线阵列转化为图结构数据；提出了一个用于天线阵列辐射方向图预测的图神经网络，该网络以图同构网络为基本框架，并引入了残差连接和复数权重，能够实现多种拓扑结构阵列辐射方向图的学习和预测，其准确率优于目前已知的基于深度学习的其他方法，时间效率较全波仿真方法提高了 6 个数量级。

本文还提出了基于图深度学习和改进黏菌算法的天线阵列综合方法。该方法以图神经网络作为代理模型，引入黏菌算法对阵列参数进行反向寻优，以实现阵列综合。在该方法中，通过引入精英反向学习策略和惯性权重策略对黏菌算法进行了优化，在标准测试函数上的对比实验结果证明了改进算法相比其他元启发式算法具有一定的优势。最后通过该方法实现了多种不同拓扑结构天线阵列的笔状波束赋形、平顶波束赋形和余割平方波束赋形，大大降低了阵列综合的复杂度，提高了设计效率。

关键词：图神经网络，深度学习，天线阵列，黏菌优化算法

ABSTRACT

With the continuous progress and development of modern communication systems, the demand for antennas is increasing, and how to complete antenna design efficiently has become a widely concerned issue. Currently, most antenna design methods heavily rely on full-wave simulation software, which demand solid theoretical knowledge and intensive computation. To solve this problem, emerging technologies such as artificial intelligence and deep learning are gradually applied to antenna design, however, artificial neural networks and deep neural networks, which are currently the most widely used, also have certain drawbacks because they only deal with a single structure of antenna or antenna array. In recent years, with the rapid development of graph neural networks (GNNs), it achieves the end-to-end processing of non-Euclidean spatial data, which provides another possibility for the optimal design of antenna arrays. In this paper, we combine graph deep learning with antenna array design, and realize the analysis and synthesis of antenna arrays with multiple different topologies, which improves the efficiency of antenna array optimization design and reduces the computational cost.

In this paper, a graph deep learning-based method for antenna array analysis is proposed at first. In this method, a graph representation of antenna arrays is proposed, which is able to transform the antenna arrays of arbitrary structures into graph structure data. A GNN-based model for radiation pattern prediction of antenna arrays is proposed, which uses graph isomorphic networks as a backbone and introduces a residual connection and complex weights. It is capable of learning and predicting the radiation pattern of antenna arrays with multiple topologies, and its accuracy is better than other currently known deep learning-based methods. What's more, time efficiency is improved by 6 orders of magnitude compared with the full-wave simulation method.

In this paper, a graph deep learning and improved slime mould algorithm (ISMA)-based method for antenna array synthesis is proposed. The method uses GNN as the antenna array analyzer and introduces the slime mould algorithm (SMA) for backward optimization of the antenna array parameters aiming to achieve antenna array synthesis. In this method, the SMA is improved by introducing elite backward learning strategy and inertia weighting strategy, and the comparison experimental results on standard test functions prove the advantages of the ISMA over other metaheuristic algorithms. Finally, the synthesis of multiple antenna arrays with different topologies is achieved by

this method, with three shaped radiation patterns including pen-shaped pattern, flat-top pattern and cosecant-square pattern, which greatly reduces the complexity of antenna array synthesis and improves the design efficiency.

KEY WORDS: Graph neural networks, Deep learning, Antenna arrays, Slime mould algorithm

目 录

第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于深度学习的天线设计研究现状.....	2
1.2.2 基于图深度学习的天线设计研究现状	4
1.2.3 基于元启发式算法的天线设计研究现状	5
1.3 本文工作安排.....	6
第 2 章 基本理论	9
2.1 天线与天线阵列.....	9
2.1.1 天线的定义与基本参数.....	9
2.1.2 天线阵列	10
2.2 图深度学习.....	12
2.2.1 图	12
2.2.2 图神经网络	13
2.3 本章小结.....	14
第 3 章 基于图深度学习的天线阵列分析方法	15
3.1 基于图神经网络的阵列分析模型	15
3.1.1 模型整体架构.....	15
3.1.2 天线阵列的图表示.....	16
3.1.3 基于图同构网络的特征提取.....	17
3.1.4 天线阵列辐射方向图预测.....	18
3.2 数据集构建.....	19
3.2.1 天线阵列案例.....	19
3.2.2 数据集样本获取.....	20
3.3 模型参数与模型评估.....	21
3.3.1 模型参数设置.....	21
3.3.2 模型评估指标.....	21
3.4 实验结果与分析.....	21
3.4.1 模型训练.....	21
3.4.2 对比实验.....	22
3.4.3 消融实验.....	24
3.5 本章小结.....	28
第 4 章 基于图深度学习和改进黏菌算法的天线阵列综合方法	31
4.1 基于图神经网络和改进黏菌算法的阵列综合模型	31

4.2 黏菌算法概述与数学模型	32
4.3 基于精英反向学习和惯性权重策略的改进黏菌算法	34
4.3.1 精英反向学习策略	34
4.3.2 惯性权重策略	34
4.3.3 改进黏菌算法流程	35
4.3.4 改进黏菌算法的性能评估	36
4.4 实验结果与分析	41
4.4.1 笔状波束赋形	41
4.4.2 平顶波束赋形	47
4.4.3 余割平方波束赋形	54
4.5 本章小结	56
第 5 章 总结与展望	59
5.1 工作总结	59
5.2 工作展望	60
参考文献	61

第1章 绪论

1.1 研究背景与意义

随着现代通信系统对天线的需求日益增多,各种基于数值分析方法的电磁仿真软件(如 HFSS、CST 等)在天线的设计与优化上发挥着重要的作用。但是电磁仿真软件在使用时通常会占用极大的计算资源,优化过程耗时较长,并且往往需要工程师掌握夯实的电磁理论基础并根据丰富的工程经验进行多次仿真调试,这使得天线的设计和优化过程繁琐复杂、效率低下,并存在优化结果不理想等问题。近年来,随着人工智能技术和深度学习的迅速发展,基于深度学习的方法逐渐被应用到了电磁领域,如电磁散射、雷达、电磁兼容等^[1-5]。而在天线的设计和优化过程中,天线结构特征和电磁特征性能指标之间存在高度非线性关系,且存在多极值、多变量等问题。机器学习、深度学习等人工智能算法因其具有强大的泛化能力,在天线的设计优化过程中有着巨大的潜力,能够通过对已有天线结构特征和电磁特征性能指标之间关系的学习,建立机器学习模型,从而对未知天线结构进行性能预测或对需求性能指标进行反向结构寻优。

为实现天线的智能设计优化,提高天线优化效率,将机器学习等优秀算法应用于天线设计中,更好地解决传统天线设计的耗时耗资问题意义深远。早在 1998 年, Mishra R K 等人^[6]就将人工神经网络(Artificial Neural Network, ANN)应用在了方形贴片天线的设计过程中,提出了一种基于神经网络的方形贴片天线模型,该模型在计算时间和精度方面都具有较好的鲁棒性,初步实现了人工智能在天线领域的应用。目前已经有很多代理模型被引入天线设计等电磁领域^[7-11],如人工神经网络、克里金插值(Kriging Interpolation)、径向基函数(Radial Basis Function, RBF)等。基于人工智能的新型天线设计与使用电磁仿真软件的传统天线设计方法相比,无论是在天线的设计效果还是优化效率方面都有着巨大的优势。

在天线阵列分析与综合领域,人工神经网络和深度神经网络等传统的神经网络算法因其在提取欧式空间数据特征方面的强大能力取得了巨大的成功,能够对阵列结构和激励等参数和辐射方向图之间的关系进行学习和训练,从而实现天线阵列的分析或综合。但传统的神经网络也正是因为只适合处理欧式空间数据,所以只能应用于单一拓扑结构的天线阵列,具有一定的局限性。

近几年,图神经网络(Graph Neural Network, GNN)因其能够处理从非欧式空间中生成的图结构数据而受到了广泛的关注,被应用在了电子商务、社交网络、生物制药、交通预测等诸多领域^[12-15]。例如在电子商务中,将用户和商品及其之间的关系建模为图结构数据,基于图的学习系统可以利用用户和商品之间的交互关系给出更高准确度的建议;在交通预测中,将地点、时间、交通流量、天气等多模态信息建模为图结构数据,基于图神经网络的模型可以利用这些多模态信息更精确的预测未来的交通流量。将图深度学习技术应用于天线阵列设计是一个较新的课题研究方向,但与上述图神经网络在各领域的应用理念相似,某些相对复杂的天线或天线阵列模型也可看作是一种图结构数据,数据中包含天线结构、阵元间的距离和耦合关系等参量。将多种不同拓扑结构的阵列建模为不规则又具有统一格式的图结构数据后,图神经网络可以利用该图结构数据更灵活有效地学习阵列结构和电磁性能之间的关系,从而突破阵列拓扑结构的限制,实现对多种不同拓扑结构的阵列的分析和综合。将图深度学习应用于阵列领域具有巨大的发展前景。

1.2 国内外研究现状

1.2.1 基于深度学习的阵列设计研究现状

传统的阵列设计和优化多依赖于工程师的理论基础和工程经验,使用电磁仿真软件通过等步长的扫参方式进行多次调试,结果很难达到最优,并且过程复杂且耗时长。随着人工智能技术的迅速发展,深度学习又迎来了新的发展高潮,将深度学习技术引入阵列领域,通过学习阵列结构参数和性能指标参数之间的关系,在一定程度上弥补电磁仿真软件的弊端,加快阵列的设计优化过程,成为近年来科研人员的关注重点。这也为阵列的设计和优化带来了一个新的设计思路。目前人工神经网络(Artificial Neural Network, ANN)和深度神经网络(Deep Neural Network, DNN)是在阵列领域使用最多且最成熟的网络模型,阵列结构设计或阵列综合为目前研究最多的两大问题。

在阵列结构设计和优化方面,多使用 ANN 进行训练和预测^[16-18]。例如,1998 年, Mishra RK 等人^[6]将人工神经网络用于方形贴片阵列设计,实现了 ANN 在阵列设计领域的应用,验证了基于人工智能实现阵列设计优化的可行性。随后,为了提高模型的准确率和训练的速度,很多学者在基础的 ANN 上进行了改进和优化,构建了更符合需求的网络模型。2005 年, Delgado H J 等人^[19]提出一种结合有限差分时域(Finite Difference Time Domain, FDTD)新型神经网络算法用于

合成印刷偶极子天线。2006 年, Mohamed M D A 等人^[20]将径向基函数(RBF)引入神经网络模型中,成功预测贴片天线的辐射贴片和馈电微带线的最佳几何尺寸。2013 年, Akdagli A 等人^[17]使用多层感知器(Multilayer Perceptron, MLP)优化人工神经网络,并成功应用于 E 形紧凑型微带天线的谐振频率计算。2018 年, Kapetanakis T N^[21]利用人工神经网络解决了求解薄圆形环形天线在自由空间辐射的逆问题。同年, Xiao Liye 等人^[22]提出了一个引入了支持向量机的人工神经网络模型,该模型能够通过每个分支对天线的回波损耗、增益、辐射方向图多个性能指标同时进行预测,在法布里珀罗天线上的实验结果验证了模型的有效性和模型效率。众多文献都验证了人工神经网络在天线结构尺寸设计中的可行性,并与传统的天线结构设计方法相比,有着巨大的优势。

在天线阵列的设计和综合方面,2007 年, Ayestaran R G 等人^[23]使用神经网络进行非均匀天线阵列合成,模型将天线阵列的辐射模式施加到每个阵元与激励电压相关联,无需对天线的几何形状进行任何假设,并且即使考虑耦合效应也可以解决非均匀天线阵列的问题。2015 年, Mishra Subhash 等人^[24]利用径向基函数神经网络(RBF-NN)对共线短偶极子和平行短偶极子的均匀线性阵列进行了方向性估计,该方法很容易适应天线阵的非线性特性,不需要复杂的数学过程,因此速度更快,文章也验证了该方法的鲁棒性。2020 年, Yuan L^[8]提出一种新的多分支人工神经网络建模技术并将其应用于解决天线阵列方向性估计的逆问题。在天线阵列的逆问题的建模过程中,模型的输入是电磁参数,阵列的几何结构参数和物理参数被设置为输出,利用逆问题的单调性对数据进行训练,通过人工神经网络的并行分支同时对阵列的多个电磁参数进行预测和求解。2021 年, Zhou Z^[25]将深度神经网络用于解决 1×8 贴片天线阵列方向图综合及其逆问题求解。该文章以电磁仿真结果作为数据集,训练 DNN 来学习产生辐射模式的激励信号的映射及其逆问题,提出的 DNN 架构为电磁解决方案提供了一种高效、可靠的补充,可推广到更大规模的天线阵或用于辅助复杂天线阵的反向设计。2022 年, Can Cui 等人^[26]提出了一个新颖的基于编码器-解码器结构的人工神经网络框架,用于可重构的非均匀间隔线阵综合。在该框架中,不同的编解码器分支用于合成阵列所需的辐射方向图。而在每个编解码器的分支中,编码器充当阵列合成器,解码器充当阵列分析器,通过对阵元振幅和位置相关损失函数最小值的寻优,不仅可以成功实现辐射方向图多种赋形,还可以获得阵元间距和阵元振幅。

上述文献证明了深度学习在天线设计与优化上的优势和潜力,也为图深度学习在该领域的应用提供了一定的基础。为突破 ANN 和 DNN 只能应用在单一结构天线阵列的局限性,将能够处理非欧式空间数据的图神经网络应用于天线阵列的分析和综合十分必要。

1.2.2 基于图深度学习的天线设计研究现状

为更好地学习非欧式空间数据的特征,利用深度学习技术实现对图数据的端到端学习成为了一个热门且重要的研究课题。2005 年, Marco Gori 等人^[27]首次提出图神经网络(Graph Neural Network, GNN)的概念。在随后的几年发展中,受卷积神经网络发展的影响,人们开始将卷积应用到图神经网络之中,并通过不断地改进和拓展,越来越多的基于图的神经网络被提出,并应用在了含有图数据的众多领域。但将图深度学习应用于天线领域当前还是一个较新的课题。

2019 年 Zhang G 等人^[28]第一次将 GNN 应用于电磁领域,提出了一个用于分布式电路设计的 GNN 模型——Circuit-GNN。如图 1-1 所示,该模型将谐振器作为节点,谐振器之间的距离(耦合关系)作为边,从而将电路建模成一种图数据;将谐振器的位置、开环方向和谐振器之间的距离作为模型的输入,电路的电磁特性作为模型的输出,训练后的模型能够实现分布式电路的性能预测和谐振器分布设计,此方法极大地加速了高频电路的设计工作。




图 1-1 Circuit-GNN 模型架构




图 1-2 基于 DGCNN 的准周期阵列分析方法

近两年,许多学者开始尝试将 GNN 应用于天线设计与优化中,并取得了一定的进展和成果。2022 年, Wei X.等人^[29]提出了一种用于分析准周期阵列的基于动态图卷积神经网络(Dynamic Graph Convolutional Neural Network, DGCNNs)的方法来分析由不同几何参数单元组成的准周期阵列。图中的每个节点表示准周期阵列中的一个单元,每个节点特征由相应单元的几何参数决定,如图 1-2(a)所示。文章提出的 DGCNN 模型如图 1-2(b)所示,能够动态更新图的边特征以获得

单元之间的互耦关系。训练成功后的 DGCNN 模型能够快速预测具有随机分布和可变尺寸单元的超材料准周期阵列的回波损耗。

同年, Tekbiyik 等人^[30]提出了一个用于天线阵列雷达波达方向 (Direction of arrival, DoA) 估计的基于图注意力网络 (GAT) 的深度学习框架, 如图 1-3 所示。该网络由四个全局注意力层 (Global Attention Layers, GALs) 和四个全连接层 (Dense Layers) 组成, 分别用于图结构数据的特征提取和对二维角度值的回归分析, 最终实现对单像素接收机压缩信道上的数据测量和进行 DoA 估算, 并在相对较低信噪比的情况下综合检索出高保真的 DoA 信息。




图 1-3 用于 DoA 的 GAT 模型框架

在上述文献中, 图神经网络被成功应用在了电磁领域中, 这为本课题使用图神经网络解决天线阵列设计问题提供了理论依据和可行性支撑。

1.2.3 基于元启发式算法的天线设计研究现状

深度学习模型和框架在天线设计领域多用来作为代理模型, 其作用是代替传统全波仿真方法对天线性能或阵列方向图进行正向预测; 而元启发式算法多用于进行天线或阵列参数的反向寻优。元启发式算法是通过模拟自然界的规则而演化出的一种新兴的计算技术, 是智能优化算法的一个重要分支, 因其在处理非线性、复杂性等问题时表现出来的先进性, 已成为越来越多的学者关注的焦点。

元启发式算法适用于求解高度非线性多参数多目标问题, 因此为寻找天线的最优解提供了可能。其中遗传算法 (Genetic Algorithm, GA) 和粒子群算法 (Particle Swarm Optimization, PSO) 提出较早且发展成熟, 在电磁领域和天线的设计优化中应用最为广泛^[31-35]。例如, 2000 年, 杨帆等^[36]将遗传算法成功地应用到微带天线的优化中, 优化出了带宽由初始 5% 展宽到 16.6% 的宽带天线、以及双频比为 1:131 且具有同向的线极化的双频工作天线; 2006 年, 焦永昌^[37]等将粒子群优化算法运用于天线阵的方向图综合上, 表明粒子群算法在天线阵列综合中具有广泛的应用前景; 2007 年, 丁敏等^[38]将二维遗传算法和时域有限差分混合模型应用于有限尺寸超宽带平面天线的自动设计, 成功地设计了一种小尺寸的超宽带天线。同年, Aaron J. Kerkhoff 等人^[39]将遗传算法优化方法应用于平面单极子天线的设计中, 优化了天线的性能, 改进了方向图的对称性, 拓宽了陷波的有效带宽。2019

年, Fan Xiaohong 等^[40]提出了一种自更新适应度估计的粒子群优化算法(SFEPSO), 以提高微带天线的设计效率, 实现了对 E 型双频微带天线和 WLAN/WiMAX 多频段天线的优化设计。

除此之外, 更多的元启发式算法被提出, 例如灰狼优化算法(Grey Wolf Optimizer, GWO)^[41]、鲸鱼优化算法(Whale Optimization Algorithm, WOA)^[42]、果蝇优化算法(Fruit Fly Optimization Algorithm, FOA)^[43]、人工蜂群算法(Artificial bee colony, ABC)^[44]等也逐渐被应用于天线的设计与优化中。2014 年, Sotirios K. 等人^[45]利用人工蜂群算法设计并优化了一种用于超高频无源射频识别标签的平面螺旋天线。2017 年, Yuan Pengliang 等人^[46]将鲸鱼优化算法引入到稀疏阵列天线综合中, 优化后的稀疏阵列天线具有更低的旁瓣电平。通过在具有不同约束条件的稀疏阵列上进行测试, 实验结果表明鲸鱼优化算法优于改进粒子群优化算法和改进遗传算法等优化算法。2018 年, Amirashkan Darvish 等人^[47]提出了一种改进的果蝇优化算法用于天线阵综合, 利用提出的算法合成了具有超宽带特性的 U 型槽微带阵列天线, 优化后的天线结构的阻抗带宽比原结构带宽提高了 181.6%。同年, 张鑫等^[48]提出了基于自适应变微分的人工蜂群算法, 并通过稀疏非均匀天线阵列和八木天线的设计验证了该算法有助于解决天线阵列设计问题。2020 年, Li Xun 等人^[49]将灰狼算法应用于线性阵列合成以及双频 E 形贴片天线和宽频带磁电偶极子天线的优化设计, 并与遗传算法、粒子群算法和差分进化等著名的元启发算法进行了比较, 验证了该算法在天线设计领域的优势和潜力。

通过以上算例可以看出, 元启发式算法已在天线的设计优化过程中得到了广泛应用。但元启发式算法存在容易陷入局部最优的问题, 如何寻找更适用于天线优化的元启发式算法, 如何改进算法而进一步提高天线的优化效率, 是本课题的研究内容之一。

1.3 本文工作安排

本文主要对图深度学习在天线阵列分析和综合上的应用进行了研究, 其章节安排如下:

第一章为绪论。主要介绍了图深度学习在天线设计领域上的研究背景与意义, 并分析了基于深度学习的天线设计方法、基于图深度学习的天线设计方法和基于元启发式算法的天线设计方法的研究现状。最后介绍了本文的工作安排和整体结构。

第二章为基础理论。首先介绍了天线的相关理论和基本参数，以及天线阵列的相关知识，重点介绍了阵列方向图的相关公式。其次对图深度学习的基础理论进行了介绍，包括图的定义以及常见的图神经网络。

第三章为基于图深度学习的天线阵列分析方法。首先详细描述了本文提出的用于阵列方向图预测的图神经网络的模型架构，架构主要分为三个部分：天线阵列的图表示、基于图同构网络的特征提取、基于残差增强和复数全连接网络的方向图预测。接着介绍了用于模型训练和预测的天线阵列算例和数据集样本构成。其次介绍了模型训练的参数设置和模型优劣的评估指标。最后进行了实验结果的定量分析和定性分析，并通过对比实验和消融实验验证了所提模型架构的先进性和有效性。实验结果表明，所提模型能够同时有效预测多种不同拓扑结构的阵列方向图，且准确性优于其他神经网络模型，并且计算效率比传统全波仿真算法提高了6个数量级。

第四章为基于图深度学习和黏菌算法的天线阵列综合方法。在本章中，首先提出了用于阵列综合的图深度学习模型架构，将黏菌算法引入其中，实现图神经网络的反向寻优任务。其次介绍了黏菌算法的基本原理和精英反向学习、惯性权重两个改进策略，并在标准测试函数上对改进算法进行了性能评估。最后完成了多种满足需求的天线阵综合，并验证了所提算法相较其他算法的优越性。

第五章为总结与展望。本章对全文的工作进行了总结，并对课题的后续研究和未来发展提出了展望。

第2章 基本理论

2.1 天线与天线阵列

2.1.1 天线的定义与基本参数

辐射或者接收无线电波的装置被称为天线，其主要完成导行电磁波（高频电流）与空间电磁波能量之间的转换。天线应将导波能量尽可能多地转变为电磁波能量，并使电磁波尽可能集中于确定的方向，还应有适当的极化和足够的工作频段。基于以上天线应具有的基本功能，定义了相关参数以能定量地设计和评价天线的性能并表征其能量转换和定向辐射能力的量。参数主要有方向图、主瓣宽度、旁瓣电平、方向系数、天线效率、极化特性、频带宽度和输入阻抗等。

由于本文重点研究图深度学习在天线阵列波束分析和综合领域的应用，所以下面将主要介绍天线方向图的相关参数。

方向图是指在离天线一定距离处，辐射场的相对场强随方向变化的曲线值，通常是在远区确定的。完整的天线方向图如图 2-1(a)所示，是在三维球坐标系下表示的。但为了绘制简化，方向图通常会使用两个互相垂直的剖面（图 2-1(a)中的 xz 和 yz 平面）表示，我们将其称为主平面方向图，但绕轴对称的方向图只需要一个剖面图，如图 2-1(b)所示，将极坐标系转换为直角坐标系，方向图可表示为如图 2-1(c)所示。

在进行定量分析时，通常会将方向图进行归一化并用 dB 表示，其公式可以表示为：

$$F(\theta, \varphi)_{\text{dB}} = 20 \log \left| \frac{F(\theta, \varphi)}{F(\theta, \varphi)_{\max}} \right| \quad (2-1)$$

其中， $F(\theta, \varphi)$ 表示 (θ, φ) 上的辐射场强， $F(\theta, \varphi)_{\max}$ 表示辐射场最大值。

为了方便分析和比较各类天线的方向图特性，还规定了其他参数，具体如下。

（1）主瓣宽度

方向图主瓣上两个半功率点之间的夹角，即场强下降到最大值的 0.707 倍处或分贝值从最大值下降至 -3dB 处对应的两点之间的夹角，被称为主瓣宽度，又称为 -3dB 波束宽度或半功率波束宽度（Half-Power Beam Width, HPBW）。

（2）第一零点波束宽度

主瓣两侧第一个零点夹角的波束宽度被称为第一零点波束宽度（Beamwidth between First Nulls, FNBW）。

（3）旁瓣电平

在天线辐射方向图中，除了主瓣，其他的波瓣均是旁瓣（Side-Lobe Level, SLL），也称副瓣。旁瓣电平的计算方法为旁瓣最大值比主瓣最大值。




图 2-1 天线方向图

2.1.2 天线阵列

将若干辐射单元（阵元）按某种方式排列，就构成了天线阵列（Antenna Array），也叫天线阵。其目的是加强和改善天线辐射场的方向性。天线阵列的辐射场是所有阵元辐射场的矢量叠加，所以影响天线阵列性能的因素包含：阵元排列形状、

阵元之间的相对位置、阵元的激励幅度、阵元的激励相位和每个阵元的方向图差异。

在各阵元为相似元的条件下,天线阵列的方向图函数为元因子和阵因子相乘之积,也称方向图乘积定理。元因子表示阵元的方向图函数,其值由阵元本身的结构和辐射性能决定。阵因子表示天线阵的方向性,其值由阵列的排列方式和阵元的激励幅度和相位决定。常见的天线阵列有线阵、面阵、环行阵等,本文主要研究了图深度学习在线阵列和矩形面阵列的分析与综合的应用,且阵列案例为由相似元组成的天线阵,因此,本节将重点介绍线阵和矩形面阵的方向图理论公式。

(1) 直线阵列

直线阵列是若干个天线单元呈直线排列的阵列,如图 2-2 所示。




图 2-2 直线阵列

N 元直线阵的辐射场为

$$F(\theta, \varphi) = f(\theta, \varphi) \cdot f_a(\theta, \varphi) = f(\theta, \varphi) \sum_{n=1}^N I_n e^{j(kd_n \sin \theta \cos \varphi + \xi_n)} \quad (2-2)$$

其中, $f(\theta, \varphi)$ 表示元因子, $f_a(\theta, \varphi) = \sum_{n=1}^N I_n e^{j(kd_n \sin \theta \cos \varphi + \xi_n)}$ 表示阵因子。 $k = 2\pi / \lambda$, λ 为天线工作波长。 I 表示阵元的激励幅度, ξ 表示阵元的激励相位, d 表示阵元的位置。

(2) 矩形面阵列

矩形面阵列的阵元排列方式如图 2-3 所示。与直线阵列的方向图计算类似,根据辐射场矢量叠加和方向图乘积定理, $M \times N$ 矩形面阵列的方向图阵因子可表示为

$$f_a(\theta, \varphi) = \sum_{m=1}^M I_m e^{j(kd_x \sin \theta \cos \varphi + \xi_x)} \sum_{n=1}^N I_n e^{j(kd_y \sin \theta \sin \varphi + \xi_y)} \quad (2-3)$$

其中, $I = I_m I_n$ 表示阵元的激励幅度, ξ_x 和 ξ_y 分别表示阵元沿 x 轴和 y 轴的激励相位, d_x 和 d_y 表示阵元在 x 轴和 y 轴的位置。




图 2-3 矩形平面阵列

2.2 图深度学习

2.2.1 图

图 (Graph) 是一种数据结构, 是对对象 (节点) 和其关系 (边) 建模成的一种特别的度量空间。这个空间体现了节点间的关系, 它不同于二维、三维之类的空间数据, 所以被称为非欧式空间数据。现实生活中, 有很多这样的非欧氏空间数据, 例如在社交、化学分子、交通等领域, 这些数据以庞大的节点数量和复杂的交互关系形成了一定图结构, 也称拓扑结构数据。

图由节点和节点之间的边组成, 如图 2-4 所示, 通常被表示为 $G(V, E)$ 的形式, 其中 G 表示一个图, V 是图 G 的节点集合, E 是图 G 的边集合。在图结构中, 不允许没有节点。每个节点都有自己的特征信息。边则用来表示任意两个节点之间存在的逻辑关系, 这种逻辑关系可以反映出图结构的特征信息。边可以是有向的, 也可以是无向的, 边集合也可以为空。




图 2-4 非欧式空间的图结构数据

2.2.2 图神经网络

为了处理非欧式空间的图结构数据，图神经网络（Graph Neural Network, GNN）孕育而生并成为解决结构不规则数据机器学习问题的重要技术。它能够直接从图结构数据中学习特征规律，并对节点特征或结构特征进行处理。

近年来，受到深度学习领域进展的影响和对非欧式空间数据处理的需要，借鉴卷积神经网络设计出的图神经网络被应用到了越来越多的图数据领域中，也被研究人员逐步开发出了很多经典的模型。2020年，Wu Z 等人^[50]提出了一种新的 GNN 分类方法，将 GNN 划分为四类，分别是：循环图神经网络（Recurrent GNN, RecGNN）、卷积图神经网络（Convolutional GNN, ConvGNN）、图自编码器（Graph Autoencoders, GAEs）、时空图神经网络（Spatial-temporal GNN, STGNN）。

RecGNN 是最早提出来的一类图神经网络^[51-53]，其目的是学习具有递归神经网络架构的节点特征。它们不断通过图中的节点与其相邻节点进行信息交换来完成消息传递，该思想启发了后续对 ConvGNN 的研究。ConvGNN 将卷积运算从栅格数据推广到了图数据，主要分为基于谱域的 ConvGNN 和基于空间的 ConvGNN 两类。其主要思想是通过聚合节点自身特征及其邻域节点特征来生成该节点的图表示，通过叠加多个图卷积层来提取更高级的节点特征。ConvGNN 在构建许多复杂的 GNN 模型中发挥着核心作用^[54-57]。GAE 是无监督学习框架，其思想是将节点或图数据编码到潜在的向量空间，并根据编码信息重建图数据，多用于学习网络嵌入^[58, 59]和图重构^[60, 61]。STGNN 是一类同时考虑空间相关性和时间相关性的图神经网络，多用于交通流量预测^[62]、驾驶员动机预测^[63]和人类行为识别^[64]等。当前的 STGNN 构建方法多将图卷积和循环神经网络或卷积神经网络结合，利用图卷积学习空间相关性，利用循环神经网络或卷积神经网络对时间相关性进行建模。

2018年，Keyulu Xu 等人^[65]在图神经网络领域基于空间的 ConvGNN 的主流做法的原理上推出了一个可以更好地表达图特征的结构——图同构网络（Graph Isomorphism Network, GIN）。GIN 同 RecGNN 和 ConvGNN 等网络模型一样，都是使用递归的方式对图中的节点特征按照边的结构进行聚合计算，但 GIN 提出了一个更高的合理性要求，即图同构。经过图同构处理后的图特征应该相同，反之则不同。GIN 模型是根据图神经网络的单射函数特性设计出来的，单射即指每个输出只对应一个输入的映射。GIN 模型的原理简而言之，GIN 在图节点邻居特征的每一步执行聚合之后，又与图节点自身的原始特征混合起来，并在最后使用可以拟合任意规则的全连接网络进行处理，使其具有单射特性。本文的第三章将对 GIN 的原理进行更详细的介绍，其计算过程也将在第三章进行展示。

2.3 本章小结

本章首先介绍了天线的相关定义与基本参数，其次介绍了天线阵列的相关概念，并对后续本文使用到的直线阵列和矩形面阵列的方向图函数进行了详细描述和推导。除此之外，本章还介绍了图深度学习的相关概念，包括图的定义和常用的图神经网络，这为本文的后续工作提供了重要的理论依据。


第3章 基于图深度学习的天线阵列分析方法

本章提出了一种全新的基于图深度学习的天线阵列分析方法，提出了一种天线阵列的图建模方案，并构建了一个新颖的具有残差增强的复数图神经网络模型。该模型以图同构网络（GIN）为主干，引入了残差连接和复数权重，训练后的模型能够高效且准确地预测多种不同拓扑结构天线阵列的辐射方向图。

3.1 基于图神经网络的阵列分析模型

3.1.1 模型整体架构

基于图神经网络的阵列分析模型整体架构如图 3-1 所示，主要由三个部分构成。第一部分是天线阵列的图表示，将天线阵列的结构参数和激励信号建模为图结构数据；第二部分为基于图同构网络的特征提取，通过图同构网络的信息传递提取阵列图数据的节点特征和边特征；第三部分为方向图预测，通过引入残差连接和复数权重的全连接网络对图数据进行进一步特征提取，最终输出预测的阵列辐射方向图。



模型构建的详细步骤如下：

步骤 1：使用全波仿真软件构建天线阵列数据样本。

步骤 2：将步骤 1 中构建的数据样本转换为图结构数据。其中每个阵元的位置信息和激励设置作为图的节点信息，具有耦合影响的阵元之间的相对位置作为图的边信息。

步骤 3：构建图神经网络模型，将天线阵列的图结构数据作为模型输入，天线阵列的辐射方向图作为真值，用于模型的监督学习。

步骤 4：调整模型参数，随着模型训练迭代次数的增加，损失函数值逐渐降低并达到稳定，此时模型输出的阵列方向图的预测值与真值的拟合程度较好且稳定。模型训练完成后，保存模型结构和参数。

步骤 5：当需要对某种拓扑结构的天线阵列的辐射方向图进行预测时，首先按上述同样方法对其进行图表示，然后输入到步骤 4 已经训练好的模型中，运行模型得到预测输出。

3.1.2 天线阵列的图表示

本文提出了一种用于天线阵列的图表示方法，如图 3-2 所示，将天线阵列的拓扑结构参数和激励（幅度和相位）参数转换为图结构数据，使其适用于图神经网络。




图 3-2 天线阵列的图表示示例

具有 N 个阵列单元的天线阵列由 N 行参数向量表示，每个阵元的参数向量被表示为 $[x, y, I, \varphi]$ ，其中 (x, y) 代表阵元的位置， I 表示阵元的激励幅度， φ 表示激励相位。

天线阵列的图结构 G 被定义为:

$$G = \{V, E, A\} \quad (3-1)$$

其中, $V = \{\mathbf{v}_i\}_{1 \leq i \leq N}$ 表示节点集合, $E = \{\mathbf{e}_{ij}\}_{1 \leq i, j \leq N}$ 表示边集合; $A = \{A_{ij}\}_{1 \leq i, j \leq N}$ 表示图 G 的邻接矩阵, 矩阵维度为 $N \times N$ 。

文献[66]验证了复数比实数具有更丰富的表示能力, 受此启发, 所提模型中引入了复数权重, 为了与其兼容匹配, 本文将天线阵列图结构数据中的节点信息的激励幅度和激励相位表示为复数形式。例如, 如果阵元激励为 $1 \angle 45^\circ$, 则使用复数可表示为 $0.707+0.707i$ 。因此, 节点 $\mathbf{v}_i$ 的特征向量用复数形式表示为:

$$\mathbf{v}_i = [I_i \cdot \cos \varphi_i, I_i \cdot \sin \varphi_i] \quad (3-2)$$

由于阵元的相对位置比绝对位置更加重要, 所以节点 $\mathbf{v}_i$ 的特征向量中没有包含阵元的位置信息 (x, y) 。但通过两个阵元之间的相对位置可以生成两个节点间的边特征向量, 即定义节点 $\mathbf{v}_i$ 和节点 $\mathbf{v}_j$ 之间的边特征向量 $\mathbf{e}_{ij}$ 为:

$$\mathbf{e}_{ij} = (\mathbf{v}_i, \mathbf{v}_j) = [x_i - x_j, y_i - y_j] \quad (3-3)$$

其中, $x_i - x_j$ 和 $y_i - y_j$ 表示两个阵元间的相对位置。

邻接矩阵 A 中的元素 A_{ij} 可以定义为:

$$A_{ij} = \begin{cases} 1, & \mathbf{e}_{ij} \in E \text{ and } 0 < d_{ij} \leq 0.5\lambda \\ 0, & \text{else} \end{cases} \quad (3-4)$$

其中, $d_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$ 表示第 i 个阵元和第 j 个阵元之间的间距; λ 表示天线阵列的工作波长。如果阵元与除自己以外的其他阵元之间的距离小于 0.5λ , 则视为两阵元间存在耦合关系, 邻接矩阵 A 中的对应元素设置为 1; 否则设置为 0, 两节点 (阵元) 不共享一个边。

根据以上定义, 可将任意结构的阵列结构转换为图结构数据, 其本质为矩阵的集合。在计算机语言中, 使用数组、列表、字典进行表示。

3.1.3 基于图同构网络的特征提取

图同构网络 (GIN) 因其单射特性具有较强的表达能力, 本文基于图同构网络设计了特征提取模块。该部分由输入层和隐藏层构成。输入层为天线阵列图表示生成的图结构数据, 隐藏层为图同构网络层, 总共有三层。隐藏层能够提取节点特征和边特征, 并能够将信息沿边从一个节点直接传递到另一个节点。与节点 $\mathbf{v}_i$ 相邻的节点集合被定义为 $NB(\mathbf{v}_i) = \{\mathbf{v}_u \in V | (\mathbf{v}_i, \mathbf{v}_u) \in E\}$, 并用 $\mathbf{e}_{iu}$ 表示边

(v_i, v_u) 的边特征向量。第 $k(k=0,1,2)$ 个隐藏层中的节点 v_i 的隐藏特征向量表示为 h_i^k 。消息传递过程为：

$$h_i^k = f_v \left(h_i^{k-1}, \sum_{v_u \in NB(v_i)} f_e \left(h_i^{k-1}, h_u^{k-1}, e_{iu} \right) \right) \quad (3-5)$$

其中, $h_i^0 = v_i$; f_v 和 f_e 通过多层感知器 (Multilayer Perceptron, MLP) 拟合得到。通过三层图同构网络隐藏层获得的 h_i^2 最终被输入到带有残差增强的复数全连接层以执行辐射方向图预测任务。

3.1.4 天线阵列辐射方向图预测

模型设置了四层全连接层以进一步提取天线阵列图结构数据特征和预测天线阵列辐射方向图。为提高模型预测方向图的准确率,本文在全连接层中引入了复数权重和残差链接。

3.1.4.1 复数权重

由 3.1.2 节可知,节点特征向量被定义为了复数形式,为了能够让模型进行复数运算并学习复数特征,在全连接层引入了复数权重。复数全连接层的计算过程如图 3-3 所示,其计算过程如下:

$$W \cdot z = (Pp - Qq) + i(Pq + Qp) \quad (3-6)$$

其中 $W = P + iQ$ 表示每个全连接层中的复数权重, $z = p + iq$ 表示每个全连接层输入的向量。为了便于计算机计算,将公式(3-6)化为矩阵表示:

$$\begin{bmatrix} \Re(W \cdot z) \\ \Im(W \cdot z) \end{bmatrix} = \begin{bmatrix} P & -Q \\ Q & P \end{bmatrix} \cdot \begin{bmatrix} p \\ q \end{bmatrix} \quad (3-7)$$

其中, $\Re(W \cdot z)$ 和 $\Im(W \cdot z)$ 分别为结果的实部和虚部,也是下一个复数全连接层的输入。最终的预测结果由最后一层的复数全连接层输出的实部和虚部融合得到。




图 3-3 复数全连接层计算过程

3.1.4.2 残差连接

为了避免模型在训练过程中出现过拟合的潜在风险,改善模型容易出现梯度消失等问题,在复数全连接网络的第一层和最后一层之间增加了一个残差连接,如图 3-4 所示。




图 3-4 复数全连接层中的残差连接

复数全连接层中的残差连接的计算公式如下:

$$H(\alpha) = \alpha + F(\alpha) \quad (3-8)$$

其中, α 是复数全连接网络第一层的输出特征, $F(\alpha)$ 表示两层全连接操作, $H(\alpha)$ 为复数全连接网络最后一层的输入。残差连接既没有增加额外参数,也没有增加计算复杂度,但有助于网络学习到更多的信息,以进一步提高模型的准确性。

3.2 数据集构建

3.2.1 天线阵列案例

为利用先验知识对模型进行训练,本文选用微带天线阵列作为算例进行数据集构建,用于模型训练及模型性能评估。

阵列天线单元为工作频率在 2.45GHz 的微带天线,其结构的主视图和侧视图如图 3-5 所示。该天线单元由介质基板和在介质基板两侧的辐射贴片、地构成,选用介电常数 $\varepsilon = 4.4$ 的 FR4 材料作为介质基板,其边长 $W_0 = 40\text{mm}$ 、厚度 $H = 1\text{mm}$ 。辐射贴片的边长为 $W_1 = 28\text{mm}$ 。馈电方式采用同轴线馈电,馈电点位置位于贴片天线中心下侧 $s = 5\text{mm}$ 处。使用该微带天线单元构建天线阵列,线阵列和面阵列结构如图 3-6 所示。




图 3-5 微带天线阵列单元结构




图 3-6 微带天线阵列结构

3.2.2 数据集样本获取

为了评估所提模型在不同拓扑结构的天线阵列上的性能，使用 3.2.1 节中的微带天线单元，构建了 5 种不同拓扑结构的天线阵列：6 元均匀线阵列（Uniform linear array, ULA）、8 元均匀线阵列、8 元（2×4）面阵列（Planar array, PA）、8 元非均匀线阵列（Non-uniform linear array, NLA）、10 元非均匀线阵列。每种类型的天线阵列均采用幅相激励。阵列的拓扑结构参数和激励设置具体如表 3-1 所示。6-ULA 和 8-ULA 的相邻阵元间距设置为 0.5λ ，8-PA、8-NLA 和 10-NLA 的相邻阵元间距范围为 $[0.4\lambda, 0.6\lambda]$ ，采样步长为 0.01λ 。所有阵列的激励幅度在 $[0,1]$ 之间，步长为 0.01；激励相位在 $[0^\circ, 180^\circ]$ 之间，步长为 10° 。每种类型的阵列根据实验设计（design of experiments, DOE）方法使用全波仿真软件生成 3000 个样本。

表 3-1 阵列拓扑结构参数和激励设置

阵列类型	相邻阵元间距 $d_{ij}(\lambda)$			激励幅度 I			激励相位 $\varphi(^{\circ})$		
	最小值	最大值	步长	最小值	最大值	步长	最小值	最大值	步长
6 元 ULA	0.5	0.5	-	0	1	0.1	0	180	10
8 元 ULA	0.5	0.5	-	0	1	0.1	0	180	10
8 元 PA	0.4	0.6	0.01	0	1	0.1	0	180	10
8 元 NLA	0.4	0.6	0.01	0	1	0.1	0	180	10
10 元 NLA	0.4	0.6	0.01	0	1	0.1	0	180	10

3.3 模型参数与模型评估

3.3.1 模型参数设置

模型采用 Adam 优化器进行训练, 初始学习率为 2×10^{-4} , 并随着迭代次数的增加当损失函数连续十次迭代不再下降时, 学习率降低为原来的一半。模型各个网络的激活函数选择 Relu 函数。训练模型的最大迭代次数设置为 200, 每轮迭代过程模型会同时处理 512 个数据样本。模型训练过程中的损失函数选用 l_1 损失函数, $l_1 = |y_{\text{pred}} - y_{\text{true}}|$, 其中 y_{pred} 为预测值, y_{true} 为真值。模型训练及测试使用的计算机处理器型号为 Intel Core i7-11700 CPU@2.50GHz, GPU 型号为 NVIDIA 3080Ti。

3.3.2 模型评估指标

本文使用平均绝对百分比误差 (Mean absolute percentage error, MAPE) 和均方根误差 (Root mean square error, RMSE) 对所提模型和比较算法的性能进行比较和评估。

MAPE 用于衡量预测值与真实值的偏离的相对大小(即百分率), 其公式为:

$$\text{MAPE} = \frac{1}{M} \sum_{m=1}^M \left| \frac{y_{\text{true}(m)} - y_{\text{pred}(m)}}{y_{\text{true}(m)}} \right| \times 100\% \quad (3-9)$$

RMSE 用于衡量预测值与真实值的偏离的绝对大小, 其公式为:

$$\text{RMSE} = \sqrt{\frac{1}{M} \sum_{m=1}^M (y_{\text{true}(m)} - y_{\text{pred}(m)})^2} \quad (3-10)$$

其中 y_{pred} 为预测值, y_{true} 为真值, M 为样本数量。

3.4 实验结果与分析

3.4.1 模型训练

根据 3-1-2 节天线阵列的图表示方法, 将总计 $3000 \times 5 = 15000$ 个样本进行预处理, 转换为图结构数据。将所有样本进行随机抽取, 80% 的样本用于训练, 20% 的样本用于测试。根据 3-3-1 节对模型参数进行初始化后开始训练, 图 3-7 显示了模型训练过程中在训练集和测试集上的损失变化, 可以看出, 模型在训练集和测试集上的损失逐渐下降, 前期模型学习率设置较大, 损失下降较快, 后期损失变化趋于平缓, 通过减小学习率使得模型损失继续缓慢下降。迭代次数达到 200

时，模型训练结束，训练集和测试集上的损失值相近，证明模型没有出现欠拟合和过拟合现象，训练效果理想。




图 3-7 训练和测试损失曲线

所有类型阵列的训练和预测结果如表 3-2 所示。对于所有类型的天线阵列，模型在训练集和测试集上的 MAPE 值均低于 4%，RMSE 值低于 0.08；模型的平均 MAPE 为 1.86%，平均 RMSE 为 0.032。相对较小的误差表明该模型能够学习多拓扑天线阵列的辐射特性并进行准确地预测。

表 3-2 模型训练和预测结果

阵列类型	训练样本 数量	测试样本 数量	训练集		测试集	
			MAPE	RMSE	MAPE	RMSE
6 元 ULA	2406	594	0.76%	0.012	0.88%	0.013
8 元 ULA	2398	602	0.95%	0.014	0.96%	0.014
8 元 PA	2389	611	0.84%	0.012	0.95%	0.013
8 元 NLA	2412	588	2.50%	0.045	2.53%	0.045
10 元 NLA	2395	605	3.86%	0.075	3.98%	0.076

3.4.2 对比实验


为验证 GNN 在同时预测多种不同拓扑结构的天线阵列辐射方向图的优越性，我们将所提的图神经网络（GNN）模型与其他基于深度学习方法的人工神经网络（ANN）^[67]和深度神经网络（DNN）^[25]进行了模型准确性和计算效率的比较，结果如表 3-3 所示。

表 3-3 模型性能比较实验

模型	指标	6 元 ULA	8 元 ULA	8 元 PA	8 元 NLA	10 元 NLA	平均值	训练 (min)	测试 (μ s)
ANN ^[67]	MAPE	1.44%	1.33%	3.01%	4.74%	4.93%	3.09%	1.63	1
	RMSE	0.021	0.017	0.051	0.072	0.081	0.048		
DNN ^[25]	MAPE	2.00%	1.32%	3.16%	5.00%	5.00%	3.30%	1.55	0.7
	RMSE	0.028	0.017	0.054	0.078	0.083	0.052		
本文所 提模型	MAPE	0.88%	0.96%	0.95%	2.53%	3.98%	1.86%	7.02	6
	RMSE	0.012	0.014	0.012	0.045	0.076	0.032		
全波仿真一个数据样本								-	4×10^6

表 3-3 的结果表明,与 ANN 和 DNN 相比,我们提出的 GNN 模型在不同拓扑结构的所有天线阵列上的 MAPE 和 RMSE 更低,预测准确度更高,能够准确有效地预测具有多种几何结构的天线阵列的辐射方向图。其原因是我们提出的基于图的方法可以通过天线阵列图表示将阵列的不同几何结构转换为统一的格式后再作为模型的输入,在处理具有多种不同结构的阵列时能够比 ANN 和 DNN 更加灵活。在计算效率方面,虽然我们所提模型所需的训练时间要比 ANN 和 DNN 长,但推理一个样本所需的时间与 ANN 和 DNN 相当,且与传统的全波仿真方法相比快了 6 个数量级。

为了更直观地对比不同方法的性能,我们随机选择了几个样本进行了可视化,从而定性的分析 ANN^[67]、DNN^[25]和我们所提的 GNN 模型的预测效果,如图 3-8 所示。每个图由天线阵列及其图结构、激励设置表和辐射方向图及其细节图组成,使用红色实线表示真值,蓝色虚线表示所提 GNN 模型的预测结果,绿色点线表示 ANN 的预测结果,紫色点划线表示 DNN 的预测结果。从可视化结果图可以看出,我们提出的模型预测的方向图与真值吻合得更好,与真值几乎完全重合,优于 ANN 和 DNN 比较算法。






图 3-8 模型预测结果可视化

3.4.3 消融实验

本文设计了多个消融实验来验证模型的有效性，包括对复数权重和残差连接的模块消融，对 GIN 层数和隐藏节点数的消融，对复数全连接层神经元个数的消融，以及对残差连接方式的消融。

3.4.3.1 模块消融

为了验证复数权重和残差连接在该方法中的有效性，我们将基础的图同构网络作为基本框架，然后将复数权重和残差连接分别引入基本框架，消融实验的结果如表 3-4 所示。

表 3-4 复数权重和残差连接模块消融实验

复数权重	残差连接	MAPE (%)					MAPE 均值	RMSE					RMSE 均值
		6 元 ULA	8 元 ULA	8 元 PA	8 元 NLA	10 元 NLA		6 元 ULA	8 元 ULA	8 元 PA	8 元 NLA	10 元 NLA	
×	×	1.52	1.99	2.03	3.91	5.01	2.89	0.023	0.027	0.027	0.067	0.093	0.047
×	✓	1.32	1.89	1.98	3.80	4.91	2.78	0.022	0.026	0.027	0.065	0.088	0.046
✓	×	1.04	1.14	1.14	2.85	4.32	2.10	0.015	0.016	0.016	0.050	0.079	0.035
✓	✓	0.88	0.96	0.95	2.53	3.98	1.86	0.013	0.014	0.013	0.045	0.076	0.032

根据表 3-4 可以看出,复数权重和残差连接都在一定程度上有效提高了基本模型的预测准确度。引入的残差连接将 MAPE 平均值从 2.89%降低到 2.78%,使 RMSE 平均值从 0.047 降低到 0.046;引入的复数权重使 MAPE 平均值降低到 2.10%,使 RMSE 平均值降低到 0.035;当复数权重和残差连接同时被集成到模型中时,模型的性能最好,将 MAPE 平均值降低到 1.86%,将 RMSE 平均值降低到 0.032,相比基本模型,MAPE 和 RMSE 的下降幅度分别达到了 35.6%和 31.9%。通过以上数据可以看出,复数权重和残差连接对提高模型准确率效果明显。

3.4.3.2 残差连接方式

网络在前向传播时,网络获得的信息会随着层数的增加而减少,而残差连接可以将网络的任意层的输入进行叠加,以增大信息量,弥补信息丢失问题。所提模型在复数全连接层引入了残差连接,然而在不同复数全连接层之间构建残差连接,模型的性能也会不同。模型含有四层复数全连接层,只构建一条残差连接的方式有三种,即在第一层和第三层复数全连接层之间(用“1,3”表示),在第二层和第四层之间(“2,4”),和所提模型中的在第一层和第四层之间(“1,4”)构建残差连接。

本文对上述三种方式的残差连接进行模型搭建,训练好的模型在测试集上的结果如表 3-5 所示。

表 3-5 残差连接方式消融实验

残差方式	MAPE (%)					MAPE 均值	RMSE					RMSE 均值
	6 元 ULA	8 元 ULA	8 元 PA	8 元 NLA	10 元 NLA		6 元 ULA	8 元 ULA	8 元 PA	8 元 NLA	10 元 NLA	
1,3	0.96	0.97	1.01	2.51	4.01	1.89	0.014	0.014	0.014	0.044	0.078	0.033
2,4	1.08	1.17	1.10	3.09	6.93	2.67	0.016	0.017	0.015	0.056	0.123	0.227
1,4 *	0.88	0.96	0.95	2.53	3.98	1.86	0.013	0.014	0.013	0.045	0.076	0.032

注:“*”为所提模型结构

通过表 3-5 可知,在第一层和第四层复数全连接层之间构建残差连接可使模型性能达到最佳,能够使网络的最后一层全连接层更大程度的获得由第一层传播的消息,还能够增加网络由前三层复数全连接层前向传播的新知识。

3.4.3.3 GIN 隐藏层层数和隐藏节点数数量设置

(1) GIN 隐藏层层数设置

图同构网络(GIN)中的隐藏层层数影响着模型网络的复杂程度。GIN 层越多,模型结构越复杂,模型参数量越大,能够拟合更复杂的非线性函数,在一定

程度上能够提高模型的精度,但其所需的训练时间也会增长,且由于数据集样本有限或较少,还可能出现模型过拟合现象。但若 GIN 层数太少,又有可能出现模型训练结果不理想的问题。所以寻找并设置合适层数的隐藏层,对模型的训练效果和训练时间十分关键。

本文分别对不同数量的 GIN 层进行了模型训练和测试,实验结果如表 3-6 所示,训练过程的损失函数变化曲线如图 3-9 所示。

表 3-6 GIN 隐藏层层数设置实验结果

层数	MAPE (%)					MAPE 均值	RMSE					RMSE 均值
	6 元 ULA	8 元 ULA	8 元 PA	8 元 NLA	10 元 NLA		6 元 ULA	8 元 ULA	8 元 PA	8 元 NLA	10 元 NLA	
2	1.00	1.05	1.02	2.74	5.63	2.28	0.015	0.015	0.014	0.049	0.104	0.039
3 *	0.88	0.96	0.95	2.53	3.98	1.86	0.013	0.014	0.013	0.045	0.076	0.032
4	0.93	0.98	0.96	2.61	3.89	1.87	0.014	0.015	0.013	0.046	0.072	0.032
5	0.99	1.12	1.12	2.87	4.34	2.09	0.015	0.016	0.015	0.050	0.081	0.035

注: “*” 为所提模型结构




图 3-9 GIN 隐藏层层数设置训练过程

由表 3-6 可知,GIN 层数设置为 3 或 4 时,模型的性能较好。通过图 3-9 可以看出,当 GIN 隐藏层层数设置为 3 时,虽在训练过程的前期,模型的拟合程度并非最好,但在迭代 200 次后,模型在训练集和测试集上的损失函数均达到最小。通过实验结果和对模型参数量的分析,最终模型设置为包含 3 层隐藏层的图同构网络。

(2) GIN 隐藏层的隐藏节点数量设置

和隐藏层层数对模型影响类似,隐藏节点数同样影响着模型在训练过程中的收敛速度和最终的性能效果。隐藏节点数在一定范围内时,模型性能会随着隐藏节点数的增多而提升,对函数的逼近效果越好,但模型的收敛速度也会下降。当隐藏节点数设置过大时,模型还可能出现过拟合问题,甚至出现模型在训练过程中陷入局部最小值而导致模型训练失败。

本文在设置了 3 层 GIN 隐藏层的基础上，分别对 GIN 隐藏层节点数初始化为 200、300、400 和 500 进行模型训练，训练结果和训练过程中的损失函数变化曲线如表 3-7 和图 3-10 所示。

表 3-7 GIN 隐藏层的隐藏节点数量设置实验结果

GIN 层 节点数	MAPE (%)					MAPE 均值	RMSE					RMSE 均值
	6 元	8 元	8 元	8 元	10 元		6 元	8 元	8 元	8 元	10 元	
	ULA	ULA	PA	NLA	NLA		ULA	ULA	PA	NLA	NLA	
200	1.01	1.18	1.13	3.04	5.30	2.28	0.015	0.018	0.015	0.049	0.086	0.037
300	0.89	1.02	1.02	2.69	4.60	2.04	0.013	0.015	0.014	0.047	0.081	0.034
400 *	0.88	0.96	0.95	2.53	3.98	1.86	0.013	0.014	0.013	0.045	0.076	0.032
500	0.88	0.91	0.96	2.50	4.35	1.92	0.012	0.013	0.013	0.048	0.082	0.034

注：“*”为所提模型结构




图 3-10 GIN 隐藏层的隐藏节点数量设置训练过程

通过表 3-7 可以看出，当 GIN 层的隐藏节点数设置为 400 时，MAPE 和 RMSE 最低，模型性能最佳。由图 3-10 也可以看出，GIN 层的隐藏节点数为 400 时，在训练集上的损失值为 0.3317，测试集上的损失值为 0.3642，均小于其他三种设置的损失值。

3.4.3.4 复数全连接层神经元数量设置

同 3.4.3.3 节中 GIN 隐藏层节点数一样，复数全连接层的神经元数量也与模型的最最终性能相关，若神经元数量较少，模型训练效果容易不理想，若神经元数量较多，模型容易出现过拟合问题。

本文在设置了 4 层复数全连接层和以(1,4)方式引入了残差连接的基础上，分别对复数全连接层中的神经元数量初始化为 128、256、512、1024 和 2048 进行模型训练，训练结果如表 3-8 所示，训练过程中的损失函数变化曲线如图 3-11 所示。

表 3-8 复数全连接层的神经元数量设置实验结果

复数全连 接层神经 元个数	MAPE (%)					MAPE 均值	RMSE					RMSE 均值
	6 元 ULA	8 元 ULA	8 元 PA	8 元 NLA	10 元 NLA		6 元 ULA	8 元 ULA	8 元 PA	8 元 NLA	10 元 NLA	
128	1.44	1.70	1.51	4.12	9.91	3.74	0.022	0.024	0.021	0.073	0.157	0.059
256	1.06	1.12	1.13	2.97	5.93	2.44	0.015	0.017	0.015	0.053	0.107	0.041
512 *	0.88	0.96	0.95	2.53	3.98	1.86	0.013	0.014	0.013	0.045	0.076	0.032
1024	0.87	0.94	1.03	2.54	3.89	1.85	0.012	0.014	0.014	0.046	0.068	0.031
2048	0.81	1.14	0.89	2.96	5.19	2.20	0.012	0.017	0.013	0.053	0.097	0.038




图 3-11 复数全连接层的神经元数量设置训练过程

通过表 3-8 可以看出，当复数全连接层含有的神经元数量为 1024 时，MAPE 和 RMSE 最低；当复数全连接层含有 512 个神经元时，模型性能次之，且与神经元数量为 1024 个时相差不大。由图 3-11 也可以看出，神经元数量设置为 512 和 1024 时，模型在迭代到 200 次时损失值相当，且复数全连接层含有 512 个神经元的模型的性能略高于后者。综上可以看出，模型复数全连接层的神经元数量的最佳设置在 512 和 1024 之间。但由于二者的模型性能差距不大，并考虑到模型的计算效率和实验室的硬件条件，本文最终将模型的复数全连接层的神经元数量设置为 512。

3.5 本章小结

本章主要介绍了基于图深度学习的天线阵列分析方法。首先介绍了基于图神经网络的阵列分析模型的整体框架，主要包含天线阵列的图表示、基于图同构网络的特征提取和基于残差增强的复数权重的预测模块三个部分。其次介绍了构建数据集选用的天线阵列案例和数据集样本的获取途径及类型分布。接着介绍了模

型的参数设置和评估指标。最后对模型的训练和测试结果进行了定量和定性分析，通过对比实验和消融实验验证了所提模型的有效性和准确性。

第4章 基于图深度学习和改进黏菌算法的天线阵列综合方法

本文提出了一种全新的基于图深度学习的天线阵列综合方法,该方法以图神经网络为代理模型,融合基于反向精英策略和惯性权重策略改进的黏菌优化算法进行反向寻优。改进的黏菌优化算法在标准的测试函数上有较好的表现,优于其他常用于阵列综合的元启发式算法和基础黏菌算法。所提方法能够对多种拓扑结构的天线阵列进行综合,实现了阵列的笔状波束赋形、平顶波束阵列赋形和余割平方波束赋形。

4.1 基于图神经网络和改进黏菌算法的阵列综合模型

基于图神经网络和改进黏菌优化算法的阵列综合方法以第三章中训练成功的图神经网络(GNN)模型作为代理模型,输入为天线阵列结构参数和激励设置,输出为天线阵列的预测方向图。使用改进的黏菌算法进行反向寻优,指导阵列结构参数和激励设置参数不断优化调整,使 GNN 模型的输出方向图逼近期望方向图,直到达到期望的阵列设计需求。基于图神经网络和改进黏菌优化算法的阵列综合模型整体架构如图 4-1 所示。




图 4-1 基于图神经网络和改进黏菌优化算法的阵列综合模型

基于图神经网络和改进黏菌优化算法的阵列综合方法的详细步骤如下：

步骤 1：选择阵列结构，初始化黏菌算法的种群参数，作为初始化阵列结构参数和激励设置。

步骤 2：输入目标阵列的期望方向图。

步骤 3：使用图神经网络根据步骤 1 中的阵列结构参数和激励设置对阵列辐射方向图进行预测。

步骤 4：将所得阵列方向图和期望方向图进行比较，求其适应度值。若适应度值没有达到预期，则传递给黏菌算法，通过精英反向学习策略和惯性权重策略对种群个体位置进行更新，并进行步骤 3；若适应度值达到预期则进行步骤 5。

步骤 5：输出最终得到的阵列综合结果，即阵列结构（阵元布局）参数和激励设置以及阵列辐射方向图。

4.2 黏菌算法概述与数学模型

2020 年，Shimin Li 等人^[68]受自然界中黏菌的扩散和觅食行为启发，提出了一种新的元启发式算法——黏菌算法（Slime mould algorithm, SMA）。该算法使用自适应权重来模拟黏菌在扩散过程中的反馈过程，以获得觅食的最佳路径，黏菌的觅食形态如图 4-2 所示。




图 4-2 黏菌的觅食形态

SMA 的数学模型如下：

黏菌可以根据空气中的气味接近食物，公式 4-1 表示其接近行为：

$$\overrightarrow{X}(t+1) = \begin{cases} \overrightarrow{X}_b(t) + \overrightarrow{vb} \cdot (\overrightarrow{W} \cdot \overrightarrow{X}_A(t) - \overrightarrow{X}_B(t)) , & r < p \\ \overrightarrow{vc} \cdot \overrightarrow{X}(t) , & r \geq p \end{cases} \quad (4-1)$$

其中， t 表示当前迭代次数； $\overrightarrow{X}$ 表示黏菌的位置； $\overrightarrow{X}_b$ 表示当前发现的具有最高气味浓度的食物的位置（最佳位置）； $\overrightarrow{X}_A$ 和 $\overrightarrow{X}_B$ 表示从黏菌中随机选择的两个个体； $\overrightarrow{vb}$ 是一个范围为 $[-a, a]$ 的参数； $\overrightarrow{vc}$ 从 1 线性递减至 0； $\overrightarrow{W}$ 表示黏菌重量。

公式 4-1 中的参数的数学公式具体如下:

$$vb = [-a, a] \quad (4-2)$$

$$a = \operatorname{arctanh}(-t/T + 1) \quad (4-3)$$

其中, T 为最大迭代次数。

$$p = \tanh|S(i) - DF|, i \in 1, 2, \dots, N \quad (4-4)$$

其中, $S(i)$ 表示第 i 个黏菌个体的适应度值, DF 表示所有迭代中得到的最佳适应度值, N 表示黏菌的个体总数 (种群规模)。

$$W(\operatorname{SmellIndex}(i)) = \begin{cases} 1 + r \cdot \log\left(\frac{bF - S(i)}{bF - wF} + 1\right), & \text{condition} \\ 1 - r \cdot \log\left(\frac{bF - S(i)}{bF - wF} + 1\right), & \text{others} \end{cases} \quad (4-5)$$

$$\operatorname{SmellIndex}(i) = \operatorname{sort}(S) \quad (4-6)$$

其中, *condition* 表示 $S(i)$ 在总体排名中前 50% 的黏菌个体; r 为 $[0, 1]$ 的任意值, bF 和 wF 分别表示当前迭代过程中得到的最佳适应度值和最差适应度值; *SmellIndex* 表示适应度值排序后的序列。

通过以上公式, 不难发现, 搜索食物的黏菌个体的位置 $\overline{X}$ 的更新主要和最佳位置 $\overline{X}_b$ 的变化有关。除此之外, 还可以通过微调参数 $\overline{vb}$ 、 $\overline{vc}$ 和 $\overline{W}$ 来更新个体位置, 以增加个体找到最优解的可能性并提高搜索效率。黏菌根据食物浓度来更新位置, 食物浓度越高, 附近的黏菌重量越大, 反之黏菌将转向其他搜索区域。黏菌对适应度值的评价过程如图 4-3。基于此, 黏菌位置更新的数学公式可写成如下形式:

$$X(t+1) = \begin{cases} \operatorname{rand} \cdot (UB - LB) + LB, & \operatorname{rand} < z \\ X_b(t) + vb \times (W \times X_A(t) - X_B(t)), & r < p \\ vc \times X(t), & r \geq p \end{cases} \quad (4-7)$$

其中, LB 和 UB 分别表示搜索范围的上下限, rand 和 r 表示 $[0, 1]$ 中的随机值, z 为用来权衡搜索与开发阶段的参数, 在本文中被设置为 0.03。




图 4-3 黏菌对适应度值的评价过程

4.3 基于精英反向学习和惯性权重策略的改进黏菌算法

与大多数元启发式算法相似，黏菌算法结构本身也存在容易陷入局部最优、收敛速度慢、收敛精度较低等问题。为了改进黏菌算法的不足，提高黏菌算法的全局探索能力和寻优能力、提高算法收敛速度，本文引入了精英反向学习策略和惯性权重策略对黏菌算法进行了改进，实验结果证明改进算法在标准的测试函数上的表现良好。

4.3.1 精英反向学习策略

精英个体是指当前种群中相对较优的个体，往往比一般个体包含更多有效信息。利用当前种群中精英个体的有效信息更新下一代的个体位置，能够提高算法搜索速度，使个体能够更快找到食物所在位置。

Tizhoosh^[69]提出的反向学习指出，相比当前解，反向解能够更快速更高效的逼近最优解，逼近最优解的概率甚至能够高一半。反向学习策略能够有效增加种群的多样性，提高个体质量，从而提高搜索效率。

基于上述精英个体和反向学习的优势，本文将精英反向学习策略引入黏菌算法之中，定义精英反向解为：

设 n 维搜索空间中群体 X 中的某精英个体 $x_{best} = (x_1, x_2, \dots, x_n)$ 的反向解为 $x_{best}^* = (x_1^*, x_2^*, \dots, x_n^*)$ ，则在第 i 维上的精英反向解可定义为：

$$x_i^* = \delta \times (lb_i + ub_i) - x_i \quad (4-8)$$

其中， x_i 表示精英个体， δ 是位于 $[0,1]$ 之间的随机数， lb_i 和 ub_i 为第 i 维搜索空间的下界和上界。本文将适应度值前 30% 的个体定义为精英个体。

4.3.2 惯性权重策略

惯性权重最早在粒子群算法中提出，算法中粒子迭代时的位置变化与惯性权重相关。粒子搜索的步长随惯性权重的增大而增大，搜索步长较大时，全局搜索能力提升，搜索步长较小时，算法具有较好的局部搜索能力，同时精度也会提高，但容易陷入局部最优。所以惯性权重旨在平衡全局搜索能力和局部搜索能力，从而一定程度上提高算法的收敛速度并避免算法陷入局部最优。

本文将惯性权重引入到黏菌算法中，下一代黏菌个体会根据加入惯性权重的上一代黏菌个体位置进行搜索和位置更新。惯性权重公式定义如下：

$$w(t) = w_{\max} - (w_{\max} - w_{\min}) \cdot 2 \cdot \frac{t}{T} \sqrt{1 - \left(\frac{t}{T}\right)^2} \quad (4-9)$$

通过公式(4-9)惯性权重的迭代更新,能够调整黏菌个体的搜索步长。经多次实验发现,将式中 $w_{\max}$ 和 $w_{\min}$ 分别设置为 0.9 和 0.4,惯性权重对黏菌算法中个体的全局搜索能力和局部搜索能力的平衡效果较好。

4.3.3 改进黏菌算法流程

针对黏菌算法容易出现搜索精度不高和搜索速度慢等局限,本文将精英反向学习策略和惯性权重策略引入黏菌算法提出了一个新的改进的黏菌算法(ISMA)。其核心思路是通过改变个体位置的更新方式来提高算法的搜索效率,个体位置更新公式可根据公式(4-8)和(4-9)将公式(4-7)更改为:

$$X(t+1) = \begin{cases} \delta \times (UB + LB) - X_{best}(t), & rand < z \\ X_b(t) + vb \times (W \times X_A(t) - X_B(t)), & r < p \\ vc \times w(t) \times X(t), & r \geq p \end{cases} \quad (4-10)$$

ISMA 的伪代码如算法 1 所示,运行环境为 Python 3.7.6,其直观的详细流程图如图 4-4 所示。

算法 1 ISMA 伪代码

1. 初始化参数,种群大小 $npop$, 维度 n , 上界 UB , 下界 LB , 迭代次数 T
2. 初始化黏菌位置 $X_i (i=1,2,\dots,n)$
3. while $t \leq T$:
 4. 计算所有黏菌个体的适应度值 $Fitness$
 5. 更新最佳适应度值 $bestFitness$, 最佳个体位置 X_b
 6. 通过公式(4-5)计算参数 W
 7. for i in range(n):
 8. 更新参数 p, vb, vc
 9. if $rand < z$:
 10. 通过公式(4-10)中的式 1 更新黏菌位置信息
 11. else:
 12. if $r < p$:
 13. 通过公式(4-10)中的式 2 更新黏菌位置信息
 14. else:
 15. 通过公式(4-10)中的式 3 更新黏菌位置信息
 16. $t = t + 1$
 17. 返回最佳适应度值 $bestFitness$, 最佳个体位置 X_b




图 4-4 改进黏菌算法流程图

4.3.4 改进黏菌算法的性能评估

为了验证基于精英反向学习策略和惯性权重策略的改进黏菌算法 (ISMA) 的性能提升效果, 我们使用常用的标准测试函数^[70]对改进算法进行了评估, 并与基础的黏菌算法 (SMA)^[68]和其他四种优化算法进行了比较, 包括常用于天线优化领域的粒子群算法 (PSO)^[71]、差分进化算法 (DE)^[72]、灰狼算法 (GWO)^[41]和鲸鱼算法 (WOA)^[42]。

表 4-1 给出了本文选用的 12 个标准测试函数。函数 f_1 - f_9 都是高维的, 函数 f_1 - f_5 为单峰函数, 函数 f_6 是一个有噪声的四次函数。函数 f_7 - f_9 是多峰函数, 其局部极小值的数量随函数维度呈指数增长, 对于许多优化算法来说, 多峰函数上的寻优是最困难的一类问题。函数 f_{10} - f_{12} 是只有少数局部极小值的低维函数。

表 4-1 标准测试函数

测试函数	维数 n	范围	最优值
单峰测试函数			
$f_1(x) = \sum_{i=1}^n x_i^2$	30	[-100,100]	0
$f_2(x) = \sum_{i=1}^n x_i + \prod_{i=1}^n x_i$	30	[-10,10]	0
$f_3(x) = \sum_{i=1}^n \left(\sum_{j=1}^i x_j \right)^2$	30	[-100,100]	0
$f_4(x) = \max_i \{ x_i , 1 \leq i \leq n \}$	30	[-100,100]	0
$f_5(x) = \sum_{i=1}^{n-1} \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right]$	30	[-30,30]	0
$f_6(x) = \sum_{i=1}^n ix_i^4 + \text{random}[0,1)$	30	[-128,128]	0
多峰测试函数			
$f_7(x) = \sum_{i=1}^n \left[x_i^2 - 10 \cos(2\pi x_i) + 10 \right]$	30	[-5.12,5.12]	0
$f_8(x) = -20 \exp \left(-0.2 \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \right) - \exp \left(\frac{1}{n} \sum_{i=1}^n \cos(2\pi x_i) \right) + 20 + e$	30	[-32,32]	0
$f_9(x) = \frac{1}{4000} \sum_{i=1}^n x_i^2 - \prod_{i=1}^n \cos \left(\frac{x_i}{\sqrt{i}} \right) + 1$	30	[-600,600]	0
固定维测试函数			
$f_{10}(x) = \left(\frac{1}{500} + \sum_{j=1}^{25} \frac{1}{j + \sum_{i=1}^2 (x_i - a_{ij})^6} \right)^{-1}$	2	[-65.536,65.536]	1
$f_{11}(x) = -\sum_{i=1}^4 e_i \exp \left[-\sum_{j=1}^6 a_{ij} (x_j - p_{ij})^2 \right]$	6	[0,1]	-3.32
$f_{12}(x) = -\sum_{i=1}^{10} \left[(X - a_i)(X - a_i)^T + c_i \right]^{-1}$	4	[0,10]	-10.536

根据表 4-1 中的函数公式、维度、取值范围对各个算法中的种群个体进行初始化, 种群数量 n_{pop} 设置为 50, 最大迭代次数 T 设置为 500。对每一个测试函数, 我们都将 PSO、DE、GWO、WOA、SMA 和 ISMA 六种算法进行了 50 次实验, 实验结果如表 4-2~表 4-4 所示。

我们使用最优值 (Min)、平均值 (Mean) 和标准差 (Standard Deviation, SD) 三个指标对算法的性能进行评估。Min 为 50 次实验中的最佳适应度值, 用于考量算法的精度; 其值越接近函数的最优解, 表示算法在一定程度上精度越高, 越

有能力寻到函数的最优解。**Mean** 是对 50 次实验结果求得的平均值,能够反映算法的一般性能,用于评价算法的精度时比 **Min** 更加客观和准确;其值越接近函数的最优解,表示算法的整体性能越好。**SD** 为 50 次实验结果的方差,能够反映所有实验结果的离散程度,用于评价算法的稳定性;其值越小,表示算法的稳定性越高。通过表 4-2~表 4-4 的实验结果可以看出,在三个评价指标上,ISMA 中的精英反向学习策略和惯性权重策略都对 SMA 有较好提升,且与 PSO、DE、GWO 和 WOA 相比,性能改善十分明显。

表 4-2 单峰测试函数数值实验结果对比

测试函数		f_1	f_2	f_3
最优解		0	0	0
PSO	Min	5.4833e-06	0.0024	30.9239
	Mean	1.9645e-04	0.0419	79.4523
	SD	3.4311e-04	0.0707	28.5959
DE	Min	6.6222e-04	0.0028	7.8723e-35
	Mean	0.0016	0.0054	2.6891e-21
	SD	4.0372e-04	0.0010	1.1392e-20
GWO	Min	7.1418e-29	1.4829e-17	1.5382e-08
	Mean	1.1709e-27	1.2645e-16	2.2082e-05
	SD	1.3863e-27	1.2318e-16	5.1136e-05
WOA	Min	1.3747e-86	5.2542e-57	2.6105e+04
	Mean	2.3656e-73	6.8151e-49	4.5622e+04
	SD	1.2966e-72	4.4331e-48	1.1690e+04
SMA	Min	0	6.2968e-310	0
	Mean	2.1346e-269	1.9364e-145	1.2706e-304
	SD	0	1.3555e-144	0
ISMA	Min	0	0	0
	Mean	0	0	0
	SD	0	0	0
测试函数		f_4	f_5	f_6
最优解		0	0	0
PSO	Min	0.6944	4.5623e-06	0.0613
	Mean	1.0569	4.0103e-04	0.1709
	SD	0.2115	0.0011	0.0575
DE	Min	15.6003	5.3002e-04	0.1880
	Mean	18.9296	0.0016	0.4258
	SD	1.8639	6.3701e-04	0.1362
GWO	Min	1.1355e-07	25.6697	4.1123e-04
	Mean	1.0044e-06	27.0130	0.0022
	SD	1.3976e-06	0.8112	0.0011
WOA	Min	0.4952	27.0881	9.6069e-05
	Mean	48.1845	28.0073	0.0037
	SD	29.4372	0.5183	0.0037
SMA	Min	1.1644e-275	0.0038	6.0258e-06
	Mean	4.1377e-135	6.6932	1.9734e-04
	SD	2.8964e-134	10.7137	2.6676e-04
ISMA	Min	0	1.9807	1.1716e-06
	Mean	0	3.5899	9.1886e-05
	SD	0	0.3986	8.5747e-05


表 4-3 多峰测试函数数值实验结果对比

测试函数		f_7	f_8	f_9
最优解		0	0	0
PSO	Min	29.0114	0.0036	1.0270e-06
	Mean	58.2077	0.1509	0.0075
	SD	14.7435	0.3723	0.0080
DE	Min	30.7683	0.0079	0.0032
	Mean	43.4623	0.0118	0.0130
	SD	5.4517	0.0025	0.0080
GWO	Min	5.6843e-14	7.5495e-14	0
	Mean	2.7662	1.0534e-13	0.0063
	SD	4.4654	1.8226e-14	0.0147
WOA	Min	0	8.8818e-16	0
	Mean	1.6367	4.2277e-15	0.0172
	SD	11.4568	2.0606e-15	0.0585
SMA	Min	0	8.8818e-16	0
	Mean	0	8.8818e-16	0
	SD	0	0	0
ISMA	Min	0	8.8818e-16	0
	Mean	0	8.8818e-16	0
	SD	0	0	0


表 4-4 固定维测试函数数值实验结果对比

测试函数		f_{10}	f_{11}	f_{12}
最优解		1	-3.32	-10.536
PSO	Min	0.9980	5.1242e-04	-10.5364
	Mean	3.3267	8.8129e-04	-9.7728
	SD	2.3170	1.5083e-04	2.0999
DE	Min	0.9980	3.7210e-04	-10.5364
	Mean	0.9980	0.0012	-10.5353
	SD	0	0.0027	0.0031
GWO	Min	0.9980	-3.3220	-10.5361
	Mean	4.6215	-3.2489	-10.4265
	SD	4.1316	0.0801	0.7569
WOA	Min	0.9980	-3.3220	-10.5358
	Mean	2.8440	-3.2403	-7.1952
	SD	3.0927	0.1041	3.3251
SMA	Min	0.9980	-3.3220	-10.5364
	Mean	0.9980	-3.2457	-10.5360
	SD	1.7725e-12	0.0573	3.3830e-04
ISMA	Min	0.9980	-3.3220	-10.5363
	Mean	1.3902	-3.2458	-8.0490
	SD	1.6988	0.0571	1.0746


除算法精度外,算法的寻优效率和收敛速度也是考量一个算法优劣的重要标准。为更直观的描述算法的寻优速度,在图 4-5 中对上述标准函数中的 2 个单峰函数、1 个多峰函数和 1 个固定维函数的参数空间和算法的适应度值随迭代次数的变化曲线进行了可视化。从图 4-5 可以看出,ISMA 在单峰函数上的收敛速度明显优于其他算法,在多峰函数和固定维函数上,与其他算法相比也十分具有竞争力。




(a) 单峰测试函数 $f_1(x)$



(b) 单峰测试函数 $f_6(x)$



(c) 多峰测试函数 $f_7(x)$



(d) 固定维测试函数 $f_{10}(x)$

图 4-5 部分测试函数的参数空间和目标空间适应度值变化曲线

4.4 实验结果与分析

在本节中,我们使用所提框架对多种不同阵元数量和拓扑结构的贴片微带天线阵列进行了笔状波束赋形、平顶波束赋形和余割平方波束赋形,阵列结构包括6元均匀间距线阵列、8元均匀间距线阵列、8元矩形面阵列、8元非均匀间距线阵列和10元非均匀间距线阵列,并将所提框架中的ISMA与粒子群算法(PSO)、差分进化算法(DE)、灰狼算法(GWO)、鲸鱼算法(WOA)、基础黏菌优化算法(SMA)进行了对比。所有实验中的种群数量 $npop$ 设置为30,各算法的最大迭代次数 T 设置为500。

4.4.1 笔状波束赋形

笔状波束赋形的要求为窄波束宽度、高增益和低副瓣,此时天线的应用范围较广。针对笔状波束赋形的要求特性,设计了适应度函数,如下所示:

$$fitness = \alpha \cdot \max_{\theta \in S_p} \{F(\theta)\} + \beta \cdot |FNBW - FNBW_d| \quad (4-11)$$

其中, S_p 表示不包括主瓣的辐射方向图, $FNBW$ 为第一零点波束宽度, $FNBW_d$ 为期望的第一零点波束宽度, α 和 β 为两个超参数。适应度函数为两部分的加权求和,前者的目的是抑制副瓣电平,后者的目的是尽可能地使主瓣宽度逼近期望的第一零点波束宽度。

在以下实验中,对 α 取值1, β 取值0.5。本次实验的笔状波束赋形的指标需求为第一零点波束宽度为 30° ,故取 $FNBW_d$ 等于30。

(1) 均匀间距线阵列的笔状波束赋形

对6元均匀间距线阵列和8元均匀间距线阵列进行笔状波束赋形,阵元间距设置为0.5倍的工作波长(0.5λ),运用所提方法对直线阵的激励电流幅度和相位进行优化,激励幅度的寻优范围为 $[0,1]$,激励相位的寻优范围为 $[0^\circ,180^\circ]$ 。图4-6和图4-7展示了阵列优化后的辐射方向图和各算法优化过程中的适应度函数下降曲线,对应的优化后的阵列激励参数如表4-5和表4-6所示。

(2) 非均匀间距线阵列的笔状波束赋形

实现了对8元非均匀间距线阵列和10元非均匀间距线阵列的笔状波束赋形,阵元的激励电流幅度设置为1,阵元的激励电流相位设置为 0° ,运用所提方法对直线阵的相邻阵元间距进行了优化,相邻阵元间距的寻优范围为 $[0.4\lambda,0.6\lambda]$ 。

优化后的阵列辐射方向图和各算法优化过程中的适应度函数下降曲线见图 4-8 和 4-9 所示，优化后的阵列分布见表 4-7 和表 4-8 所示。

(3) 矩形面阵列的笔状波束赋形

实现了对 8 元矩形面阵列的笔状波束赋形，运用所提方法对阵列的阵元间距和激励幅度、激励相位进行同时优化，激励幅度的寻优范围为 $[0,1]$ ，激励相位的寻优范围为 $[0^\circ,180^\circ]$ ，相邻阵元间距的寻优范围为 $[0.4\lambda,0.6\lambda]$ 。图 4-10 展示优化后的阵列辐射方向图和各算法优化过程中的适应度函数下降曲线，表 4-9 给出优化后的阵列结构参数和激励参数。




图 4-6 6 元均匀间距线阵列的笔状波束赋形

表 4-5 6 元均匀间距线阵列的笔状波束赋形结果

阵元	PSO		DE		GWO	
	幅度	相位	幅度	相位	幅度	相位
1	1	178.36	0.85	94.18	0.79	49.61
2	0.79	180	0.49	62.95	0.39	12.68
3	1	128.70	0.69	92.98	0	39.77
4	1	180	0.05	83.68	0.62	43.54
5	1	180	0.66	61.96	0.39	0.25
6	0.74	167.39	0.83	167.85	0.38	56.52
适应度值	-7.3678		-7.2605		-9.0958	
阵元	WOA		SMA		ISMA	
	幅度	相位	幅度	相位	幅度	相位
1	0.88	158.78	1	0.03	0.98	0.01
2	0	158.72	0.54	0.01	0.25	0
3	0	125.14	0.12	0	0.57	0
4	0.82	158.78	0.65	0	0.14	0
5	0.51	158.77	0.27	0	0.50	0
6	0.74	158.77	0.94	0	0.85	0
适应度值	-9.1838		-10.1090		-10.1834	




图 4-7 8 元均匀间距线阵列的笔状波束赋形

表 4-6 8 元均匀间距线阵列的笔状波束赋形结果

阵元	PSO		DE		GWO	
	幅度	相位	幅度	相位	幅度	相位
1	0.62	88.31	0.38	100.12	0.19	0
2	0.59	38.88	0.63	150.89	0.25	12.66
3	0.15	115.24	0.48	94.92	0.03	56.81
4	0.54	107.22	0.32	138.48	0.31	68.97
5	0.79	102.40	0.69	63.98	0.12	43.57
6	0.19	89.05	0.71	14.02	0.18	0
7	0.61	152.71	0.65	159.02	0.29	0.04
8	0.81	159.87	0.66	141.34	0.22	18.42
适应度值	-20.9503		-22.8634		-21.4698	
阵元	WOA		SMA		ISMA	
	幅度	相位	幅度	相位	幅度	相位
1	0.65	111.39	0.64	121.21	0.99	0.11
2	0.62	111.36	0.49	76.92	0.34	37.41
3	0.42	111.47	0.47	83.14	0.84	0
4	0.58	111.44	0.56	101.59	0.99	0
5	0.49	111.41	0.29	33.54	0.14	0
6	0.22	111.54	0.56	89.37	0.77	0.03
7	0.63	111.33	0.48	89.18	0.87	156.94
8	0.62	111.49	0.48	57.46	0.96	0
适应度值	-23.007		-22.7846		-23.2547	




图 4-8 8 元非均匀间距线阵列的笔状波束赋形

表 4-7 8 元非均匀间距线阵列的笔状波束赋形结果

阵元	PSO	DE	GWO
	阵元位置		
1	0	0	0
2	0.534	0.566	0.595
3	1.080	0.986	0.997
4	1.507	1.388	1.397
5	1.943	1.788	1.797
6	2.516	2.188	2.198
7	2.930	2.606	2.789
8	3.431	3.162	3.389
适应度值	-19.86	-17.39	-19.82

阵元	WOA	SMA	ISMA
	阵元位置		
1	0	0	0
2	0.599	0.595	0.598
3	1.176	0.995	1.131
4	1.676	1.470	1.639
5	2.076	1.871	2.039
6	2.486	2.273	2.498
7	2.886	2.798	2.898
8	3.474	3.381	3.487
适应度值	-19.66	-19.97	-19.98




图 4-9 10 元非均匀间距线阵列的笔状波束赋形

表 4-8 10 元非均匀间距线阵列的笔状波束赋形结果

阵元	PSO	DE	GWO
	阵元位置		
1	0	0	0
2	0.600	0.600	0.600
3	1.977	1.200	1.200
4	2.735	1.800	1.800
5	3.291	2.400	2.366
6	3.619	3.000	2.949
7	4.180	3.600	3.537
8	4.724	4.200	4.063
9	5.257	4.800	4.663
10	5.855	5.000	5.263
适应度值	-8.92	-8.44	-9.61

阵元	WOA	SMA	ISMA
	阵元位置		
1	0	0	0
2	0.596	0.600	0.600
3	1.192	1.200	1.200
4	1.789	1.751	1.800
5	2.385	2.299	2.318
6	2.966	2.883	2.903
7	3.483	3.408	3.493
8	4.079	4.007	3.964
9	4.676	4.575	4.540
10	5.193	5.175	5.138
适应度值	-8.89	-9.58	-9.61




图 4-10 8 元矩形面阵列的笔状波束赋形

表 4-9 8 元矩形面阵列的笔状赋形结果

阵元	PSO			DE		
	位置	幅度	相位	位置(λ)	幅度	相位
1	(0, 0)	0.78	135.60	(0, 0)	0.83	84.42
2	(0.600, 0)	0.55	179.97	(0.595, 0)	0.49	122.42
3	(1.025, 0)	0.18	180.00	(1.187, 0)	0.62	9.20
4	(1.625, 0)	0.68	179.72	(1.785, 0)	0.81	2.77
5	(0, 0.597)	0.36	60.1	(0, 0.595)	0.46	77.45
6	(0.600, 0.597)	0.67	126.4	(0.595, 0.595)	0.40	27.08
7	(1.025, 0.597)	0.49	37.28	(1.187, 0.595)	0.31	140.13
8	(1.625, 0.597)	0.42	89.71	(1.785, 0.595)	0.55	115.23
适应度值	-7.5373			-9.0247		
阵元	GWO			WOA		
	位置	幅度	相位	位置	幅度	相位
1	(0, 0)	0.57	35.02	(0, 0)	1	0
2	(0.591, 0)	0.41	10.24	(0.592, 0)	0.97	0
3	(1.176, 0)	0.53	53.93	(1.049, 0)	0.64	0
4	(1.744, 0)	0.29	41.65	(1.571, 0)	1	0
5	(0, 0.597)	0.36	8.71	(0, 0.600)	0.97	0
6	(0.591, 0.597)	0.44	52.84	(0.592, 0.600)	0.48	0.01
7	(1.176, 0.597)	0.34	127.96	(1.049, 0.600)	0.44	0
8	(1.744, 0.597)	0.33	127.76	(1.571, 0.600)	0.96	0
适应度值	-8.9268			-8.6670		
阵元	SMA			ISMA		
	位置	幅度	相位	位置	幅度	相位
1	(0, 0)	0.99	180	(0, 0)	1	180
2	(0.684, 0)	0.81	180	(0.600, 0)	0.92	180
3	(1.284, 0)	0.97	179	(1.190, 0)	0.80	180
4	(1.884, 0)	1	180	(1.770, 0)	1	180
5	(0, 0.586)	0.23	180	(0, 0.589)	1	180
6	(0.684, 0.586)	1	180	(0.600, 0.589)	0.94	180
7	(1.284, 0.586)	1	179	(1.190, 0.589)	0.83	180
8	(1.884, 0.586)	1	180	(1.770, 0.589)	1	180
适应度值	-12.1174			-12.6925		

从表 4-5~表 4-9 都可以看出, 与 PSO、DE、GWO、WOA 和 SMA 算法相比, 使用 ISMA 算法优化得到的最佳适应度值最小, 说明 ISMA 对各阵列的辐射方向图的优化效果最好, 使用精英反向学习策略和惯性权重策略对黏菌算法进行改进是有效的。通过图 4-6~图 4-10 展示的最终优化得到的天线阵列辐射方向图可以更直观地看出, 所提方法优化后的辐射方向图的第一零点波束宽度更接近设计需求的期望第一零点波束宽度, 且副瓣电平抑制更理想, 更优于通过其他算法优化后的辐射方向图, 基本满足设计需求。

4.4.2 平顶波束赋形

针对平顶波束 (Flat-top pattern, FTP) 赋形的要求特性, 设计了适应度函数, 如下所示

$$fitness = \alpha \cdot \left| \max_{\theta \in S_p} \{F(\theta)\} - PSLL_d \right| + \beta \cdot \sum_{\theta \in S_m} |F(\theta) - F_{FTP}(\theta)| \quad (4-12)$$

其中, S_p 表示不包括主瓣的辐射方向图, S_m 表示主瓣, $PSLL_d$ 为目标副瓣电平, F_{FTP} 为平顶波束的目标函数, α 和 β 为两个超参数。适应度函数为两部分的加权求和, 前者的目的是抑制副瓣电平, 后者的目的是尽可能地使主瓣逼近目标函数。在以下实验中, 对 α 取值 0.5, β 取值 0.01。

(1) 主瓣宽度为 $[-22.5^\circ, 22.5^\circ]$ 的均匀间距线阵列的平顶波束赋形

对 6 元均匀间距线阵列和 8 元均匀间距线阵列进行平顶波束赋形, 阵元间距设置为 0.5λ , 对直线阵的激励电流幅度和相位进行优化, 激励幅度的寻优范围为 $[0, 1]$, 激励相位的寻优范围为 $[0^\circ, 180^\circ]$ 。根据主瓣宽度的目标要求, 目标函数 F_{FTP} 的表达式如下:

$$F_{FTP}(\theta) = \begin{cases} 0 & -22.5 \leq \theta \leq 22.5 \\ -20\text{dB} & \text{其他} \end{cases} \quad (4-13)$$

根据公式(4-12)和(4-13)对阵列进行优化, 阵列优化后的辐射方向图和各算法优化过程中的适应度函数下降曲线如图 4-11 和图 4-12 所示, 对应的优化后的阵列结构参数和激励参数分别见表 4-10 和 4-11。

(2) 主瓣宽度为 $[-22.5^\circ, 22.5^\circ]$ 的非均匀间距线阵列的平顶波束赋形

对 8 元非均匀间距线阵列和 10 元非均匀间距线阵列进行平顶波束赋形, 对阵元间距和激励电流幅度、相位同时进行优化, 相邻阵元间距的寻优范围为 $[0.4\lambda, 0.6\lambda]$, 激励幅度的寻优范围为 $[0, 1]$, 激励相位的寻优范围为 $[0^\circ, 180^\circ]$ 。目标函数 F_{FTP} 的表达式同公式(4-13)。阵列优化后的辐射方向图和各算法优化过程

中的适应度函数下降曲线如图 4-13 和图 4-14 所示，优化后的阵列结构参数和激励参数如表 4-12 和表 4-13 所示。

(3) 主瓣宽度为 $[-15^\circ, 30^\circ]$ 和 $[-5^\circ, 40^\circ]$ 的 10 元非均匀线阵列平顶波束赋形

实验还考虑了更多平顶波束赋形的需求，除了主瓣宽度为 $[-22.5^\circ, 22.5^\circ]$ 的平顶波束赋形外，我们还通过优化阵元间距和激励电流幅度、相位对 10 元非均匀线阵列进行了主瓣宽度为 $[-15^\circ, 30^\circ]$ 和 $[-5^\circ, 40^\circ]$ 的平顶波束赋形。

主瓣宽度为 $[-15^\circ, 30^\circ]$ 的目标函数 F_{FTP} 的表达式为：

$$F_{FTP}(\theta) = \begin{cases} 0 & -15 \leq \theta \leq 30 \\ -20\text{dB} & \text{其他} \end{cases} \quad (4-14)$$

同理，主瓣宽度为 $[-5^\circ, 40^\circ]$ 的目标函数 F_{FTP} 的表达式为：

$$F_{FTP}(\theta) = \begin{cases} 0 & -5 \leq \theta \leq 40 \\ -20\text{dB} & \text{其他} \end{cases} \quad (4-15)$$

分别根据公式(4-14)和公式(4-15)对 10 元非均匀线阵列进行优化，阵列优化后的辐射方向图和各算法优化过程中的适应度函数下降曲线如图 4-15 和图 4-16 所示，优化后的阵列结构参数和激励参数见表 4-14 和表 4-15。





图 4-11 主瓣宽度为 $[-22.5^\circ, 22.5^\circ]$ 的 6 元均匀间距线阵列的平顶波束赋形

表 4-10 主瓣宽度为 $[-22.5^\circ, 22.5^\circ]$ 的 6 元均匀间距线阵列的平顶波束赋形结果

阵元	PSO		DE		GWO	
	幅度	相位	幅度	相位	幅度	相位
1	1	156.85	0.34	102.92	0.25	7.11
2	0.91	180.00	0.04	76.28	0.02	58.93
3	1.56	143.60	0.72	93.62	0.72	60.60
4	0.43	143.87	0.76	130.76	0.75	180
5	0.74	77.16	0.95	150.06	0.72	173.66
6	0.46	40.34	0.45	74.72	0.01	23.73
适应度值	18.4734		18.4697		17.4413	

阵元	WOA		SMA		ISMA	
	幅度	相位	幅度	相位	幅度	相位
1	0.01	180	0.10	7.75	0.34	91.10
2	0.67	0	0.81	146.94	0.19	0.12
3	1	0	0.81	146.93	0.67	0
4	0.91	0	0.01	146.94	1	0
5	0.10	6.63	0.11	15.70	0.77	0.01
6	0.34	15.67	0.13	5.70	0.06	0.04
适应度值	21.0860		16.7420		15.0349	



(a) 优化后的方向图

(b) 适应度变化曲线

图 4-12 主瓣宽度为 $[-22.5^\circ, 22.5^\circ]$ 的 8 元均匀间距线阵列的平顶波束赋形表 4-11 主瓣宽度为 $[-22.5^\circ, 22.5^\circ]$ 的 8 元均匀间距线阵列的平顶波束赋形结果

阵元	PSO		DE		GWO	
	幅度	相位	幅度	相位	幅度	相位
1	0.66	70.49	0.12	12.34	0.15	126.73
2	0.99	51.67	0.10	136.67	0.22	0
3	0.64	177.68	0.23	78.03	0.01	11.43
4	0.24	176.17	0.51	28.28	0.42	154.30
5	0.16	146.31	0.34	147.52	0.86	3.89
6	0.57	67.43	0.28	103.50	0.92	60.06
7	0.17	127.33	0.10	178.99	0.81	173.40
8	0.09	126.67	0.10	30.50	0.13	9.88
适应度值	12.5777		13.1954		12.6922	

阵元	WOA		SMA		ISMA	
	幅度	相位	幅度	相位	幅度	相位
1	0.02	28.31	0.02	140.31	0.61	180
2	0.32	72.26	0.67	0	0.99	153.91
3	0.17	12.63	0.86	0	0.88	180
4	0.49	0	0.76	0	0.59	180
5	0.79	0	0.57	0.01	0.01	124.59
6	0.81	0	0.01	142.07	0.06	0.91
7	0.70	0	0.18	9.12	0.43	0.92
8	0.08	63.01	0.29	47.31	0.01	166.87
适应度值	10.9432		10.1422		9.8376	






图 4-13 主瓣宽度为 $[-22.5^{\circ}, 22.5^{\circ}]$ 的 8 元非均匀间距线阵列的平顶波束赋形

表 4-12 主瓣宽度为 $[-22.5^{\circ}, 22.5^{\circ}]$ 的 8 元非均匀间距线阵列的平顶波束赋形结果

阵元	PSO			DE			GWO		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.18	153.14	0.000	0.48	7.80	0	0.02	0.77
2	0.555	0.18	161.18	0.490	0.24	106.57	0.419	0.01	51.33
3	1.100	0.36	125.46	1.070	0.50	43.24	0.929	0.78	0
4	1.664	0.17	17.16	1.554	0.83	168.50	1.529	0.98	0
5	2.251	0.20	102.50	2.078	0.93	49.22	2.128	0.59	0
6	2.721	0.68	122.05	2.567	0.58	105.36	2.728	0.01	0.04
7	3.297	0.96	2.71	3.147	0.46	63.37	3.141	0.04	0.57
8	3.888	0.59	8.78	3.714	0.29	113.86	3.565	0.28	65.98
适应度值	10.4568			10.4618			10.0457		
阵元	WOA			SMA			ISMA		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.02	0.96	0	0.01	98.72	0	0.03	179.17
2	0.405	0.15	81.58	0.554	0.44	128.88	0.439	0.44	170.50
3	1.004	0.73	0	1.149	0.01	140.58	0.840	0.01	33.89
4	1.577	0.96	0	1.692	0.89	0.03	1.303	0.06	129.72
5	2.194	0.63	18.80	2.221	0.55	0	1.870	0.72	179.99
6	2.721	0.07	125.82	2.820	1	0.02	2.463	1	179.98
7	3.275	0.01	0	3.418	0.89	0	3.060	0.62	117.17
8	3.811	0.31	21.95	4.008	0.01	4.65	3.657	0.01	17.61
适应度值	11.6278			10.0695			9.2614		

图 4-14 主瓣宽度为 $[-22.5^\circ, 22.5^\circ]$ 的 10 元非均匀间距线阵列的平顶波束赋形表 4-13 主瓣宽度为 $[-22.5^\circ, 22.5^\circ]$ 的 10 元非均匀间距线阵列的平顶波束赋形结果

阵元	PSO			DE			GWO		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.11	90.51	0	0.23	65.23	0	0.02	0.31
2	0.584	0.08	85.88	0.536	0.31	132.04	0.443	0.46	59.70
3	1.142	0.15	124.92	1.119	0.49	87.86	0.848	0.01	83.02
4	1.664	0.24	27.14	1.580	0.49	178.03	1.248	0.01	9.13
5	2.094	0.45	15.71	2.143	0.68	128.64	1.656	0.49	0.02
6	2.535	0.95	77.68	2.609	0.80	122.25	2.065	0.62	0
7	3.115	0.75	103.10	3.087	0.97	122.30	2.540	0.94	0
8	3.635	0.44	171.84	3.610	0.44	159.86	3.051	0.81	0
9	4.170	0.21	143.27	4.076	0.09	114.16	3.500	0.22	0.03
10	4.718	0.24	17.90	4.584	0.27	70.03	3.906	0.01	21.43
适应度值	14.1054			10.075			13.5663		
阵元	WOA			SMA			ISMA		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.01	3.42	0	0.10	148.51	0	0.01	158.65
2	0.598	0.01	119.26	0.558	0.02	8.98	0.451	0.06	0
3	1.010	0.06	0	1.144	0.27	82.67	0.915	0.06	157.22
4	1.411	0.43	65.98	1.577	0.11	148.69	1.422	0.01	0
5	1.811	0.01	10.75	2.163	0.31	173.70	1.825	0.24	128.71
6	2.401	0.47	0	2.664	0.78	180	2.225	0.06	54.12
7	2.842	0.88	0	3.203	0.99	180	2.779	0.01	24.27
8	3.251	0.92	0.01	3.790	0.84	180	3.279	0.49	0.05
9	3.665	0.77	0	4.381	0.01	0.02	3.857	0.78	0.06
10	4.070	0.03	72.40	4.901	0.27	101.47	4.450	0.59	0.01
适应度值	16.4951			7.7811			6.5300		




(a) 优化后的方向图

(b) 适应度变化曲线

图 4-15 主瓣宽度为 $[-15^\circ, 30^\circ]$ 的 10 元非均匀间距线阵列的平顶波束赋形

表 4-14 主瓣宽度为 $[-15^\circ, 30^\circ]$ 的 10 元非均匀间距线阵列的平顶波束赋形结果

阵元	PSO			DE			GWO		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0.000	0.18	39.46	0.000	0.09	176.45	0	0.26	40.29
2	0.421	0.36	135.50	0.468	0.31	48.68	0.405	0.14	19.34
3	0.936	0.28	75.95	0.888	0.20	49.66	0.812	0.41	37.35
4	1.480	0.43	163.92	1.298	0.04	33.83	1.320	0.53	144.43
5	1.981	0.06	105.06	1.756	0.46	133.96	1.730	0.74	0.36
6	2.472	0.30	123.04	2.256	0.80	152.92	2.154	0.84	0.40
7	2.875	0.87	137.01	2.746	0.97	96.96	2.556	0.57	7.31
8	3.354	0.75	61.75	3.284	0.67	135.09	3.030	0.14	1.09
9	3.821	0.84	55.75	3.837	0.18	83.65	3.470	0.24	49.86
10	4.333	0.30	43.61	4.349	0.24	89.67	3.885	0.01	16.06
适应度值	17.4166			15.4821			14.4313		
阵元	WOA			SMA			ISMA		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.01	0.54	0	0.01	72.78	0	0.23	0
2	0.401	0.01	4.61	0.419	0.17	177.07	0.595	0.83	62.38
3	0.801	0.01	0.31	0.865	0.01	0.07	1.066	1	0
4	1.217	0.03	0	1.388	0.04	5.93	1.645	0.99	15.51
5	1.620	0.01	0	1.956	0.96	5.61	2.232	0.39	101.52
6	2.020	0.05	0	2.425	0.86	0	2.709	0.04	53.73
7	2.421	0.01	0	2.858	0.97	81.89	3.275	0.36	105.12
8	2.821	0.09	0.72	3.318	0.89	38.28	3.871	0.01	17.31
9	3.224	0.06	0	3.741	0.34	0.45	4.470	0.04	0.98
10	3.626	0.03	0.23	4.341	0.24	179.99	5.015	0.02	153.55
适应度值	26.5571			11.4579			9.7072		

图 4-16 主瓣宽度为 $[-5^\circ, 40^\circ]$ 的 10 元非均匀间距线阵列的平顶波束赋形表 4-15 主瓣宽度为 $[-5^\circ, 40^\circ]$ 的 10 元非均匀间距线阵列的平顶波束赋形结果

阵元	PSO			DE			GWO		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.10	161.47	0	0.02	139.49	0	0.04	1.38
2	0.504	0.02	79.28	0.568	0.19	36.33	0.435	0.01	9.05
3	0.928	0.49	70.99	1.065	0.06	80.97	1.012	0.06	70.38
4	1.511	0.41	60.41	1.637	0.56	28.08	1.519	0.10	89.70
5	2.071	0.52	31.21	2.189	0.66	167.76	2.147	0.04	113.02
6	2.534	0.60	133.09	2.664	0.90	168.50	2.714	0.56	95.86
7	2.959	0.80	26.64	3.110	0.52	43.04	3.142	0.62	8.44
8	3.477	0.82	96.34	3.589	0.35	157.34	3.678	0.74	103.52
9	3.980	0.11	41.82	4.118	0.31	130.11	4.187	0.49	4.22
10	4.443	0.59	115.27	4.600	0.01	32.29	4.781	0.20	4.70
适应度值	18.0604			16.9345			18.4712		
阵元	WOA			SMA			ISMA		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.07	180	0	0.03	17.86	0	0.04	35.95
2	0.425	0.01	31.55	0.410	0.29	0	0.400	0.01	1.54
3	0.912	0.11	11.41	0.935	0.01	123.21	0.832	0.01	17.84
4	1.340	0.64	30.90	1.368	0.06	73.64	1.420	0.18	147.57
5	1.899	0.54	94.51	1.838	0.53	24.19	1.964	0.20	92.07
6	2.418	0.63	20.01	2.395	0.83	0	2.507	0.07	133.75
7	2.864	0.23	103.29	2.944	0.84	0.89	2.947	0.50	96.71
8	3.455	0.01	22.01	3.345	0.14	39.55	3.416	0.72	178.99
9	3.877	0.12	32.41	3.758	0.24	20.85	3.842	0.86	29.36
10	4.329	0.16	39.31	4.339	0.04	31.97	4.439	0.97	124.24
适应度值	18.2583			12.6262			11.3675		

表 4-10~表 4-15 中的最佳适应度值可以看出 ISMA 对各阵列的辐射方向图的优化效果最好。通过图 4-11~图 4-16 可以看出, 四种算法在一定程度上都能够优化出平顶波束的方向图, 其中 ISMA 算法优化后的方向图主瓣更接近期望方向图, 并且副瓣电平更低。

4.4.3 余割平方波束赋形

针对余割平方波束 (Cosecant-square pattern, CSP) 赋形的要求特性, 设计了适应度函数, 如下所示:

$$fitness = \alpha \cdot \left| \max_{\theta \in S_p} \{F(\theta)\} - PSLL_d \right| + \beta \cdot \sum_{\theta \in S_m} |F(\theta) - F_{CSP}(\theta)| \quad (4-16)$$

其中, S_p 表示不包括主瓣的辐射方向图, S_m 表示主瓣, $PSLL_d$ 为目标副瓣电平, F_{CSP} 为余割平方波束的目标函数, α 和 β 为两个超参数, 在以下实验中, 分别取值 0.5 和 0.01。本次实验的目标余割波束要求为副瓣电平 -20dB, 故取 $PSLL_d$ 等于 20; 并要求主瓣宽度为 $[-5^\circ, 35^\circ]$, 目标函数的表达式如下:

$$F_{CSP}(\theta) = \begin{cases} 0 & -5 \leq \theta \leq 5 \\ \frac{\csc^2(\theta)}{2 \csc^2(5^\circ)} - 0.5 & 5 \leq \theta \leq 35 \\ -20 & \text{其他} \end{cases} \quad (4-17)$$

对 8 元非均匀间距线阵列和 10 元非均匀间距线阵列根据公式(4-16)和公式(4-17)进行余割平方波束赋形, 对阵元间距和激励电流幅度、相位同时进行优化, 寻优范围分别为 $[0.4\lambda, 0.6\lambda]$ 、 $[0, 1]$ 和 $[0^\circ, 180^\circ]$ 。8 元非均匀间距线阵列的余割平方波束赋形结果见图 4-17 和表 4-16 所示, 10 元非均匀间距线阵列的余割平方波束赋形结果见图 4-18 和表 4-17 所示。





图 4-17 8 元非均匀间距线阵列的余割平方波束赋形

表 4-16 8 元非均匀间距线阵列的余割平方波束赋形结果

阵元	PSO			DE			GWO		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.13	108.15	0	0.06	83.72	0	0.09	16.67
2	0.501	0.32	59.31	0.531	0.45	109.50	0.406	0.14	11.07
3	1.072	0.23	21.53	1.116	0.13	73.31	0.877	0.40	180
4	1.581	0.20	70.58	1.659	0.31	178.61	1.289	0.01	89.30
5	2.145	0.72	166.34	2.139	0.82	103.59	1.694	0.76	180
6	2.664	0.77	16.06	2.567	0.87	116.54	2.276	0.83	55.42
7	3.111	0.76	85.78	3.036	0.93	48.16	2.801	0.59	0.01
8	3.622	0.27	93.08	3.570	0.58	61.82	3.211	0.02	11.75
适应度值	42.9624			40.1225			68.4484		
阵元	WOA			SMA			ISMA		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.37	68.36	0	0.43	80.28	0	0.49	0.11
2	0.447	0.25	0	0.592	1	162.42	0.405	0.01	179.89
3	0.869	0.36	0	1.042	1	0	1.005	0.07	74.98
4	1.269	0.01	0	1.444	1	0.56	1.558	0.48	0
5	1.773	0.01	0	1.886	0.79	45.35	1.965	0.86	0.76
6	2.173	0.04	1.14	2.286	0.01	41.38	2.528	0.99	158.42
7	2.675	0.13	0	2.845	0.01	167.12	3.101	0.51	33.72
8	3.097	0.01	0	3.433	0.57	1.14	3.609	0.06	0.77
适应度值	83.1453			70.7324			38.2575		



(a) 优化后的方向图

(b) 适应度变化曲线

图 4-18 10 元非均匀间距线阵列的余割平方波束赋形

表 4-17 10 元非均匀间距线阵列的余割平方波束赋形结果

阵元	PSO			DE			GWO		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.34	106	0	0.84	162.29	0	0.20	159.12
2	0.435	0.04	135.41	0.441	0.73	87.55	0.488	0.71	166.96
3	0.943	0.15	174.03	0.906	0.91	25.30	1.028	0.91	179.95
4	1.364	0.46	105.42	1.337	0.71	69.90	1.511	1	168.08
5	1.944	0.44	61.21	1.793	0.18	126.82	1.971	0.14	162.25
6	2.540	0.55	167.26	2.196	0.16	37.20	2.471	0.01	95.29
7	2.970	0.71	117.68	2.663	0.50	19.20	3.010	0.56	180
8	3.431	0.92	36.39	3.146	0.28	157.85	3.410	0.01	127.03
9	3.851	0.86	81.33	3.639	0.08	62.40	4.007	0.11	73.16
10	4.326	0.48	69.62	4.116	0.25	43.00	4.596	0.31	91.82
适应度值	35.2969			34.7472			46.1954		
阵元	WOA			SMA			ISMA		
	位置	幅度	相位	位置	幅度	相位	位置	幅度	相位
1	0	0.16	179.56	0	0.11	4.49	0	0.16	167.09
2	0.402	0.18	48.77	0.422	0.08	126.75	0.547	0.25	10.38
3	0.975	0.02	62.64	0.948	0.01	172.42	1.128	0.04	115.93
4	1.570	0.59	156.04	1.348	0.02	156.94	1.708	0.49	129.14
5	2.163	0.99	87.12	1.900	0.24	0.05	2.262	0.06	179.74
6	2.739	0.75	0.11	2.421	0.04	1.49	2.795	0.25	9.25
7	3.242	0.88	0.80	3.016	0.18	0.02	3.203	0.61	2.62
8	3.793	0.13	171.15	3.608	0.59	12.59	3.604	0.96	173.26
9	4.215	0.12	0	4.205	0.55	1.05	4.198	0.99	179.98
10	4.978	0.29	0	4.805	0.38	71.11	4.600	0.41	174.78
适应度值	37.1586			28.6901			27.6995		

通过上述结果可以看出，我们提出的算法对天线阵列的优化效果更好，主瓣形状和副瓣电平都更接近于目标函数。通过适应度函数下降曲线也可以看出，ISMA 的性能更优，尤其是在对 8 元非均匀间距线阵列的余割平方波束赋形的过程中，其最佳适应度值相比其他算法大大降低，收敛效果最为成功。

4.5 本章小结

本章主要介绍了基于图深度学习和改进黏菌算法的天线阵列综合方法。首先介绍了基于图神经网络和改进黏菌算法的阵列综合模型的整体框架，并描述了框架的流程步骤。其次对框架中引入的黏菌算法进行了概述和数学模型介绍。基于基础的黏菌算法提出了两个改进策略，即精英反向学习策略和惯性权重策略，详细描述了改进黏菌算法的公式和流程，并将其与多种元启发式算法在标准测试函

数上进行了对比实验,实验结果验证了改进黏菌算法的优势。最后使用所提阵列方法对多种不同拓扑结构的微带天线阵列进行了笔状波束赋形、平顶波束赋形和余割平方波束赋形。

第5章 总结与展望

5.1 工作总结

随着人工智能和深度学习的快速发展,人们越来越多的利用人工智能和深度学习技术来解决各种非线性和计算需求较大的问题。近几年,很多学者使用深度学习技术来处理例如化学分子、社交网络等非欧式空间数据时,发现人工神经网络、深度神经网络、循环神经网络等经典的网络模型存在局限性,进而提出了能够处理非欧式空间数据的图神经网络,并将其应用到了诸多图结构数据的领域中。在对人工智能在天线阵列应用的调研中,我们也发现常用于天线阵列设计和优化的人工神经网络和深度神经网络存在一定的局限性。目前已有的研究,能够针对人工智能和深度学习的技术特点,设计出能够预测天线阵列方向图或实现天线阵列综合的神经网络模型,并在预测效果中取得较高的准确度,比传统的全波仿真方法计算效率大幅提高;但是这些基于人工神经网络和深度神经网络的天线设计模型通常只能对单一结构的天线阵列进行优化设计,普适性较差。

本文以实现多种不同拓扑结构天线阵列的分析和预测为目标,在进行深入理论分析的基础上,利用图深度学习技术提出了一种基于图神经网络的阵列分析方法,并结合改进的黏菌优化算法提出了一种基于图神经网络和黏菌算法的阵列综合方法。论文的主要工作内容总结如下:

第一章介绍了图深度学习在天线设计领域上的研究背景与意义,调研了该领域的国内外研究现状,并介绍了本文的工作安排和整体结构。

第二章介绍了天线和天线阵列以及图深度学习的相关理论和基础知识,为后续基于图深度学习的天线阵列分析和综合方法提供了理论支撑。

第三章提出了基于图深度学习的天线阵列分析方法。主要贡献有:1)提出了一个用于天线阵列的图表示方法,能够有效地将任意结构的天线阵列转换为统一的图结构数据。2)提出了一个用于阵列方向图预测的图神经网络的模型架构,在基于图同构网络的基本框架中引入了残差连接和复数权重。3)构建了五种不同拓扑结构的天线阵列数据集并对其进行训练和测试,实验结果证明了模型架构的有效性,能够同时有效地预测多种不同拓扑结构的阵列方向图。4)通过多组对比实验和消融实验验证了所提模型架构的先进性、准确性优于其他神经网络模型,并且计算效率比传统全波仿真算法提高了6个数量级。

第四章提出了基于图深度学习和黏菌算法的天线阵列综合方法。主要贡献有：1) 以图神经网络为代理模型，结合改进黏菌算法，提出了一个能够实现多种不同拓扑结构天线阵列综合的模型框架。2) 针对黏菌算法的特点，通过精英反向学习策略和惯性权重策略对其进行了改进，通过在标准测试函数上进行的对比实验验证了改进黏菌算法的性能较好，优于对比算法。3) 通过多种不同任务的阵列综合实验，实现了多种不同拓扑结构天线阵列的笔状波束赋形、平顶波束赋形和余割平方波束赋形，验证了该综合方法的有效性。

5.2 工作展望

由于图深度学习发展时间较短，还没有被广泛应用在天线领域，本文也是对图深度学习和天线阵列的分析及综合进行了尝试性的结合。虽取得了阶段性成果，但图深度学习在天线领域的应用仍存在很大的改善空间和研究价值。针对本文目前的研究和现存问题，未来还可以从以下几点出发进行完善和改进：

(1) 在图深度学习应用于天线阵列分析方面，本文训练的模型更适应于数据集中的线阵列和面阵列。未来可以将数据集扩充到更具多样性的拓扑结构阵列样本上，例如加入圆阵、圆环阵等样本，以设计出更完善、更具普适性的图神经网络模型。

(2) 在图深度学习应用于天线阵列综合方面，本文将图深度学习作为代理模型，引入改进黏菌算法以实现网络模型的逆向任务。未来可以通过构建方向图的图结构数据，调换现有的输入输出数据，以实现只通过图神经网络就可以完成天线阵列综合任务。

(3) 在图深度学习应用于天线领域方面，本文只将图深度学习应用于天线阵列的分析和综合。实际上，有很多天线领域或电磁领域的问题都可以看作是对非欧式空间数据的处理和计算，例如对超材料结构的设计、对超材料天线的设计等。未来可以针对天线领域不同问题的特点，构建图结构数据表示方法，将图深度学习应用于更多的天线领域或电磁领域，以进一步提高深度学习技术在天线领域的优势。

随着科技的不断发展，市场对天线需求的不断增多，传统的电磁仿真软件因其设计耗时长、调试繁琐等问题无法为天线设计提供更强有力的支撑。使用深度学习技术进行天线的设计与优化是未来趋势，而对图深度学习在天线领域的应用需要不断的尝试，本文的后续工作和主要研究方向将对以上不足进行尝试和改进，力求进一步提高模型和算法的性能与精度。

参考文献

- [1] Li L L, Wang L G, Teixeira F L, et al. DeepNIS: Deep neural network for nonlinear electromagnetic inverse scattering [J]. IEEE Transactions on Antennas and Propagation, 2019, 67(3): 1819-1825.
- [2] Yao H M, Jiang L J. Machine learning based neural network solving methods for the FDTD method [C]. Proceedings of the 2018 IEEE Antennas and Propagation Society International Symposium on Antennas and Propagation & Usnc/Ursi National Radio Science Meeting. Boston: IEEE, 2018: 2321-2322.
- [3] Yang Y, Li Y, Li K, et al. DECCO: Deer-learning enabled coverage and capacity optimization for massive MIMO systems [J]. IEEE Access, 2018, 6: 23361-23371.
- [4] Shi D, Fang W, Zhang F F, et al. A novel method for intelligent EMC management using a "knowledge base" [J]. IEEE Transactions on Electromagnetic Compatibility, 2018, 60(6): 1621-1626.
- [5] Chen S Z, Wang H P, Xu F, et al. Target classification using the deep convolutional networks for SAR images [J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(8): 4806-4817.
- [6] Mishra R K, Patnaik A. Neural network-based CAD model for the design of square-patch antennas [J]. IEEE Transactions on Antennas and Propagation, 1998, 46(12): 1890-1891.
- [7] Yuan L, Yang X-S, Wang C, et al. Multibranch artificial neural network modeling for inverse estimation of antenna array directivity [J]. IEEE Transactions on Antennas and Propagation, 2020, 68(6): 4417-4427.
- [8] Sharma Y, Zhang H H, Xin H. Machine learning techniques for optimizing design of double T-shaped monopole antenna [J]. IEEE Transactions on Antennas and Propagation, 2020, 68(7): 5658-5663.
- [9] Cui L, Zhang Y, Zhang R, et al. A modified efficient KNN method for antenna optimization and design [J]. IEEE Transactions on Antennas and Propagation, 2020, 68(10): 6858-6866.
- [10] Aguni L, El Yassini A, Chabaa S, et al. Design of a symmetric CPW-fed patch antenna for WLAN/WIMAX applications using ANN [J]. Wireless Personal Communications, 2020, 115(1): 439-456.
- [11] Kumar P, Tripathi P, Raj S, et al. ANN based novel inverted L shape slotted patch antenna for wide band applications [C]. Proceedings of the 2019 International

- Conference on Computing, Power and Communication Technologies (GUCON). New Delhi: IEEE, 2019: 390-393.
- [12] Liu W, Zhang Y, Wang J, et al. Item relationship graph neural networks for e-commerce [J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(9): 4785-4799.
- [13] Kan S, Cen Y, Li Y, et al. Local semantic correlation modeling over graph neural networks for deep feature embedding and image retrieval [J]. IEEE Transactions on Image Processing, 2022, 31: 2988-3003.
- [14] Jiang S, Balaprakash P. Graph neural network architecture search for molecular property prediction [C]. Proceedings of the 2020 IEEE International Conference on Big Data. Atlanta: IEEE, 2020: 1346-1353.
- [15] Cui Z, Henrickson K, Ke R, et al. Traffic graph convolutional recurrent neural network: A deep learning framework for network-scale traffic learning and forecasting [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(11): 4884-4894.
- [16] Kaur M, Sivia J S. Giuseppe peano and cantor set fractals based miniaturized hybrid fractal antenna for biomedical applications using artificial neural network and firefly algorithm [J]. International Journal of Rf and Microwave Computer-Aided Engineering, 2020, 30(1): 1-11.
- [17] Akdagli A, Toktas A, Kayabasi A, et al. An application of artificial neural network to compute the resonant frequency of E-shaped compact microstrip antennas [J]. Journal of Electrical Engineering-Elektrotechnicky Casopis, 2013, 64(5): 317-322.
- [18] Guney K, Sarikaya N. A hybrid method based on combining artificial neural network and fuzzy inference system for simultaneous computation of resonant frequencies of rectangular, circular, and triangular microstrip antennas [J]. IEEE Transactions on Antennas and Propagation, 2007, 55(3): 659-668.
- [19] Delgado H J, Thursby M H. A novel neural network combined with FDTD for the synthesis of a printed dipole antenna [J]. IEEE Transactions on Antennas and Propagation, 2005, 53(7): 2231-2236.
- [20] Mohamed M D A, Soliman E A, El-Gamal M A. Optimization and characterization of electromagnetically coupled patch antennas using RBF neural networks [J]. Journal of Electromagnetic Waves and Applications, 2006, 20(8): 1101-1114.
- [21] Kapetanakis T N, Vardiambasis I O, Ioannidou M P, et al. Neural network modeling for the solution of the inverse loop antenna radiation problem [J]. IEEE Transactions on Antennas and Propagation, 2018, 66(11): 6283-6290.

- [22] Xiao L-Y, Shao W, Jin F-L, et al. Multiparameter modeling with ANN for antenna design [J]. IEEE Transactions on Antennas and Propagation, 2018, 66(7): 3718-3723.
- [23] Ayestaran R G, Las-Heras F, Martinez J A. Non uniform-antenna array synthesis using neural networks [J]. Journal of Electromagnetic Waves and Applications, 2007, 21(8): 1001-1011.
- [24] Mishra S, Yadav R N, Singh R P. Directivity estimations for short dipole antenna arrays using radial basis function neural networks [J]. IEEE Antennas and Wireless Propagation Letters, 2015, 14: 1219-1222.
- [25] Zhou Z, Wei Z, Zhang Y, et al. Training of deep neural networks in electromagnetic problems: a case study of antenna array pattern synthesis [C]. Proceedings of the 2021 IEEE MTT-S International Wireless Symposium (IWS). Nanjing: IEEE, 2021: 1-3.
- [26] Cui C, Li W T, Ye X T, et al. Synthesis of mask-constrained pattern-reconfigurable nonuniformly spaced linear arrays using artificial neural networks [J]. IEEE Transactions on Antennas and Propagation, 2022.
- [27] Gori M, Monfardini G, Scarselli F. A new model for learning in graph domains [C]. Proceedings of the 2005 IEEE International Joint Conference on Neural Networks. Montreal: IEEE, 2005: 729-734.
- [28] G Z, H H, D K. Circuit-GNN: Graph neural networks for distributed circuit design [C]. Proceedings of the 36th International Conference on Machine Learning. California: PMLR, 2019: 7364-7373.
- [29] Xiang W, Zhang Z, Yang X, et al. Fast prediction of quasi-periodic array using dynamical graph convolutional neural networks [J]. IEEE Antennas and Wireless Propagation Letters, 2022: 1-5.
- [30] Tekbiyik K, Yurduseven O, Kurt G K. Graph attention network-based single-pixel compressive direction of arrival estimation [J]. IEEE Communications Letters, 2022, 26(3): 562-566.
- [31] Dhaliwal B S, Pattnaik S S. Development of PSO-ANN ensemble hybrid algorithm and its application in compact crown circular fractal patch antenna design [J]. Wireless Personal Communications, 2017, 96(1): 135-152.
- [32] Pratap P, Bhatia R S, Kumar B. Design and simulation of equilateral triangular microstrip antenna using particle swarm optimization (PSO) and advanced particle swarm optimization (APSO) [J]. Sadhana-Academy Proceedings in Engineering Sciences, 2016, 41(7): 721-725.
- [33] 宋立众, 段舒雅, 林涛. 一种结合遗传算法和 HFSS 的天线仿真与优化方法 [J]. 微波学报, 2015, 31(03): 1-6.

- [34] Li Y-L, Shao W, You L, et al. An improved PSO algorithm and its application to UWB antenna design [J]. IEEE Antennas and Wireless Propagation Letters, 2013, 12: 1236-1239.
- [35] 孙思扬, 吕英华, 张金玲, et al. 基于遗传算法的超宽带微带天线优化设计 [J]. 电波科学学报, 2011, 26(01): 62-66.
- [36] 杨帆, 张雪霞. 遗传算法在微带天线优化中的应用 [J]. 电子学报, 2000, (9): 91-95.
- [37] 焦永昌, 杨科, 陈胜兵, et al. 粒子群优化算法用于阵列天线方向图综合设计 [J]. 电波科学学报, 2006, (01): 16-20.
- [38] Ding M, Jin R, Geng J. Optimal design of ultra wideband antennas using a mixed model of 2-D genetic algorithm and finite-difference time-domain [J]. Microwave and Optical Technology Letters, 2007, 49(12): 3177-3180.
- [39] Kerkhoff A J, Ling H. Design of a band-notched planar monopole antenna using genetic algorithm optimization [J]. IEEE Transactions on Antennas and Propagation, 2007, 55(3): 604-610.
- [40] Fan X, Tian Y, Zhao Y. Optimal design of multiband microstrip antennas by self-renewing fitness estimation of particle swarm optimization algorithm [J]. International Journal of Antennas and Propagation, 2019, 2019: 1-9.
- [41] Mirjalili S, Mirjalili S M, Lewis A. Grey wolf optimizer [J]. Advances in Engineering Software, 2014, 69: 46-61.
- [42] Mirjalili S, Lewis A. The whale optimization algorithm [J]. Advances in Engineering Software, 2016, 95: 51-67.
- [43] Pan W-T. A new fruit fly optimization algorithm: Taking the financial distress model as an example [J]. Knowledge-Based Systems, 2012, 26: 69-74.
- [44] Karaboga D, Basturk B. A powerful and efficient algorithm for numerical function optimization: artificial bee colony (ABC) algorithm [J]. Journal of Global Optimization, 2007, 39(3): 459-471.
- [45] Goudos S K, Siakavara K, Sahalos J N. Novel spiral antenna design using artificial bee colony optimization for UHF RFID applications [J]. IEEE Antennas and Wireless Propagation Letters, 2014, 13: 528-531.
- [46] Yuan P L, Guo C J, Ding J, et al. Synthesis of nonuniform sparse linear array antenna using whale optimization algorithm [C]. Proceedings of the 6th Asia-Pacific Conference on Antennas and Propagation (APCAP). Xian: IEEE, 2017: 1-3.
- [47] Darvish A, Ebrahimzadeh A. Improved fruit-fly optimization algorithm and its applications in antenna arrays synthesis [J]. IEEE Transactions on Antennas and Propagation, 2018, 66(4): 1756-1766.

- [48] Zhang X, Zhang X, Wang L. Antenna design by an adaptive variable differential artificial bee colony algorithm [J]. IEEE Transactions on Magnetics, 2018, 54(3): 1-4.
- [49] Li X, Luk K M. The grey wolf optimizer and its applications in electromagnetics [J]. IEEE Transactions on Antennas and Propagation, 2020, 68(3): 2186-2197.
- [50] Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks [J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(1): 4-24.
- [51] Dai H, Kozareva Z, Dai B, et al. Learning steady-states of iterative algorithms over graphs [C]. Proceedings of the 35th International Conference on Machine Learning (ICML). Stockholm: Journal Machine Learning Research, 2018: 1-9.
- [52] Gallicchio C, Micheli A, Ieee. Graph echo state networks [C]. Proceedings of the 2010 International Joint Conference on Neural Networks (IJCNN). Barcelona: IEEE, 2010: 1-8.
- [53] Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model [J]. IEEE Transactions on Neural Networks, 2009, 20(1): 61-80.
- [54] Levie R, Monti F, Bresson X, et al. CayleyNets: Graph convolutional neural networks with complex rational spectral filters [J]. IEEE Transactions on Signal Processing, 2019, 67(1): 97-109.
- [55] Chiang W-L, Liu X, Si S, et al. Cluster-GCN: An efficient algorithm for training deep and large graph convolutional networks [C]. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. Anchorage: Assos Computing Machinery, 2019: 257-266.
- [56] Li Q, Han Z, Wu X-M, et al. Deeper insights into graph convolutional networks for semi-supervised learning [C]. Proceedings of the 32nd AAAI Conference on Artificial Intelligence. New Orleans: Assoc Advancement Artificial Intelligence, 2018: 3538-3545.
- [57] Monti F, Boscaini D, Masci J, et al. Geometric deep learning on graphs and manifolds using mixture model CNNs [C]. Proceedings of the 30th Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu: IEEE, 2017: 5425-5434.
- [58] Tu K, Cui P, Wang X, et al. Deep recursive network embedding with regular equivalence [C]. Proceedings of the 24th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. London: Assoc Computing Machinery, 2018: 2357-2366.
- [59] Pan S, Hu R, Long G, et al. Adversarially regularized graph autoencoder for graph embedding [C]. Proceedings of the 27th International Joint Conference on Artificial Intelligence. Stockholm, 2018: 2609-2615.

- [60] Simonovsky M, Komodakis N. GraphVAE: Towards generation of small graphs using variational autoencoders [C]. Proceedings of the Artificial Neural Networks and Machine Learning – ICANN 2018. Rhodes: Springer International Publishing, 2018: 412-422.
- [61] Bojchevski A, Shchur O, Zügner D, et al. NetGAN: Generating graphs via random walks [C]. Proceedings of the 35th International Conference on Machine Learning (ICML). Stockholm: Journal Machine Learning Research, 2018: 1-16.
- [62] Dai J, Cao Y, Shen Q, et al. Traffic flow prediction based on multi-spatial-temporal graph convolutional network [J]. Application Research of Computers, 2022, 39(3): 780-784.
- [63] Jain A, Zamir A R, Savarese S, et al. Structural-RNN: Deep learning on spatio-temporal graphs [C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 5308-5317.
- [64] Li F, Li J, Zhu A, et al. Enhanced spatial and extended temporal graph convolutional network for skeleton-based action recognition [J]. Sensors, 2020, 20(18).
- [65] Xu K, Hu W, J L. How powerful are graph neural networks? [C]. Proceedings of the International Conference on Learning Representations (ICLR). Vancouver, 2019: 1-17.
- [66] Trabelsi C, Bilaniuk O, Zhang Y, et al. Deep Complex Networks [C]. Proceedings of the International Conference on Learning Representations (ICLR). 2018: 1-19.
- [67] Feng C Z, Li W T, Cui C, et al. An efficient and universal static and dynamic convex optimization for array synthesis [J]. IEEE Antennas and Wireless Propagation Letters, 2022: 1-5.
- [68] Li S, Chen H, Wang M, et al. Slime mould algorithm: A new method for stochastic optimization [J]. Future Generation Computer Systems, 2020, 111: 300-323.
- [69] Tizhoosh H R. Opposition-based learning: A new scheme for machine intelligence [C]. Proceedings of the International Conference on Computational Intelligence for Modelling, Control and Automation and International Conference on Intelligent Agents, Web Technologies and Internet Commerce (CIMCA-IAWTIC). Vienna: IEEE, 2005: 695-701.
- [70] Xin Y, Yong L, Guangming L. Evolutionary programming made faster [J]. IEEE Transactions on Evolutionary Computation, 1999, 3(2): 82-102.
- [71] Kennedy J, Eberhart R. Particle swarm optimization [C]. Proceedings of the ICNN'95 - International Conference on Neural Networks. 1995: 1942-1948.
- [72] Storn R, Price K. Differential Evolution - A Simple and Efficient Heuristic for global Optimization over Continuous Spaces [J]. Journal of Global Optimization, 1997, 11(4): 341-359.