



廣東工業大學  
GUANGDONG UNIVERSITY OF TECHNOLOGY

# 硕士学位论文

基于智能算法的天线模型优化设计

作者姓名：户肖剑

导师姓名：吴多龙

学科（专业）或领域名称：电子科学与技术

论文答辩年月：2025年05月



中图分类号:

学校代号: 11845

UDC:

密级:

学

号: 2112215046

广东工业大学硕士学位论文  
(工学硕士)

基于智能算法的天线模型优化设计

户肖剑

指导教师姓名、职称: 吴多龙 副研究员

校外指导教师姓名、职称: 无

学科(专业)或领域名称: 电子科学与技术

学生所属学院: 物理与光电工程学院

答辩委员会主席: 涂治红

论文答辩日期: 2025年05月22日

A Dissertation Submitted to Guangdong University of Technology  
in Partial Fulfillment of the Requirement  
for the Degree of Master of Engineering Science

Optimal Design of Antenna Model Based on Intelligent  
Algorithm

Candidate: HU Xiaojian

Supervisor: WU Duo-Long

May 21, 2025  
School of Physics and Optoelectronic Engineering  
Guangdong University of Technology  
Guangzhou, Guangdong, P. R. China, 510006

## 摘要

天线作为通信系统中的关键器件，承担着收发信号的重要任务，其性能直接影响整体通信系统的传输质量。随着技术的快速演进，传统天线设计方法难以满足日益复杂的结构需求和多维度的设计自由度要求，这推动了对新型天线技术的迫切需求。智能优化算法凭借其快速收敛性和全局搜索能力，能够高效探索多维设计空间，精准定位满足性能要求的天线结构。在此背景下，本文以启发式智能算法和 AI 深度学习算法的天线代理模型为研究对象，深入研究智能算法分别对天线单元和阵列的设计技术。本文的主要研究内容如下：

(1) 提出了一种精确径向基的神经网络模型对于一款加载了两个 E 形带以及一个 I 形带的全双工天线进行设计。优化结果显示了天线的阻抗带宽从 3.44–3.56 GHz 扩展为 3.40–3.68 GHz 的频率范围，并且传输和接收端口实现了大于 35 dB 的高隔离。

(2) 提出了一种人工智能深度学习算法，高效的优化一个双极化天线。该方法是一种基于反向传播算法的多维输入和输出变量的代理模型。输入被定义为两个端口的阻抗带宽、平均隔离度和最大增益的期望目标，输出被定义为天线的尺寸变量。实验结果表明，所提出的人工智能深度学习方法在收敛速度(即获得所需目标的总电磁仿真数量)和时间成本方面具有优势，在 3.47–3.58 GHz 的带宽内具有高于 40 dB 的高隔离度，并在约 22.7 小时内实现了两个端口 4.3 dBi 的最大增益。

(3) 提出了一种平面天线阵列的基于改进的多元宇宙算法的波束形成模型。该模型针对于传统的多元宇宙算法的一些不足之处，融入了一种新的优化机制，增强了算法的全局寻找最优解的能力。使用改进的多元宇宙算法优化了平面天线阵列的波束图，实现了方位向以及俯仰向方向图的低旁瓣电平，并可以有效的控制旁瓣电平值。同时，对于阵列的不期望信号到达角的零点生成抑制以及最大化输出均值信号干扰加噪声比的目标也进行了显著改善。通过与遗传算法、灰狼算法以及多元宇宙算法优化的数值结果比较，验证了所提出的算法具有更快的收敛速度以及更好的优化性能。

综上，本文研究了智能算法技术在天线设计中的应用。智能算法可有效突破传统设计方法的局限，为高性能天线系统提供新的优化范式。研究成果对 5G/6G 通信系统的天线设计具有重要参考价值，未来将进一步探索算法在更复杂场景下的应用

**关键词：**全双工天线；双极化天线；AI 深度学习算法；天线阵列



## ABSTRACT

As a key component in communication systems, antennas play the critical task of transmitting and receiving signals, and their performance directly affects the transmission quality of the entire communication system. With the rapid advancement of technology, traditional antenna design methods have struggled to meet the increasingly complex structural requirements and multi-dimensional design freedom demands, driving an urgent need for novel antenna technologies. Intelligent optimization algorithms, leveraging their fast convergence and global search capabilities, can efficiently explore multi-dimensional design spaces and accurately identify antenna structures that meet performance requirements. Against this backdrop, this thesis focuses on heuristic intelligent algorithms and AI deep learning-based antenna surrogate models, conducting an in-depth study of intelligent algorithms for the design of both antenna elements and arrays. The main research contributions are as follows:

(1) A precise radial basis function neural network model was proposed to design a full-duplex antenna loaded with two E-shaped strips and one I-shaped strip. The optimization results demonstrated an expansion of the impedance bandwidth from 3.44–3.56 GHz to 3.40–3.68 GHz, while achieving high isolation ( $>35$  dB) between the transmission and reception ports.

(2) An artificial intelligence deep learning algorithm was proposed to efficiently optimize a dual-polarized antenna. This method is a surrogate model based on backpropagation algorithms with multi-dimensional input and output variables. The inputs were defined as the desired targets for the impedance bandwidth, average isolation, and maximum gain of the two ports, while the outputs were defined as the antenna's dimensional parameters. Experimental results showed that the proposed deep learning approach offers advantages in convergence speed (i.e., the total number of electromagnetic simulations required to achieve the desired targets) and time cost, achieving high isolation ( $>40$  dB) within a bandwidth of 3.47–3.58 GHz and a maximum gain of 4.3 dBi for both ports in approximately 22.7 hours.

(3) A beamforming model for planar antenna arrays based on an improved multi-verse optimizer (MVO) algorithm was proposed. Addressing some shortcomings of the traditional MVO algorithm, a novel optimization mechanism was incorporated to enhance the algorithm's global search capability. The improved MVO algorithm was applied to optimize the beam patterns of planar antenna arrays, achieving low sidelobe levels in both azimuth and elevation planes while effectively controlling sidelobe values. Additionally, significant improvements were made in suppressing nulls at undesired signal arrival angles and maximizing the output

signal-to-interference-plus-noise ratio. Comparative evaluations with genetic algorithms, grey wolf optimization, and the original MVO algorithm confirmed that the proposed method exhibits faster convergence and superior optimization performance.

In summary, this thesis investigates the application of intelligent algorithms in antenna design. These algorithms effectively overcome the limitations of traditional design methods, providing a new optimization paradigm for high-performance antenna systems. The research findings hold significant reference value for antenna design in 5G/6G communication systems, and future work will further explore the application of these algorithms in more complex scenarios.

**Key words:** Full-duplex antenna; dual-polarized antenna; intelligent algorithm; antenna array

# 目 录

|                               |    |
|-------------------------------|----|
| 第一章 绪论.....                   | 1  |
| 1.1 本课题研究背景及研究意义 .....        | 1  |
| 1.2 国内外研究现状.....              | 1  |
| 1.2.1 启发式算法的天线设计的研究现状.....    | 1  |
| 1.2.2 深度学习的天线设计的研究现状.....     | 3  |
| 1.2.3 自适应混合算法的天线设计的研究现状 ..... | 6  |
| 1.3 本课题研究目标和主要研究内容 .....      | 10 |
| 1.3.1 课题研究目标.....             | 10 |
| 1.3.2 主要研究内容.....             | 10 |
| 1.4 课题来源.....                 | 11 |
| 1.5 本章小结.....                 | 11 |
| 第二章 全双工天线的神经网络设计研究 .....      | 12 |
| 2.1 引言.....                   | 12 |
| 2.2 精确径向基函数神经网络模型 .....       | 12 |
| 2.3 天线结构的分析与设计.....           | 16 |
| 2.4 实验结果与分析.....              | 20 |
| 2.5 本章小结.....                 | 22 |
| 第三章 双极化天线的 AI 深度学习设计研究 .....  | 23 |
| 3.1 引言.....                   | 23 |
| 3.2 反向传播算法原理.....             | 23 |
| 3.3 双极化天线的设计.....             | 25 |
| 3.3.1 MIMO-BP 算法优化流程 .....    | 25 |
| 3.3.2 天线优化结构.....             | 27 |
| 3.3.3 MIMO-BP 算法优化的天线性能 ..... | 30 |
| 3.4 本章总结.....                 | 31 |
| 第四章 基于智能算法的天线阵列设计研究 .....     | 32 |
| 4.1 引言.....                   | 32 |
| 4.2 改进的多元宇宙算法原理 .....         | 33 |
| 4.3 天线阵列的波束形成优化 .....         | 37 |
| 4.3.1 波束优化模型.....             | 37 |
| 4.3.2 平面天线阵列的辐射图函数.....       | 39 |
| 4.3.3 旁瓣电平的抑制.....            | 41 |
| 4.3.4 旁瓣电平的控制.....            | 42 |
| 4.3.5 自适应波束形成.....            | 44 |

|                 |    |
|-----------------|----|
| 4.4 本章总结.....   | 51 |
| 第五章 结论与展望 ..... | 52 |
| 参考文献.....       | 55 |

# 第一章 绪论

## 1.1 本课题研究背景及研究意义

随着无线通信技术的迅速发展,对天线性能的要求日益提高。传统的天线设计方法主要依赖经验公式和实验调试,设计周期长、成本高,且难以满足现代通信系统对多频段、宽带宽、高增益和低功耗的需求。使用自适应免疫退火算法提升了可重构天线设计的精度和自动化效率<sup>[1]</sup>。一种高效率的改进的粒子群优化算法通过三个天线模型验证了有效性<sup>[2]</sup>。使用一种改进的杜鹃搜索算法优化单脉冲天线的差异模式,获得了较好的天线性能<sup>[3]</sup>。通过人工智能(Artificial intelligence, AI)深度学习算法强大的决策能力以及逼近任意非线性函数关系的能力等优势,建立了一种模拟电磁求解器的深层物理模型。即将 AI 深度学习算法模型进行不断的学习训练,获得一种天线结构的物理参数到性能参数之间的映射关系,用以辅助设计者进行天线的设计<sup>[4-5]</sup>。虽然 AI 深度学习算法的预测不确定性的特性,需要很多天线尺寸与对应的性能参数的训练集样本来弥补,导致天线的优化设计时间相应增长。但是通过结合多种优化理论框架,改进算法不足之处, AI 深度学习还是可以作为天线的自动化设计的一种有效方法。随着 5G 和未来 6G 通信技术的快速发展,对于快速设计高性能天线的需求也更加紧迫。这使得研究者们面对着很大的挑战。

## 1.2 国内外研究现状

根据智能算法优化天线模型的实现方式,主要分为启发式种群行为算法,深度学习算法以及自适应混合算法等。

### 1.2.1 启发式算法的天线设计的研究现状

启发式智能算法包括遗传算法、粒子群优化、模拟退火以及蚁群优化等算法。启发式智能算法不依赖于求解问题的具体数学特性,而是通过模拟自然界中的物理机制(如进化和群体行为等)搜索最优解。天线设计是一个复杂的多目标优化问题,通常在阻抗带宽、增益、辐射方向图以及尺寸等多个性能之间进行权衡。启发式智能算法能够在复杂的非线性设计空间中快速找到近似最优解,具有很好的灵活性,适用于各种天线类型的设计问题,包括单目标和多目标优化<sup>[6]</sup>,这能够帮助天线工程师有效地处理天线模型优化复杂的问题。


文献[7]采用自适应的粒子群优化算法对一种三维结构的半球形天线的谐振寄生条带结构迭代优化。如图 1-1 所示，以寄生条带的长度和位置作为优化参数，天线模型的阻抗带宽作为优化目标，最终实现了整体天线结构的小型化，并获得了 700 MHz 的阻抗带宽。



图 1-1 自适应 PSO 优化的 3 维的半球形天线结构

Figure 1-1 Adaptive PSO optimized hemispherical antenna structure in three dimensions

文献[8]通过引入一种蝙蝠群体智能优化算法，解决了多层堆叠贴片天线的宽阻抗带宽设计问题。如图 1-2 所示，在蝙蝠群体智能算法进行天线堆叠结构的优化中，将两层以及三层贴片结构的长度、宽度以及两个馈电端口的距离作为优化参数，阻抗带宽定义为优化目标，实现了 34.9% 的相对阻抗带宽。



(a) 两层的贴片天线

(b) 三层的贴片天线

图 1-2 蝙蝠算法优化的贴片天线

Figure 1-2 Patch antenna optimized by bat algorithm

文献[9]应用改进的二进制粒子群优化算法对理想的“ $\pm 1$ ”激励磁电偶极子天线阵进行优化，“+1”激励表示磁电偶极子从默认方向馈电，“-1”激励表示磁电偶极子从物理相反的方向馈电，如图 1-3 所示。根据优化的阵列组合，将磁电偶极子单元与

256 路并联功分器相结合,设计了一个  $16 \times 16$  的毫米波天线阵,优化的工作带宽为 24.1–35.4 GHz, 相对带宽为 38%, 驻波比小于 2.4, 信噪比小于 -17.2 dB, 增益高达 26.3 dBi。这个设计方法对于宽带毫米波无线应用具有重大意义。




图 1-3 毫米波天线结构

Figure 1-3 Millimeter wave antenna structure

### 1.2.2 深度学习的天线设计的研究现状

在常规微波器件的设计中,通常需要反复调整和优化大量参数(如几何尺寸、材料特性、工作频率等)以达到预期的性能目标(如带宽、增益、回波损耗、辐射方向图等)。这一过程往往依赖经验驱动的试错方法或基于电磁仿真的迭代优化,耗时费力且计算成本高昂。AI 深度学习作为一种高效的代理模型,能够显著加速这一优化过程。通过训练神经网络等深度学习模型,可以快速预测微波器件的性能,替代部分耗时的电磁仿真,从而实现高效的参数优化 AI 深度学习不仅能够加速设计流程,还能探索传统方法难以发现的设计空间,为微波器件的创新设计提供强大支持<sup>[10]</sup>。因此, AI 深度学习作为一种代理模型,正在成为微波器件设计中不可或缺的工具,极大地提升了设计效率和性能。

文献[11]提出了一种用于超宽带天线设计的深度学习模型,该模型通过智能算法确定深度网络的模型结构,具有较高的特征学习能力和非线性函数逼近能力,并应用在 MIMO 天线陷波结构的优化设计中,其 S 参数拟合良好,达到了期望的超宽带目标,如图 1-4 所示。在相同训练样本的情况下,其所提出的优化模型与普遍使用的建模方法相比,获得了精度较高的效果,优化的 MIMO 天线的均方根误差为 3.56%。该模型具有更高的预测和泛化能力,也可用于更复杂的天线设计。






图 1-4 MIMO 天线结构

Figure 1-4 MIMO Antenna Structure

文献[12]提出一种新颖的双通道神经网络用于第五代手机的宽带 MIMO 天线阵列设计, 该天线工作于 N77/N78/N79 的 Sub-6 GHz 新无线电频段, 如图 1-5 所示。该方法使用特征简化方法减小设计空间, 生成有效标识特征的数据集。通过对多个设计目标使用定义的特征图来代替深度学习模型的直接优化方法。优化后的-6 dB 阻抗带宽达到了 45.5% (3.28–5.21 GHz), 隔离度小于-12.5 dB。




图 1-5 5G 手机 MIMO 天线

Figure 1-5 5G cellphone MIMO antenna

文献[13]使用多层感知机神经网络模型对于微带天线辐射体上十字形槽的 4 个尺寸以及介质基板与金属地板之间的空气间隙值进行了输出预测, 输入层为天线的性能参数, 包括双谐振点(Dual resonance, DR), 双频增益(Dual frequency gain, DFG), 双频

指向(Dual frequency directivity, DFD), 双频天线效率(Dual frequency antenna efficiency, DFA)以及双频率辐射效率(Dual frequency radiation efficiency, DFR), 输出层为槽的尺寸和空气间隙, 如图 1-6 所示, 最终实现了 1.74–1.99 GHz 的阻抗带宽。




图 1-6 多层感知机神经网络模型

Figure 1-6 Multi-layer perceptron neural network model

文献[14]提出一种用于降低频率可重构天线互耦和隔离器优化的人工智能驱动的自动设计程序, 其采用并行代理模型辅助差分进化算法加速天线的设计过程。优化的频率可重构天线阵列拓扑结构, 如图 1-7 所示, 其可以在 2.5 GHz 的 ISM 频段和 3.4 GHz 的 WiMAX 频段之间灵活切换。通过使用该方法对隔离器的优化, 高频段和低频段的互耦分别降低了 8 dB 和 7 dB。




图 1-7 频率可重构天线阵列拓扑结构

Figure 1-7 Topology of the frequency reconfigurable antenna array

文献[15]通过一种优化方法用于模拟天线特性的深度神经网络的最优模型超参数, 并基于长短期记忆深度神经网络, 如图 1-8 所示, 用于天线的结构尺寸优化。目标是预测扩展的频率响应, 在训练深度神经网络时应用各种随机方法确定最优超参数。可以从散射参数、增益和辐射方向图方面对于天线逆向设计结构。该方法解决了在确定超参数时严重依赖设计者经验的问题。此外, 预测天线未来的频率响应可以大大减少设

计者在计算或测量大频段时的工作量，即无需再计算或测量整个频段。以一个包含两个阵元的天线阵列验证该方法的有效性。




图 1-8 用于天线建模的基于 LSTM 的回归深度神经网络预测未来频带

Figure 1-8 LSTM-based regression deep neural network for forecasting future frequency band used for modeling antennas

### 1.2.3 自适应混合算法的天线设计的研究现状

自适应混合算法是针对单个算法往往存在不足之处而产生的一种改进方式，可以很好地改善单个算法的缺点，提升算法性能。遗传算法虽然应用范围很广，但是具有容易过早收敛，陷入局部最优解，以及进化后期搜索效率低的弱点。如果将模拟退火算法引入到遗传算法群体更新的阶段，既能保证群体的多样性，又能在后期逐步加快收敛速度，克服了遗传算法的以上弱点，从而得到一种混合算法，即模拟退火遗传算法。提出一种人工神经网络和脉冲神经网络自适应混合神经网络算法，进一步提升了模型的处理速度和精确度。

文献[16]将两种粒子群优化算法整合到基于群算子分解的多目标优化算法中，提出了一种改进的混合优化算法，并作为天线设计的自动优化方案。该设计方案的有效性通过一个单频带天线以及一个双频紧凑型高隔离多输入多输出(Multiple Input Multiple Output, MIMO)天线验证，如图 1-9 所示。优化结果显示，单频带天线能够实现 1.24 GHz 的阻抗带宽以及大于 20 dB 的隔离度。双频的 MIMO 天线可以实现 3.3–3.62 GHz 以及 4.85–5.90 GHz 的阻抗带宽以及大于 20 dB 的隔离度。




图 1-9 蝙蝠算法优化的贴片天线

Figure 1-9 Patch antenna optimized by bat algorithm

文献[17]提出了一种基于改进的遗传算法和粒子群优化算法的相控阵天线方向图合成算法。所优化的阵元结构，如图 1-10 所示。通过图 1-11 的优化流程，对于阵元激励幅值的优化设计，可以有效的实现天线阵列的波束扫描。对比于常规的遗传算法和粒子群算法，该混合算法具有更好的优化性能，并具有较高的精度和稳定的鲁棒性。




图 1-10 天线阵元结构

Figure 1-10 Antenna array element structure




图 1-11 优化流程

Figure 1-11 Optimization flow

文献[18]提出一种基于法布里-珀罗腔技术的高增益宽带谐振型的移动通信基站天线。采用一种实值编码混合遗传算法优化一个由方形和环形贴片构成的覆盖层，如图 1-12 所示。在保证天线高增益宽频带的特性下，可以将覆盖层优化的很薄，这在实际应用中具有很强的优势。




图 1-12 覆盖层结构

Figure 1-12 Overlay structure

文献[19]提出了一种基于人工神经网络和模拟退火算法的混合方法用以设计宽带贴片天线。人工神经网络的结构，如图 1-13 所示，其用以描述天线几何尺寸和 S 参数之间的非线性关系，并利用 HFSS 全波仿真获得的数据集对人工神经网络进行训练，再结合模拟退火算法用以展宽贴片天线的带宽。图 1-14 展示了所优化的贴片天线结构。




图 1-13 人工神经网络结构

Figure 1-13 Artificial neural network structure




图 1-14 天线结构

Figure 1-14 Antenna structure

文献[20]提出将自定义变异粒子群算法和基于混沌映射的改进遗传算法相结合，具有更快的收敛速度并且不会陷入局部最优解，如图 1-15 所示。通过将如图 1-16 所示的一个偶极子天线的阻抗带宽优化到 3.3–3.8 GHz，验证了该混合算法的有效性。




图 1-15 多目标混合优化算法

Figure 1-15 Multi-objective hybrid optimization algorithm




图 1-16 偶极子天线

Figure 1-16 Dipole antenna

综上所述, 启发式智能算法, 深度学习算法以及自适应混合算法都能够高效的优化天线结构和目标性能, 这三种方法对于实现 5G 和 6G 时代天线高性能的快速优化设计有着重要的研究意义。

### 1.3 本课题研究目标和主要研究内容

#### 1.3.1 课题研究目标

本课题的研究目标是:

##### (1) 全双工天线的神经网络算法设计研究

将神经网络算法应用于全双工天线的优化设计, 前提是理解天线的工作机理。此外, 天线的结构形式多种多样, 有些结构参数对于天线的性能影响很小, 但有些参数对于天线性能非常敏感。将天线性能敏感性参数作为优化变量, 而天线的阻抗带宽, 隔离度以及增益性能作为目标函数。通过电磁仿真软件与神经网络算法运行软件进行联合计算, 最终得到期望的天线性能。

##### (2) 小型化天线的 AI 深度学习设计研究

通过构建 AI 深度学习模型, 实现对天线结构的高效优化, 在保证天线小型化尺寸的同时, 显著提升其隔离度性能。深入分析不同天线结构与性能之间的复杂关系, 挖掘隐藏在数据中的规律, 为天线设计提供更精准的指导。此外, 开发一套基于 AI 深度学习的天线设计工具, 降低人工设计成本, 缩短研发周期, 推动天线设计向智能化、高效化方向发展, 为 5G/6G 及未来通信技术提供高性能的小型化天线解决方案。

##### (3) 天线阵列的启发式智能算法优化研究

启发式智能算法多种多样, 但是在算法的收敛速率、优化效率以及找寻最优解能力方面有着差异。因此, 首先需要比较多种经典启发式智能算法的优劣, 找寻一种性能较优的算法。从而, 在该算法基础上进一步改进, 使得对于天线阵列的优化设计更有效率。最后, 通过设定多种优化目标函数, 并使用启发式智能算法对天线阵列的激励幅值和激励相位进行优化调整, 实现对于旁瓣电平的有效抑制和控制。

#### 1.3.2 主要研究内容

第一章介绍了智能算法优化天线设计的研究起源、重要性和同行研究情况。

第二章提出了一种全双工天线的精确径向基函数神经网络的设计方法。基于本次研究, 我们搭建了一个三层的神经网络结构, 对天线的阻抗带宽, 隔离度以及增益进行优化, 其工作带宽可达 3.40–3.68 GHz。通过 I 型带和 E 型带的解耦结构的引入, 实现



了全双工天线大于 35 dB 的隔离度。

第三章提出了一种新的多输入天线性能和多输出天线尺寸变量的 AI 深度学习方法。我们设计了一个 4 层的神经网络，其包含一个输入层，2 个隐藏层和一个输出层。其中输入层的输入定义为双极化天线的 L 形短路结构，矩形槽，L 形金属贴片以及 T 形分支的结构参数，共包含 12 个尺寸。输出层为阻抗带宽，隔离度和增益三种性能。最终实现了 3.47–3.58 GHz 内的大于 40 dB 的高隔离度。

第四章提出了一种改进的多元宇宙算法对于平面天线阵列的辐射图进行优化，可以实现低副瓣的方向图，并可以有效控制方向图的旁瓣电平为任意值。此外，在主瓣指向角度确定的情况下，可以在任意角度生成零点，同时也可以降低旁瓣电平。

## 1.4 课题来源

本课题来源于广东省重点领域研发计划项目(2020B010176001)以及省部共建精密电子制造技术与装备国家重点实验室项目并受以上项目资助。

## 1.5 本章小结

本章介绍了天线的智能算法设计的研究背景，并阐述了提升天线高效率高性能设计的紧迫性。随后，以国内外有关研究成果作为依据，进行了详细的分析和介绍。对主流天线算法优化技术进行深入剖析，确立了针对新一代无线通信系统的高性能技术研究目标和基本研究内容。



## 第二章 全双工天线的神经网络设计研究

### 2.1 引言

随着 5G 通信技术的迅速发展,全双工天线在通信系统中发挥着越来越重要的作用。全双工天线允许通信双方在同一时间段进行传输信号的发送和接受。其被广泛应用于手机、平板以及电脑等电子通讯设备。如此一来,就对全双工天线发送和接受端口之间的抗干扰能力提出了很高要求。为了抑制全双工天线发送和接受端口之间的自干扰,提出了一种基于叠层贴片结构和一对金属探针的带内全双工天线,能够在 3.23–4.26 GHz 频带内实现大于 20 dB 的隔离度<sup>[21]</sup>。通过引入金属化过孔,以及在接地板上刻蚀 U 型槽,实现了收发端口之间大于 54 dB 的高隔离<sup>[22]</sup>。另一方面,神经网络算法具备更强的决策能力以及逼近非线性关系能力等优势而迅速普及各个行业,也包括电磁学以及天线领域<sup>[23–24]</sup>。训练完成的人工智能深度学习算法模型近似为电磁仿真软件求解器,用于显著的加快基于 EM 的模型设计和优化<sup>[25–26]</sup>。因此,为适应现代通信技术的迅速发展,将人工智能技术应用于 5G 通信天线领域是一个具有挑战性的探索目标。

本章提出了一种基于精确径向基函数神经网络模型,高效的对于一款加载了两个 E 形带以及一个 I 形带的全双工天线进行优化设计。优化结果显示了天线的阻抗带宽从 3.44–3.56 GHz 扩展为 3.40–3.68 GHz 的频率范围,并且传输和接受端口实现了大于 35 dB 的高隔离。

### 2.2 精确径向基函数神经网络模型

精确径向基函数(Precise Radial Basis Function, PRBF)神经网络在 20 世纪 80 年代首次提出,其是一种特殊类型的包含三层前馈神经网络的算法。以其结构简单、非线性关系逼近精度高以及高效的运算受到研究者的广泛关注。精确径向基神经网络的核心理念是通过高斯函数,多二次函数以及逆多元二次函数将输入数据映射到高维度计算,从而以三层网络结构实现复杂的非线性关系的建模。精确径向基神经网络包含输入层、隐藏层(径向基函数层)以及输出层三层网络结构,如图 2-1 所示。

精确径向基函数常被用于高精度函数的逼近以及插值运算,通常需要精确拟合无噪声或低噪声的已知数据点。在科学计算中的复杂函数逼近,如流体力学以及电磁模型仿真和工程中的传感器标定(如温度、压力传感器的非线性校正),精确径向基函数神经网络能够严格通过所有训练样本点,并实现较小的误差插值。精确径向基函数神经网络也常用于小样本数据建模。尤其是在医疗诊断、材料设计、医学图像分析(如肿




图 2-1 精确径向基神经网络拓扑结构

Figure 2-1 Precise radial basis neural network topology

瘤分类，样本稀缺）和在实验数据有限情况下的材料特性预测中，精确径向基函数神经网络能够在小样本下避免过拟合，并利用径向基的局部特性捕捉非线性关系。在需要快速响应的非线性控制动态系统控制中，如智能机器人的轨迹规划中的精确路径生成，工业过程控制的化学反应温度调节，精确径向基函数神经网络的局部反应特性能够精确适合这种实时控制的情况。精确径向基函数神经网络在信号处理与时间序列预测中，能够精确用以非线性信号建模和短期预测，语音信号增强以及金融时间序列的预测。此外，精确径向基函数神经网络可以通过稀疏化和混合模型提升泛化能力和预测的精确度。

精确径向基神经网络的输入层用以输入数据特征，并映射到隐藏层。输入向量的维度决定了输入层的节点数。精确径向基神经网络的隐藏层以径向基函数作为单元基形成隐藏层计算空间，每个单元基对应一个计算中线点。隐藏层中的径向基函数用以计算输入的数据特征与中心点之间的差值，从而再映射到高维空间计算。

径向基函数一般以 $\varphi(x)$ 表示， $x$ 表示输入数据的位置， $c_i$ 定义为中心点， $\sigma$ 表示径向

基函数的方差, 普遍使用的径向基函数为高斯函数, 反演 S 型函数以及拟多二次函数, 分别如(2.1), (2.2), 和(2.3)所示:

$$\varphi_1(x, c_i) = \exp\left(-\frac{\|x - c_i\|^2}{2\sigma^2}\right) \quad (2.1)$$

$$\varphi_2(x, c_i) = \frac{1}{1 + \exp\left(\frac{\|x - c_i\|^2}{\sigma^2}\right)} \quad (2.2)$$

$$\varphi_3(x, c_i) = \frac{1}{\sqrt{\|x - c_i\|^2 + \sigma^2}} \quad (2.3)$$

精确径向基函数神经网络的输出层是网络的最终运算步骤, 其是一种线性层的运算, 通过将隐藏层的输出进行线性加权, 生成网络的最终预测结果。

表 2-1 与其它神经网络模型的比较

Table 2-1 Comparison with other neural network models

| 特性     | 精确径向基函数 | 多层感知机 | 传统径向基 |
|--------|---------|-------|-------|
| 网路深度   | 单隐层     | 多隐层   | 单隐层   |
| 训练速度   | 快       | 慢     | 中等    |
| 局部逼近能力 | 强       | 弱     | 强     |
| 参数解释性  | 高       | 低     | 中等    |

精确径向基函数神经网络是一种先进的神经网络架构, 其特性在诸多方面展现出独特的优势。与多层感知机相比, 精确径向基神经网络的训练速度更快。多层感知机通常依赖于复杂的非线性优化算法, 如反向传播, 容易在训练过程中陷入局部最优解, 导致训练时间较长且模型泛化能力受限。而精确径向基神经网络凭借其线性输出层, 能够更高效地进行参数优化, 从而大幅缩短训练时间, 同时其局部逼近能力较强, 能够更好地捕捉数据中的细微变化和局部特征, 这对于处理复杂的非线性关系至关重要。与传统径向基神经网络相比, 精确径向基神经网络在参数解释性上更为出色。传统径向基网络的中心点选择往往较为随意, 缺乏明确的物理意义, 这使得模型的可解释性较差, 难以理解模型内部的决策机制。精确径向基神经网络则通过特定的算法或方法, 使得中心点的选择具有明确的物理意义, 例如可以与数据中的关键特征或模式相对应, 从而提高了模型的透明度和可信度, 便于用户理解和应用。

总体而言, 精确径向基神经网络凭借其径向基函数的局部特性以及简洁的三层神经网络结构, 在解决非线性建模问题时能够实现高效性与高精度的平衡。其核心优势在于隐藏层的几何解释性和输出层的线性可解性, 这使得它在小样本、高维数据场景




图 2-2 全双工天线结构

Figure 2-2 Full duplex antenna structure

中表现尤为优异。在小样本情况下，精确径向基神经网络能够充分利用有限的信息，避免过拟合，从而获得可靠的模型性能；在高维数据场景中，其高效的训练机制和强大的局部逼近能力使其能够有效处理数据的复杂性和维度灾难问题。此外，精确径向基神经网络还具有广阔的应用前景，有望在边缘计算、实时系统等领域进一步拓展应用边界。在边缘计算中，精确径向基神经网络可以快速响应本地数据，实现即时的智能决策；在实时系统中，其快速的训练和推理能力能够满足实时数据处理和动态系统控制的需求，为实时系统的稳定运行和性能优化提供有力支持。




图 2-3 精确径向基函数神经网络模型

Figure 2-3 Precise radial basis function neural network model

## 2.3 天线结构的分析与设计

在当今通信技术飞速发展的时代，全双工通信系统因其能够实现信号的双向同时传输，极大地提高了频谱利用效率和通信容量，而备受关注。为了进一步提升全双工通信系统的性能和效率，本节提出了一种天线设计方式——基于精确径向基函数神经网络的两层全双工天线结构，如图 2-2(a)-(c)所示，其独特的结构设计和优异的性能表现有望为全双工通信领域带来新的突破。

该全双工天线采用两层介质板结构，这两层介质基板 Sub1 和 Sub2 均选用 RO4003C 板材，这种材料在高频电路和天线设计领域久负盛名，凭借其卓越的电气性能而被广泛应用。其介电常数为 3.38，损耗角正切仅为 0.0027，这些关键参数赋予了天线在高频工作状态下极低的信号损耗特性，确保了信号在传输过程中的完整性，同时极大地提高了能量传输效率，使得天线能够在高频率下稳定、高效地工作，为全双工通信系统提供了坚实的硬件基础。而这两层介质板的厚度均被设计为 1.524 mm，这一厚度的选取是经过反复权衡和优化的结果。在实际应用中，天线不仅要具备良好的电气性能，还需要兼顾尺寸、重量以及机械稳定性等多方面因素。1.524 mm 的厚度使得天线在保持紧凑体积的同时，能够满足紧凑空间的安装要求，便于集成到各种通信设备中，且不会因过薄而影响其结构强度和稳定性，也不会因过厚而增加不必要的重量和体积，从而实现了天线性能与实际应用需求之间的完美平衡。

在全双工天线的馈电环节，采用了两根同轴电缆进行馈电，这种馈电方式在通信天线领域具有显著的优势。它能够为天线提供稳定、可靠的信号传输，确保信号在从馈电端到天线辐射体的传输过程中不会出现幅度和相位的大幅波动，从而保障了通信信号的质量。同时，同轴电缆还具有良好的抗干扰能力，在复杂的电磁环境中，能够有效




图 2-4 阻抗特性

Figure 2-4 Impedance characteristic




图 2-5 仿真的 S 参数

Figure 2-5 Simulated S parameter

抵御外界电磁干扰对信号传输的不良影响，保证天线在各种工作场景下都能稳定运行。同轴电缆通过金属探针将信号精准地传输到天线的辐射体，金属探针的设计巧妙地贯穿两层介质，一直延伸到第一层介质板 Sub1 的顶层辐射体。这种结构不仅确保了信号的高效传输，还实现了良好的电气连接，使得信号能够在天线内部顺畅地传导，为天线的辐射性能奠定了坚实的基础。在第一层介质板 Sub1 的顶层贴片辐射体上，围绕两个探针设计了直径为  $d_2$  的孔洞，这些孔洞的设置经过了深入的理论分析和实验验证。它们在天线的工作过程中发挥着至关重要的作用，能够有效地优化天线的辐射性




图 2-6 3.54 GHz 频率处的电流分布

Figure 2-6 Current distribution at 3.54 GHz




图 2-7 两个端口的天线增益

Figure 2-7 Antenna gain for both ports

能。具体来说，这些孔洞可以改变天线周围的电磁场分布，减少信号在传输过程中的反射现象，从而降低信号损耗，提高天线的辐射效率和方向性，使得天线在全双工通信中能够更加精准地发送和接收信号，进一步提升通信质量。

为了实现全双工通信模式下信号的有效区分和传输，这两个馈电端口分别被明确定义为传输端口 TX 和接收端口 RX。这种明确的端口定义是全双工天线设计的关键环节之一，它使得天线在同时进行发送和接收操作时，能够清晰地区分发送信号和接收信号，避免了信号之间的相互干扰和混淆。通过精确的端口设计和信号处理，天线能






图 2-8 3.54 GHz 频率处的主极化与交叉极化图

Figure 2-8 Main polarization and cross polarization diagram at 3.54 GHz

够确保发送信号准确无误地传输到接收端，同时接收信号也能稳定地被接收并进行后续处理，从而极大地提高了全双工通信系统的可靠性和效率，为实现高质量的双向通信提供了有力保障。

在进一步优化天线性能方面，一个金属的 I 形带被巧妙地设计在第一层介质板 Sub1 顶层两个贴片辐射体之间，这一设计不仅在结构上增强了天线的整体稳定性，使



其能够更好地抵御外界机械冲击和振动，确保天线在长期使用过程中的性能稳定，而且在电气性能上也发挥了重要作用。I 形带能够对天线的谐振频率进行精细调节，使其能够精准地匹配工作频段，从而保证天线在特定频率下具有最佳的辐射性能和传输效率。同时，它还可以调节天线的阻抗特性，使其更好地与负载相匹配，减少信号在天线与负载之间传输时的反射损耗，进一步提高天线的性能指标，使天线能够更加高效地工作在全双工通信系统中，满足复杂通信环境下的各种性能要求。

在第二层介质板 Sub2 的顶层设计了两个金属 E 形带，E 形带作为一种在天线领域广泛应用的常见结构元素，其独特的形状和结构特性使其在提升天线性能方面具有诸多优势。它能够有效地增强天线的辐射效率，使得天线能够以更高的功率将信号辐射出去，从而扩大通信覆盖范围，提高通信信号的强度和质量。同时，E 形带还可以显著提升天线的方向性，使天线的辐射方向更加集中，减少了信号在非目标方向上的散射和损耗，进一步提高了通信信号的定向传输能力，这对于全双工通信系统中信号的精准发送和接收至关重要。此外，通过巧妙地调整 E 形带的尺寸和形状，可以实现对天线性能的精细调控，使其能够更好地适应不同的通信需求和工作场景，为全双工天线的性能优化提供了灵活多样的调整手段，使其在各种复杂的通信环境中都能展现出优异的性能表现。

## 2.4 实验结果与分析

如图 2-3 所示，采用了精确径向基函数神经网络模型对全双工天线的性能进行优化。精确径向基函数神经网络以其强大的非线性拟合能力和高效的优化性能，在天线设计领域展现出了巨大的应用潜力。该模型的激励输入涵盖了 4 个关键的期望性能特性，这些特性是衡量天线性能优劣的核心指标。具体而言，包括阻抗带宽  $bw|S_{11}|$ ，这一指标直接关系到天线在特定频段内的工作稳定性和信号传输效率；通带内隔离度最大值  $max|S_{21}|$ ，它决定了发送和接收信号之间的相互干扰程度，对于全双工通信系统的正常运行至关重要；以及发送端口和接收端口的最大增益  $max(Gain1)$ 、 $max(Gain2)$ ，这两个参数直接影响天线的辐射能力和信号覆盖范围，是提升通信质量的关键因素。而响应输出则是针对需要优化的 E 形带以及 I 形带的 8 个尺寸变量，通过对这些尺寸变量的精确控制，可以实现对天线性能的精细调控，使其在全双工通信系统中发挥出最佳

性能。

为了确保天线设计的准确性和高效性,我们采用了商用仿真软件 HFSS 以及 Matlab 软件进行联合仿真设计。HFSS 以其在高频电磁场仿真领域的卓越性能而被广泛应用于天线设计,能够精确地模拟天线的电磁特性;而 Matlab 则在数据处理和算法实现方面具有强大的优势,两者结合,为天线的优化设计提供了强有力的工具支持。如图 2-4 所示,通过对比分析,我们可以清晰地看到,相比于未加 E 形带以及 I 形带的 Ant. A 结构,添加了 E 形带以及 I 形带的 Ant. B 结构在 3.49 GHz 和 3.65 GHz 的频点上展现出了显著的优势。具体而言, Ant. B 结构的电阻值更接近理想的  $50\ \Omega$  标准,同时电抗值也更接近 0,这表明其阻抗匹配性能得到了极大的改善。这一改进主要得益于 E 形带以及 I 形带的引入,它们激发了一个新的谐振模式,从而有效地扩展了阻抗带宽,使得天线能够在更宽的频段内实现良好的阻抗匹配,提高了信号传输的效率和稳定性。

如图 2-5 所示, Ant. A 的阻抗带宽为 3.44–3.56 GHz,而经过优化后的 Ant. B 结构的阻抗带宽显著扩展为 3.40–3.68 GHz。这一扩展不仅提高了天线的工作频段范围,还增强了其在不同频率下的适应性和稳定性,使其能够更好地满足全双工通信系统对频段覆盖和信号传输质量的要求。如图 2-6 所示,在添加了 E 形带以及 I 形带的寄生结构后,仅激励 TX 端口,以 RX 端口作为  $50\ \Omega$  负载进行测试。结果显示,由 TX 端口流向 RX 端口的电流在 RX 端口处发生了显著的电流抵消现象,电流强度明显降低。这一现象表明,寄生结构的引入极大地增强了两个端口之间的隔离度,从 20 dB 增大到了 35 dB 的高隔离度范围。这种高隔离度的实现,有效减少了发送信号和接收信号之间的相互干扰,提高了全双工通信系统的可靠性和通信质量,为实现高效的双向通信提供了有力保障。

图 2-7 展示了仿真的天线增益随频率的变化图。从图中可以看出, TX 端口在阻抗带宽范围内可以实现的最大增益约为 5.47 dBi,而 RX 端口实现的最大增益为 4.5 dBi。这些增益值表明,经过优化后的天线在发送和接收信号方面都具备了较高的性能,能够有效地辐射和接收信号,从而扩大通信覆盖范围,提高通信信号的强度和质量,满足全双工通信系统对天线增益的要求。

图 2-8 为中心频率处的主极化与交叉极化方向图。无论在水平面还是垂直面,交叉

极化分量一直保持在一个很低的水平。这一特性对于提高通信信号的质量和抗干扰能力具有重要意义。低交叉极化分量意味着天线在辐射和接收信号时，能够最大限度地减少信号在非期望方向上的散射和干扰，从而提高信号的纯净度和方向性，进一步提升通信系统的性能和可靠性。

综上所述，这些优异的极化性能，使得天线在复杂的电磁环境中能够更加稳定、高效地工作，为全双工通信系统提供了高质量的信号传输保障，展现了其在现代通信技术中的重要应用价值。

## 2.5 本章小结

本章探讨了一种基于 PRBF 神经网络模型的方法，高效的对于一款全双工天线进行优化设计，优化时间（包括数据集收集以及结构参数优化）约为 23 小时。使用 PRBF 神经网络优化的天线结构为加载的两个 E 形带以及一个 I 形带。最终的优化结果显示，通过激发的一个新的谐振模式，天线的阻抗带宽从 3.44–3.56 GHz 扩展为 3.40–3.68 GHz 的频率范围，并且 TX 和 RX 端口也实现了大于 35 dB 的高隔离。

## 第三章 双极化天线的 AI 深度学习设计研究

### 3.1 引言

人工智能深度学习算法已在学术界和工业界得到发展。由于人工智能算法具有更强的决策能力和对非线性模型的近似能力,因此可有效地用于解决天线优化设计中收敛速度慢和局部最优解的问题<sup>[27-30]</sup>。训练完成的人工智能模型可以用作电磁仿真求解器,大大加快基于电磁问题的设计和优化<sup>[31-34]</sup>。提出了一种深度学习方法自动设计毫米波发射天线阵列<sup>[35]</sup>。一种自适应高斯过程算法在七天内优化了室内基站天线,取得了期望的性能<sup>[36]</sup>。贝叶斯神经网络也被提出用于线性天线阵列<sup>[37]</sup>和四频段 5G 毫米波天线<sup>[38]</sup>的优化设计,但由于其预测的不确定性,导致时间成本增加。K-近邻算法只用了很少的训练数据集就获得了法布里-珀罗谐振器天线的理想优化模型<sup>[39]</sup>。然而,该模型的优化目标只是阻抗带宽。反向的人工神经网络模型也被用于多模谐振天线的高性能设计<sup>[40]</sup>。然而,它们的优化过程较为复杂,因为需要分别运行 S 参数、增益和辐射图的三种优化分支才能同时实现所有性能的设计。因此,建立一个具有多输入目标特征和多输出维度变量的人工智能深度学习模型,对于改进天线优化和减少设计工作量具有挑战性。

本章提出了一种基于反向传播算法的 AI 深度学习优化方法,适用于紧凑型双极化高隔离天线。首先,介绍了具有  $L$  个隐藏层的反向传播结构模型及其优化原理。然后,利用反向传播方法优化了具有六个期望的性能目标的 L 形短路针、矩形槽、L 形金属贴片和 T 形分支,共 12 个尺寸变量的天线结构。最后,使用该方法优化的双极化高隔离度天线的结果表明,与手动天线设计相比,该方法在实现相同的性能目标方面具有更快、更高效的优势。

### 3.2 反向传播算法原理

基于深度前向传播和反向传播网络<sup>[41]</sup>,  $x_i^l$  表示第  $l$  层的第  $i$  个神经元,  $l=0$  表示输入层,  $l \in [1, L]$  表示算法网络的隐藏层,  $l = (L + 1)$  表示输出层。所有层的神经元个数都是可变的,并以  $N_l$  ( $i \in [0, L + 1]$ ) 的集合表示,比如,  $N_0 = N$ ,  $N_1 = M$ ,  $N_2 = K$ ,  $N_{L+1} = Q$  等,  $N$ ,  $M$ ,  $K$  和  $Q$  皆为任意的正整数。

反向传播算法的结构,如图 3-1 所示,其包含一个输入层,  $L$  个隐藏层以及一个输出层。多输入目标特征记为  $a_n^0$ , 长度为  $N_0$ , 多输出几何变量记为  $a_q^{L+1}$ , 长度为  $N_{L+1}$ 。




图 3-1 AI 深度学习方法的结构模型

Figure 3-1 The structural model of AI deep learning method

所有隐藏层的神经元个数都是可变的，分别为 $[N_1, N_2, \dots, N_L]$ 。第 $i$ 个神经元在第 $l$ 层的线性结果和非线性激活输出分别记为 $z_i^l$ 和 $a_i^l$ ，第 $i$ 个神经元在第 $l$ 层的偏置记为 $b_i^l$ ，偏置 $b_i^l$ 在第 $l$ 层的最佳值记为 $c_i^l$ ，其中 $l \in [1, L]$ 。从 $(l-1)$ 层的第 $j$ 神经元到 $L$ 层的第 $i$ 神经元的连接权重用 $w_{ij}^l$ 表示，其中 $l \in [1, L]$ 。

第 $l$ 层第 $i$ 个神经元的前向传播过程可以表示为：

$$z_i^l = \sum_{j=1}^{N_{l-1}} w_{ij}^l a_j^{l-1} + b_i^l \quad (3.1)$$

$$a_i^l = f(z_i^l) \quad (3.2)$$

$$f(x) = \frac{1}{1+e^{-x}} \quad (3.3)$$

其中， $f(x)$ 表示反向传播算法网络的非线性激活函数。

AI 深度学习算法的反向优化过程是通过计算预测值和预期值之间的误差来调整权重 $w_{ij}^l$ 和偏置 $b_i^l$ 的网络参数。预测值与期望值之间的损失函数为：

$$\Delta(a_i^{L+1}, a_i) = \frac{1}{Q} \sum_{i=1}^Q (a_i^{L+1} - a_i)^2 \quad (3.4)$$

其中， $a_i^{L+1}$ 表示 $(L+1)$ 层中第 $i$ 个输出的预测值，输出层的神经元总数用 $N_{L+1}$ 表示，




图 3-2 天线优化设计的流程图

Figure 3-2 Flow diagram of the antenna optimization design

$a_i$ 表示第  $i$  个实际标签数据值。输出层的第  $i$  个残差值 $\delta_i^{L+1}$ 定义为:

$$\delta_i^{L+1} = \frac{\partial}{\partial z_i^{L+1}} \Delta(a_i^{L+1}, a_i) \quad (3.5)$$

第  $l$  个隐层神经元的残差值 $\delta_i^l$ 可以通过对输出层的残差值进行反向运算得出:

$$\delta_i^l = \sum_{j=1}^{N_{l+1}} w_{ij}^{l+1} \delta_j^{l+1} \frac{\partial a_i^l}{\partial z_i^l} \quad (3.6)$$


其中,  $w_{ij}^{l+1}$ 是第  $l$  层第  $j$  个神经元与第  $(l+1)$  层第  $i$  个神经元的连接权重,  $\delta_j^{l+1}$ 是第  $j$  个神经元在第  $(l+1)$  层的输出残差值。根据这些残差值, 采用梯度下降法优化 AI 深度学习中的权重和偏置参数, 以获得最佳网络参数 $p_i^l$ 和 $c_i^l$ , 其中 $p_i^l$ 表示第  $i$  个神经元的连接权重的最佳值,  $c_i^l$ 是第  $i$  个神经元在第  $l$  层的偏置的最佳值。从而, 基于多输入多输出的反向传播(Multi-input multi-output backpropagation, MIMO-BP)的 AI 深度学习算法的结构模型可用来近似电磁仿真求解器的非线性关系。

### 3.3 双极化天线的设计


#### 3.3.1 MIMO-BP 算法优化流程

所提出的天线优化设计框架如图 3-2 所示, 算法工作流程如下:


步骤一: 天线结构的  $v$  种不同的尺寸参数组合是通过在一个区间内对每个参数随



(a) 俯视图



(b) Sub1 的顶层和底层



(c) Sub2 的底层

图 3-3 天线结构

Figure 3-3 Antenna structure

机取值而生成的，如(3.7)所示：

$$x(v, j) = p_L(j) * I(v, 1) + (p_H(j) - p_L(j)) * r(v, 1) \quad (3.7)$$

其中,  $v$  是正整数,  $j \in [1, N_{L+1}]$  表示待优化的所有维度变量,  $p_L(j)$  和  $p_H(j)$  为第  $j$  个尺寸的下限和上限,  $I(v, 1)$  为  $v \times 1$  的单元矩阵,  $r(v, 1)$  为  $v \times 1$  的随机矩阵, 取值在 0 和 1 之间。此外, 基于 MATLAB-HFSS-API 的联合仿真功能包, 在 MATLAB 软件中编写上述算法, 将  $v$  个不同尺寸组合的数据依次导入 HFSS 程序, 获得其性能参数, 并生成数据集。

步骤二: 在训练 AI 深度神经网络之前, 由于  $N_{L+1}$  维变量具有不同的取值区间, 因此必须对数据集进行归一化处理, 使输入数据特征具有相同的度量标准, 介于 0 和 1 之间。

步骤三: 应用归一化数据集来训练所构建的深度神经网络模型。

步骤四: 模型训练完成后, 输入优化天线的预期性能目标集  $s_n$ , 模型就会预测出  $N_{L+1}$  个变量的尺寸。假设  $N_{L+1}$  维尺寸在设计参数范围内, 这种情况下, 即满足停止准则, HFSS 软件将自动被调用, 更改相应参数, 进行仿真, 并得到性能结果  $u_n$ 。此外, 如果结果中的性能参数与所需性能目标一致或在设定的平均相对误差(Average Relative Error, ARE)范围内, 则优化过程结束, ARE 的数学表达式为(3.8), 其中  $n \in [1, N_0]$  表示总共  $N_0$  个优化后的性能参数。否则, 流程将返回步骤三, 重新执行上述流程。

$$ARE = \frac{1}{N_0} \sum_{n=1}^{N_0} (|s_n - u_n| / s_n) \quad (3.8)$$

### 3.3.2 天线优化结构

如图 3-3 所示, 应用紧凑型双极化贴片天线<sup>[42]</sup>作为案例研究, 以验证所提出的 AI 深度学习算法的优化性能。该天线由 Sub 1 和 Sub 2 两个介质层、两个塑料垫片、两个端口、一个 T 型槽和若干金属短路过孔组成, 作为 Ant. A 的初始结构。在 Ant. A 基础上增加两个 L 形短路过孔并在金属接地板上蚀刻了三个矩形槽, 作为 Ant. B, 从而将端口 1 和端口 2 之间的隔离度从 4 dB 提升到了 20 dB。然后, 添加两个 L 形金属贴片作为第三种结构 Ant. C, 又将端口 1 和端口 2 之间的隔离度从 20 dB 提高到 26 dB。最后一种结构 Ant. D, 在辐射贴片上有两个 T 形分支, 使端口 1 和端口 2 之间的隔离度从 26 dB 提高到 40 dB, 阻抗带宽从 3.47 GHz 提高到 3.58 GHz, 达到了 110 MHz 的阻






图 3-4 MIMO-BP 结构

Figure 3-4 The MIMO-BP structure

抗带宽。


由于在金属地面上增加了两个 L 形短路针和三个矩形蚀刻槽、两个 L 形金属贴片以及在辐射贴片上增加了两个 T 形分支，该天线的性能大大提高。此外，该天线还具有体积小、隔离度高、易于平面集成等优点。因此，对这些关键结构进行优化具有挑战性。相关的优化设计参数的取值区间如表 3-1 所示。

表 3-1 天线结构的优化变量


Table 3-1 Optimized variables in the antenna structure (Unit: mm)

| 尺寸      | $g_1$ | $g_3$ | $L_3$ | $L_4$ | $L_5$ | $L_6$ | $L_7$ | $L_8$ | $S_3$ | $W_2$ | $W_3$ | $W_4$ |
|---------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 下界      | 0.5   | 1.0   | 3.7   | 5.0   | 7.5   | 6.5   | 10.5  | 2.5   | 0.5   | 0.5   | 2.0   | 2.5   |
| 上界      | 1.5   | 3.0   | 5.7   | 7.0   | 9.5   | 8.5   | 12.5  | 4.5   | 2.0   | 2.5   | 4.0   | 4.5   |
| [42]    | 0.69  | 0.61  | 5.54  | 5.89  | 8.01  | 7.44  | 11.4  | 3.51  | 1.06  | 1.2   | 3.77  | 3.01  |
| MIMO-BP | 0.68  | 1.65  | 5.52  | 5.91  | 8.05  | 7.35  | 11.44 | 3.51  | 1.07  | 1.2   | 3.72  | 3.00  |

图 3-4 显示了根据图 3-1 的理论模型提出的 4 层神经网络结构。在该模型中，优化天线性能参数的六个目标输入值分别是阻抗带宽  $bw(|S_{11}|)$  和  $bw(|S_{22}|)$ ， $avg1(|S_{21}|)$  和  $avg2(|S_{21}|)$  对应两个通带频率范围的平均隔离度，端口 1 的最大增益  $max(Gain1)$  和端口 2 的最大增益  $max(Gain2)$ 。天线结构的 12 维尺寸参数作为输出进行优化。根据万能逼近理论<sup>[37]</sup>，为了防止无法模拟电磁求解器的风险和避免过拟合，引入了第 1 个隐藏层，



(a) S 参数



(b) 实现的增益

图 3-5 MIMO-BP 方法的预测结果

Figure 3-5 The predicted results of MIMO-BP method

然后在输入层的顶部和底部各扩展一个神经元，共 8 个神经元。为了稳定网络模型，增加了第 2 个隐藏层，并根据输出层神经元的数量确定了 12 个神经元。参考文献[38]中的天线性能，分别将带宽  $bw(|S_{11}|)$  和  $bw(|S_{22}|)$ 、平均隔离度  $avg1(|S_{21}|)$  和  $avg2(|S_{21}|)$ 、最大增益  $max(Gain1)$  以及  $max(Gain2)$  这六个参数值设为 110 MHz、110 MHz、-42.2 dB、-42.2 dB、4.3 dBi、和 4.3 dBi 作为期望的性能目标。收集数据集的数量设为 400，即电磁模拟次数，这一过程耗时 16.7 小时。优化后的天线性能之间的平均相对误差为 1.0%。

### 3.3.3 MIMO-BP 算法优化的天线性能

天线模型在 ANSYS HFSS 19.5.0 中运行，并使用 MATLAB R2022a 作为算法编程工具。在戴尔 T7920 工作站(配置：2\*Intel(R) Xeon(R) Gold 6248R CPU @ 3.00GHz、48 核、256 GB 内存和 4 GB NVIDIA T600 GPU)上进行了 30 次电磁仿真优化验证，优化过程运行了约 6 个小时。

通过提出的 AI 深度学习方法对天线性能参数的预测结果如图 3-5 所示。由于双端口天线的对称性设计，端口 1 和端口 2 的反射系曲线以及增益特性表现出高度一致性，因此图中仅展示了端口 1 的反射参数和增益特性曲线作为代表。仿真结果显示，基于所提出的 AI 方法预测的-10 dB 阻抗带为 110 MHz，工作频带覆盖 3.47 GHz 至 3.58 GHz 范围。值得注意的是，该方法对带宽和增益特性的预测结果与文献[42]中的实测数据表现出很好的一致性，验证了所提 AI 深度学习方法准确性和可靠性。此外，在 3.47–3.58 GHz 的整个工作带宽内，端口 1 和端口 2 之间的隔离经优化后始终保持在 40 dB 以上，这一优异的端口隔离性能表明该天线设计能有效抑制端口间耦合，满足多输入多输出（MIMO）天线系统的严格要求。

表 3-2 与其它工作的比较

Table 3-2 Comparison with Other Works

| 参考文献 | 算法模型      | 计算次数 | MIMO | 优化分支 | 应用         | 优化时间<br>(hours) |
|------|-----------|------|------|------|------------|-----------------|
| [19] | 差分进化      | 2790 | Yes  | 1    | 隔离器        | 61.4            |
| [36] | 高斯过程      | 1144 | Yes  | 1    | 基站天线       | 182.4           |
| [38] | 贝叶斯<br>网络 | 1202 | Yes  | 1    | 毫米波天线      | 48.5            |
| [40] | 人工网络      | 100  | Yes  | 3    | 布里珀罗<br>天线 | 33.37           |
| Pro. | 反向传播      | 430  | Yes  | 1    | 双极化天线      | 22.7            |

为了突出这项工作的优点和新颖性，题述 AI 深度学习方法优化天线的工作与其它工作做了相关指标的对比，如表 3-2 所示。所提出的基于反向传播的 AI 深度学习算法优化天线设计具有优化时间短、用少量电磁仿真次数即可达到预期目标，以及具有多个优化的输入天线性能参数和多个输出尺寸变量等特点。对于优化过程复杂度，用同时优化天线性能的分支数表示，使用一个优化分支即可完成六个性能参数的优化。此外，还采用了文献[43]中的模型评估方法，即平均绝对百分比误差来评估所提出的 AI

深度学习模型。训练集和测试集的误差值分别为 0.84% 和 0.95%，其中测试集为 20% 的数据样本。

### 3.4 本章总结

本章探讨了一种基于反向传播算法的天线优化设计方法。以双极化高隔离度天线为实验对象，优化了 L 形短路针、矩形槽、L 形金属贴片和 T 形分支这四种决定天线高性能的结构。此外，使用该方法对天线优化的结果在 3.47–3.58 GHz 的工作带宽内实现了优于 40 dB 的高隔离度，两个端口的最大增益均为 4.3 dBi。所提出的 AI 深度学习算法模型在收敛速度和总时间成本方面具有显著优势。

## 第四章 基于智能算法的天线阵列设计研究

### 4.1 引言

当使用同等振幅和相位激励天线阵列时，往往会产生旁瓣较高的辐射方向图。而如果人工去手动调节每个阵元的激励值，特别是对于大规模多输入多输出(Multiple Input Multiple Output, MIMO)天线阵列，则需要耗费大量的人力以及物力资源。因此，一些智能优化算法，包括调制技术<sup>[44]</sup>，累计合成技术<sup>[45]</sup>，粒子群优化<sup>[46]</sup>，改进的遗传算法<sup>[47-48]</sup>，灰狼优化<sup>[49]</sup>以及差分进化<sup>[50]</sup>等，在设定线性天线阵列辐射方向图的目标函数后，即可快速的逼近期望的波束优化目标。一种以提升优化效率的结合差分进化和凸优化的混合优化算法被提出降低线性天线阵列的辐射图的旁瓣电平<sup>[51]</sup>，但是，它仅关注了线性天线阵列辐射图旁瓣电平的降低。一些有关天线阵列的自适应波束形成方案被提出可以动态的引导天线阵列的主波束指向期望的输入信号的到达角，并可以在不期望信号的到达角放置零点，以抑制干扰信号和噪声<sup>[52-54]</sup>。在文献[55]中，一种可变步长的最小均方算法被提出以应用于线性阵列的自适应波束形成，并在两个干扰信号不同到达角的方向产生了零点，进行有效抑制。在文献[56]中，一种基于门控递归单元结构的递归神经网络被应用于线性天线阵列的不期望接受信号的抑制。它们实现的是以最大化输出信号干扰加噪声比为目标仅对于不期望的输入信号进行抑制。这些工作没有为了进一步提升通信系统的稳定性，同时也需要对旁瓣电平进行有效抑制的研究。

本章提出了一种高效的非均匀平面天线阵列的基于改进的多元宇宙算法的辐射图优化模型。该算法针对于传统的多元宇宙算法的一些不足之处，提出了一种新的虫洞存在机制以及用以宇宙种群间的物质更新的一个加权学习因子和一种新的白/黑洞轨道，增强了算法的局部开采性能以及全局寻找最优解的能力。使用改进的多元宇宙算法优化了两类平面天线阵列的波束形成，一类是对称的天线阵列，同时实现了方位向以及俯仰向方向图的低旁瓣电平，并可以有效控制方位向以及俯仰向产生不同的旁瓣电平值，另一类是非对称的天线阵列，同时实现了方位向以及俯仰向辐射方向图的低旁瓣电平，期望信号到达角的主瓣指向和不期望信号到达角(Angle of Arrival, AOA)的零点生成抑制以及最大化输出均值信号干扰加噪声比的目标优化。通过与遗传算法(Genetic algorithm, GA)、灰狼优化器(Grey wolf optimizer, GWO)以及多元宇宙优化器

(Multiverse optimizer, MVO)优化的数值结果比较验证了所提出的优化模型具有更快的收敛速度以及更好的优化性能。

## 4.2 改进的多元宇宙算法原理

对于多维优化问题,多元宇宙算法将由个体组成的多元宇宙定义为优化问题的可行解,并将宇宙中存在的多维物质定义为优化对象。每个宇宙都被定义包含一个膨胀率,该膨胀率表征了可行解的适应度值。多元宇宙理论解释了物理学中存在多个宇宙空间的可能性。单个火球的大爆炸产生了单个宇宙,多个大火球的大爆炸则可以创造出多元宇宙。该理论的核心概念是,在多维宇宙空间中,黑洞具有极强的引力,可以吸引宇宙中的任何物体,白洞具有极强的斥力,可以排斥宇宙中的物质,而虫洞则是连接不同宇宙空间的轨道,可以进行物质转移。在黑洞、白洞和虫洞的共同作用下,整个多元宇宙群体可以达到稳定状态。基于该理论,提出了多元宇宙优化器(Multiverse optimizer, MVO)<sup>[57]</sup>。

在 MVO 算法中,对于随机数 $r_1 \in [0,1]$ ,如果 $r_1$ 小于第 $i$ 个宇宙 $U_i$ 的归一化膨胀率 $IR(U_i)$ ,其中 $i=1,2,3,\dots,I$ , $I$ 表示总的宇宙数目。轮盘选择机制会选择在当前最大膨胀率 $IR(U_{max})$ 的宇宙 $A$ 周围产生白洞,从而与当前存在黑洞的宇宙 $B$ 建立白洞和黑洞物质交换轨道,在两个宇宙之间进行物质转移,如图 4-1 所示。否则,如果 $r_1$ 大于 $IR(U_i)$ ,则当前宇宙个体保留原有物质。这个物质转移过程的数学表达式为:

$$x_i^j = \begin{cases} x_r^j & r_1 < IR(U_i) \\ x_i^j & r_1 > IR(U_i) \end{cases} \quad (4.1)$$

其中, $x_i^j$ 表示第 $i$ 个宇宙中的第 $j$ 个物体, $x_r^j$ 是轮盘选择机制下第 $r$ 个宇宙中的一个物体, $r = 1, 2, 3, \dots, I$ 和 $j = 1, 2, 3, \dots, J$ 。

在传统的 MVO 算法中,宇宙个体会激发内部物质通过虫洞向当前最优宇宙个体移动,以提高其膨胀率。物质向当前最优宇宙个体移动的移动距离速率由函数 $d(t)$ 决定,见式(4.2):

$$d(t) = 1 - \frac{t^{1/er}}{T^{1/er}} \quad (4.2)$$




图 4-1 产生白洞和黑洞物质交换轨道的轮盘机制

Figure 4-1 The roulette mechanism produces the white and black hole matter exchange orbits




图 4-2 传统的虫洞存在概率函数( $wep(t)$ ), 反  $S$  函数( $isf(t)$ ), 以及加权学习因子( $wlf(t)$ )

Figure 4-2 The wormhole existence probability for the traditional ( $wep(t)$ ) and the inverse  $s$ -function ( $isf(t)$ ), and the weighted learning factor ( $wlf(t)$ )




图 4-3 白洞形成黑洞的过程

Figure 4-3 The process from a black hole to a white hole

其中,  $t$  和  $T$  分别表示当前和最大迭代时间,  $er = 6$  表示探索率。

此外, MVO 用函数  $wep(t)$  表示虫洞存在概率(Wormhole Existence Probability, WEP)。

它控制着宇宙间物质的交换和更新。 $wep(t)$ 越大,各个宇宙之间的信息交流越多,越小则相反。 $wep(t)$ 的表达式为:

$$wep(t) = wep_{min} + \frac{wep_{max} - wep_{min}}{T} t \quad (4.3)$$

其中 $wep_{min}$ 和 $wep_{max}$ 分别代表 WEP 的最小值和最大值。图 4-2 给出了 $wep_{min} = 0$ 、 $wep_{max} = 1$ 和  $T=260$  的值,并绘制了 $wep(t)$ 曲线。此外, MVO 通过比较 $wep(t)$ 和随机数 $r_2 \in [0,1]$ 的大小来定义宇宙空间中是否存在虫洞。当 $r_2 < wep(t)$ 时,存在虫洞,否则,不存在虫洞。

如图 4-2 所示,随着迭代时间的增长,传统的 $wep(t)$ 从 $wep_{min}$ 线性增长到 $wep_{max}$ ,因此在迭代初期, $r_2$ 将以更大的概率大于 $wep(t)$ ,即不存在虫洞,这就减少了宇宙种群之间的信息交流。当前最优宇宙通常离全局最优解较远。随着迭代时间的增加,当前最优宇宙的物质信息过多会导致宇宙种群的快速同化,不利于维持种群多样性。在迭代时间的后期, $wep(t)$ 值更为重要。尽管如此,宇宙种群之间信息继承的累积效应使得各个宇宙之间的同化程度很高,差异较小。轮盘选择机制所建立的白洞和黑洞物质交换轨道在降低种群同化的不利影响方面具有挑战性,这意味着算法很难跳出局部最优解的困境。

为了加强宇宙种群之间的信息交流,提高算法寻找全局最优解的性能,提出了一个随算法迭代时间递减变化的反  $s$  函数,该函数 $isf(t)$ 可用来描述新虫洞存在概率的特征,见式(4.4):

$$isf(t) = isf_{max} - \frac{1}{1 + ae^{b-ct/T}} \quad (4.4)$$

其中, $isf_{max}$ 为 $isf(t)$ 的最大值,设定 $isf_{max} = 1$ ,  $a = 0.4$ ,  $b = 5.5$  以及  $c = 0.04$ 。

与传统的 $wep(t)$ 相比,在算法运行的早期阶段, $isf(t)$ 显著增加,可以大大提高宇宙种群个体间物质更新,避免算法陷入局部最优解集。到了后期,宇宙种群之间已经产生了同化现象,个体之间的物质更新对于算法找到全局最优解的意义已经不大。因此,虽然 $isf(t)$ 逐渐减小,但并不影响算法得到最优解,还能保证算法的收敛稳定性。

此外,还引入了加权学习因子 $wlf(t)$ ,其函数形式见式(4.5):



$$wlf(t) = wlf_{max} - \frac{1}{1 + ae^{b-ct/T}} \quad (4.5)$$

其中  $wlf_{max} = 0.46$ ,  $a = 1.1$ ,  $b = 5.5$ , 以及  $c = 0.04$ , 曲线  $wlf(t)$  如图 4-2 所示。在算法迭代时间的早期阶段,  $wlf(t)$  的变化速率较快, 以拓宽子宇宙个体从父宇宙继承的物质信息的搜索域, 增加宇宙个体物质更新的多样性。相比之下,  $wlf(t)$  的变化率在算法运行的后期逐渐减小, 这进一步保证了算法稳定收敛到最优解。

在传统的 MVO 中, 当  $r_2 > wep(t)$  时, 宇宙中的个体之间没有信息交换, 即宇宙中的物质没有更新。因此, 我们进一步引入了天体物理学的黑洞反演机制, 以增强算法的全局探索和优化能力。该机制假定被黑洞吸收的物质最终会被黑洞捕获并储存在黑洞内。那么, 根据基本物理定律, 这些物质不可能被摧毁, 而必须以特定的物质形式存在。假设整个黑洞空间会以压缩的形式不断堆积, 当压缩到极致时, 就会形成一个虚拟的白洞, 之前被吞噬的物质就会被释放出来。这样就有可能形成一个包含这种物质的新宇宙。根据该定理并细化到算法中, 假设黑洞物质的压缩过程是一种螺旋递减运动, 最后汇聚到螺旋中心, 形成白洞。在这一过程中始终存在一个虚拟的白洞或黑洞轨道, 那么第  $i$  个宇宙中物质更新的新方式见式(4.6):

$$x_i^j = (x_{bh}^j - x_{wh}^j)S_f + x_{wh}^j \quad (4.6)$$

其中,  $x_{bh}^j$  表示存在黑洞的第  $i$  个宇宙中第  $j$  个物质,  $x_{wh}^j$  表示当前存在白洞的第  $i$  个宇宙中的第  $j$  个物质个体,  $S_f$  为螺旋因子, 表达式为:

$$S_f = p^{qT} \sin(2\pi q) \quad (4.7)$$

设置  $p = 0.01$ ,  $q = 10^{-5}$ , 以及  $T=260$ 。可以得到黑洞形成白洞的过程, 如图 4-3 所示, 其中  $[0, 0.5]$  是算法运行过程中  $S_f$  值的范围。

因此, 所提出的改进的多元宇宙算法(Improved Multiverse optimizer, IMVO)的种群物质更新的新方式定义为:

$$x_i^j = \begin{cases} (1 - \omega)x_{bu}^j + \omega x_{bh}^j + \epsilon t_{dr}, r_3 < 0.5 \\ (1 - \omega)x_{bu}^j + \omega x_{bh}^j - \epsilon t_{dr}, r_3 \geq 0.5 \\ S_f(x_{bh}^j - x_{wh}^j) + x_{wh}^j, r_2 \geq wep(t) \end{cases} \quad (4.8)$$




图 4-4 波束优化模型

Figure 4-4 The beam optimization model




图 4-5 优化设计流程


Figure 4-5 Flow diagram of the optimization design

其中,  $\omega = wlf(t)$ ,  $x_{bu}^j$  表示轮盘选择机制下第  $i$  个宇宙的第  $j$  个物质, 当  $r_2 < wep(t)$  时,  $\epsilon = r_4(b_u^j - b_l^j) + b_l^j$ 。第  $j$  个优化物质的上界和下界分别为  $b_u^j$  和  $b_l^j$ 。  $r_3$  和  $r_4$  的随机数为  $[0,1]$ 。当  $r_3 < 0.5$  时, 表示宇宙种群中的物质正向继承当前最优宇宙的物质; 反之, 则负向继承。

### 4.3 天线阵列的波束形成优化

#### 4.3.1 波束优化模型

如图 4-4 所示, 针对平面天线阵列(Planar Antenna Array, PAA)提出的波束成形优化模型遵循最小化优化原则, 主要分为三个部分: 第一部分是宇宙种群之间通过白洞、黑



(a) 平面天线阵列模型 (b) 坐标系统

图 4-6 天线阵列配置

Figure 4-6 Antenna array configuration


洞和虫洞轨道进行物质交换和更新，用于获得包含  $2 \times M \times N$  物质的最优宇宙个体。最佳宇宙被定义为波束目标函数的最优解，它包含  $M \times N$  个激励权重和  $M \times N$  个平面天线阵列的阵元间距。第二部分是激励平面天线阵列，并根据第一部分提供的最优解重新排列天线阵元的位置。第三部分是在平面天线阵列上生成所需的  $xz$  和  $yz$  平面的辐射图。图 4-5 显示了优化模型的算法框架，具体工作流程如下：

步骤一：初始化宇宙种群大小  $N$ 、最大迭代时间  $T$ 、 $isf(t)$  和  $wlf(t)$  的大小以及平面天线阵列的俯仰向和方位向阵元数。激励权重的模数值定义为  $(0, 1)$ ，阵元间距定义为  $(-0.25, 0.25)$ 。然后，根据所需的平面天线阵列辐射图，将表征阵元激励权重和间距的多维物质作为优化对象，在每个宇宙的定义区间内随机初始化，并定义波束优化目标函数。

步骤二：根据定义的波束优化目标函数，引入当前运行时间的优化参数值，计算出每个宇宙的相应波束适应度值，并将其定义为该宇宙的膨胀率。

步骤三：根据(4.1)和(4.8)产生的白洞、黑洞轨道和虫洞轨道，通过宇宙种群交换和物质更新来降低宇宙的膨胀率，即降低波束优化的成本函数值，获得更优的激励权重和阵元间距。

步骤四：当前 IMVO 的迭代计算会更新  $t_{dr}$ 、 $isf(t)$  和  $wlf(t)$  参数。宇宙种群之间的物质信息也将同时更新。

图 4-7 10×10 PAA 的初始的  $xz$  平面和  $yz$  平面的辐射图Figure 4-7 The initial  $xz$ - and  $yz$ -plane radiation pattern of the 10×10 PAA

步骤五：如果达到规定的最终时间  $T$ ，算法模型将终止优化，输出当前最优宇宙的解信息，并将其输入平面天线阵列，生成所需的  $xz$  平面和  $yz$  平面的辐射图。反之，迭代时间  $t \rightarrow (t + 1)$  跳转执行步骤 2。

#### 4.3.2 平面天线阵列的辐射图函数

如图 4-6(a)所示，一个平面天线阵列被排列成一个矩形阵列。每个阵元由每个交叉点的编号  $(m, n)$  标识，其中  $1 \leq m \leq M$  和  $1 \leq n \leq N$ ，则整个阵列共有  $M \times N$  个阵元。如图 4-6(b)所示，排列在  $yz$  平面上的平面天线阵列，辐射方向为  $r$ ，其在  $xy$  平面和  $yz$  平面上的投影分别用  $r_{p1}$  和  $r_{p2}$  表示，则方位角  $az$  和俯仰角  $el$  与  $\theta$  角和  $\varphi$  角的坐标转换描述为：

$$\begin{cases} \tan az = \tan \theta \cos \varphi \\ \sin el = \sin \theta \sin \varphi \\ \cos \theta = \cos az \cos el \\ \tan \varphi = \tan el / \sin az \end{cases} \quad (4.9)$$


根据文献[58]，排列在第  $m$  列和第  $n$  行的阵元的激励权重  $w_{mn}$  表示为：

$$w_{mn} = I_{mn} e^{j(\beta_{my} + \beta_{nz})} \quad (4.10)$$


其中， $I_{mn}$  表示第  $m$  列和第  $n$  行阵元的激励幅值， $\beta_{my}$  和  $\beta_{nz}$  分别表示第  $(m, n)$  个阵元与第  $(1, 1)$  个参考阵元在  $y$  方向和  $z$  方向的相位差。

第  $m$  列中第  $n$  个和第  $(n-1)$  个阵元之间的间距用  $d_{mn}$  表示，见式(4.11)：

$$d_{mn} = d_{my} + jd_{nz} \quad (4.11)$$




(a) xz 平面



(b) yz 平面

图 4-8 10×10 PAA 的 4 种算法优化的旁瓣电平抑制优化的辐射图

Figure 4-8 The radiation pattern of the 10×10 PAA for the reducing SLL optimized with four algorithms

图 4-9 四种算法优化后的波束目标函数  $F_1$  的适应度值Figure 4-9 The fitness value of the beam objective function  $F_1$  optimized by the four algorithms

其中,  $d_{my}$  和  $d_{nz}$  分别表示第  $(m,n)$  个阵列元与第  $(1,1)$  个参考阵元在  $y$  方向和  $z$  方向上的距离。

从而，平面天线阵列的辐射方向图函数可以描述为：

$$f(\theta, \varphi) = \sum_{m=1}^M \sum_{n=1}^N w_{mn} e^{j\frac{2\pi}{\lambda}(d_{my}\sin\theta\cos\varphi + d_{nz}\sin\theta\sin\varphi)} \quad (4.12)$$

### 4.3.3 旁瓣电平的抑制

一个  $10 \times 10$  的平面天线阵列包含 100 个理想阵元，被用作降低旁瓣电平(Sidelobe Level, SLL)的研究对象。对于初始的  $10 \times 10$  的平面天线阵列，激励权重设为 1，每个阵元的间距设为半波长，即 0.5 米。

由于阵列是对称的，如图 4-7 所示，这个  $10 \times 10$  的平面天线阵列的  $xz$  平面和  $yz$  平面的辐射图相同，最大 SLL 均为 -13.0 dB。因此，在等激励权重和等间距形成的平面天线阵列中存在较大的 SLL。为了增强阵列天线的辐射覆盖能力，需要抑制平面天线阵列的 SLL。降低 SLL 的优化波束目标函数  $F_1$  定义为(4.13)：

$$F_1 = \max(f(\theta, \varphi_0))_{\theta \in \Theta} + \max(f(\theta_0, \varphi))_{\varphi \in \Phi} \quad (4.13)$$

其中， $\max(f(\theta, \varphi_0))$  和  $\max(f(\theta_0, \varphi))$  分别表示  $xz$  平面的旁瓣区间  $\Theta$  和  $yz$  平面的旁瓣区间  $\Phi$  的最大 SLL，如果  $xz$  平面的辐射图的主瓣覆盖  $2\theta_m$  的角度范围，则  $\Theta$ ：

$$\Theta = \{\theta | \theta_{min} \leq \theta \leq (\theta_0 - \theta_m) \cup \theta | (\theta_0 + \theta_m) \leq \theta \leq \theta_{max}\} \quad (4.14)$$

同样，如果  $yz$  平面的辐射图的主瓣的角覆盖范围为  $2\varphi_m$ ，则  $\Phi$  为：

$$\Phi = \{\varphi | \varphi_{min} \leq \varphi \leq (\varphi_0 - \varphi_m) \cup \varphi | (\varphi_0 + \varphi_m) \leq \varphi \leq \varphi_{max}\} \quad (4.15)$$

其中， $\theta_{min} = \varphi_{min} = -90^\circ$ ， $\theta_{max} = \varphi_{max} = 90^\circ$ ， $(\theta_0, \varphi_0)$  为主瓣的最大功率角度，均设为  $0^\circ$ 。

根据 GA、GWO、MVO 和 WDP-MVO 建立的波束优化模型，按照波束目标函数对  $10 \times 10$  的平面天线阵列的辐射图进行优化。为保证优化性能比较的公平性，将四种算法的可行解数设为 60，最大迭代次数设为 260 次。

四种算法优化后的辐射图如图 4-8 所示，在  $xz$  平面上，GWO 可以比 GA 多降低 6.3 dB 的 SLL，在  $yz$  平面上，它们都可以将 SLL 降低到 -16.0 dB 以下。MVO 可以将  $xz$  平面和  $yz$  平面的 SLL 分别降低到 -23.5 dB 和 -34.4 dB。 $yz$  平面的 SLL 降低水平比  $xz$

表 4-1 与其它工作的比较

Table 4-1 COMPARISON WITH OTHER WORKS

| 参考文献 | 优化算法  | 阵列维度 | 阵列类型 | SLL (dB)        |
|------|-------|------|------|-----------------|
| [44] | 调制技术  | 1D   | 时间调制 | -20.0           |
| [45] | 累计合成  | 1D   | 分布式  | -12.0           |
| [47] | GWO   | 1D   | 线性阵列 | -19.0           |
| [52] | 分布式算法 | 2D   | 纹波阵列 | xz-plane: -20.0 |
|      |       |      |      | yz-plane: -20.0 |
| Pro. | IMVO  | 2D   | 平面阵列 | xz-plane: -30.5 |
|      |       |      |      | yz-plane: -30.7 |

平面低 10.9 dB，这表明 MVO 有陷入局部最优解的趋势，即只抑制了  $yz$  平面的旁瓣电平下降，却忽略了同样重要的  $xz$  平面的旁瓣电平。与 MVO 相比，IMVO 在  $yz$  平面的旁瓣电平增加了 3.7 dB，但在  $xz$  平面的旁瓣电平减少了 7.0 dB，使得  $xz$  平面和  $yz$  平面的旁瓣电平都小于 -30.0 dB，旁瓣电平的性能也优于 GA 和 GWO。如图 4-9 所示，IMVO 的波束目标函数  $F_1$  的适应度值更低，收敛到最优解的速度更快，这表明 IMVO 在  $xz$  平面和  $yz$  平面的辐射图优化方面具有更强的全局优化能力。

此外，表 4-1 将这项工作与其他文献中有关降低波束的旁瓣电平的工作进行了比较。在对更复杂的二维天线阵列进行波束成形优化时，所提出的 IMVO 可以同时将平面阵列的  $xz$  平面和  $yz$  平面的辐射图的旁瓣电平抑制到更低的水平。

#### 4.3.4 旁瓣电平的控制

为了进一步验证基于 IMVO 的波束优化模型在降低平面天线阵列的辐射图的旁瓣电平方面的有效性和灵活性，研究对象仍为  $10 \times 10$  的平面天线阵列，设计了三种不同的旁瓣电平控制方案，分别为 Case1、Case2 和 Case3。Case1 是将  $xz$  平面和  $yz$  平面的旁瓣电平分别减小到 -30.0 dB 和 -20.0 dB；相反，Case2 将  $xz$  平面和  $yz$  平面的旁瓣电平分别减小到 -20.0 dB 和 -30.0 dB；Case3 将  $xz$  平面和  $yz$  平面的旁瓣电平都减小到 -25.0 dB。优化控制旁瓣电平的波束目标函数  $F_2$  定义为(4.16)：

$$F_2 = (\max(f(\theta, \varphi_0)) - De(f(\theta, \varphi_0)))_{\theta \in \Theta} + (\max(f(\theta_0, \varphi)) - De(f(\theta_0, \varphi)))_{\varphi \in \Phi} \quad (4.16)$$




图 4-10 三种不同 SLL 控制情况的优化辐射图

Figure 4-10 Optimized radiation pattern for three different SLL control cases

其中  $\max(f(\theta, \varphi_0))$ 、 $\max(f(\theta_0, \varphi))$ 、 $\Theta$  和  $\Phi$  与(4.13)的定义一致。 $De(f(\theta, \varphi_0))$  和



$De(f(\theta_0, \varphi))$ 分别表示  $xz$  平面和  $yz$  平面上所期望的旁瓣电平。

三种旁瓣电平控制情况下的四种算法优化后的辐射图如图 4-10 所示。在 Case1 中，GA 和 GWO 都无法满足  $xz$  和  $yz$  平面的 -30.0 dB 和 -20.0 dB 的理想波束辐射图。与 GA 和 GWO 相比，MVO 可以近似满足  $yz$  平面的目标值，并能进一步降低  $xz$  平面的旁瓣电平，但仍不能满足目标值。IMVO 可以将  $xz$  平面和  $yz$  平面的旁瓣电平分别优化为 -29.7 dB 和 -19.8 dB，近似满足期望的旁瓣电平。对于 Case2，所有四种算法都能近似满足  $xz$  平面的 -20dB 的目标值，但只有 IMVO 能近似满足  $yz$  平面的 -30.0 dB 的目标值。

最后，在 Case3 中，GA 和 GWO 可以分别近似达到  $xz$  平面和  $yz$  平面的 -25.0 dB 的目标值，MVO 可以近似达到  $xz$  平面的目标值，但只能将  $yz$  平面的 SLL 降低到 -21.8 dB。IMVO 可以将  $xz$  平面和  $yz$  平面的 SLL 分别优化为 -24.7 dB 和 -24.8 dB，近似满足两个平面的理想旁瓣电平。此外，如图 4-11 所示，IMVO 在控制旁瓣电平方面的波束目标函数  $F_2$  的适应度值更低，而且收敛到旁瓣电平最佳解集的速度更快。因此，基于 WDP-MVO 的优化模型可以有效控制平面天线阵列的  $xz$  和  $yz$  平面辐射图的旁瓣电平。


#### 4.3.5 自适应波束形成

通过平面天线阵列传输通信信号时，需要有效地抑制不需要的信号，使输出信号干扰加噪声比(Signal Interference Plus Noise Ratio, SINR)最大化，以提高传输质量和稳定性。平面天线阵列接收的期望信号定义为  $s_0(k)$ ，其 AOA 定义为  $(\theta_{s_0}, \varphi_{s_0})$ ，干扰信号定义为  $s_v(k)$ ， $v = 1, 2, 3, \dots, V$ ，其 AOA 定义为  $(\theta_{s_v}, \varphi_{s_v})$ 。对于接受信号，还包含零均值高斯白噪声信号  $l_{mn}(k)$ ，其中  $k = 1, 2, 3, \dots, K$  表示第  $k$  个采样块。此外，为了简化平面天线阵列的自适应波束形成问题的理论模型的分析，将  $M \times N$  的平面天线阵列拼接并按列从头到尾转换成  $1 \times G$  的线性天线阵，其中  $G = M \times N$ 。然而，对于所研究的波束优化目标来说，仍然是二维的。那么，对于激励权重  $w_{mn}$ 、阵元间距  $d_{mn}$  和噪声信号  $l_{mn}(k)$ ，可分别转换为  $\mathbf{w}$ 、 $\mathbf{d}$  和  $\mathbf{L}(k)$ ，即(4.17)、(4.18)和(4.19)：


$$\mathbf{w} = [w_1, w_2, w_3, \dots, w_G]^H \quad (4.17)$$

$$\mathbf{d} = [d_1, d_2, d_3, \dots, d_G] \quad (4.18)$$


$$\mathbf{L}(k) = [l_1(k), l_2(k), l_3(k), \dots, l_G(k)]^H \quad (4.19)$$



(a) Case1



(b) Case2



(c) Case3

图 4-11 四种算法优化后的波束目标函数  $F_2$  的适应度值

Figure 4-11 The fitness value of the beam objective function  $F_2$  optimized by the four algorithms

其中上标  $H$  表示赫米特算子。平面天线阵列的转向矢量  $\mathbf{a}$  定义为:

$$\mathbf{a} = [a_1, a_2, a_3, \dots, a_G]^H \quad (4.20)$$

而对于阵列转向矢量  $\mathbf{a}$  的元素分量  $a_g, g = 1, 2, 3, \dots, G$ ,  $a_g$  表示为(4.21):

$$a_g = e^{j\frac{2\pi}{\lambda}(d_{my}\sin\theta\cos\varphi - \sin\theta_0\cos\varphi_0 + d_{nz}\sin\theta\sin\varphi - \sin\theta_0\sin\varphi_0)} \quad (4.21)$$

其中,  $\theta_0$  和  $\varphi_0$  分别为平面天线阵列的  $xz$  平面和  $yz$  平面辐射图的主瓣最大功率点的指向角。平面天线阵列接收到的预期信号  $\mathbf{X}_{ds}(k)$  可定义为:

$$\mathbf{X}_{ds}(k) = \mathbf{a}s_0(k) \quad (4.22)$$

平面天线阵列接收到的干扰信号  $\mathbf{X}_{is}(k)$  可以表示为:

$$\mathbf{X}_{is}(k) = \mathbf{A}_V \mathbf{S}(k) \quad (4.23)$$

其中,  $\mathbf{A}_V$  是由干扰信号 AOA 转向向量  $\mathbf{a}_v$  构成的阵列转向矩阵,  $\mathbf{S}(k)$  是由第  $k$  个采样块的所有干扰信号构成的列向量,  $\mathbf{A}_V$ 、 $\mathbf{a}_v$  和  $\mathbf{S}(k)$  的定义分别为(4.24)、(4.25)和(4.26):

$$\mathbf{A}_V = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_V] \quad (4.24)$$

$$\mathbf{S}(k) = [s_1(k), s_2(k), \dots, s_V(k)]^H \quad (4.25)$$

$$\mathbf{a}_v = \mathbf{a}(\theta_{sv}, \varphi_{sv}), v = 1, 2, 3, \dots, V \quad (4.26)$$

平面天线阵列接收到的总输入信号  $\mathbf{X}(k)$  表示为:

$$\mathbf{X}(k) = \mathbf{X}_{ds}(k) + \mathbf{X}_{is}(k) + \mathbf{L}(k) \quad (4.27)$$

那么, 平面天线阵列的自适应波束形成输出函数  $f$  可表示为:


$$f = \mathbf{w}^H \mathbf{X}(k) \quad (4.28)$$

根据文献[59], 第  $k$  个采样块的干扰信号和噪声信号的自相关矩阵  $\mathbf{R}_{is}(k)$  和  $\mathbf{R}_{ns}(k)$ , 可以通过从相应信号的采样块构建的矩阵的平均值来近似, 如(4.29)和(4.30)所示:

$$\mathbf{R}_{is}(k) = \frac{1}{K} \mathbf{X}_{is}(k) \mathbf{X}_{is}^H(k) \quad (4.29)$$

$$\mathbf{R}_{ns}(k) = \frac{1}{K} \mathbf{L}(k) \mathbf{L}^H(k) \quad (4.30)$$

第  $k$  个采样块的期望信号功率  $P_{ds}(k)$  和非期望信号功率  $P_{us}(k)$  分别定义为:



(a) xz 平面的辐射图 (b) yz 平面的辐射图

图 4-12 一个 12×10 PAA 的初始辐射图

Figure 4-12 Initial radiation pattern of the 12×10 PAA

$$P_{ds}(k) = \mathbf{w}^H \mathbf{a} \mathbf{a}^H \mathbf{w} \quad (4.31)$$

$$P_{us}(k) = \mathbf{w}^H \mathbf{R}_{is}(k) \mathbf{w} + \mathbf{w}^H \mathbf{R}_{ns}(k) \mathbf{w} \quad (4.32)$$

然后，第  $k$  个采样块的 SINR 定义为：

$$SINR(k) = P_{ds}(k) / (P_{us}(k)) \quad (4.33)$$

以一个 12×10 的平面天线阵列作为研究对象，其中包含 120 个理想阵元，假定 PA 接收到的信号共有  $K=100$  个时间采样块。如图 4-12 所示，在激励权重和间距相等的情况下形成的  $xz$  平面和  $yz$  平面的初始辐射图的 SLL 较高，分别为 -13.04 dB 和 -13.0 dB，对阵列天线的辐射覆盖能力有很大干扰。因此，在抑制干扰信号、提高  $K$  个时间采样块的平均信噪比(Mean Signal Interference Plus Noise Ratio, MSINR)的同时，还需要有效抑制 SLL，因此波束目标函数  $F_3$  定义为：

$$F_3 = \max (f(\theta, \varphi_0))_{\theta \in \Theta} + \max (f(\theta_0, \varphi))_{\varphi \in \Phi} + \alpha f(\theta_{sv}, \varphi_{sv}) + \beta \times MSINR \quad (4.34)$$

其中， $\max (f(\theta, \varphi_0))$  和  $\max (f(\theta_0, \varphi))$  分别表示平面天线阵列在  $xz$  平面旁瓣区间  $\Theta$  和  $yz$  平面旁瓣区间  $\Phi$  中辐射图的最大 SLL。 $f(\theta_{sv}, \varphi_{sv})$  表示  $xz$  平面和  $yz$  平面辐射图中波束水平值对应的干扰信号的 AOA( $\varphi_{sv}, \theta_{sv}$ )。

三种不同的信号投射平面天线阵列情景(Case1、Case2 和 Case3)被设置，以验证基于 IMVO 的波束优化模型的性能，其中所需信号的信噪比为 10 dB，所有非所需信号的






图 4-13 三种不同信号投射情况下的辐射方向图优化

Figure 4-13 The optimized radiation pattern for three different signal projection cases


干扰信噪比为 40 dB。此外,在这三种情况下,  $xz$  平面和  $yz$  平面辐射图中主瓣的指向



(a) Case1



(b) Case2



(c) Case3

图 4-14 四种算法优化后的波束目标函数  $F_2$  的适应度值

Figure 4-14 The fitness value of the beam objective function  $F_2$  optimized by the four algorithms

是由式(4.21)的初始化控制的。对于所需的信号，AOA( $\theta_0, \varphi_0$ )被定义为( $0^\circ, 0^\circ$ ),

AOA( $\theta_{s_1}, \varphi_{s_1}$ ), ( $\theta_{s_2}, \varphi_{s_2}$ )和( $\theta_{s_3}, \varphi_{s_3}$ )分别定义为( $\pm 30^\circ, \pm 30^\circ$ ), ( $\pm 40^\circ, \pm 50^\circ$ )和( $\pm 50^\circ, \pm 40^\circ$ )。

四种算法对这三种场景辐射图的优化结果如图 4-13 所示。对优化结果的总体分析表明, 在  $xz$  平面和  $yz$  平面的辐射图中, 主瓣的最大功率点角度为  $0^\circ$ 。GA 可以将旁瓣电平降低到小于 -16.2 dB, 而 GWO 可以将  $xz$  平面和  $yz$  平面中的一个平面的辐射图的旁瓣电平降低到 -23.0 dB 以下, 但 Case 3 中  $xz$  平面的辐射图的旁瓣电平只能降低到 -13.4 dB 以下。此外, GA 和 GWO 最多只能在  $xz$  平面和  $yz$  平面之一的辐射图的干扰信号 AOA 处产生零点。它们优化平面天线阵列的输出 MSINR 分别大于 28.4 dB 和 29.3 dB, 但都小于 30 dB。

表 4-2 与其它工作的比较

Table 4-2 COMPARISON WITH OTHER WORKS

| 参考文献 | 优化算法   | 阵列维度 | 阵列类型 | SLL (dB) | MSINR (dB) |
|------|--------|------|------|----------|------------|
| [54] | 凸优化    | 1D   | 稀疏阵列 | -14.0    | 10.0       |
| [55] | 最小均方差  | 1D   | 线性阵列 | -8.0     | 39.0       |
| [56] | 循环神经网络 | 1D   | 线性阵列 | -13.0    | 27.0       |
| [59] | 迭代求解   | 1D   | 线性阵列 | -20.0    | 25.0       |
| Pro. | IMVO   | 2D   | 平面阵列 | -22.0    | 37.2       |

MVO 和 IMVO 分别将  $xz$  平面和  $yz$  平面辐射图中的旁瓣电平降低到 -17.4 dB 和 -21.7 dB 以下, 可知 IMVO 在降低旁瓣电平方面更具优势。此外, 对于  $xz$  平面和  $yz$  平面上的所有不同干扰信号, MVO 和 IMVO 都能在 AOA 处产生零点。MVO 在干扰信号 AOA 处的波束抑制深度小于 -37.7 dB, 而 IMVO 优化的波束抑制深度小于 -46.9 dB, 这表明 IMVO 具有更好的干扰抑制能力。IMVO 优化平面天线阵列的 MSINR 输出值高于 37.2 dB。此外, 如图 4-14 所示, IMVO 的波束目标函数  $F_3$  的适应度值更低, 收敛到波束形成最优解的速度更快。

为了突出这项工作的优点和新颖性, 表 4-2 展现了基于 IMVO 的波束成形方法与其他工作的比较。IMVO 优化了复杂二维天线阵列的主波束指向和非期望信号抑制的波束形成, 同时考虑了降低  $xz$  和  $yz$  平面辐射图的 SLL 的目标优化, 并可以在降低 SLL 和输出 MSINR 方面达到更好的优化性能。

## 4.4 本章总结

本章探索了一种基于 IMVO 的波束成形方法，用于平面天线阵列的  $xz$  和  $yz$  平面辐射图的优化设计。新的宇宙种群间物质更新方法使得 IMVO 实现了更快的收敛速度和更强的全局最优解求解能力。利用 IMVO 优化的平面天线阵列的  $xz$  和  $yz$  平面辐射图的结果表明，旁瓣电平可以同时降低到  $-30.0$  dB 以下，并且可以有效控制  $xz$  和  $yz$  平面的不同的旁瓣电平。此外，当平面天线阵列在  $xz$  平面和  $yz$  平面上投射信号时，主瓣指向所需的信号，而非所需的信号则被抑制。同时，旁瓣电平可以降低到小于  $-21.7$  dB，最大输出 MSINR 可以大于  $37.2$  dB。通过与 GA、GWO 和 MVO 算法的优化结果进行比较，验证了 IMVO 的高性能设计方法。



## 第五章 结论与展望

### 研究结论

传统天线设计依赖经验公式和数值仿真,耗时且难以找到全局最优解,而智能算法能够高效搜索复杂参数空间,显著提升设计效率。此外,天线设计通常涉及多目标优化问题,如增益、带宽和辐射方向图等,智能算法能够同时优化多个性能指标,提升天线整体性能。在复杂电磁环境中,深度学习算法可以自适应调整天线参数,实现智能波束成形和干扰抑制,增强通信系统的稳定性和可靠性。随着 5G/6G 通信、物联网等技术的快速发展,天线设计面临更高要求,智能算法能够有效应对高频段、大规模 MIMO 等挑战,推动天线技术的创新。智能算法不仅降低了研发成本,还推动了天线设计的智能化发展,为未来通信系统提供强有力的技术支持。因此,本论文主要研究了应用于全双工天线、双极化天线以及天线阵列的智能算法研究,主要取得了以下成果:

(1) 提出了一种基于精确径向基函数 (Precise Radial Basis Function, PRBF) 神经网络模型的高效优化方法,并成功应用于一款加载了两个 E 形带和一个 I 形带的全双工天线设计。通过优化,天线的阻抗带宽从原来的 3.44–3.56 GHz 显著扩展至 3.40–3.68 GHz,同时实现了传输和接收端口之间大于 35 dB 的高隔离度。

(2) 提出了一种基于 AI 深度学习算法的高效优化方法,用于设计双极化高隔离度天线。该方法利用多输入多输出反向传播算法构建模型,其中输入为目标特征,包括双端口阻抗带宽、平均隔离度和最大增益的预期值,输出为天线的尺寸变量。通过天线原型的仿真验证,证明了该方法的有效性及其对天线性能的准确预测。实验结果表明,所提出的方法在收敛速度(即达到目标设计所需的总电磁仿真次数)和时间成本方面表现优异,在 3.47–3.58 GHz 带宽内实现了优于 40 dB 的高隔离度,并在约 22.7 小时内获得了两个端口 4.3 dBi 的最大增益。这些优势使其可以成为天线优化设计领域具有竞争力的解决方案。

(3) 提出了一种基于改进多元宇宙算法的高效优化模型,用于非均匀平面天线阵列的辐射波束优化。该模型针对传统多元宇宙算法的局限性,引入了一种新机制,显著提升了算法的局部开采能力和全局寻优性能。利用改进后的算法,对两类平面天线阵列的波束形成进行了优化:一类是对称平面天线阵列,实现了方位向和俯仰向方向图的低旁瓣电平,并能够灵活控制两个方向的旁瓣电平值;另一类是非对称平面天线阵列,在实现低旁瓣电平的同时,还实现了主瓣指向期望信号到达角、零点抑制不期望信号

到达角以及最大化输出信号干扰加噪声比的目标优化。通过与遗传算法、灰狼算法和传统多元宇宙算法的优化结果对比,验证了所提模型在收敛速度和优化性能上的优势。

综上,本文研究了智能算法在天线设计中的创新应用,针对传统设计方法效率低、优化能力有限等问题提出了三种智能化解决方案。首先,基于精确径向基神经网络的全双工天线设计实现了带宽扩展(3.40–3.68 GHz)和高端口隔离(> 35 dB);其次,深度学习算法在双极化天线优化中展现出高效性,仅用 22.7 小时即达成> 40 dB 隔离度和 4.3 dBi 增益;最后,改进的多元宇宙算法成功优化了对称/非对称阵列的波束特性,在旁瓣控制、干扰抑制等方面显著优于传统算法。这些研究成果不仅验证了智能算法在多目标优化、复杂电磁环境适应等方面的优势,更为 5G/6G 时代的高性能天线设计提供了新的技术路径,推动了天线设计向智能化、高效化方向发展。

### 未来研究展望

本文所提出的面向高效率高性能的天线优化算法技术研究具有极其重要的理论意义和工程应用价值。由于本课题涉及的理论知识范围广泛,加上时间方面的限制,本论文尚存在着一些不足之处有待完善,后续可以从以下几个方面进行进一步研究:

(1)第二章提出精确径向基函数神经网络对于全双工单频段天线的设计,后续可进一步探索精确径向基函数神经网络模型在多频段、多模式天线设计中的应用,以应对 5G 及未来 6G 通信系统中更复杂的频谱需求。通过优化算法提升天线的增益、辐射效率及方向性,同时降低功耗和尺寸,实现更紧凑、高性能的智能化天线。

(2)第三章中提出了一种基于 AI 深度学习的双极化天线优化方法,该方法通过先进的神经网络模型和优化算法,初步满足了天线主要性能的设计需求,包括阻抗匹配、增益提升、隔离度改善等关键性能指标。这一成果不仅为双极化天线的设计提供了一种高效、准确的解决方案,也为后续的天线设计研究奠定了坚实的基础。然而,这仅仅是优化方法应用的起点。为了进一步拓展其应用范围和提升其性能,后续的研究可以在多个维度上进行深化和拓展。一方面,可以将该方法应用于更多类型的天线设计,例如其他极化方式(如圆极化、混合极化)或具有复杂形状(如多层结构、非规则形状)的天线。通过这些应用,可以验证该方法的广泛适用性,探索其在不同天线结构和工作条件下的优化潜力,为各种复杂天线设计提供通用的优化框架。

(3)第四章中提出了一种改进的多元宇宙算法,用于优化天线阵列的激励权重和阵元间距,以实现波束方向图的旁瓣抑制。这一算法通过模拟多元宇宙的演化过程,有效地解决了天线阵列优化中的复杂非线性问题,显著降低了旁瓣电平,提高了波束方向

图的性能。这一成果在天线阵列设计领域具有重要的应用价值，为实现高性能波束控制提供了新的思路和方法。然而，算法的优化和改进是一个持续的过程。后续研究可以进一步深入探讨算法参数对优化性能的影响。通过系统地调整和优化算法参数，如宇宙数量、维度、引力常数等，可以进一步提升算法的收敛速度和全局寻优能力。这不仅能够加快优化过程，减少计算成本，还能提高优化结果的准确性和可靠性，使其在实际应用中更具竞争力。

## 参考文献

- [1] X. Xu et al.. Intelligent Design of Reconfigurable Microstrip Antenna Based on Adaptive Immune Annealing Algorithm [J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-14.
- [2] K. Fu, X. Cai, B. Yuan, Y. Yang and X. Yao. An Efficient Surrogate Assisted Particle Swarm Optimization for Antenna Synthesis [J]. IEEE Transactions on Antennas and Propagation, 2022, 70(7): 4977-4984.
- [3] X. Li, S. Ma and G. Yang, Synthesis of Difference Patterns for Monopulse Antennas by an Improved Cuckoo Search Algorithm [J]. IEEE Antennas and Wireless Propagation Letters, 2017, 16: 141-144.
- [4] K. Tan, Y. Lu, Z. Zhao, D. Wang and B. Chen. A Dual-Kernel Computational Framework for Artificial Intelligence-Based Indoor Communication Analysis [J]. IEEE Antennas and Wireless Propagation Letters, 2023, 22(12): 2984-2987.
- [5] R. Mwang'amba, P. Mei, M. O. Akinsolu, B. Liu and S. Zhang. Gain Bandwidth Enhancement and Sidelobe Level Stabilization of mmWave Lens Antennas Using AI-Driven Optimization [J]. IEEE Antennas and Wireless Propagation Letters, 2024, 23(11): 3554-3558.
- [6] J. S. Smith and M. E. Baginski. Thin-Wire Antenna Design Using a Novel Branching Scheme and Genetic Algorithm Optimization [J]. IEEE Transactions on Antennas and Propagation, 2019, 67(5): 2934-2941.
- [7] M.-C. Tang, X. Chen, M. Li, and R. W. Ziolkowski. Particle Swarm Optimized, 3-D-Printed, Wideband, Compact Hemispherical Antenna [J]. IEEE Antennas Wireless Propagation Letters, 2018, 17(11): 2031-2035.
- [8] Z. Shao, L. -F. Qiu, and Y. P. Zhang. Design of Wideband Differentially Fed Multilayer Stacked Patch Antennas Based on Bat Algorithm [J]. IEEE Antennas Wireless Propagation Letters, 2020, 19(7):1172-1176.
- [9] X. Dai, X. Li and K. -M. Luk. A Planar Wideband Millimeter-Wave Antenna Array With Low Sidelobe Using ‘ $\pm 1$ ’ Excitations [J]. IEEE Transactions on Antennas and Propagation, 2021, 69(10): 6999-7004.
- [10] Y. Xiao, K. W. Leung, K. Lu and C. -S. Leung, Mode Recognition of Rectangular Dielectric Resonator Antenna Using Artificial Neural Network [J]. IEEE Transactions on Antennas and Propagation, 2022, 70(7): 5209-5216.
- [11] J. Nan, H. Xie, M. Gao, Y. Song, and W. Yang. Design of UWB Antenna Based on

- Improved Deep Belief Network and Extreme Learning Machine Surrogate Models [J]. IEEE Access, 2021, 9:126541-126549.
- [12] H. Ahmed, X. Zeng, H. Bello, Y. Wang, and N. Iqbal. Sub-6 GHz MIMO antenna design for 5G smartphones: A deep learning approach [J]. AEU-International Journal of Electronics and Communications, 2023, 168.
- [13] T. Khan, A. De, and M. Uddin. Prediction of Slot-Size and Inserted Air-Gap for Improving the Performance of Rectangular Microstrip Antennas Using Artificial Neural Networks [J]. IEEE Antennas Wireless Propagation Letters, 2013, 12: 1367-1371.
- [14] J. Zhang, M. O. Akinsolu, B. Liu, and G. A. E. Vandenbosch. Automatic AI-driven design of mutual coupling reducing topologies for frequency reconfigurable antenna arrays [J]. IEEE Transactions on Antennas and Propagation, 2021, 69(3):1831-1836.
- [15] L. Kouhalvandi and L. Matekovits. Hyperparameter Optimization of Long Short-Term Memory-Based Forecasting DNN for Antenna Modeling Through Stochastic Methods [J]. IEEE Antennas Wireless Propagation Letters, 2022, 21(4): 725-729.
- [16] Q. -Q. Li, Q. -X. Chu, and Y. -L. Chang. Design of Compact High-Isolation MIMO Antenna with Multiobjective Mixed Optimization Algorithm [J]. IEEE Antennas Wireless Propagation Letters, 2020, 19(8):1306-1310.
- [17] W. T. Li, X. W. Shi, Y. Q. Hei, S. F. Liu, and J. Zhu. A Hybrid Optimization Algorithm and Its Application for Conformal Array Pattern Synthesis [J]. IEEE Transactions on Antennas and Propagation, 2010, 58(10): 3401-3406.
- [18] D. Kim, J. Ju, and J. Choi. A Mobile Communication Base Station Antenna Using a Genetic Algorithm Based Fabry-Pérot Resonance Optimization [J]. IEEE Transactions on Antennas and Propagation, 2012, 60(2): 1053-1058.
- [19] Y. He, J. Huang, W. Li, L. Zhang, S. -W. Wong, and Z. N. Chen. Hybrid Method of Artificial Neural Network and Simulated Annealing Algorithm for Optimizing Wideband Patch Antennas [J]. IEEE Transactions on Antennas and Propagation, 2024, 72(1): 944-949.
- [20] V. H. Hasbestan, Y. Farhang, K. Majidzadeh, and C. Ghobadi. Multi-Objective Hybrid Optimization Algorithm for Design a Printed MIMO Antenna With n78-5G NR Frequency Band Applications [J]. IEEE Access, 2023, 11: 68231-68242.
- [21] Y. -Z. Liang, F. -C. Chen, K. -R. Xiang, and W. -F. Zeng. Wideband Co-Polarized Stacked Patch Antenna for In-Band Full-Duplex Applications [J]. IEEE Transactions on Antennas and Propagation, 2023, 71(12): 9920-9925.

- [22] J. C. Dash and D. Sarkar. A Colinearly Polarized Full-Duplex Antenna With Extremely High Tx–Rx Isolation [J]. *IEEE Antennas and Wireless Propagation Letters*, 2022, 21(12): 2387-2391.
- [23] J. P. Jacobs. Accurate Modeling by Convolutional Neural-Network Regression of Resonant Frequencies of Dual-Band Pixelated Microstrip Antenna [J]. *IEEE Antennas and Wireless Propagation Letters*, 2021, 20(12): 2417-2421.
- [24] J. Jin, Q. Su, Y. Xu, Z. He and Y. Lu, Efficient Radiation Pattern Prediction of Array Antennas Based on Complex-Valued Graph Neural Networks [J]. *IEEE Antennas and Wireless Propagation Letters*, 2022, 21(12) pp. 2467-2471.
- [25] F. Feng, W. Na, J. Jin, J. Zhang, W. Zhang and Q. -J. Zhang. Artificial Neural Networks for Microwave Computer-Aided Design: The State of the Art [J]. *IEEE Transactions on Microwave Theory and Techniques*, 2022, 70(11): 4597-4619.
- [26] L. Yuan, L. Wang, X. -S. Yang, H. Huang and B. -Z. Wang. An Efficient Artificial Neural Network Model for Inverse Design of Metasurfaces [J]. *IEEE Antennas and Wireless Propagation Letters*, 2021, 20(6): 1013-1017.
- [27] A. Massa, D. Marcantonio, X. Chen, M. Li, and M. Salucci. DNNs as Applied to Electromagnetics, Antennas, and Propagation—A Review [J]. *IEEE Antennas Wireless Propagation Letters*, 2019, 18(11): 2225-2229.
- [28] S. Koziel, N. Çalık, P. Mahouti, and M. A. Belen. Low-Cost and Highly Accurate Behavioral Modeling of Antenna Structures by Means of Knowledge-Based Domain-Constrained Deep Learning Surrogates [J]. *IEEE Transactions on Antennas and Propagation*, 2023, 71(1): 105-118.
- [29] Y. Su, Y. Yin, S. Li, H. Zhao and X. Yin. Bandwidth Improvement for Patch Antenna via Knowledge-Based Deep Reinforcement Learning [J]. *IEEE Antennas and Wireless Propagation Letters*, 2024, 23(12): 4094-4098.
- [30] N. Sarker, P. Podder, M. R. H. Mondal, S. S. Shafin and J. Kamruzzaman. Applications of Machine Learning and Deep Learning in Antenna Design, Optimization, and Selection: A Review [J]. *IEEE Access*, 2023, 11: 103890-103915.
- [31] J. H. Kim and S. W. Choi. A Deep Learning-Based Approach for Radiation Pattern Synthesis of an Array Antenna [J]. *IEEE Access*, 2020, 8: 226059-226063.
- [32] Z. Zhou, Z. Wei, J. Ren, Y. Yin, G. F. Pedersen and M. Shen. Two-Order Deep Learning for Generalized Synthesis of Radiation Patterns for Antenna Arrays [J]. *IEEE Transactions on Artificial Intelligence*, 2023, 4(5): 1359-1368.

- [33] J. Zhang, M. O. Akinsolu, B. Liu, and S. Zhang. Design of Zero Clearance SIW Endfire Antenna Array Using Machine Learning-Assisted Optimization [J]. IEEE Transactions on Antennas and Propagation, 2022, 70(5): 3858-3863.
- [34] J. Tak, A. Kantemur, Y. Sharma, and H. Xin. A 3-D-Printed W-Band Slotted Waveguide Array Antenna Optimized Using Machine Learning [J]. IEEE Antennas Wireless Propagation Letters, 2018, 17(11): 2008-2012.
- [35] W. -Q. Deng, S. Xu, Z. Xu and S. -Y. Zhu. Automated Design of Millimeter-Wave Dielectric Transmitarray Antenna Using Tandem Network [J]. IEEE Antennas and Wireless Propagation Letters, 2024, 23(11): 3549-3553.
- [36] B. Liu et al.. An Efficient Method for Complex Antenna Design Based on a Self Adaptive Surrogate Model-Assisted Optimization Technique [J]. IEEE Transactions on Antennas and Propagation, 2021, 69(4): 2302-23151.
- [37] C.-Y. Chan and P. M. Goggans. Multiobjective Design of Linear Antenna Arrays Using Bayesian Inference Framework [J]. IEEE Transactions on Antennas and Propagation, 2014, 62(11): 5524-5530.
- [38] Y. Liu et al.. An Efficient Method for Antenna Design Based on a Self-Adaptive Bayesian Neural Network-Assisted Global Optimization Technique [J]. IEEE Transactions on Antennas and Propagation, 2022, 70(12): 11375-11388.
- [39] L. Cui, Y. Zhang, R. Zhang, and Q. H. Liu. “A Modified Efficient KNN Method for Antenna Optimization and Design [J]. IEEE Transactions on Antennas and Propagation, 2020, 68(10): 6858-6866.
- [40] L. -Y. Xiao, W. Shao, F. -L. Jin, B. -Z. Wang, and Q. H. Liu. Inverse Artificial Neural Network for Multiobjective Antenna Design [J]. IEEE Transactions on Antennas and Propagation, 2021, 69(10): 6651-6659.
- [41] I. Goodfellow, Y. Bengio, and A. Courville. “6 Deep Feedforward Networks,” in Deep Learning [M]. Cambridge, MA, USA: MIT Press, 2016.
- [42] D.-L. Wu, J. H. Chen, K. Y. Yang, W. J. Zhu, and L. H. Ye. A Compact Dual-Polarized Patch Antenna With L-Shaped Short Pins [J]. IEEE Antennas Wireless Propagation Letters, 2023, 22(4): 689-693.
- [43] L.-Y. Xiao, W. Shao, F.-L. Jin, and B.-Z. Wang. Multiparameter modeling with ANN for antenna design [J]. IEEE Transactions on Antennas and Propagation, 2018, 66(7): 3718-3723.
- [44] Q. Zeng et al.. Phase Modulation Technique for Harmonic Beamforming in Time-

- Modulated Arrays [J]. IEEE Transactions on Antennas and Propagation, 2022, 70(3): 1976-1988.
- [45] Y. Wang, Q. Yang, H. Wang, and Y. Zeng. Grating Lobe Suppression for Distributed Phased Array via Accumulated Array Pattern Synthesis [J]. IEEE Antennas Wireless Propagation Letters, 2023, 22(7): 1527-1531.
- [46] N. Jin and Y. Rahmat-Samii. Advances in Particle Swarm Optimization for Antenna Designs: Real-Number, Binary, Single-Objective and Multiobjective Implementations [J]. IEEE Transactions on Antennas and Propagation, 2007, 55(3): 556-567.
- [47] L. Cen, Z. L. Yu, W. Ser, and W. Cen. Linear Aperiodic Array Synthesis Using an Improved Genetic Algorithm [J]. IEEE Transactions on Antennas and Propagation, 2012, 60(2): 895-902.
- [48] B. V. Ha, M. Mussetta, P. Pirinoli, and R. E. Zich. Modified Compact Genetic Algorithm for Thinned Array Synthesis [J]. IEEE Antennas Wireless Propagation Letters, 2016, 15: 1105-1108.
- [49] X. Li and K. M. Luk. The Grey Wolf Optimizer and Its Applications in Electromagnetics [J]. IEEE Transactions on Antennas and Propagation, 2020, 68(3): 2186-2197.
- [50] D. G. Kurup, M. Himdi, and A. Rydberg. Synthesis of uniform amplitude unequally spaced antenna arrays using the differential evolution algorithm [J]. IEEE Transactions on Antennas and Propagation, 2003, 51(9): 2210-2217.
- [51] S. Fang, W. Li, Z. Xue, and W. Ren. Synthesis of Distributed Array Consisting of Two Subarrays via Hybrid Method of Differential Evolution Optimization and Convex Optimization [J]. IEEE Antennas Wireless Propagation Letters, 2021, 20(2): 125-129.
- [52] Z. D. Zaharis, I. P. Gravas, P. I. Lazaridis, T. V. Yioultsis, C. S. Antonopoulos, and T. D. Xenos. An Effective Modification of Conventional Beamforming Methods Suitable for Realistic Linear Antenna Arrays [J]. IEEE Transactions on Antennas and Propagation, 2020, 68(7): 5269-5279.
- [53] K. Zhong, J. Hu, Y. Cong, G. Cui, and H. Hu. RMOCG: A Riemannian Manifold Optimization-Based Conjugate Gradient Method for Phase-Only Beamforming Synthesis [J]. IEEE Antennas Wireless Propagation Letters, 2022, 21(8): 1625-1629.
- [54] Z. Zheng, Y. Fu, and W. -Q. Wang. Sparse Array Beamforming Design for Coherently Distributed Sources [J]. IEEE Transactions on Antennas and Propagation, 2021, 69(5): 2628-2636.
- [55] B. Jalal, X. Yang, Q. Liu, T. Long, and T. K. Sarkar. Fast and Robust Variable-Step-Size



- LMS Algorithm for Adaptive Beamforming [J]. IEEE Antennas Wireless Propagation Letters, 2020, 19(7): 1206-1210.
- [56] I. Mallioras, Z. D. Zaharis, P. I. Lazaridis, and S. Pantelopoulos. A Novel Realistic Approach of Adaptive Beamforming Based on Deep Neural Networks [J]. IEEE Transactions on Antennas and Propagation, 2022, 70(10): 8833-8848.
- [57] S. Mirjalili, S. Mohammad Mirjalili, and A. Hatamlou. Multi-Verse Optimizer: a nature-inspired algorithm for global optimization [J]. Neural Computing and Applications, 2016, 27(2): 495-513.
- [58] C. A. Balanis. “Arrays: Linear, Planar, and Circular,” in Antenna Theory: Analysis and Design [M]. NJ, USA: Wiley, 2016.
- [59] I. P. Gravas, Z. D. Zaharis, T. V. Yioultis, P. I. Lazaridis, and T. D. Xenos. Adaptive Beamforming With Sidelobe Suppression by Placing Extra Radiation Pattern Nulls [J]. IEEE Transactions on Antennas and Propagation, 2019, 67(6): 3853-3862.

