

单位代码: 10293 密 级:

南京邮电大学

硕 士 学 位 论 文



论文题目: 基于机器学习的天线性能
分析与优化

学 号 1019020823

姓 名 彭康宁

导 师 许锋

学 科 专 业 电磁场与微波技术

研 究 方 向 机器学习、天线性能分析与优化

申请学位类别 工学硕士

论文提交日期 2022.03

Analysis and Optimization of Antenna Performance based on Machine Learning

Thesis Submitted to Nanjing University of Posts and
Telecommunications for the Degree of
Master of Science in Engineering



By

Kangning Peng

Supervisor: Prof. Feng Xu

March 2022

摘要

天线作为一种变换器,能够实现传输线上的导行波和自由空间中传播的电磁波之间的相互转换,在无线通信、广播电视、雷达导航等方面发挥重要作用,且具有小型化、多频段工作、可重构的趋势,而天线结构也随着应用需求的增加而变得复杂,设计自由度增加。天线性能分析通常基于 HFSS, CST, FEKO 软件,对于具有多个设计自由度的天线性能的分析与优化通常耗时较长,花费的计算资源多。而基于机器学习的辅助优化设计方法能够基于 HFSS, CST 对初步建立的天线模型进行粗略仿真,得到一定的数据样本,再使用该数据样本训练机器学习模型,训练好的模型能够对天线进行优化参数范围内的精细化仿真,并结合优化算法,实现天线性能的快速分析与优化。本文针对不同的天线结构,基于设计的机器学习方法,对其在天线性能分析以及优化设计中的应用进行深入研究,主要工作内容如下:

首先,设计了一种平面单极子天线,并基于 CST 仿真软件得到大量的训练样本,再基于广义回归神经网络(GRNN)与主成分分析法(PCA)相结合的机器学习模型,用以快速分析该天线的性能。并将该机器学习模型与其他机器学习模型进行对比,验证提出的机器学习模型用于天线性能分析的有效性;此外,将集成学习(Ensemble Learning)与后向传播神经网络(Back Propagation),主成分分析法(PCA)结合,用于预测分析所设计天线在整个频段内的回波损耗(S11)与最大增益(MaxGain),以及宽边辐射增益(Gain)。

其次,将深度学习模型应用到电磁问题的求解。由于二维有限区域内的静电场问题与平面反射超表面单元及天线阵列的逆设计问题具有相似性。因此,本文在基于卷积神经网络(CNN)求解二维泊松方程的基础上,创新性地条件生成对抗网络(CGAN)用于该有限区域内二维泊松方程的求解。提出了 9 个新的计算场景,基于有限差分法(FEM)得到训练样本,并用于条件生成对抗网络(CGAN)的训练,再将训练好的模型用于快速求解该方程。将 CGAN 与 CNN 的预测性能进行对比,并且用于预测新场景,预测结果表明,条件生成对抗网络(CGAN)可以代替 FEM,快速准确地求解二维泊松方程。

最后,将变分自编码器(VAE)与 BP 神经网络结合,实现在整个频段上对天线性能的预测,并基于遗传算法(GA)实现对天线性能的优化。以单极子天线为例,优化结果表明,该算法能较为精确快速地实现天线性能的预测,并且基于 GA 算法优化天线性能,获得最优结构参数。此外,VAE 与 BPNN 相结合的机器学习模型与 Pareto 算法相结合,实现对天线性能的多目标优化。本文给出了将机器学习方法用于天线性能分析与优化设计的流程框架,可以作为研究此类问题的通用解法。

关键词: 机器学习, 深度学习, 天线性能分析, 优化设计, 多目标优化

Abstract

As a kind of converter, the antenna can realize conversation between the guided travelling wave in the transmission line and the electromagnetic wave propagating in free space. It plays an important role in wireless communication, radio and television, radar navigation and so on. It has the trend of miniaturization, multi-band operation and reconfiguration, and the antenna structure also becomes complex and the degree of design freedom increases for the application requirements. Antenna performance analysis is usually based on HFSS, CST and FEKO software. Therefore, the analysis and optimization of antenna performance with multiple design degrees of freedom usually takes a long time and occupies a lot of computing resources. The aided optimization design method based on machine learning can roughly simulate the preliminarily established antenna model based on HFSS and CST to obtain data samples and then use the data samples to train the machine learning model. The trained model can carry out fine simulation within the range of optimization parameters, and combine with the optimization algorithm to realize the rapid analysis and optimization of antenna performance. Based on the machine learning method, this paper deeply studies its application in antenna performance analysis and optimization design. The main work is as follows:

Firstly, a planar monopole antenna is designed, and a large number of training samples are obtained by CST. Then, the machine learning method based on the combination of generalized regression neural network (GRNN) and principal component analysis (PCA) is used to quickly analyze the performance of the antenna. This method is also compared with other machine learning methods to verify the effectiveness in antenna performance analysis. In addition, ensemble learning is combined with back propagation neural network (BPNN) and PCA to predict the return loss (S_{11}) and gain of the designed antenna in the whole frequency band.

Secondly, the deep learning method is applied to solve electromagnetic problems. Because the electrostatic field problem in two-dimensional finite region is similar to the inverse design problem of planar reflective meta-surface element and antenna array. Based on the convolution neural network (CNN) to solve the two dimensional Poisson's equation, this paper creatively uses the conditional generative adversarial network (CGAN) to solve this equation in the finite region. Nine secenes are proposed and the training samples are obtained based on the finite difference method (FEM) and used for training CGAN, and then the trained model is used to quickly solve the

equation. The prediction performance of CGAN is compared with CNN, and the prediction results show that CGAN can replace FEM to quickly and accurately solve the two-dimensional Poisson's equation.

Finally, variational auto-encoder (VAE) is combined with BPNN to predict the antenna performance in the whole frequency band, and the performance is optimized based on genetic algorithm (GA). Taking monopole antenna as an example, the optimized results indicate that this algorithm can accurately and quickly predict the antenna performance and obtain the optimal structural parameters. Furthermore, this proposed machine learning method is combined with Pareto algorithm to realize the multi-objective optimization of antenna performance. This paper presents a framework for applying machine learning method to antenna performance analysis and optimization design, which can be used as a general solution to this kind of problem.

Key words: machine learning, deep learning, antenna performance analysis, optimization design, multi-objective optimization

目录

专用术语注释表	VI
第一章 绪论	1
1.1 研究背景	1
1.1.1 天线的发展方向	1
1.1.2 人工智能在电磁场中的应用	2
1.2 研究现状	2
1.2.1 单个天线或阵列单元的性能分析.....	2
1.2.2 单个天线或阵列单元的优化设计.....	3
1.2.3 超表面天线阵列及其单元的逆向设计.....	3
1.2.4 天线阵列故障单元的检测	4
1.3 本文研究工作	4
第二章 相关背景知识介绍	6
2.1 两种常用人工神经网络	6
2.1.1 后向传播神经网络(BPNN)	6
2.1.2 广义回归神经网络(GRNN)	8
2.2 两种深度学习模型	9
2.2.1 卷积神经网络 (CNN)	9
2.2.2 生成对抗神经网络 (GAN)	11
2.3 智能优化算法	12
2.3.1 GA 算法.....	12
2.3.2 Pareto 遗传算法	13
2.4 本章小结	13
第三章 基于机器学习算法分析天线性能	14
3.1 基于 GRNN-PCA 分析天线性能	14
3.1.1 CPW 馈电的缝隙加载单极子天线设计.....	15
3.1.2 CPW 馈电的缝隙加载单极子天线的性能.....	15
3.1.3 基于 GRNN-PCA 分析天线性能	17
3.2 基于 BPNN-Ensemble-PCA 分析天线性能.....	20
3.2.1 混合八角分形单极子天线的设计.....	20
3.2.2 基于 BPNN-Ensemble-PCA 分析天线性能.....	23
3.2.3 天线性能的预测结果	25
3.2.4 与其他机器学习方法的对比	26
3.3 本章小结	28
第四章 基于 CGAN 求解二维泊松方程	29
4.1 基于 FDM 求解二维泊松方程.....	29
4.2 基于 CGAN 求解二维泊松方程	31
4.3 基于 CGAN 得到的预测结果	32
4.4 与 CNN 预测性能的对比	38
4.4.1 预测精度的对比	38
4.4.2 训练时间和预测时间的对比	40
4.5 结果分析	41
4.6 本章小结	41
第五章 基于 VAE-BPNN-GA 优化设计天线.....	43
5.1 VAE-BPNN 的原理.....	43

5.1.1 基于 VAE 实现数据降维.....	43
5.1.2 基于 VAE-BPNN 的性能预测.....	45
5.2 基于 GA 实现性能的优化.....	46
5.2.1 双 T 形单极子天线的优化.....	46
5.2.2 基于 VAE-BPNN 的预测结果.....	48
5.2.3 基于 VAE-BPNN-GA 的优化结果.....	50
5.3 与 PCA-BPNN-GA 预测性能的比较.....	51
5.3.1 预测精度和优化性能的对比	51
5.3.2 预测时间的对比	53
5.4 结果分析	53
5.5 基于 VAE-BPNN-GA 优化天线的相对带宽.....	55
5.6 基于 VAE-BPNN-GA 优化具有带陷性能的超宽带单极子天线.....	55
5.7 本章小结	60
第六章 总结与展望	62
6.1 全文工作总结	62
6.2 后期工作展望	63
参考文献	65
附录 1 程序清单	68
附录 2 攻读硕士学位期间撰写的论文	73
致谢	74

专用术语注释表

符号说明:

S_{11}	天线回波损耗
MaxGain	天线最大增益
TolEfficiency	天线总辐射效率
VSWR	电压驻波比

缩略词说明:

GRNN	General Regression Neural Network	广义回归神经网络
PCA	Principal Component Analysis	主成分分析法
ANN	Artificial Neural Network	人工神经网络
BPNN	Back Propagation Neural Network	后向传播神经网络
MLPNN	Multilayer Perceptron Neural Network	多层感知器神经网络
RBFNN	Radius Basis Function Neural Network	径向基函数神经网络
SVM	Support Vector Machine	支持向量机
CNN	Convolutional Neural Network	卷积神经网络
GAN	Generative Adversarial Network	生成对抗网络
CGAN	Conditional Generative Adversarial Network	条件生成对抗网络
FDM	Finite Difference Method	有限差分法
VAE	Variational Auto-Encoder	变分自编码器
GA	Genetic Algorithm	遗传算法
NSGA	Non-dominated Sorting Genetic Algorithm	非劣排序遗传算法
MOM	Method of Moments	矩量法
FDTD	Finite-Difference Time-Domain Method	时域有限差分法
FEM	Finite Element Method	有限差分法
GTD	Geometrical Theory Diffraction	几何绕射理论
CPW	CoPlanar Waveguide	共面波导
FOM	Figure of Merit	品质因素

第一章 绪论

1.1 研究背景

天线作为一种变换器,能够实现传输线上传播的导行波与自由空间中传播的电磁波之间的相互变换,是无线电设备中用来发射或接收电磁波的部件。无线电通信、广播、电视、雷达、导航、电子对抗、遥感、射电天文等工程系统,凡是利用电磁波来传递信息的,都依靠天线来进行工作^[1]。天线的发展大致可分为三个历史阶段,第一阶段为 19 世纪末至 20 世纪 30 年代初的线天线时期,典型天线为八木天线;第二阶段为 20 世纪 30 年代初至 50 年代末的面天线时期,这一时期广泛采用抛物面天线和其他形式的反射面天线,并且还发明了波导缝隙天线、介质棒天线、螺旋天线等。此外,天线的基本理论也得到了丰富和完善;第三阶段为 20 世纪 50 年代至今的大发展时期,这一时期对天线提出许多新的要求,如:高增益、精密跟踪、快速扫描、宽频带、低旁瓣等,并出现了许多新型天线。由于天线结构日益复杂,对其进行分析的方法也从理论分析法如传输线模型法、腔体模型法、几何光学法、口径场法等,发展为电磁场数值计算方法如矩量法(MOM)^[2]、时域有限差分法(FDTD)^[3]、有限元法(FEM)^[4]和几何绕射理论(GTD)^[5]等,这些数值计算方法成为分析各种复杂天线问题的有力工具,并已形成商用软件,主要有 HFSS、CST、FEKO、XFDTD 等。

1.1.1 天线的发展方向

随着无线通信技术的不断发展,市场对无线通信设备的要求越来越高,其也被赋予越来越多的功能,而天线作为无线电系统中不可缺少的设备,主要的发展方向为:多频带化、智能化、小型化、集成化及高性能化(宽频带、高增益、低旁瓣、低交叉极化等)、可重构^[6-7]。随着天线的结构愈加复杂,设计自由度增加,以及天线的多功能化,基于 HFSS、CST 等仿真软件实现对天线结构的仿真通常花费几分钟至十几分钟,对于天线性能的优化以及获得最优设计参数这一过程则需要在优化参数范围内重复多次迭代,这一优化过程可能要花费数天甚至数十天,不仅耗费大量时间,且占据大量的计算资源^[8]。因此,对于较为复杂的天线结构或大型阵列,需要采取一定的方法在保证精确度的情况下,加速其仿真和优化过程,减少计算资源的消耗。

1.1.2 人工智能在电磁场中的应用

人工智能从概念提出到蓬勃发展,机器智能水平飞速提升主要得益于三个因素:大数据、机器学习(深度学习)算法、GPU 硬件平台。并且人工智能的概念已经逐步渗入到各行各业,并将其与该领域的技术相融合,转化为现实生产力,满足实际需求。而机器学习、深度学习算法现已被逐渐应用到电磁场领域中,主要为天线^[9-11]、微波电路的加速优化设计^[12-13],超表面逆设计^[14],数值计算加速^[15],故障检测^[16]等。机器学习或深度学习算法通过采集的训练样本数据来训练代理模型,并将该训练好的模型代替复杂繁琐的理论计算模型,或者耗时的电磁仿真软件,以便后续能快速而精确地预测性能,实现优化设计。这也为天线性能分析和结构参数的优化提供了研究思路。

1.2 研究现状

机器学习方法现已被广泛地应用于单个天线性能分析和优化设计,阵列天线单元的性能分析和设计,超表面天线阵列的逆向设计,以及天线阵列故障单元的检测等。其研究思路大致为:首先,基于 CST 或 HFSS 等软件对初步设计的天线结构进行性能仿真,获得一定数量的样本数据集;其次,设计适用于该问题的机器学习或深度学习算法,将数据样本分为训练样本和验证样本,并用训练样本数据训练该机器学习算法模型,当该算法模型在验证样本数据集上的预测误差小于设定的阈值时,其可以代替电磁仿真软件对新的天线尺寸参数进行性能分析,在保证一定预测精度的情况下,大大缩减了仿真时间;最后,结合优化算法如遗传算法(GA)^[17],粒子群算法(PSO)^[18]等,在设定的尺寸参数范围内实现对天线某一性能或多个性能的优化,大大缩减了仿真优化时间。

1.2.1 单个天线或阵列单元的性能分析

文献^[19]中将 10 种不同的基本机器学习模型相结合,并基于该混合机器学习模型对天线在某个频点处的多个性能参数进行分析或设计。首先,通过特征选择选出对天线性能影响最大的尺寸参数,以减少训练样本数据量;其次,混合多种基础机器学习模型,并建立天线尺寸参数与性能参数之间的非线性映射关系,从而快速而准确地分析天线性能或设计天线;混合机器模型与 10 个基本机器学习模型相比,具有最小的预测误差,表明了该混合机器模型的可行性和有效性;文献^[20]为了克服微带贴片天线工作带宽窄的缺点,通过在辐射贴片上加载缝隙来实现双频谐振,增加阻抗带宽,并且基于 MLP 和 RBF 来预测天线的两个谐振频点,从

而计算该天线的工作带宽,实验结果表明,RBF神经网络具有更高的预测精度和更短的预测时间;此外,除了采用ANN对单个天线的某一性能参数进行仿真,文献^[21]设计了一种新的机器学习模型,实现了对天线的S参数,增益,以及辐射方向图的计算。该机器学习模型将ANN,SVM算法与向量拟合(Vector Fitting)方法相结合,分别训练三个预测不同性能参数的模型,预测结果表明,该机器学习模型能代替仿真软件实现快速而精确的性能分析;文献^[22]则基于SVM算法对反射天线阵列单元的反射系数进行预测,阵列单元的尺寸参数,介电基质参数,以及入射角度,工作频率作为SVM模型的输入,而天线在两种极化状态下的反射系数作为输出。预测结果和仿真结果的对比表明该算法可以作为一种代理模型,并用于整个阵列的辐射方向图的快速计算。

1.2.2 单个天线或阵列单元的优化设计

在单一天线或天线阵列的设计过程中,通常需要对其某个性能参数进行优化或多目标优化。由于基于仿真软件的仿真优化耗费较多的时间和计算资源,因此,训练机器学习模型来作为代理模型对天线及其阵列的性能进行预测,并结合优化算法对其进行优化设计。文献^[21]中基于机器学习模型对法布里-珀罗谐振腔天线的S参数,增益以及辐射方向图进行预测,并结合NSGA-II算法实现了对天线的优化,满足设计指标;文献^[23]中基于SVM模型建立反射阵列单元的尺寸参数、入射角度与其对应的共极化和交叉反射极化反射系数之间的非线性映射关系,用以代替耗时繁琐的MOM-LP仿真模型,在保证预测精度的情况下,实现对其反射系数矩阵的快速预测,从而便于后续对天线阵列单元的性能进行优化,以满足设计要求。

1.2.3 超表面天线阵列及其单元的逆向设计

随着超表面概念和技术的日益成熟,其在天线中的应用也愈加广泛。并且超表面单元或阵列的设计自由度较大,因此,结合机器学习尤其是深度学习算法能够快速实现超表面单元或阵列的设计。文献^[24]提出了一种将卷积自编码器(CAN)和逆向设计神经网络(IDN)相结合的深度学习模型,建立超表面吸收体在工作频带内的反射系数曲线与尺寸参数之间的非线性映射关系。其中,CAN用于对采样频点较多,维度较高的反射系数曲线进行降维,IDN用于建立CAN得到的降维数据样本与尺寸参数之间的映射关系。因此,该深度学习模型可以基于反射系数的要求,直接预测得到结构参数,大大缩短了优化时间,节省了计算资源;文献^[25]中基于GAN对于给定的传输系数光谱,逆向设计对应的超表面结构。该超表面结构由介质基底和不同形状的金属贴片结构组成,将金属贴片结构编码化,用0-1矩阵表示。该基于GAN

的深度学习模型主要由生成器, 判别器, 以及模拟器组成, 生成器用于根据给定的传递函数得到对应的超表面结构矩阵, 判别器和模拟器共同作用于生成器, 控制生成器产生合理的, 符合传输系数频谱的结构, 预测结果表明, 该深度学习模型能基于任意设定的频谱, 快速逆向设计超表面; 对于可编码超表面阵列天线的设计, 文献^[26]采取了 CNN 来建立阵列天线的波束指向与可编码超表面对应的编码矩阵之间的映射关系, 超表面单元集成了有源元件, 以其通断状态表示 1-0, 基于辐射方向图表示天线阵列的波束指向。该方案为天线中的实时复波束的形成提供一种可能的研究思路。

1.2.4 天线阵列故障单元的检测

天线阵列由许多辐射单元组成, 当存在故障单元时, 会对天线阵列的辐射方向图等造成破坏, 使天线系统无法正常工作。因此, 很有必要对故障单元进行检测, 便于采取相应措施进行馈电调整, 以恢复方向图。文献^[27]中基于 ANN 对直线阵列天线的故障元件进行监测, 建立存在故障元件的阵列天线的辐射方向图与故障单元的数量和位置的映射关系, 实验结果证明, ANN 可以代替校准系统实现对故障元件的精准预测, 避免校准系统损坏或者由此造成的维护成本增加等问题; 文献^[28]则基于 CNN 实现了微带贴片天线阵列故障元件的数量和位置的预测, 将辐射方向图作为 CNN 的输入, 所有天线单元的馈电情况作为 CNN 的输出, 随着训练样本的增多, CNN 的预测准确率逐渐提高, 并且高于 SVM 的预测精度。

1.3 本文研究工作

随着无线通信技术的不断发展, 其在广播、电视、雷达、导航、电子对抗、射电天文等工程系统中发挥越来越重要的作用。天线作为无线通信技术中的重要组成部分, 由于通信行业高速率大容量低时延的要求, 其也被赋予越来越多的功能, 并且朝着多频带化、小型化、高性能化和可重构的方向发展, 因此, 对于天线或天线阵列的设计变得愈加复杂。而基于 CST 和 HFSS 等电磁仿真软件的性能分析和优化设计通常需要耗费较长时间, 占用较多计算资源, 随着人工智能学科的不断发展和机器学习与深度学习理论的不断丰富和完善, GPU 计算性能的不断增强, 其在电磁场与电磁波领域的应用也逐渐广泛, 尤其是微波器件的加速设计。本文主要研究机器学习在天线性能分析和优化设计中的应用, 工作内容主要包括以下三个方面:

(1) 设计新的机器学习模型和天线结构, 并将该机器学习模型用于分析设计天线的性能, 主要为工作频带内的 S 参数曲线和增益曲线。首先, 设计了一个 CPW 馈电的 Ψ 形缝隙加载的单极子天线, 该天线具有阻抗带宽较宽的特点, 并且通过 Ψ 形缝隙在阻抗带宽内形成阻带

特性；其次，将 GRNN 模型与 PCA 算法相结合，用于预测不同缝隙尺寸下天线结构的 S 参数曲线；最后，将所设计的 GRNN-PCA 与 BPNN-PCA，RBFNN-PCA，GRNN 和 RBFNN 算法的预测性能进行比较，验证了该模型较高的预测精度和较为简单的结构特征。此外，还将集成学习的思想用于机器学习模型的设计中，并用于天线性能分析，进一步验证了集成学习模型相比于单一机器学习模型的优势。

(2) 基于 CGAN 求解二维泊松方程。设置 9 个不同的应用场景，并基于 FDM 求解所有场景下的泊松方程，得到一定的训练样本用以训练设计的 CGAN 模型，其对测试样本的预测结果表明，其能够代替 FDM 算法实现对电磁方程的加速计算。并且与基于 CNN 的计算结果对比，其具有更高的预测精度，更短的预测时间，并且需要的训练样本数更少，适用的计算场景更多。

(3) 设计新的机器学习模型，将 VAE 与 BPNN 相结合，作为代理模型实现对天线性能的分析，并将 VAE-BPNN 模型与 GA 算法相结合，对其 S 参数性能进行优化。采用其他文献中的天线结构以验证该算法的有效性，并将其与其他算法对比，进一步证明了该算法的高效性与准确性。将 VAE-BPNN 与 GA 算法中的 NSGA-II 算法相结合，可以实现多目标性能的优化，并对参考文献中的天线性能进行多目标优化来验证该算法的有效性。

第二章 相关背景知识介绍

本章主要介绍人工智能相关背景知识，主要包括常用的机器学习、深度学习算法，以及集成学习思想、智能优化算法等。

2.1 两种常用人工神经网络

ANN 是基于生物学中神经网络的基本原理，以网络拓扑知识为基础，模拟人脑的神经系统对复杂信息的处理机制的一种数学模型。该模型以并行分布的处理能力、高容错性、智能化和自学习等能力为特征，由大量的节点之间相互联结构成。每层节点都使用一种激活函数，每两层节点之间的连接代表权值，网络的输出取决于网络结构、网络连接方式、权重和激活函数。每层权值和阈值的更新基于梯度下降算法，目标函数为实际值与预测值之间的差值，通过对权值和阈值的不断更新，逐渐减小目标函数值直至收敛到设定的阈值误差。本章介绍较为常用，也是本文使用的两种 ANN，即：BPNN、GRNN。

2.1.1 后向传播神经网络(BPNN)

BPNN 属于监督学习算法，通过输入层-隐藏层-输出层结构建立起输入参数和对应标签之间的非线性映射关系，其结构如图 2.1 所示。BPNN 的计算由正向计算过程和反向计算过程组成，并基于梯度下降传播算法更新神经网络每层的权值和阈值，以使目标函数最终收敛到设定的误差值。




图 2.1 BPNN 结构

图中，隐藏层层数为一层或多层，且正向计算过程用以下公式表征：

$$z^l = w^{l-1} x^{l-1} + b^l \quad (2.1)$$

$$x^l = f(z^l) \quad (2.2)$$

$$x^{l-1} = [x_1^{l-1}, x_2^{l-1}, \dots, x_k^{l-1}]; \quad b^l = [b_1^l, b_2^l, \dots, b_k^l] \quad (2.3)$$

$$w^{l-1} = \begin{bmatrix} w_{11}^{l-1} & w_{12}^{l-1} & \dots & w_{1k}^{l-1} \\ w_{21}^{l-1} & w_{22}^{l-1} & \dots & w_{2k}^{l-1} \\ \dots & \dots & \dots & \dots \\ w_{k1}^{l-1} & w_{k2}^{l-1} & \dots & w_{kk}^{l-1} \end{bmatrix} \quad (2.4)$$

式中, z^l 表示第 l 层神经元输入, x^{l-1} 为第 $l-1$ 层神经元输出, x^l 为第 l 层神经元输出, b^l 是第 l 层阈值, w^{l-1} 代表连接第 l 层和第 $l-1$ 层的权值, O 为 BP 神经网络的预测输出。式(2.2)表示 BP 神经网络第 l 层的激活函数, 通常为 sigmoid 函数、tansig 函数、relu 函数或者 leaky relu 函数。

误差反向传播的基本思想是: (1) 计算每一层的状态和激活值, 直到最后一层; (2) 计算每一层的误差, 误差的计算过程从最后一层向前推进; (3) 更新每层的权值和阈值, 使预测值和实际值的误差最小。迭代步骤 (2) 和 (3), 直至满足收敛误差。训练过程中的目标函数为:

$$E_{total} = \frac{1}{N} \sum_{i=1}^N E_{(i)} = \frac{1}{N} \sum_{i=1}^N \frac{1}{2} \sum_{k=1}^{n_L} (y_k^{(i)} - o_k^{(i)})^2 \quad (2.5)$$

式中, N 是估价训练样本的样本数量, $E_{(i)}$ 是单个样本的目标函数, $y_k^{(i)}$ 是待预测的实际值, $O_k^{(i)}$ 是 BP 神经网络的预测值, n_L 是待预测值的维度。

反向传播算法的目标是调整权重和偏置使总体目标函数最小, 可以采用梯度下降法来更新 w^l 和 b^l , $2 \leq l \leq L$, 参数更新公式如下:

$$\begin{aligned} w^{(l)} &= w^{(l)} - \mu \frac{\partial E_{total}}{\partial w^{(l)}} = w^{(l)} - \frac{\mu}{N} \sum_{i=1}^N \frac{\partial E_{(i)}}{\partial w^{(l)}} \\ b^{(l)} &= b^{(l)} - \mu \frac{\partial E_{total}}{\partial b^{(l)}} = b^{(l)} - \frac{\mu}{N} \sum_{i=1}^N \frac{\partial E_{(i)}}{\partial b^{(l)}} \end{aligned} \quad (2.6)$$

由上面公式可知, 求得每个训练数据的目标函数 $E_{(i)}$ 对参数的偏导数 $\frac{\partial E_{(i)}}{\partial w^{(l)}}$ 和 $\frac{\partial E_{(i)}}{\partial b^{(l)}}$, 即可得到参数的迭代更新公式。

2.1.2 广义回归神经网络(GRNN)

GRNN 是 RBFNN 的一种，具有较强的非线性映射能力和学习速度，比 RBFNN 具有更强的优势，网络最后收敛于样本集聚较多的优化回归，样本数据少时，预测效果较好，可以处理不稳定数据。其主要由输入层、模式层、求和层、和输出层组成。GRNN 的结构如图 2.2 所示。




图 2.2 GRNN 结构

图中， $[x_1, x_2, \dots, x_m]^T$ 为输入向量， m 为输入向量的维数，输入层神经元的数目等于学习样本中输入向量的维数，各神经元是简单的分布单元，直接将输入变量传递给模式层。 $[P_1, P_2, \dots, P_n]^T$ 为模式层的神经元， n 代表学习样本的数目，各神经元对应不同的样本，模式层神经元传递函数为：

$$p_i = \exp \left[-\frac{(X - X_i)^T (X - X_i)}{2\sigma^2} \right] \quad i=1,2,\dots,n \quad (2.7)$$

神经元 i 的输出为输入变量与其对应的样本 X 之间 Euclid 距离平方的指数平方 $D_i^2 = (X - X_i)^T (X - X_i)$ 的指数形式。式中， X 为网络输入变量； X_i 为第 i 个神经元对应的学习样本。

求和层的神经元为 $[S_D, S_{N1}, S_{N2}, \dots, S_{Nk}]^T$ ，个数为 $k+1$ ，使用两种类型的神经元进行求和。一

类的计算公式为 $\sum_{i=1}^n \exp \left[-\frac{(X - X_i)^T (X - X_i)}{2\sigma^2} \right]$ ，对所有模式层神经元的输出进行算数求和，其模式层与各神经元的连接权值为 1，传递函数为：

$$S_D = \sum_{i=1}^n p_i \quad (2.8)$$

另一类计算公式为 $\sum_{i=1}^n Y_i \exp \left[-\frac{(X - X_i)^T (X - X_i)}{2\sigma^2} \right]$ ，对所有模式层的神经元进行加权求和，模式层中第 i 个神经元与求和层第 j 个分子之间的连接权值为第 i 个输出样本 y_i 中第 j 个元素，传递函数为：

$$S_{Nj} = \sum_{i=1}^n y_{ij} p_i, \quad j=1,2,\dots,k \quad (2.9)$$

输出层的神经元数目等于学习样本中输出向量的维数 k ，各神经元将求和层的输出相除，神经元 j 的输出对应估计结果 $\hat{y}(x)$ 的第 j 个元素，即：

$$y_j = \frac{S_{Nj}}{S_D} \quad j=1,2,\dots,k \quad (2.10)$$

2.2 两种深度学习模型

机器学习是一种实现人工智能的方法，深度学习是一种实现机器学习的技术^[29]。深度学习（DL）是机器学习（ML）领域中一个新的研究方向，被引入机器学习使其更接近于人工智能（AI）。深度学习是学习样本数据的内在规律和表示层次，这些学习过程中获得的信息对诸如文字，图像和声音等数据的解释有很大的帮助。其最终目标是让机器像人一样能够具有分析学习能力，能够识别文字、图像和声音等数据。深度学习是一个复杂的机器学习算法，在语音和图像识别方面取得的效果，远远超过先前相关技术。主要的深度学习模型分为有监督的神经网络，常用的模型为卷积神经网络（CNN），和无监督的预训练网络，常用的模型为生成对抗神经网络（GAN）和自编码器（AE）。

2.2.1 卷积神经网络（CNN）

卷积神经网络是一类包含卷积计算且具有深度结构的前馈神经网络，具有表征学习的能力，其隐含层内的卷积核参数共享和层间连接的稀疏性使卷积神经网络相比于传统的神经网络，能够以较小的计算量对格点化特征，如像素和音频等进行学习，因此，被广泛地应用于图像处理。卷积神经网络共有五个层级结构，包括输入层、卷积层、激活层、池化层和全连

接层，其结构如图 2.3 所示。




图 2.3 CNN 的结构图

CNN 的输入层可以处理多维数据。一维 CNN 的输入层接收一维或二维数组；二维 CNN 的输入层接收二维或三维数组；三维 CNN 的输入层接收三维或四维数组。在将训练样本输入到 CNN 前，首先对输入的数据进行归一化至[0,1]区间，有利于提升 CNN 的学习效率。如图 2.3 所示，CNN 的隐藏层主要由卷积层、激活层、池化层、全连接层组成。其中，卷积层的输入数据来自输入层的二维或三维数据，三维数组由许多通道的二维数组构成，卷积层的卷积核包含权重系数，用以对输入数据进行特征提取。卷积神经网络的计算公式如下，对于卷积层的二维或三维输入矩阵以及卷积核的大小，其表达式为：

$$a^{[l-1]} = n_H^{[l-1]} \times n_W^{[l-1]} \times n_C^{[l-1]}, \quad w^{[l]} = f^{[l]} \times f^{[l]} \times n_C^{[l-1]} \quad (2.11)$$

式中， $a^{[l-1]}$ 表示来自 $l-1$ 层的输入矩阵， $n_H^{[l-1]}$ 为 $l-1$ 层的输入矩阵的高， $n_W^{[l-1]}$ 为 $l-1$ 层的输入矩阵的宽， $n_C^{[l-1]}$ 表示输入通道数量， $n_C^{[l-1]}=1$ 为二维数组， $n_C^{[l-1]}>1$ 为三维数组； $w^{[l]}$ 代表卷积核矩阵，并且 $f^{[l]}$ 为卷积核大小，即卷积核的高和宽，卷积核的通道数与 $l-1$ 层的输入矩阵的通道数相同。将输入数据矩阵与卷积核进行卷积计算，得到输出矩阵，表达式为：

$$z^{[l]} = n_H^{[l]} \times n_W^{[l]} \times n_C^{[l]} \quad (2.12)$$

$$n_H^{[l]} = \left\lceil \frac{n_H^{[l-1]} + 2p^{[l]} - f^{[l]}}{s^{[l]}} + 1 \right\rceil \quad (2.13)$$

$$n_W^{[l]} = \left\lceil \frac{n_W^{[l-1]} + 2p^{[l]} - f^{[l]}}{s^{[l]}} + 1 \right\rceil \quad (2.14)$$

其中, $f^{[l]}$ 表示卷积核的大小, $p^{[l]}$ 表示填充, $s^{[l]}$ 表示计算步长, $n_C^{[l]}$ 表示卷积核的数量, 三者共同决定了卷积层输出矩阵的大小, 是卷积神经网络的超参数。卷积核与输入数据矩阵的卷积可理解为对其进行了一次线性运算, 计算公式如下:

$$z^{[l]} = w^{[l]} a^{[l-1]} + b^{[l]} \quad (2.15)$$

式中, $a^{[l-1]}$ 为输入二维或三维矩阵, $w^{[l]}$ 表示卷积核矩阵, $b^{[l]}$ 是一个实数, 表示偏置参数, $z^{[l]}$ 作为卷积层的输出, 输入到下一层激活层, 进行非线性运算。

激活层使用的激活函数对卷积层的输出结果进行非线性映射, 该非线性映射关系可以由式 (2.16) 表示:

$$a^{[l]} = g(z^{[l]}) \quad (2.16)$$

式中, $g(\bullet)$ 为激活函数, $a^{[l]}$ 表示激活层的输出矩阵。使用较为广泛的激励函数主要有: Sigmoid 函数, Tanh 函数, ReLu 函数以及 Leaky ReLu 函数。

卷积层进行特征提取, 激活层进行非线性运算后的结果传递至池化层进行特征选择和信息过滤, 且池化层不包含权重系数。常用的池化层有最大池化和平均池化。

CNN 中的全连接层等价于前馈神经网络中的隐含层, 其作用是对提取的特征进行非线性组合以得到输出。

2.2.2 生成对抗神经网络 (GAN)

GAN 是一种深度学习网络, 能够生成与真实输入数据具有相似特征的数据, 其由两个一起训练的网络组成, 即生成器和判别器。GAN 的结构由图 2.4 表示。




图 2.4 GAN 的结构图

如图 2.4 所示, 生成器的输入是满足某一分布的任意向量, 其生成与训练样本结构相似的数据。判别器的输入为训练数据和来自生成器的生成数据, 并且判别器将其判定为“真实值”或“生成值”。

在训练 GAN 的过程中, 生成器和判别器需要同时训练以最大化两个网络的性能, 即训练生成器以生成类似训练数据, 足以“欺骗”判别器的数据; 训练判别器以区分真实数据和生成的数据。GAN 训练过程中使用的目标优化函数用公式 (2.7) 表示。

$$\min_G \max_D V(D, G) = E_{x \sim P_{data}(x)} [\log D(x)] + E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (2.17)$$

式中, D 表示判别器, G 表示生成器, $D(x)$ 为真实数据被判别为真的概率, $D(G(z))$ 为生成数据被判别为真的概率; $P_{data}(x)$ 为真实数据的概率分布, $P_z(z)$ 为生成数据的概率分布。 $E(\cdot)$ 表示数学期望, V 为待优化目标函数。

公式 (2.7) 可以分为以下两个公式, 分别作为生成器和判别器的目标函数, 即:

$$\max_D V(D, G) = E_{x \sim P_{data}(x)} [\log D(x)] + E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (2.18)$$

$$\min_G V(D, G) = E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (2.19)$$

生成器和判别器的目标函数需要同时进行交替优化, 并且最终达到一个纳什平衡状态, 即判别器可以区分真实数据和生成数据, 而生成器可以“以假乱真”的数据。

2.3 智能优化算法

智能优化算法是一种具有全局优化性能、通用性强, 适合于并行处理的算法。这种算法一般具有严密的理论依据, 可以在一定时间内找到最优解或近似最优解。本文所使用的优化算法有用于单目标优化的 GA 算法, 和用于多目标优化的 Pareto 遗传算法。

2.3.1 GA 算法

GA 算法是模拟达尔文生物进化论的自然选择和遗传学机理的生物进化过程的计算模型, 是一种通过模拟自然进化过程搜索最优解的方法。

其主要特点是直接对结构对象进行操作, 不存在求导和函数连续性的确定; 具有内在的隐并行性和更好的全局寻优能力; 采用概率化的寻优方法, 不需要确定的规则就能自动获取和指导优化的搜索空间, 自适应地调整搜索方向。

遗传算法以一种群的所有个体为对象, 并利用随机化技术指导对一个被编码的参数空间

进行高效搜索。其中，选择、交叉和变异构成了遗传算法的遗传操作；参数编码、初始群体的设定、适应度函数的设计、遗传操作设计、控制参数设定五个要素组成了遗传算法的核心内容。首先，通过随机方式形成若干个种群个体，并对初始种群进行编码；其次，通过适应度函数对每个个体进行评价，淘汰适应度值低的个体，并且选择适应度值较高的个体参加遗传操作，经过遗传操作后的个体集合形成下一代的种群；对这个新种群进行下一轮进化，直至满足迭代代数或者收敛到全局最优值。

2.3.2 Pareto 遗传算法

多目标求解会筛选出一个相对较优的解的集合，在这个集合里就要用到 Pareto 算法找出相对优的解，或者最优解。多目标优化问题的数学模型一般可以写成如下形式：

$$\begin{cases} V - \min f(x) = [f_1(x), f_2(x), \dots, f_p(x)]^T \\ s.t. x \in X \end{cases} \quad (2.20)$$

对于多目标函数，通常存在一个最优解集，使得所有目标函数达到一个整体最优状态，即继续优化某一个目标函数必然导致另一个目标函数性能的下降。所有最优解对应的目标函数构成了 Pareto 前沿，如图 2.5 所示。




图 2.5 Pareto 前沿

对于两个目标的问题，其 Pareto 最优前沿通常是条线。而对于多个目标，其 Pareto 最优前沿通常是个超曲面。

2.4 本章小结

本章主要介绍一些人工智能的相关背景知识，主要包括本文所使用的一些机器学习和深度学习模型，如结构较为简单的 ANN 模型（BPNN 和 GRNN），结构较为复杂的深度学习模型（CNN 和 GAN），以及智能优化算法（GA 算法以及 Pareto 遗传算法）。

第三章 基于机器学习算法分析天线性能

基于机器学习算法实现对天线的辅助优化设计,从而缩小基于 HFSS、CST 等软件的迭代仿真优化时间,首先需要获取一定量的数据样本用以训练设计的机器学习模型,训练好的机器学习模型可以代替 CST、HFSS 等,实现对天线性能的分析 and 精细优化。本章首先基于机器学习算法来分析天线性能。设计了一种 CPW 馈电的缝隙加载单极子天线,该天线具有较宽的阻抗带宽,并且在该阻抗带宽内实现了带阻特性。并且基于 GRNN 和 PCA 相结合的机器学习算法,即 GRNN-PCA,预测该天线的 S_{11} 曲线和 MaxGain 曲线以及 Gain 曲线;此外,还设计了一种 CPW 馈电的分形单极子天线,并将集成学习的思想运用到天线的性能分析,即设计了一种 BPNN-Ensemble-PCA 机器学习模型,预测该天线的 S_{11} 曲线和 MaxGain 曲线,以及 Gain 曲线。并且,将提出的机器学习模型与其他算法在预测精度上进行比较,验证本章采用的机器学习算法的有效性。

3.1 基于 GRNN-PCA 分析天线性能

随着无线通信技术的不断发展,超宽带天线的应用逐渐广泛,其具有较宽的阻抗带宽和增益带宽,超宽带的频带范围为 3.1-10.6GHz^[30]。目前,超宽带天线主要有共面波导馈电的单极子天线、分形天线等^[31-33]。文献^[34]是通过在辐射贴片中蚀刻弯曲缝隙槽线以及在馈线中蚀刻 U 形槽线来实现具有带陷特性的工作在 WLAN 和 WiMAX 频带的超宽带天线。文献^[35]通过在辐射贴片中蚀刻 H 形缝隙,提出了一种用于 WLAN 和 WiMAX 的小型化 CPW 馈电八边形单极子天线。文献^[36]中给出了一种用于多波段的 H 分形天线,其在谐振频点处均具有较大的方向性。因此,本节设计了一种 CPW 馈电的加载 ψ 形缝隙的八边形单极子天线,阻抗带宽为 4-14GHz,覆盖 C 波段, X 波段和一部分 Ku 波段,并且为了防止天线对 WIMAX/WLAN/WIFI 等频段产生干扰,辐射贴片上加载的 ψ 形缝隙在 4-14GHz 内产生带陷特性,并且通过改变 ψ 形缝隙的尺寸来调节陷波的频率范围,而其宽边辐射的增益带宽为 4-10GHz。此外,提出了一种将 GRNN 与 PCA 相结合的机器学习模型: GRNN-PCA,并用以分析所设计天线的 S_{11} 性能参数和 MaxGain 性能曲线以及 Gain 性能曲线,结果表明该机器学习模型具有较高的预测精度。

3.1.1 CPW 馈电的缝隙加载单极子天线设计

与同轴馈电和微带馈电的相比，CPW 馈电的天线通常具有更宽的阻抗带宽^[37]。因此，本节采用 CPW 对 ψ 形缝隙加载的八边形单极子天线进行馈电，该天线的辐射贴片与 CPW 馈线蚀刻在介质基底的同一表面。图 3.1 绘制了该天线的设计过程，使用的介质基底为 FR-4，其相对介电常数为 $\epsilon_r = 4.3$ ，损耗角正切为 $\tan \delta = 0.025$ ，厚度为 1.6mm。Ant.1 为构造天线的基本结构；接着，切去 Ant.1 中基本天线结构的辐射贴片的四个角，为 Ant.2 中的天线结构；最后，对 Ant.2 中天线的八角形贴片加载 ψ 形缝隙，得到 Ant.3 中的天线结构。




图 3.1 CPW 馈电的 ψ 形缝隙加载的八边形单极子天线的构造过程。天线的尺寸参数（单位：mm）：
 $W_g=9.55$, $L_g=9$, $L_p=13.2$, $W_p=13.2$, $S=3.1$, $W=0.3$, $gap=0.6$, $L_t=27.6$, $W_t=22.8$, $W_s=1.0$, $L_s=2.5$, $S_{gap}=3.5$

3.1.2 CPW 馈电的缝隙加载单极子天线的性能

基于 CST 对设计的天线结构进行仿真，图 3.2 绘制了天线结构 Ant.1-3 在 2-14GHz 频段内的回波损耗（S 参数曲线）和在 $\Phi=0, \Theta=0$ 的宽边增益曲线。




图 3.2 CPW 馈电的单极子天线的性能对比。(a) Ant.1-3 的 S_{11} 曲线；(b) Ant.1-3 在 ($\Phi=0, \Theta=0$) 的 Gain 曲线

如图 3.2 (a) 所示, Ant.1 对应的天线, 即 CPW 馈电的正方形单极子天线具有最小的阻抗带宽; CPW 馈电的八边形单极子天线极大地拓宽了阻抗带宽, 为 4-14GHz, 可以覆盖 C 波段、X 波段和 Ku 波段; 并且为了避免对 WIFI/WIMAX/WLAN 等频段产生干扰, 通过在八边形辐射贴片上切割 ψ 形缝隙来产生 4-14GHz 中的阻带特性, 即 Ant.3 对应的天线, 如图 3.2 (a) 所示, 调节 ψ 形缝隙的尺寸大小, 改变阻带的频率范围。图 3.2 (b) 为 Ant.1-3 的宽边辐射增益曲线, 其在 4-10GHz 范围内约为 2dBi, 这是由于随着频率的增加, 在阻抗带宽的高频段处, 天线的 E 面和 H 面辐射方向图发生了畸变, $\Phi=0$, $\Theta=0$ 不再为最大辐射方向, 因此, 在 10-14GHz 频段内的宽边辐射增益下降, 该天线的增益带宽为 4-10GHz。而 2-14GHz 内的最大增益 (MaxGain) 以及总辐射效率 (TotEfficiency) 曲线如图 3.3 所示。CPW 馈电的加载 ψ 形缝隙的八边形单极子天线在阻抗带宽 (4-14GHz) 内的辐射效率接近 80%, 而阻带内的辐射效率较低。





图 3.3 CPW 馈电的单极子天线的辐射性能对比。(a) Ant.1-3 的最大增益 (MaxGain) 曲线; (b) Ant.1-3 的总辐射效率 (TotEfficiency) 曲线

图 3.4 则给出了 4GHz, 8GHz, 12GHz 处的 E 面辐射方向图和 H 面辐射方向图。






图 3.4 CPW 馈电的单极子天线的辐射方向图 (左图: E 面, 右图: H 面)。(a) 4GHz; (b) 8GHz; (c) 12GHz

如图 3.4 (a) 所示, Ant.1-3 中天线的 E 面辐射方向图为 yoz 平面, 均呈 8 字形, 类似于平面单极子天线的 E 面辐射; 而其 H 面辐射表现出全向辐射特性, 为 xoz 平面。在阻抗带宽的低频段, 即 4GHz 和 8GHz, Ant.1-3 中的天线均表现出类似于偶极子的 E 面和 H 面的辐射方向图, 而在阻抗带宽的高频段, 即 12GHz, 由于天线的尺寸大于两个波长, 天线的 E 面和 H 面辐射方向图发生畸变。

3.1.3 基于 GRNN-PCA 分析天线性能

为了避免耗时的仿真过程, 可以使用 ANN 来分析天线性能。GRNN 是 ANN 的一种, 具有很强的非线性映射能力、学习速度和较强的泛化性能^[38]。因此, 提出了一种结合 GRNN 和 PCA 的新型机器学习方法, 以建立天线的尺寸参数与性能参数 S_{11} 和 MaxGain 曲线, 以及 Gain 曲线之间的非线性映射关系。

为了分析缝隙尺寸参数对天线 S_{11} 和 MaxGain 性能参数, 以及 Gain 性能参数的影响, $[W_s, L_s, S_{gap}]$ 作为 GRNN 的输入参数, 2-14GHz 频段内的 S_{11} , MaxGain 曲线, Gain 曲线是 GRNN

的输出参数，将该输出变量的特征维度设置为 1000，可能包含冗余数据和噪声，这将导致复杂的计算。因此，首先基于 PCA 对样本的输出数据进行降维，提取出数据的主要特征。

本节中， W_s 的取值范围为：[0.6:0.1:1.0]， L_s 的取值范围为：[2.0:0.1:2.5]， S_{gap} 的取值范围为：[2.5:0.1:3.5]，单位为 mm，总共产生了 330 个样本。按照训练集和测试集的比例为 9:1 的比例划分样本数据，其中，300 个样本用于训练，剩余样本为测试样本。经 PCA 降维处理后，训练样本的 S_{11} 曲线输出数据的维度降为 5，MaxGain 曲线输出数据的维度降为 3，Gain 曲线输出数据的维度降为 5。

基于输入数据和降维后的输出数据，建立了 GRNN 模型，如图 3.5 所示，并且给出了每一层的神经元数量。用训练好的 GRNN 预测测试样本的降维输出，然后对其进行数据重构。可以得到不同尺寸参数的 S_{11} 曲线和 MaxGain 曲线，与 CST 的仿真结果相比，结果基本保持一致。 S_{11} 曲线和 MaxGain 曲线的预测结果以及预测误差如图 3.6 和 3.7 所示。




图 3.5 GRNN 的结构图：(a) S_{11} ；(b) MaxGain




图 3.6 GRNN-PCA 对 S_{11} 曲线的预测结果。(a) 所有测试样本的预测误差；(b) GRNN-PCA 对测试样本的预测结果与 CST 的仿真结果的对比 ($W_s=0.7\text{mm}$, $L_s=2.5\text{mm}$, $S_{gap}=3.3\text{mm}$)




图 3.7 GRNN-PCA 对 MaxGain 曲线的预测结果。(a) 所有测试样本的预测误差；(b) GRNN-PCA 对测试样本的预测结果与 CST 的仿真结果的对比 ($W_s=0.7\text{mm}$, $L_s=2.5\text{mm}$, $S_{gap}=3.3\text{mm}$)

从图 3.6 的对比结果可以看出，对于所有测试样本，GRNN-PCA 对于 S_{11} 曲线的预测，在 2-14GHz 所有频点上的平均预测误差均低于 0.5dB，并且对于 ψ 形缝隙的尺寸参数为： $W_s=0.7\text{mm}$, $L_s=2.5\text{mm}$, $S_{gap}=3.3\text{mm}$ 的测试样本，基于 GRNN-PCA 对 S_{11} 的预测结果基本与 CST 的仿真结果一致；而图 3.7 的对比结果则表明，对于所有测试样本，GRNN-PCA 对于 MaxGain 曲线的预测，在 2-14GHz 所有频点上的平均预测误差均低于 0.15dB，并且基于 GRNN-PCA 对 MaxGain 的预测结果同样与 CST 的仿真结果一致。

表 3.1 列出了不同机器学习方法对 S_{11} 曲线和 MaxGain 曲线所有测试样本所有频点上的平均预测误差。

表 3.1 不同机器学习方法的预测性能对比（单位：dB）

机器学习方法	测试样本的平均预测误差 (S_{11})	测试样本的平均预测误差 (MaxGain)
GRNN-PCA	0.1385	0.0406
BPNN-PCA	0.1043	0.0328
RBFNN-PCA	0.8912	0.2360
GRNN	0.1393	0.0359
RBFNN	0.9036	0.2379

根据表 3.1 基于不同机器学习方法对测试样本的 S_{11} 曲线和 MaxGain 曲线预测误差的对比结果可知，RBFNN-PCA 和 RBFNN 具有最高的预测误差；GRNN-PCA 与 GRNN 对 S_{11} 曲线和 MaxGain 曲线的平均预测误差基本一致，但相比于 GRNN，GRNN-PCA 的结构相对简单，训练该机器学习模型所需的计算量较少；BPNN-PCA 的预测误差最小，但训练该机器学习模型所需的计算量最大，所需的时间最长。因此，综合来看，GRNN-PCA 相比于其他机器学习模型在预测天线性能方面具有较强的优势。

对于天线的 ψ 形缝隙尺寸，即： $W_s=0.7\text{mm}$, $L_s=2.5\text{mm}$, $S_{gap}=3.3\text{mm}$ ，其宽边辐射增益，

即基于 GRNN-PCA 模型对 Gain ($\Phi=0$, $\Theta=0$) 的预测值随频率的变化如图 3.8 所示。




图 3.8 CPW 馈电的加载 Ψ 形缝隙的八边形单极子天线的 Gain ($\Phi=0$, $\Theta=0$) 的预测结果如图所示, 在 5.6GHz 和 8.4GHz 下的 Gain 的预测值分别为 3.64dBi 和 2.33dBi。

3.2 基于 BPNN-Ensemble-PCA 分析天线性能

本节提出了一种新的机器学习模型用于分析设计的融合 Koch 结构的混合八角分形单极子天线, 其阻抗带宽为 C 波段, X 波段, 和一部分 Ku 波段, 相比于基本单极子天线结构, 本节设计的天线具有更宽的阻抗带宽, 更好的 S 参数性能, 更高的最大增益 (MaxGain), 以及小型化特性。该机器学习模型将集成学习的思想用于 BPNN, 为 PCA 算法与集成 BPNN 的结合, 用以预测天线的 S 参数曲线和最大增益 (MaxGain) 曲线。与其他机器学习方法相比, 具有更高的预测精度。

3.2.1 混合八角分形单极子天线的设计

该天线的设计基于 CPW 馈电的单极子天线, 其设计过程如图 3.9 所示。使用的介质基底为 Rogers RO4003C, 其相对介电常数为 $\epsilon_r=3.55$, 损耗角正切为 $\tan \delta = 0.0027$, 厚度为 1.5mm。




图 3.9 混合八角分形单极子天线的设计过程。(a) Ant.1; (b) Ant.2; (c) Ant.3

如图所示, Ant.1 中的方形单极子天线为基本结构, Ant.2 为八边形单极子天线, Ant.3 结

合了 Koch 分形结构，并在八边形贴片上采用另一种分形结构。其中，Ant.1 中天线结构的尺寸参数列在表 3.2 中。

表 3.2 Ant.1 中天线尺寸参数（单位：mm）

L_m	g	S	W_f	L_f
15.4	0.5	0.235	3.4	8.5
L_g	W_g	L_s	W_s	h
8	12.7	28.4	29.27	1.5

图 3.9（b）是基础八边形单极子天线结构，而第一次分形和第二次迭代 Koch 分形结构加载在该八边形单极子天线上。并且本节在八边形贴片上蚀刻一种新的分形结构，构成图 3.9（c）中的天线结构。新的分形结构的第一次迭代和第二次迭代比例，即 $ratio_1$ 和 $ratio_2$ ，表现在 Ant.2 中天线的分形结构尺寸参数上，为 $a_1=a*ratio_1$ ， $a_2=a_1*ratio_2=a*ratio_1*ratio_2$ 。

由于分形的自相似性和空间填充^[39]，电流在有限体积空间中最大化，从而产生了新的工作频率，拓宽带宽，改善 S_{11} 性能，并实现了天线的小型化。给出了图 3.9 中在 $ratio_1=0.5$ ， $ratio_2=0.5$ 的情况下，Ant.1-3 中天线的 S_{11} 参数曲线和 MaxGain 曲线，如图 3.10 所示。




图 3.10 基于 CST 对 Ant.1-3 中天线的仿真结果。（a） S_{11} ；（b）MaxGain

如图 3.10 所示，Ant.1 中由 CPW 馈电的基本单极子天线的工作带宽较窄，而 Ant.2 中 CPW 馈电的八边形单极子天线尽管具有较大的工作带宽，但其在 5-11GHz 具有较大的反射系数。Ant.3 中融合 Koch 结构的分形单极子天线相对于 Ant.1-2 表现出了更好的 S_{11} 性能和更高的 MaxGain。

图 3.11 给出了 Ant.3 中由 CPW 馈电的混合分形八角形单极子天线($ratio_1=0.5$, $ratio_2=0.5$) 分别在 4GHz，8GHz，12GHz 处的 E 面和 H 面辐射方向图。




图 3.11 Ant.3 中天线在 4GHz, 8GHz, 12GHz 处的辐射方向图。(a) E 面；(b) H 面

由图 3.11 在 4GHz, 8GHz, 12GHz 的 E 面和 H 面辐射方向图可知，其在阻抗带宽低频段，即 4GHz，其 E 面辐射方向图呈 8 字形，H 面辐射方向图呈全向辐射，符合平面单极子天线的辐射特点，而随着工作频率的升高，天线的尺寸相对于波长增加，E 面和 H 面的辐射方向图发生畸变，即 12GHz 处的最大辐射方向不再是 $\Phi=0$, $\Theta=0$ ，并且 H 面不再是全向辐射特性。

Ant.3 中天线 ($ratio_1=0.5$, $ratio_2=0.5$) 在 $\Phi=0$, $\Theta=0$ 方向（即宽边辐射方向）上的增益曲线如图 3.12 所示。




图 3.12 Ant.3 天线 ($ratio_1=0.5$, $ratio_2=0.5$) 在 $\Phi=0$, $\Theta=0$ 方向的 Gain 曲线

从上图可得，在 4-8GHz 频段，天线的宽边辐射增益 $\text{Gain}(\Phi=0, \Theta=0)$ 为 2-3dB，与图 3.10 (b) 中 4-8GHz 频段的 MaxGain 数值基本保持一致，且符合图 3.11 中 4GHz, 8GHz 处 E 面辐射方向图呈 8 字形，H 面辐射方向图呈全向辐射的特点，而在 12GHz 其辐射方向图发生畸变，E 面和 H 面辐射方向图不再呈 8 字形和全向辐射的特性，即最大辐射方向不再是 $\Phi=0$, $\Theta=0$ 。因此，该天线的宽边辐射增益带宽为 4-8GHz。而整个阻抗带宽内天线的辐射效率和总效率分别绘制在图 3.13 中。




图 3.13 Ant.3 天线 ($ratio_1=0.5$, $ratio_2=0.5$) 的效率。(a) 辐射效率; (b) 总效率

如图所示, 在阻抗带宽 (4-14GHz) 内, 其辐射效率 (RadEfficiency) 基本在 90% 以上, 总效率 (TotEfficiency) 基本在 80% 以上。

3.2.2 基于 BPNN-Ensemble-PCA 分析天线性能

由于计算机资源和仿真时间的限制, S_{11} 曲线和 MaxGain 曲线的采样点分别为 1001 和 21。因此, 由于采样点较少, 最大增益曲线不够平滑, 如图 3.10 (b) 所示, 为了使最大增益曲线更平滑, 采用三次样条插值拟合 MaxGain 曲线, 并将曲线的特征维度扩展到 1001。

用于天线性能分析和设计的一些常用机器学习方法通常基于单个神经网络, 包括 BPNN、RBFNN、GRNN、ELM 和 SVR 等。然而, 单个神经网络一般不是最佳分类器, 因为其对于包含随机误差或数据量不足的复杂数据集, 对于单个神经网络的训练可能会收敛到局部最小点, 从而导致过度拟合, 泛化性能下降, 即使对于相同的训练数据, 不同的神经网络结构或不同的初始化方法也可能导致不同的测试结果^[40]。

因此, 将集成思想运用于神经网络的架构中, 提出了集成神经网络, 结合不同结构的神经网络的优点, 为不同的训练样本找到最适合的网络结构和训练方法, 可以减少偏差, 防止过度拟合, 从而提高泛化性能^[41]。

由于反射系数 S_{11} 和最大增益 MaxGain 可以通过 $ratio_1$ 和 $ratio_2$ 这两个迭代因子进行调整, 并且根据表 3.1 中几种不同的机器学习方法对天线的 S_{11} 曲线参数和 MaxGain 曲线的预测误差的对比可知, BPNN-PCA 对测试样本具有最小的预测误差, 因此可以通过目前应用最广泛的 BPNN 建立输入参数 [$ratio_1$, $ratio_2$] 和输出参数 [S_{11} , MaxGain] 之间的非线性映射关系, 其非线性映射能力强, 自学习和自适应能力强, 具有良好的泛化性能和容错能力。

本节中, 输入参数是两个迭代因子 $ratio_1$ 和 $ratio_2$, 其均在 [0.1:0.1:0.9] 的范围内, 输出参数是 S_{11} 曲线和 MaxGain 曲线, 两者的特征维度均为 1001。共有 81 个样本, 按照 9: 1 的比

例划分样本数据，即随机抽取其中的 70 个样本进行训练，剩余样本用于测试。

由于输出参数之间的维度较大，无法快速收敛到全局最小值，因此很难基于 BPNN 直接建立输入参数和输出性能之间的非线性映射关系。同时，由于所有样本的性能参数的特征变量之间可能存在着线性相关关系，这导致了冗余数据和复杂计算。因此可以采用主成分分析法（PCA）将线性相关变量转换为一组线性不相关的主成分，以使用更小的维度表示数据，消除数据噪音，简化计算^[42]。经 PCA 算法处理后， S_{II} 的特征维度可以降维到 6，MaxGain 降维到 4。

虽然 BPNN 得到了广泛的应用，但其仍然存在一些缺点，如容易收敛到局部极小值，对初始权值敏感，可能存在过拟合等。因此，提出了一种集成 BPNN 和 PCA 相结合的方法来预测 S_{II} 曲线和 MaxGain 曲线。Bagging, Boosting, 和 Stacking 是集成学习中常用的技术^[43]。在本节中，将 Bagging 中常用的 Bootstrap 技术与 Stacking 技术相结合，以训练 BPNN-Ensemble-PCA 模型并预测测试样本。

首先，基于 Bootstrap 技术对初始训练样本进行划分，将其划分为 T 个不同的训练集和测试集，即： $\{dataset_1, dataset_2, dataset_3, \dots, dataset_T\}$ 。Stacking 技术首先用于根据划分的 T 个训练集和测试集，训练出 T 个初始 BPNN 模型；而 T 个测试集中的测试样本组成了一个新的数据集合，并用来训练次级 BPNN 模型。新的训练数据集中， T 个初级 BPNN 模型对于测试样本的预测输出作为次级 BPNN 模型的输入，而其真实样本作为次级 BPNN 模型的输出，通过训练次级 BPNN 模型建立输入和输出之间的非线性映射关系。Stacking 技术的工作机理如图 3.12 所示。




图 3.12 Stacking 技术的工作机理

基于 Bootstrap 算法，生成 T 组不同的训练集和测试集，用于训练和测试 T 个初级 BPNN 模型，由于不同的训练集和测试集，其对应的数据特征分布不同，因此，需要对每组训练集和测试集的输入和输出采用不同的 BPNN 结构建立非线性映射关系。Bootstrap 的基本思想是：假设初始训练样本数据为 $D=\{(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots, (x_m, y_m)\}$ ，每次从训练样本 D 中任

意采集一个样本并放回，这一过程总共进行 m 次。因此，一个用于训练 BPNN 模型的训练集中包含重复的训练样本，而那些从未被选中的样本构成了测试集，占据原始训练样本总数的 36.8%。对原始训练样本基于 Bootstrap 方法进行 T 次操作，即将原始训练样本划分为 T 个不同的训练集和测试集： $\{dataset_1, dataset_2, dataset_3, \dots, dataset_T\}$ 。

基于 BPNN 建立初级机器学习模型和次级机器学习模型。本节中， $T=20$ ，即建立 20 个初级机器学习模型，并且对于每个 BPNN，其隐藏层的神经元数目为 5-25，依据测试集的预测误差来选择最优 BPNN 网络结构，即隐藏层神经元数目。两个 BPNN-Ensemble-PCA 模型用以分别预测天线的 S_{11} 曲线和 Max Gain 曲线。

如图 3.12 所示，训练好的初级 BPNN 模型 $\{net_1, net_2, net_3, \dots, net_T\}$ 用来训练测试样本，并且测试样本平均值作为次级 BPNN 的输入，训练好的次级 BPNN 对初级 BPNN 模型预测的测试样本平均值进行预测，得到最终的预测结果，可以用如下公式进行表示。

$$Test_Output_Prediction = F_s \left(\frac{1}{T} \sum_{i=1}^T F_p^i (Test_Input) \right) \quad (3.1)$$

式中， F_p^i 是初级机器学习模型， F_s 是次级机器学习模型。

3.2.3 天线性能的预测结果

天线在整个频段内对于所有训练样本和测试样本的 S_{11} 曲线的预测误差如图 3.13 (a) 所示，并且对于测试样本 ($ratio_1=0.4, ratio_2=0.2$) 的预测结果和仿真结果的对比如图 3.13 (b) 所示。对于 MaxGain 曲线的预测结果绘制在图 3.14 中。




图 3.13 S_{11} 的预测结果。(a) 对于训练样本和测试样本的预测误差；(b) 测试样本的预测结果和仿真结果的对比




图 3.14 MaxGain 的预测结果。(a) 对所有训练样本和测试样本的预测误差；(b) 测试样本的预测结果和仿真结果的对比

从上图可以看出,除了少数几个频点外, S_{11} 对训练样本和测试样本的预测误差在 3-13GHz 范围内几乎低于 2.5%, MaxGain 在 3.8-13.3GHz 范围内低于 2%, 表明 BPNN-Ensemble-PCA 可以较为准确地预测天线性能。此外, 预测所得的 S_{11} 和 MaxGain 曲线与 CST 的仿真结果基本一致, 如图 3.13 (b) 和图 3.14 (b) 所示。CST 对测试样本的仿真时间为 5min, 而 BPNN-Ensemble-PCA 的预测时间为 0.013s, 表明训练好的 BPNN-Ensemble-PCA 可以代替 CST 在较短的时间内对天线的性能进行分析。

3.2.4 与其他机器学习方法的对比

GRNN 是一种 RBF 神经网络, 具有较强的非线性映射能力和学习速度, 预测效果较好, 在训练样本较少的情况下也能处理不稳定数据。因此, 本文将 BPNN-Ensemble-PCA 和一些与 GRNN 相关的机器学习方法进行比较, 包括 GRNN, GRNN-PCA, GRNN-Ensemble, GRNN-Ensemble-PCA, 对比结果如下所示。




图 3.15 不同机器学习方法对于训练样本和测试样本的预测误差的对比。(a) S_{11} ; (b) MaxGain

表 3.3 不同机器学习方法对 S_{11} 的平均预测误差的对比 (%)

机器学习方法	训练样本	测试样本
Single-GRNN	1.0554	5.8005
GRNN-PCA	2.2477	5.9094
GRNN-Ensemble	3.2971	5.0456
GRNN-Ensemble-PCA	2.8431	3.9630
BPNN-Ensemble-PCA	1.7108	2.1117

表 3.4 不同机器学习方法对 MaxGain 的平均预测误差的对比 (%)

机器学习方法	训练样本	测试样本
Single-GRNN	1.0328	2.6202
GRNN-PCA	1.0159	2.8552
GRNN-Ensemble	1.6372	1.2014
GRNN-Ensemble-PCA	1.2895	1.8674
BPNN-Ensemble-PCA	1.0949	1.3258

如图 3.15 (a) 和 (b) 所示, 对于整个频带上的所有训练样本和测试样本, BPNN-Ensemble-PCA 对于 S_{11} 和 MaxGain 的预测具有最小的预测误差。对于所有训练样本和测试样本的所有频点, BPNN-Ensemble-PCA 也具有最小的平均预测误差, 其对于 S_{11} 曲线的平均预测误差分别为 1.7108%和 2.1117%, 对 MaxGain 曲线的平均预测误差分别为 1.0949%和 1.3258%, 如表 3.3 和表 3.4 所示。这些数据表明, 所提出的机器学习方法能代替繁琐、耗时的软件模拟, 并有效、快速地分析天线的性能。

用该 BPNN-Ensemble-PCA 模型对天线的宽边辐射增益(Gain)进行预测, 并与其他机器学习模型对训练样本和测试样本的平均预测误差进行对比,对比结果显示在图 3.16 和表 3.5 中, 并且给出 Sample5, 即: Ratio1=0.1, Ratio2=0.4 情况下 BPNN-Ensemble-PCA 预测的天线宽边辐射增益(Gain)。




图 3.16 不同机器学习方法对 Gain 曲线的预测误差对比。(a) 训练样本; (b) 测试样本

表 3.5 不同机器学习方法对 Gain 的平均预测误差的对比 (%)

机器学习方法	训练样本	测试样本
Single-GRNN	1.1867	3.3793
GRNN-PCA	1.6187	2.3425
GRNN-Ensemble	1.8032	3.0238
GRNN-Ensemble-PCA	1.7268	3.1728
BPNN-Ensemble-PCA	1.7711	1.7818

从图 3.16 中可以看到, 在 8GHz 处, BPNN-Ensemble-PCA 对训练样本和测试样本的预测误差均较大, 结合图 3.12 该天线的 Gain ($\Phi=0$, $\Theta=0$) 曲线可知, 其在 8GHz 处的 Gain 近似为 0, 因此, 计算出的相对误差较大。但图 3.16 与表 3.5 均表明, 相较于其他机器学习算法, BPNN-Ensemble-PCA 对训练样本和测试样本, 具有最好的预测性能。图 3.17 给出了 Sample5 对应的天线 Gain 曲线预测值。




图 3.17 Gain 曲线的预测结果。

从上图可以看出, BPNN-Ensemble-PCA 对天线的 Gain 曲线的预测结果与 CST 的仿真结果基本保持一致, 验证了该算法较好的预测性能。

3.3 本章小结

本章阐述了将机器学习方法用于天线性能分析的原理, 提出了新的机器学习模型, 即 GRNN-PCA 和 BPNN-Ensemble-PCA, 分别用于分析所设计的天线结构即 CPW 馈电的加载 ψ 形缝隙的八边形单极子天线和 CPW 馈电的融合 Koch 结构的分形八边形单极子天线。预测的天线性能参数为 S_{11} 曲线和 MaxGain 曲线, 并将提出的机器学习算法与其他机器学习算法的预测性能, 以及与仿真结果进行比较, 验证了设计的机器学习算法较高的预测精度和较快的预测速度。

第四章 基于 CGAN 求解二维泊松方程

CNN, GAN, CGAN 由于其具有局部感知和参数共享的优点, 在二维图像处理方面具有较大的优势^[44], CNN 近年来已经较多地运用于天线阵列分析和可重构超表面的逆设计中, CGAN 则在这方面的应用较少。基于二维有限区域内的静电场问题与图像处理问题的相似性, 本章在已有文献利用 CNN 求解这一问题的基础上, 通过 CGAN 算法重新求解, 相比于 CNN, 获得了更高的预测精度, 同时设置了更多的计算场景, 泛化能力更强。

4.1 基于 FDM 求解二维泊松方程

静电场中的电势由区域内的源分布和相对介电常数分布决定, 并且有限区域的电势求解还取决于所设置的边界条件。这一原理可以用泊松方程来表示, 公式如下:

$$\nabla \cdot (\varepsilon_r(r) \nabla \phi(r)) = -\frac{\rho(r)}{\varepsilon_0}, \quad \phi(r)|_{x=0,a; y=0,b} = 0 \quad (4.1)$$

式中, $\rho(r)$ 为区域内的源分布, $\varepsilon_r(r)$ 为区域内的相对介电常数分布, ε_0 是真空中介电常数, $\phi(r)$ 是待求解的电势, a 和 b 为有限区域的边界大小。这里我们以求解二维有限区域内的泊松方程为例, 使用的边界条件为狄利克雷边界条件, 即设置有限区域边界电势为 0。首先采用 FDM^[45]对方程 (3.1) 进行离散化, 离散化后的形式为:

$$\begin{aligned} & \frac{\varepsilon_r(i+1/2, j)[\phi(i+1, j) - \phi(i, j)] - \varepsilon_r(i-1/2, j)[\phi(i, j) - \phi(i-1, j)]}{(\Delta x)^2} \\ & + \frac{\varepsilon_r(i, j+1/2)[\phi(i, j+1) - \phi(i, j)] - \varepsilon_r(i, j-1/2)[\phi(i, j) - \phi(i, j-1)]}{(\Delta y)^2} \\ & = -\frac{\rho(i, j)}{\varepsilon_0} \end{aligned} \quad (4.2)$$

式中, (i, j) 表示二维区域内的网格点, $\varepsilon_r(i, j)$, $\rho(i, j)$ 为已知参数, $\phi(i, j)$ 是待求解的变量。对公式 (3.2) 进行进一步整理可得:

$$\begin{aligned} & \left[\frac{\varepsilon_r(i, j)}{(\Delta x)^2} + \frac{\varepsilon_r(i-1, j)}{(\Delta x)^2} + \frac{\varepsilon_r(i, j)}{(\Delta y)^2} + \frac{\varepsilon_r(i, j-1)}{(\Delta y)^2} \right] \phi(i, j) = \frac{\varepsilon_r(i, j)}{(\Delta x)^2} \phi(i+1, j) \\ & + \frac{\varepsilon_r(i, j)}{(\Delta y)^2} \phi(i, j+1) + \frac{\varepsilon_r(i-1, j)}{(\Delta x)^2} \phi(i-1, j) + \frac{\varepsilon_r(i, j-1)}{(\Delta y)^2} \phi(i, j-1) + \frac{\rho(i, j)}{\varepsilon_0} \end{aligned} \quad (4.3)$$

该公式可以通过超松弛迭代算法^[46]求解，并且基于设定的迭代误差，二维有限区域内的电势将收敛到特定值，与简单迭代法相比，超松弛迭代法具有更快的迭代速度。

基于文献^[47]中的有限区域大小，相对介电常数分布和源分布，设定 $\Delta x = \Delta y = 0.1m$ ， $\rho/\varepsilon_0 = 100V/m^2$ ，建立了 9 个不同相对介电常数分布的场景，如图 4.1 所示。




图 4.1 二维区域内的不同场景

从图 4.1 中可以看出，有 9 种用于训练和测试的场景。二维区域的网格大小是 64×64 ，待求解电势的区域为深色区域，其大小为 32×32 。图中的黄色圆点为源电荷的可能分布位置，而每个场景下的相对介电常数分布设定为：

(1) 场景 1：区域中心的六边形，其半径变化范围为 $0.1-1.3mm$ ，旋转角度变化范围为 $\pi/20$ rad 到 π rad。该六边形区域的相对介电常数为 $[1.25, 2.5, 5, 20, 40, 80]$ 中的任一值，其余部分的

相对介电常数为 10。

(2) 场景 2: 图 3.1(b) 中四个六边形的半径变化范围为 0.1-0.6mm, 角度变化范围为 $\pi/20$ - π rad。所有六边形区域的相对介电常数相等并为 [1.25, 2.5, 20, 40, 80] 中的任一值。

(3) 场景 3: 四个六边形区域的半径和旋转角的变化范围和场景 2 相同, 但其相对介电常数完全不同。

(4) 场景 4: 图中六边形区域偏离中心点并且其半径变化范围为 0.1-0.9mm, 旋转角和相对介电常数的设置与场景 1 相同。

图 3.1(e) - (h) 中的场景设置与 (a) - (d) 相同, 但由六边形变为了八边形, 并且场景 9 的设置与文献^[47]中相同。

区域内的点源分布可以表示为任意网格点与源电荷位置间的距离, 计算公式如下:

$$\text{dist}(i, j) = \sqrt{(i - i_n)^2 + (j - j_n)^2} \quad (4.4)$$

式中, (i, j) 表示整个区域内的网格点, (i_n, j_n) 代表源电荷的位置。

4.2 基于 CGAN 求解二维泊松方程

二维有限区域内的电势由相对介电常数分布, 源电荷分布, 和边界条件确定, 由于 GAN 只能保证通过训练产生与训练样本的电势分布类似的结果, 因此, 基于 CGAN 来求解二维泊松方程。CGAN 是一种 GAN, 并且在训练过程中利用标签, 即训练样本对应的相对介电常数分布和源电荷分布, 来控制 CGAN 产生对应于标签的电势。而真实图像与产生的虚假图像为预测区域内的电势分布^[48]。CGAN 的结构如图 4.2 所示, 构成 CGAN 的生成器和判别器都是 CNN。




图 4.2 CGAN 的结构

如图所示, 训练样本的标签 (整个区域内的相对介电常数分布和源电荷分布) 与任意向量相结合, 作为生成器 (Generator) 的输入, 真实图像或生成图像 (电势分布) 和标签 (相对介电常数分布和源分布) 相结合作为判别器的输入, 并且判断图像与标签是否相一致。如果真实图像与标签相一致, 判别器的输出为真, 而对于真实图像与标签不一致, 或者输入数据为生成图像和标签的组合, 则判别器的输出为假。

生成器和判别器进行交替训练并且训练过程中的目标优化函数可以表示为：

$$\max_D \tilde{V} = \frac{1}{M} \sum_{i=1}^{M_1} \log D(c^i, x^i) + \frac{1}{M} \sum_{i=1}^{M_2} \log(1 - D(c^i, \tilde{x}^i)) + \frac{1}{M} \sum_{i=1}^{M_3} \log(1 - D(c^i, \hat{x}^i)) \quad (4.5)$$

$$\min_G \tilde{V} = \frac{1}{M} \sum_{i=1}^M \log(1 - D(G(c^i, z^i))) \quad (4.6)$$

式中，M 是所有观测样本的数量， c^i 是训练样本的标签， x^i ， $\tilde{x}^i$ ， $\hat{x}^i$ 分别表示与标签相一致的真实图像，生成图像，以及与标签不一致的真实图像。 $D(\cdot)$ 表示判断图像为真的概率，取值范围为[0,1]，公式（4.5）为最大化目标函数，即让判别器尽可能地区分真实图像和生成图像，判别图像是否为真实图像以及是否与标签一致； $G(\cdot)$ 表示根据输入的标签与任意向量生成与真实数据结构一致的数据，公式（4.6）为最小化目标函数，即让生成器尽可能生成足以“以假乱真”的数据。

此外，由标签控制生成器生成的图像与标签对应的真实图像之间的误差也作为训练生成器的目标函数的一部分，可以重新写成以下公式：

$$\min_G \tilde{V} = \frac{1}{M} \sum_{i=1}^M \log(1 - D(G(c^i, z^i))) + \frac{1}{M} \sum_{i=1}^M \text{Error}(G(c^i, z^i), x^i) \quad (4.7)$$

式中， $\text{Error}(G(c^i, z^i), x^i)$ 是生成图像与真实图像之间的相对预测误差，即由生成器生成的电位分布与实际电位分布之间的预测误差。

4.3 基于 CGAN 得到的预测结果

对于设定的 9 个计算场景，每个场景采用 5000 个数据样本，其中任意 4000 个样本作为训练样本训练 CGAN，剩余 1000 个样本作为测试样本。本文中，将区域中的相对介电常数分布和源电荷分布作为标签，对应于相对介电常数分布和源电荷分布的电位分布作为数据图像，训练样本通过 FDM 算法得到。设置的标签维度为[64,64,2]，代表该有限区域内的相对介电常数分布和源电荷分布，真实图像和生成图像的维度为[32,32,1]，为观测区域内的电位分布，是待预测值。根据图 4.2 的结构，输入生成器的任意噪声向量符合正态分布，并且其维度为[100,1]。

样本总数为 45000，其中，36000 个样本作为训练样本，任意选择其中的 360 个样本作为验证样本来测试 CGAN 的训练结果，即其是否可以根据标签（相对介电常数分布和源电荷分布）生成对应的图像（电位分布），绘制训练好的 CGAN 对验证样本在观测区域内的预测误

差，以及对所有验证样本在观测区域内所有点上的预测误差平均值随迭代轮数的变化曲线。

生成图像（预测的电位分布）和实际图像（真实的电位分布）之间的相对预测误差作为评判训练好的 CGAN 的预测性能的标准，可以用如下公式表示：

$$Err(i, j) = 20 \log_{10} \left(\frac{abs(\phi_{FDM}(i, j) - \phi_{Prediction}(i, j))}{abs(\phi_{FDM}(i, j))} \right) \quad (4.8)$$

式中， $\phi_{FDM}(i, j)$ 是网格点 (i, j) 处的电位，由 FDM 算法计算所得。 $\phi_{Prediction}(i, j)$ 是基于 CGAN 所得的电位预测值。观测区域内所有点的电位预测误差平均值的计算公式如下：

$$Err_{ave} = \frac{1}{N_x N_y} \sum_{i=1}^{N_x} \sum_{j=1}^{N_y} 20 \log_{10} \left(\frac{abs(\phi_{FDM}(i, j) - \phi_{Prediction}(i, j))}{abs(\phi_{FDM}(i, j))} \right) \quad (4.9)$$

式中， N_x 和 N_y 分别是该二维观测区域在两个方向上的网格数。

在 CGAN 的训练过程中，生成器和判别器的损失函数，即公式（4.5）和公式（4.6）分别通过 Adam^[49] 优化算法来优化。该深度学习神经网络的架构和计算平台为 MATLAB，并且对于 CGAN 的训练基于 NVIDIA GTX1660S。为了避免 GAN 训练过程中出现的训练不稳定，梯度消失和模式崩塌等问题，采用小批量判别器来缓解模式崩塌，采用学习率衰减策略来缓解训练不稳定和梯度消失。本文在 CGAN 的训练过程中，在每轮优化的每次迭代过程中所使用的小批量训练样本数为 128，设置的初始学习率为 0.0002，并且学习率衰减因子为 0.1，每 300 轮迭代将学习率乘以衰减因子。

训练好的 CGAN 对在观测区域内所有验证样本的相对预测误差如图 4.3（a）所示。而图 4.3（b）绘制了所有验证样本在观测区域内所有点的相对预测误差平均值随迭代轮数的变化曲线。




图 4.3 基于 CGAN 对验证样本的预测误差 （a）训练样本观测区域内的预测误差（单位:dB） （b）训练样本观测区域内所有点的平均预测误差随迭代轮数的变化曲线

从图 4.3（a）中可以看出，观测区域内所有点上的预测误差均低于 -42dB（0.79%），并且所有观测点的平均预测误差随着迭代轮数的增加逐渐收敛到 -48dB，即 0.4%，且不再下降。该 CGAN 的训练时间为 31 小时 15 分钟 03 秒。

基于训练好的 CGAN 得到 9 个场景下所有训练样本和测试样本在观测区域内的相对预测误差，预测结果如图 4.4 所示，并且对每个场景下，基于 CGAN 预测的任一测试样本的电位分布与基于 FDM 所得的电位分布对比图绘制在图 4.5 中。





图 4.4 基于 CGAN 对所有训练样本和测试样本的预测误差（单位：dB）（a）所有训练样本（b）所有测试样本

正如图 4.4 所示，对于所有训练样本（36000）和测试样本（9000），其在观测区域内每个点上的平均预测误差都低于-40dB（1%），并且图 4.4 中所有网格点的平均预测误差分别为-47.6457dB（0.41%）和-47.0952dB（0.44%）。






图 4.5 基于 CGAN 预测的电位分布与基于 FDM 计算的电位分布的对比

如图 4.5 所示,训练好的 CGAN 对测试样本的预测结果与 FDM 计算所得结果基本一致,验证了 CGAN 的精确性。

而在每个计算场景下,对于所有的训练样本和测试样本,基于 CGAN 所得的,观测区域内所有点的电位值的平均预测误差在表 1 中列出。

表 4.1 基于 CGAN 对所有点的电位的平均预测误差

训练样本	训练样本平均预测误差 (dB (%))	测试样本	测试样本平均预测误差 (dB (%))
场景 1	-49.7041(0.33)	场景 1	-49.5878(0.33)

场景 2	-49.3728(0.34)	场景 2	-49.0597(0.35)
场景 3	-48.0897(0.39)	场景 3	-47.7342(0.41)
场景 4	-52.1805(0.25)	场景 4	-52.2256(0.24)
场景 5	-50.5692(0.30)	场景 5	-50.5830(0.30)
场景 6	-48.2810(0.39)	场景 6	-47.8934(0.40)
场景 7	-48.7643(0.36)	场景 7	-48.3660(0.38)
场景 8	-52.1740(0.25)	场景 8	-51.9972(0.25)
场景 9	-39.2004(1.10)	场景 9	-36.6621(1.47)

如表 4.1 所示, 对于场景 1-8, 对于所有训练样本和测试样本, 观测区域内所有点的平均预测误差都小于 0.5%, 而对于场景 9, 对于所有训练样本和测试样本, 则小于 3%。

对于不在训练样本和测试样本范围内的, 如区域中心的相对介电常数分布为三角形, 四边形和五边形的样本, 计算场景如图 4.6 所示。基于 CGAN 所得的预测误差分布图, 电位分布图以及其与 FDM 计算结果对比在图 4.7 和图 4.8 中表示。





图 4.6 不同于训练样本和测试样本的新计算场景。区域中心分别为: (a) 三角形; (b) 四边形; (c) 五边形






图 4.7 CGAN 对新场景中的样本在观测区域的预测误差 (单位: dB)。区域中心相对介电常数分布为:
(a) 三角形; (b) 四边形; (c) 五边形

由上图可知, CGAN 对不在训练样本和测试样本范围内的样本的预测精度也较高, 并且对观测区域内所有点的平均预测误差分别为 -43.2570dB (0.69%), -46.3338dB (0.48%), -48.1352dB (0.39%), 证明了 CGAN 较高的预测性能。




图 4.8 基于 CGAN 得到的电位分布及其与 FDM 的结果对比。区域中心相对介电常数分布为: (a) 三角形; (b) 四边形; (c) 五边形

从图 4.8 的对比结果可看出, CGAN 对新样本的电位分布的预测结果基本与 FDM 的计算结果一致, 进一步验证了 CGAN 对于未出现在训练样本集和测试样本集中的新样本的较强的预测性能, 展现了较强的泛化能力, 表明了 CGAN 可以代替 FDM, 根据有限区域内的相对介电常数分布和源电荷分布计算狄利克雷边界条件下的电位分布。

4.4 与 CNN 预测性能的对比

CNN 在图像处理方面具有较强的优势，是一种深度学习神经网络，主要用于图像分类和图像识别。因此，CNN 同样可以用于有限区域内二维泊松方程的求解。本节主要基于相对预测误差，即公式（4.8）和公式（4.9），以及训练样本和测试样本耗费的预测时间，对 CGAN 和 CNN 的预测性能进行对比。其中，在 CNN 网络结构的基础上，采用与 CGAN 相同的初始学习率，学习率衰减因子，迭代轮数，小批量数据样本数和优化算法。

4.4.1 预测精度的对比

基于训练好的 CNN，对所有验证样本在观测区域内的电位分布的预测误差，以及对所有观测点电位值的平均预测误差随迭代轮数的变化曲线如图 4.9 所示。




图 4.9 基于 CNN 所得的验证样本的预测结果。(a) 观测区域内的预测误差（单位：dB）；(b) 所有观测点上的平均预测误差随迭代轮数的变化曲线

从上图中可以看出，基于 CNN 所得的，观测区域内所有点的预测误差均低于-26dB（5.01%），并且所有网格点的电位值的预测误差平均值在训练过程中逐渐收敛到-38dB（1.26%），低于 CGAN 所得的误差收敛值。CNN 网络结构的训练时间为 17 时 54 分 03 秒。对比图 4.3，CGAN 的训练时间更长，但其平均预测误差收敛到-48dB（0.4%），相比 CNN 具有更高的精确性。对于 9 个场景下的所有训练样本和测试样本，在观测区域内所有点上的平均预测误差，表 4.2 和表 4.3 给出了 CGAN 和 CNN 的预测性能对比。

表 4.2 CGAN 和 CNN 对训练样本的预测性能对比

训练样本	CGAN 平均预测误差（dB（%））	CNN 平均预测误差（dB（%））
场景 1	-49.7041(0.33)	-41.2605(0.86)
场景 2	-49.3728(0.34)	-38.9880(1.12)
场景 3	-48.0897(0.39)	-36.0886(1.57)

场景 4	-52.1805(0.25)	-41.5581(0.84)
场景 5	-50.5692(0.30)	-41.8929(0.80)
场景 6	-48.2810(0.39)	-37.7146(1.30)
场景 7	-48.7643(0.36)	-36.4973(1.50)
场景 8	-52.1740(0.25)	-41.4080(0.85)
场景 9	-39.2004(1.10)	-35.0810((1.76)

表 4.3 CGAN 和 CNN 对测试样本的预测性能对比

测试样本	CGAN 平均预测误差 (dB (%))	CNN 平均预测误差 (dB (%))
场景 1	-49.5878(0.33)	-41.1605(0.87)
场景 2	-49.0597(0.35)	-38.9422(1.13)
场景 3	-47.7342(0.41)	-36.0444(1.58)
场景 4	-52.2256(0.24)	-41.6846(0.82)
场景 5	-50.5830(0.30)	-41.9646(0.80)
场景 6	-47.8934(0.40)	-37.5755(1.32)
场景 7	-48.3660(0.38)	-36.2943(1.53)
场景 8	-51.9972(0.25)	-41.4213(0.85)
场景 9	-36.6621(1.47)	-35.0823(1.76)

根据表 4.2 和表 4.3 的对比结果可知，在每个场景下，基于 CGAN 预测所得的，对于所有训练样本和测试样本，观测区域内所有点的电位值平均预测误差都低于 CNN 的预测结果，即 CGAN 具有更高的准确性。对所有训练样本，CGAN 对所有观测点的预测误差平均值为 -47.6457dB(0.41%)，测试样本相对应的值为-47.0952dB(0.44%)；CNN 则为-38.9805dB(1.12%)和-38.9273dB（1.18%）。

CGAN 和 CNN 对所有测试样本电位值的平均预测误差的概率分布如图 4.10 所示。




图 4.10 CGAN 和 CNN 关于所有测试样本平均预测误差的概率分布对比。(a) CGAN；(b) CNN

从图中可以看出,对于 CNN,超过 60%的测试样本,其平均预测误差高于 2%;而对于 CGAN,超过 80%的测试样本,其平均预测误差低于 1%,进一步证明了 CGAN 相比 CNN,具有更高的预测准确性。

因此,根据两种深度学习模型的预测精确度的对比结果,可知 CGAN 可以代替 FDM,根据有限区域内的相对介电常数分布和源电荷分布计算电位分布。并且,在保证计算精确度的情况下,CGAN 计算 1000 个测试样本所花费的时间为 0.7 秒,而基于 FDM 算法计算所花费的时间为 126.71 秒,表明训练好的 CGAN 在预测电位分布上的高效性。

4.4.2 训练时间和预测时间的对比

关于 CGAN 和 CNN 的对比,CGAN 对验证样本的预测误差在训练过程中收敛到-48dB (0.4%),CNN 对验证样本的预测误差则收敛到-38dB (1.26%),并且不再下降,表明 CGAN 具有比 CNN 更高的预测精度。对比图 4.3 (b)和图 4.8 (b),CGAN 进行 1200 次迭代花费的时间为 31 时 15 分 03 秒,CNN 进行 1200 次迭代花费的时间为 17 时 54 分 03 秒。尽管 CGAN 的训练时间更长,但对于每个计算场景,所有训练样本和测试样本的预测时间不同,即 CGAN 的预测时间短于 CNN。关于预测时间的对比列在表 4.4 中。

表 4.4 CGAN 与 CNN 关于预测时间的对比 (单位: s)

训练样本	CGAN 预测时间	CNN 预测时间	测试样本	CGAN 预测时间	CNN 预测时间
场景 1	1.84	11.13	场景 1	0.62	2.77
场景 2	1.73	11.13	场景 2	0.66	2.74
场景 3	1.70	11.03	场景 3	0.67	2.71
场景 4	1.66	11.07	场景 4	0.70	2.73
场景 5	1.73	11.11	场景 5	0.69	2.72
场景 6	2.26	11.12	场景 6	1.43	2.73
场景 7	1.98	11.09	场景 7	0.69	2.72
场景 8	1.94	11.19	场景 8	0.40	2.72
场景 9	1.93	11.18	场景 9	0.44	2.72

根据表 4.4 中对 CGAN 和 CNN 的预测时间的对比,在每个计算场景下,两种深度学习模型对所有训练样本(4000)和测试样本(1000)的预测时间都短于 FDM 的计算时间,但 CNN 的预测时间几乎为 CGAN 的 4-6 倍。CGAN 相比于 CNN,具有更高的预测精度和更短的预测时间。

4.5 结果分析

根据表 4.1, CGAN 在每个计算场景下, 对所有训练样本和测试样本观测区域内所有点的电位值的平均预测误差结果可知, 场景 2, 3, 6, 7, 9 的预测误差大于其他计算场景对应的预测误差, 并且场景 9 的误差数值最大。由于场景 2, 3, 6, 7, 9 对应的区域中的相对介电常数分布变化较大, 并且场景 9 中沿网格区域 X 和 Y 方向的相对介电常数变化最剧烈, 即梯度最大, 因此, 基于 CGAN 所得的预测误差最大, 其相比于 CNN, 性能提升不大。

CGAN 的预测性能优于 CNN 的原因在于, CGAN 可以根据标签生成类似于实际数据样本分布的样本, 训练好的生成器获得真实数据样本的概率分布, 而训练好的判别器则控制生成器, 根据标签生成类似实际数据样本分布的数据。因此, 其预测性能优于直接建立输入和输出之间的非线性映射关系的 CNN。

此外, 将本文所用的训练好的 CGAN 用于文献^[47]中的数据集, 基于 CGAN 对设置的 5 个场景下的电位分布进行预测, 所有测试样本在观测区域内所有网格点的平均预测误差为 -42.7632dB (0.73%), 而基于 CNN 的平均预测误差最终收敛到 -32.3dB (2.43%), 证明了 CGAN 较强的泛化性能。此外, 相对于文献^[47]中设置了 5 个计算场景, 并且每个场景采集的样本数为 10000, 本文对于每个场景所使用的样本数为 5000, 设置了 9 个计算场景, CGAN 使用了更小的数据集, 能够对更多的场景进行预测。

然而, 场景 9 的预测精度仍有待于提升, 并且将深度学习方法用于边界条件更复杂的泊松方程的求解, 以及更复杂场景下泊松方程的求解, 这些工作是未来的一些研究方向, 需要进行更深入的研究。

由于 CNN, GAN, 和 CGAN 这些深度学习算法拥有局部感知和参数共享的优点, 因此, 其在二维图像处理方面具有较强的优势, CNN 近年来已经被广泛地运用于天线阵列辐射性能的分析以及超表面单元和阵列的逆设计中, 而 CGAN 却较少地运用于这方面。本章的创新性在于, 相较于 CNN, 可以通过合理地设计 CGAN 网络, 使其在分析类似于二维图像问题时, 具有更高的预测精度。同时, CGAN 需要更少的训练样本, 适应于更多的应用场景, 具有更强的泛化性能。因此, 有望以 CGAN 代替 CNN, 更多地应用于天线阵列的分析和设计中。

4.6 本章小结

本章提出了将 CGAN 用于二维有限区域内泊松方程的求解, 根据区域内的相对介电常数分布, 源电荷分布, 以及边界条件, 基于 CGAN 预测电位分布, 并将其与 CNN 进行预测性

能的对比。设置了 9 个不同的计算场景，每个场景采集 5000 个样本，并将相对介电常数分布和源电荷分布作为 CGAN 的标签，观测区域内的电位分布作为 CGAN 待生成和待判别的图像。训练好的 CGAN 可以在 0.7 秒内实现对每个场景下的所有测试样本的预测，平均预测误差为 -47.0928dB (0.44%)，优于 CNN。对于训练集和测试集中的未出现的数据样本，即区域中心为三角形，四边形和五边形，CGAN 的预测误差均小于 0.7%，表明 CGAN 可以代替 FDM 快速准确地求解二维泊松方程。

此外，尽管 CGAN 的训练时间长于 CNN，但在每个计算场景下，CNN 对所有训练样本和测试样本的预测时间为 CGAN 的 4-6 倍，进一步证明了 CGAN 相比于 CNN，具有更高的预测精度和更短的预测时间。

相比于参考文献^[47]基于 CNN，采用 50000 个样本计算 5 个场景下的电位分布，本文基于 CGAN，采用 45000 个样本计算 9 个场景下的电位分布，使用更小的数据集，进一步证明了 CGAN 预测数据的精确性和高效性。

第五章 基于 VAE-BPNN-GA 优化设计天线

通过 CST 仿真得到一定量的数据样本,并用该数据样本集来训练所设计的机器学习模型,训练好的模型可以代替 CST 对天线进行精细化仿真,并结合优化算法,实现对天线性能的精细优化。本章提出了一种机器学习模型,将 VAE 与 BPNN 相结合,可以实现对天线的某一性能参数曲线进行分析,并结合智能优化算法实现对天线的单一性能或多个性能参数的优化。并以双 T 形单极子天线和具有带陷性能的超宽带单极子天线为例,训练该机器学习模型,用以代替 CST,实现对该天线的 S 参数曲线的快速预测,结合 GA 算法对结构参数进行优化,以实现最优性能;结合 NSGA-II 算法对天线的多个目标进行优化,并以具有带陷特性的超宽带单极子天线为例,同时实现对其 4-6GHz 和 6-9GHz 频段内的 S_{11} 性能的优化。

5.1 VAE-BPNN 的原理

传统的基于机器学习方法分析天线性能,通常分析天线在某一谐振频点的 S_{11} ,带宽(BW),和天线增益(Gain),主要是建立天线的多个尺寸参数和谐振频点处的性能参数之间的非线性映射关系,无法根据建立的映射关系预测整个频段的性能,比如 S_{11} 曲线或者增益(Gain)曲线。因为它们的维度是非常大的,基于 CST 的默认设置获得的维度是 1001。基于 BPNN,GRNN 或者 RBF 直接建立天线的尺寸参数和天线的性能曲线参数的映射关系较为复杂,计算量较大。训练时间将会随着模型复杂度的提升而增加,同时预测精度也会下降。而本章提出的 VAE-BPNN 算法能够解决这一问题。

S_{11} 曲线是最常用的天线性能参数,本章将 VAE-BPNN 用以预测天线的该变量,以验证该算法的可行性。原始空间中,数据样本包含冗余变量或噪音,导致了预测精度的下降,因此,减少原高维变量中的冗余信息可以提高预测精度。即通过降维算法来提取出高维数据中的主成分,以此来加快计算或实现可视化。

5.1.1 基于 VAE 实现数据降维

自编码器(AE)是一种可以通过无监督学习来学习输入数据的有效表征的算法^[50]。对输入数据的有效表征过程为编码,编码后的维度通常小于输入数据的维度,因此,AE 可以用于数据降维,此外,AE 可以生成任意类似于输入数据结构的样本,即解码。因此,AE 由编码器和解码器构成,编码器的功能是将原始输入数据空间 R^n 映射到潜在变量空间 R^d ($d < n$),

输入样本 x 通过编码器映射成潜在空间的向量，该向量表征输入数据的特征信息，而解码器则将该特征变量恢复成原始数据。AE 的结构如图 5.1 所示。




图 5.1 AE 的结构图

如图 5.1 所示，潜在空间的数据维度通常小于输入数据的维度，是待调节的超参数，通常由重构误差决定。但 AE 是一种数据压缩算法，编码器将输入数据 x 编码成潜在空间的低维向量 z ，再由解码器将其复原的过程是一个确定性过程，只是对训练数据样本有较好的表征。因此，对未出现在训练样本中的测试样本，其解码器的重构误差可能较大。

VAE 不同于 AE 在于其编码和解码过程不是对输入数据的简单重构，其在潜在空间上施加一种概率分布，并通过训练集学习输入数据样本的概率分布，因此，通过解码器得到的输出数据符合输入样本的分布特征。因此，可以通过从潜在空间的概率分布采集样本并产生新的数据样本^[51]。

基本原理为通过编码器将真实数据样本映射到潜在空间的数据分布上，再将该数据分布传递到解码器中，根据该概率分布生成大量样本。训练编码器和解码器直到生成样本和真实样本之间的误差小于设定的阈值。VAE 在 AE 的基础上进行变分处理，以便将输入数据集映射为目标分布的均值和方差，其结构如图 5.2 所示。

VAE 的损失函数，即证据下界损失（ELBO），用以计算梯度。ELBO 定义为两个独立损失项之和，即重构损失和 KL 损失之和，表示为公式（5.1）。

$$ELBO \text{ loss} = \text{reconstruction loss} + \text{KL loss} = \frac{1}{M} \sum_{m=1}^M \left(\sum_{n=1}^N \frac{1}{2} \left(\hat{S}_{11}(n) - S_{11}(n) \right)^2 - 0.5 \sum_{l=1}^L \left(1 + \log(\sigma_l) - \mu_l^2 - \sigma_l^2 \right) \right) \quad (5.1)$$

式中， M 是小批量数据的大小， N 是输出数据的维度， L 是潜在空间的维度大小。以对天线的 S_{11} 曲线进行降维与重构为例，重构误差定义为重构的 S_{11} 曲线和原始 S_{11} 曲线的平方差，用以测量解码器的输出数据与原始数据的接近程度；KL 误差用以测量给潜在空间施加的概率分布和输入数据的概率分布之间的差异。潜在空间的维度 L 可以通过 VAE 的输出数据与原始

数据之间的重构误差决定。




图 5.2 VAE 的结构图

5.1.2 基于 VAE-BPNN 的性能预测

高维变量可以通过编码器映射到低维特征空间，并用该特征空间内的向量表征。接着，BPNN 可以用来建立其他的输入变量如天线的尺寸参数与降维后的性能参数变量之间的非线性映射关系，BPNN 的结构如图 5.3 所示。BPNN 是最基本的神经网络，其输出通过前向传播过程完成，并且每层的权值和阈值通过对损失函数的逆向求导来更新。




图 5.3 BPNN 的结构图

对 BPNN 的权值和阈值的更新如公式 (2.1) - (2.6) 所示。训练好的 BPNN 建立天线的输入尺寸参数和 VAE 降维后的天线性能参数之间的非线性映射关系，根据天线的尺寸参数，预测其对应的降维后的性能参数，再基于 VAE 的解码器生成其原始维度的性能曲线。

5.2 基于 GA 实现性能的优化

本章将 VAE-BPNN 机器学习模型与 GA 算法相结合, 对天线的某一性能, 即 S_{11} 进行优化。首先, 在天线待优化的尺寸参数范围内, 生成初始种群样本, 并对其进行编码; 接着, 根据目标函数计算种群中每个样本的适应度, 基于每个样本被赋予的适应度值, 一些样本被选中以产生下一代样本; 被选中的个体进行交叉、变异、重组从而产生新的种群个体。由于新一代的种群遗传了前一代种群的某些优良特征, 其具有更优越的性能。因此, 其会最终收敛到全局最优, 该基于遗传算法获得最优性能的流程如图 5.4 所示。这里用以计算每个样本适应度的目标函数是基于 VAE-BPNN 预测所得的在某一频段的高维向量。当满足收敛目标或达到设置的迭代代数, 将获得最优设计性能, 对应的结构参数为最优结构参数。





图 5.4 GA 的流程图

5.2.1 双 T 形单极子天线的优化

为了验证 VAE-BPNN-GA 算法的有效性, 即对高维变量预测的精确性, 以及能否实现对天线性能的优化, 以文献^[52]中的双 T 形单极子天线为例, 基于 VAE-BPNN 模型, 预测对应的 S_{11} 曲线, 并且结合 GA 算法得到最优结构参数。该天线结构如图 5.5 所示。

图 5.5 双 T 形单极子天线的结构^[52]

该天线的 S_{11} 曲线随结构参数的变化而变化，这里选择的待优化的结构参数向量为：

$[l_{21}, l_{22}, w_1, w_2, w]$ ，对应的 S_{11} 向量为： $[S_{11}^{(1)}, S_{11}^{(2)}, S_{11}^{(3)}, \dots, S_{11}^{(1000)}]$ ，观测频段范围为 1.5-6GHz。

由文献^[52]可知，其有两个工作频段，分别工作在 2.4GHz 和 5.2GHz。文献^[53]中基于三种机器学习方法 Lasso, ANN, KNN 分别对天线的性能参数进行预测和优化，以获得在工作频段 2.4-3.0GHz 和 5.15-5.6GHz 的最优性能。计算 2.4-3.0GHz 和 5.15-5.6GHz 频段内所有频点上的 S_{11} 之和，并将其作为品质因素（FOM）。

然而，由于这三种方法直接建立天线的尺寸参数和两个频段内所有频点的性能参数之间的非线性映射关系，因此，FOM 改变，则需要重新训练新的模型。此外，该种算法需要遍历参数范围内的所有样本，由于样本量较大，获得最优解的时间要比基于遗传算法所花的时间长。

本章基于训练好的 VAE-BPNN 预测天线的 S 参数曲线，并且结合智能优化算法对天线的多个目标进行优化时，不需要对模型进行重新训练。设置的天线结构参数范围为： $l_{21} \in [6.3, 7.3]$ ， $l_{22} \in [6.3, 7.3]$ ，采样间隔为 0.5mm， $w_1 \in [1, 3.5]$ ， $w_2 \in [1, 3.5]$ ， $w \in [1, 3.5]$ ，采样间隔为 0.25mm。样本总数为 11979，分为训练样本和测试样本，训练样本可以进一步分为训练集和测试集。输入数据的维度为 5，输出数据的维度为 1000，为了基于 BPNN 建立输入尺寸参数和 VAE 降维后的输出性能参数之间的非线性映射关系，首先采用 PCA 方法分析 S 参数曲线可能的特征维度为 8。

由于采集的样本总数为 10^4 数量级，这里选择的训练样本数为 11859，占总数的 99%。此外，将训练样本通过 Bootstrap 采样法分为训练集和验证集，比例分别为 63.2% 和 36.8%，前

者用于训练 VAE 模型，后者用来验证潜在空间维度分别为 5, 10, 15, 20 时解码器的重构性能。

5.2.2 基于 VAE-BPNN 的预测结果

本节架构的 VAE-BPNN 模型结构如图 5.6 所示，变量 latentDim 表征了隐藏特征的维度。




图 5.6 VAE 的结构

如图所示，在定义模型的梯度函数时，需要对均值向量和方差向量进行采样，并将其传输到解码器进行数据重构。因此，反向传播算法不能基于随机采样操作来实现，这可以通过重新参数化来解决。用于训练 VAE 的轮数为 500，小批量样本数为 48，初始学习率为 0.001，学习率衰减因子为 0.1，网络的权重参数通过求解损失函数关于权重参数的梯度，并基于 Adam 优化算法进行更新。网络搭建和优化计算平台为 MATLAB，对 VAE 的训练基于 GPU: NVIDIA GTX1660S。

特征空间维度 latentDim 的选择，基于验证集的 S 参数曲线在 1.5-6GHz 频段内的重构误差，不同特征维度对应的重构误差表示在图 5.7 中。




图 5.7 不同特征维度的验证样本的平均预测误差

从图 5.7 可以看出, 不同特征维度下的所有验证样本在整个频段上的重构误差曲线基本一致, 因此, 选择潜在空间的特征维度为 5, 并且基于 BPNN 建立天线的结构参数 (维度为 5) 与降维后的 S 参数向量 (维度为 5) 之间的非线性映射关系。对于测试样本, BPNN 得到其对应的 S 参数降维向量, 再通过 VAE 的解码器生成高维 S 参数曲线。

经多次调试, 最终确定的 BPNN 结构为 5-10-10-10-10-5, 输入层和输出层的神经元个数为 5, 有 5 层隐藏层, 并且每层隐藏层的神经元个数为 10, 使用的激活函数为 ReLu 函数, 该 BPNN 的训练算法为 LM 算法^[54]。因此, 可以通过训练好的 BPNN 预测训练样本和测试样本降维后的 S 参数向量, 而对应的高维 S 参数样本 (1000) 则基于 VAE 的解码器重构。图 5.8 绘制了基于 VAE-BPNN 的预测重构过程。




图 5.8 VAE-BPNN 的结构示意图

基于 VAE-BPNN 对所有训练样本和测试样本在 1.5-6GHz 的预测重构误差如图 5.9 所示。并且, 对训练样本和测试样本在 1.5-6GHz 内所有频点上预测重构误差平均值分别为 1.0790% 和 1.0682%, 表明该算法对天线的 S 参数曲线有较高的预测精度。




图 5.9 VAE-BPNN 的重构误差。(a) 所有训练样本；(b) 所有测试样本

5.2.3 基于 VAE-BPNN-GA 的优化结果

为了获得最优天线性能，即在 2.4-3.0GHz 和 5.15-5.6GHz 实现最优的 S 参数性能，VAE-BPNN 与 GA 算法相结合获得最优设计结构。首先，设定 GA 算法的初始种群个数为 20000，种群个体的取值范围为： $l_{21} \in [6.3, 7.3]$ ， $l_{22} \in [6.3, 7.3]$ ， $w_1 \in [1, 3.5]$ ， $w_2 \in [1, 3.5]$ ， $w_3 \in [1, 3.5]$ ；接着，基于目标函数评估种群中所有个体的适应度值，并且可以表示为公式 (5.2)。

$$ObjV = \sum_{f=2.4}^{f=3.0} |S_{11}(f)| + \sum_{f=5.15}^{f=5.6} |S_{11}(f)| \quad (5.2)$$

式中， S_{11} 为基于 VAE-BPNN 获得的预测曲线。

将 GA 算法用于目标函数的优化，其优化过程以及收敛到最优设计参数所对应的 S 参数曲线如图 5.10 所示。




图 5.10 VAE-BPNN-GA 的优化结果。(a) GA 算法的进化过程；(b) S 参数曲线预测结果及其与仿真结果和参考文献的对比

如图 5.10 (a) 所示，公式 (5.2) 定义的目标函数最终收敛到最优值，即由 VAE-BPNN 预测所得的，在两个工作频段内所有频点上的 S_{11} 之和。优化所得最优设计参数为： $l_{21}=6.3\text{mm}$ ，

$l_{22}=7.3\text{mm}$, $w_1=1\text{mm}$, $w_2=3.5\text{mm}$, $w_3=3.5\text{mm}$ 。根据图 5.10(b) 的对比结果可知, VAE-BPNN-GA 优化的 S_{11} 曲线与 CST 的仿真结果基本一致, 并且与文献^[53]的最优设计结构: $l_{21}=7.3\text{mm}$, $l_{22}=6.3\text{mm}$, $w_1=1\text{mm}$, $w_2=3.5\text{mm}$, $w_3=3.5\text{mm}$ 相比, 也基本保持一致。证明了该优化算法的有效性, VAE-BPNN 算法对优化样本的预测误差在图 5.11 中表示。




图 5.11 VAE-BPNN 的预测性能。(a) 相对预测误差; (b) 预测结果与仿真结果的对比

所有频点上的平均预测误差为 1.2039%, 并且预测结果和仿真结果的对比表明了其较强的优化能力。

5.3 与 PCA-BPNN-GA 预测性能的比较

为了测试 VAE-BPNN-GA 算法在预测和优化天线性能方面的优越性, 将其与 PCA-BPNN-GA 算法相比较, PCA-BPNN-GA 算法为 PCA, BPNN 和 GA 的结合。而基于 PCA 的数据降维和重构是一种线性映射, 并且构成 PCA 的编码器和解码器可以看作只有一层结构的神经网络。本节在预测精度和预测时间方面对 VAE-BPNN-GA 算法和 PCA-BPNN-GA 算法进行对比。

5.3.1 预测精度和优化性能的对比

由第三章的内容可知, PCA 与 VAE 的作用相同, 都可以对数据进行降维, 但 VAE 相比 PCA 较为灵活, 在编码过程中, VAE 既能表征线性变换, 也能表征非线性变换, 而 PCA 只能执行线性变换。并且 VAE 解决了 AE 中非正则化潜在空间的问题, 其潜在空间的变量是平滑连续的, 并为整个空间提供了生成能力。因此, 基于 PCA-BPNN 对训练样本和测试样本的重构误差如图 5.12 所示。




图 5.12 基于 PCA-BPNN 的相对预测误差。(a) 训练样本；(b) 测试样本

对于所有训练样本和测试样本，在 1.5-6GHz 内所有工作频点上的平均预测重构误差分别为 1.6910% 和 1.7958%，高于基于 VAE-BPNN 预测所得的平均重构误差(1.0790% 和 1.0682%)。并且从图 5.9 和图 5.12 的对比中可以看出，在整个频带内，基于 VAE-BPNN 的平均预测误差均低于 3%，而基于 PCA-BPNN 的平均预测误差均低于 5.5%，证明了 VAE-BPNN 的预测精度高于 PCA-BPNN。将 PCA-BPNN 与 GA 相结合，对该天线的 S 参数性能进行优化，图 5.13 为优化过程以及优化结果。




图 5.13 PCA-BPNN-GA 的优化结果。(a) GA 的优化过程；(b) 优化后的 S 参数曲线以及与 CST 仿真结果和文献优化结果的对比

从图 5.13 (b) 的优化结果可以看出，基于 PCA-BPNN-GA 所得的最优结构参数为： $l_{21}=7.3\text{mm}$ ， $l_{22}=6.8\text{mm}$ ， $w_1=1\text{mm}$ ， $w_2=3.5\text{mm}$ ， $w_3=3.5\text{mm}$ ，对应的预测重构 S 参数曲线与 CST 的仿真结果基本一致，但由于 PCA-BPNN 的预测精度低于 VAE-BPNN，因此，其无法收敛到基于 VAE-BPNN-GA 或文献^[53]所得的最优设计结果。PCA-BPNN 对最优设计结构的 S 参数的预测误差如图 5.14 所示。




图 5.14 PCA-BPNN 的预测结果。(a) 相对预测误差；(b) 预测结果和仿真结果的对比

PCA-BPNN 对最优设计结构的所有频点上的相对预测误差平均值为 2.1066%。并且从图 5.14 (b) 与图 5.11 (b) 的对比结果可以看出, VAE-BPNN 具有更高的预测精度。

5.3.2 预测时间的对比

由 5.3.1 部分可知, VAE-BPNN-GA 具有较高的预测精度, 并且训练好的 VAE-BPNN 可以代替 CST, 对天线的 S 参数性能进行分析。而在预测时间方面, VAE-BPNN, PCA-BPNN 和 CST 的对比如下:

表 5.1 不同机器学习方法的对比

Machine Learning Method	Computation time (seconds)	Average Prediction Error (%)
VAE-BPNN	0.03	1.2039
PCA-BPNN	0.05	2.1066
CST	160	

由表 5.1 的对比结果可知, 与 CST 相比, VAE-BPNN 和 PCA-BPNN 能在较短时间内快速实现对天线性能的分析, 并且 VAE-BPNN 耗费的时间更短, 同时具有更高的预测性能。与文献^[52]所采用的机器学习方法对比, 尽管需要获得更多的训练样本, 但可以实现 1.5-6GHz 整个频段内的 S_{11} 曲线, 避免了在优化其他基于 S_{11} 曲线的性能参数时, 需要重新训练新的机器学习模型, 如对于相对带宽的优化。

5.4 结果分析

与文献^[55-56]中的分析相似, 基于 PCA, 对编码器获得的由均值向量和方差向量构成的潜在空间进行降维, 并取前两维主成分分量进行可视化, 所有验证样本在该二维空间内形成的聚类如图 5.15 (a) 所示; 验证样本在基于 PCA 所得的第一和第二主成分构成的空间的分布由图 5.15 (b) 绘制。




图 5.15 验证样本在二维潜在空间中的分布。(a) VAE; (b) PCA

从 VAE 和 PCA 的验证样本在潜在空间的分布可以看出, VAE 的编码器获得的均值和方差都围绕中心聚集, 形成一个连续的采样空间, 而 PCA 获得的两个主成分在空间上的分布相对离散, 无法形成连续的映射空间。因此, VAE 的解码器可以看作一个生成器, 对训练样本和测试样本具有更高的重构精度, 基于 GA 算法可以更准确、快速地获得最佳天线结构参数。

VAE 的重构性能优于 PCA 的原因在图 5.16 中得到了进一步的解释。




图 5.16 数据降维和重构的原理图。(a) AE; (b) VAE

如图 5.16 (a) 所示, 输入数据可以通过编码器映射为潜在空间中的低维向量, 然后基于解码器将低维向量恢复成原始的高维数据向量。因此, 对于训练集中的样 X_1 本和 X_2 , 其可以基于训练好的 VAE 实现无损重构, 而对于未出现在训练集中的样本 X_3 , 解码器有可能生成乱码; 而在训练 VAE 时, 给潜在空间施加一个概率分布, 并学习输入数据的分布, 并将该分布传输给解码器, 解码器根据该分布生成对应的高维向量。对于潜在空间中训练样本点 X_1 和 X_2 附近的测试样本点 X_3 , 即图 5.16 (b) 中红色区域和绿色区域中的样本点, 与训练样本点满足相同的数据分布, 因此, 解码器可以生成概率分布相同但是不同于训练样本的点。这也解释了 VAE 比 PCA 具有更高的预测精度的原因。

5.5 基于 VAE-BPNN-GA 优化天线的相对带宽

基于 VAE-BPNN-GA 算法对天线两个工作频带内的 S 参数进行优化已经得到验证, 该算法还被应用于天线的相对带宽的优化, 两个工作频段的相对带宽可以用公式 (5.3) 表示。

$$FBW = 2 \times (f_{\max} - f_{\min}) / (f_{\max} + f_{\min}) \quad (5.3)$$

式中, $f_{\max}$, $f_{\min}$ 分别是满足回波损耗小于 -10dB 的上限工作频率和下限工作频率。因此, 基于 VAE-BPNN 预测的 S 参数曲线, 将公式 (5.3) 作为目标函数, 并结合 GA 算法对天线的 FBW 进行优化, 得到最优设计参数。

最终得到的最优设计参数为: $l_{21}=6.3\text{mm}$, $l_{22}=7.3\text{mm}$, $w_1=1\text{mm}$, $w_2=3.5\text{mm}$, $w_3=3.5\text{mm}$, 对应的最优 FBW 为 31.1183%, 大于文献^[57]中基于其他机器学习方法获得的最优 FBW, 即 27.8460%; 而基于 CST 对获得的最优结构参数进行仿真, 其 FBW 为 30.4745%, 预测结果与仿真结果基本保持一致, 表明了 VAE-BPNN-GA 算优越的预测性能和较强的优化能力。

5.6 基于 VAE-BPNN-GA 优化具有带陷性能的超宽带单极子天线

将 VAE-BPNN-GA 算法用于文献^[58]中的具有陷波特性的超宽带单极子天线的 S 参数性能优化。该天线结构如图 5.17 所示。




图 5.17 具有单陷波特性的超宽带单极子天线的结构图^[58]。(a) 天线上表面; (b) 天线底面

由该天线的结构图可知, 该天线的馈电方式为微带线馈电, 并且将结构参数: $[L_A, W_A, L_B, W_B]$ 作为控制天线的 S 参数性能曲线的变量, 通过对这一结构参数向量优化来实现对天线的 S_{11} 曲线进行优化。天线除了 $[L_A, W_A, L_B, W_B]$, 其他结构参数值为: $L=36\text{mm}$, $L_1=16\text{mm}$, $L_2=22.7\text{mm}$, $L_3=1.3\text{mm}$, $L_4=1.5\text{mm}$, $L_5=0.5\text{mm}$, $L_6=11.5\text{mm}$, $W=24\text{mm}$, $W_1=6.5\text{mm}$, $W_2=10.25\text{mm}$, $W_3=3.5\text{mm}$; L_A : $[15.5, 18.5]$, 取样间隔为 0.5mm , L_B : $[0, 1.5]$, 取样间隔为

0.25mm, W_A : [3.5, 5], 取样间隔为 0.25mm, W_B : [0, 1.5], 取样间隔为 0.25mm。介质基底为 FR-4, 相对介电常数为 4.3, 损耗角正切为 0.025, 高度为 1.6mm。

基于 CST 对天线结构仿真, 并对 $[L_A, W_A, L_B, W_B]$ 进行参数扫描获得其中一部分样本数为 1771, 将该样本分为训练样本和测试样本。其中, 训练样本数为 1500, 剩余样本作为测试样本; 接着, 采用 Bootstrap 方法将训练样本进一步划分为训练集和验证集, 训练集用来训练 VAE 模型, 验证集用以证明 VAE 能够很好地对数据进行降维和重构。

VAE 的特征空间的维度经多次试验, 选定为 4, 不同维度的潜在空间对应的重构误差如图 5.18 所示。




图 5.18 不同特征维度下的重构误差

由于待优化的天线结构参数维度为 4, 因此, 测试不同特征维度下所有验证样本的重构误差平均值, 从图 5.18 中可以看出, 测试的特征维度为 [4, 8, 12, 16, 20], 并且取潜在空间的特征维度为 4, 对应的重构误差最小, 即将 $\text{latentDim} = 4$ 作为编码器输出向量的维度。

BPNN 建立天线的结构参数与编码器降维后的 S 参数向量之间的非线性映射关系, 对于测试样本, 训练好的 BPNN 输出其对应的 S 参数降维向量, 解码器根据该预测的降维向量生成原始的高维 S 参数曲线。VAE-BPNN 对所有训练样本和测试样本的预测重构误差如图 5.19 所示。




图 5.19 VAE-BPNN 的预测重构误差。(a) 所有训练样本; (b) 所有测试样本

由图 5.19 可知, 所有训练样本在 2-12GHz 内所有频点上的预测重构误差均低于 2.5%, 所有测试样本在 2-12GHz 内所有频点上的预测重构误差均低于 3%, 并且其平均值分别为 0.7785% 和 0.8108%, 表明 VAE-BPNN 能以较高精度实现对天线 S 参数性能的预测分析。

文献^[58]基于其他机器学习方法优化所得的结构参数为: $L_A=15.9948\text{mm}$, $W_A=4.0014\text{mm}$, $L_B=1.9978\text{mm}$, $W_B=0.4983\text{mm}$, 对应的 VSWR 仿真曲线如图 5.20 所示。




图 5.20 参考文献^[58]对 VSWR 性能曲线的优化结果

由上图的参数优化结果可知, 该天线在 4-6GHz 具有带陷特征, $\text{VSWR} > 2$; 而在 6-9GHz 的 VSWR 也大于 2, 不符合天线的通带要求, 即 $\text{VSWR} < 2$ 的要求。因此, 需要同时实现在 4-6GHz 频带内尽可能 $\text{VSWR} > 2$, 而在 6-9GHz 频带内尽可能 $\text{VSWR} < 2$ 的目标。

通常情况下, 对处于冲突状态的多个目标的同时优化, 不存在一个最优设计使所有目标同时达到最优, 一个目标性能的改善, 往往以其它一个或多个目标性能的降低为代价。对于一个多目标优化问题而言, 其 Pareto 最优解不是唯一的, 而是多个解并构成 Pareto 最优解集。在可行解集中没有比 Pareto 最优解所对应的个体性能更好的解, 各 Pareto 最优解之间也没有优劣之别。由于 Pareto 最优解集中的任何解都有可能成为最优解, 因此, 设计者可以根据自己的意愿和对目标的重视程度进行设计。而要解决多个目标无法同时达到最优的情况, 通常使用 NSGA-II 算法^[59]。

NSGA-II 算法作为 GA 的一种变形, 可以实现多目标优化, 其基本思想为: 首先, 随机产生规模为 N 的初始种群, 非支配排序后通过遗传算法的选择、交叉、变异三个基本操作得到第一代子种群; 其次, 从第二代开始, 将父代种群与子代种群合并, 进行快速非支配排序, 同时对每个非支配层中的个体进行拥挤度计算, 根据非支配关系以及个体的拥挤度选取合适的个体组成新的父代种群; 最后, 通过遗传算法的基本操作产生新的子代种群; 依次类推, 直到满足程序结束的条件^[60]。算法的流程图如图 5.21 所示。




图 5.21 NSGA-II 算法的流程图

将 4-6GHz 和 6-9GHz 频段内各频点上的 S_{11} 值分别作为两个待优化的目标函数，表示为公式 (5-4)：

$$\max \text{Obj}V_1 = \sum_{f=4}^{f=6} |S_{11}(f)| \quad (5.4a)$$

$$\min \text{Obj}V_2 = \sum_{f=6}^{f=9} |S_{11}(f)| \quad (5.4b)$$

式中，(5.4a) 为最大化 4-6GHz 频段内所有频点上的 S_{11} 值，(5.4b) 为最小化 6-9GHz 频段内所有频点上的 S_{11} 值，即保证天线仅在 4-6GHz 内具有带陷特征，同时在除了 4-6GHz 的其他频段范围内有较好的阻抗带宽性能。基于 NSGA-II 所得 Pareto 最优解集由图 5.22 表征。对于 6-9GHz 频段内所有频点上的 S_{11} 值之和赋予更大的重视程度，即公式 (5.4b) 的目标函数值越小越好。




图 5.22 Pareto 最优解集 (Pareto 前沿)

由上图的 Pareto 前沿可知, 选择 Pareto 最优解集中, 公式 (5.4b) 的最小值对应的结构参数, 即: $L_A=18.5\text{mm}$, $W_A=3.5\text{mm}$, $L_B=0.46983\text{mm}$, $W_B=1.5\text{mm}$ 作为 NSGA-II 算法优化后的最优设计参数。训练好的 VAE-BPNN 对优化后的天线结构的 S_{11} 曲线的预测结果, 与 CST 的仿真结果, 文献^[58]的优化结果的对比, 以及预测误差如图 5.23 所示。




图 5.23 NSGA-II 算法的优化结果。(a) VAE-BPNN 的预测结果与 CST 的仿真结果和文献优化结果的对比; (b) VAE-BPNN 的预测误差

从图 5.23 可知, VAE-BPNN 对 NSGA-II 优化所得的最优天线结构的 S_{11} 参数曲线的预测结果与 CST 的仿真结果基本保持一致, 并且优于文献^[58]优化所得的天线结构的 S_{11} 性能。所有频点上的预测误差均低于 10%, 且其预测误差平均值为 1.7898%。

将 VAE-BPNN-NSGA-II 优化所得天线结构的 VSWR 曲线与文献^[58]中天线结构的 VSWR 曲线的对比结果绘制在图 5.24 中。该天线待优化的结构参数为: $[L_A, W_A, L_B, W_B]$, 基于 CST 的参数扫描总样本数为 2401, 采集其中的 1771 个样本, 并划分为训练集, 验证集和测试集。将训练集和测试集用于训练和测试 VAE-BPNN 的预测重构性能, 训练好的 VAE-BPNN 可以代替 CST 对天线性能进行预测; 接着, 再结合 NSGA-II 算法对天线性能优化得到最优结构参数。该对比结果进一步表明了本章提出的机器学习模型在预测和优化天线性能方面的高

效性。




图 5.24 VSWR 优化结果对比

从图 5.24 中的 S_{11} 参数对比结果中可以看出，基于 VAE-BPNN-NSGA-II 得到的最优设计参数，其在 4-6GHz 频段内具有更好的阻带特性，并且在 6-12GHz 频段内具有更好的 10dB 阻抗带宽。因此，其在整个频段内的 S_{11} 性能曲线优于文献中所得的优化结果。

而基于 CST 的优化时间和基于本章提出的机器学习优化算法的优化时间对比如下：

表 5.2 VAE-BPNN-NSGA-II 算法与 CST 的仿真优化时间对比

	VAE-BPNN-NSGA-II	CST
CST 仿真时间	1771 个样本（295h）	2401 个样本（400h）
VAE-BPNN 训练时间	50min	/
NSGA-II 优化时间	400s	/
VAE-BPNN 预测时间	0.1s	/

根据表 5.2 中的时间对比，在保证预测精度的前提下，VAE-BPNN-NSGA-II 算法在对天线进行多目标优化方面，花费的仿真优化时间相比于 CST，大大减少，一定程度上避免了 CST 通过参数扫描对天线性能进行优化时需要冗长的时间，提升了设计自由度较大的天线性能的优化效率。

5.7 本章小结

本章提出了一种机器学习模型，将 VAE 与 BPNN 算法相结合，在保证预测精度的情况下，代替 CST，HFSS 等仿真软件，实现对天线性能参数的快速预测，并基于 GA 算法对天线性

能进行优化。以双 T 形单极子天线为例, 基于 VAE-BPNN-GA 对其 S 参数性能进行预测并优化, 并与 PCA-BPNN-GA 算法的预测优化性能进行对比, 本文提出的机器学习模型具有更高的预测精度和更短的预测时间。此外, 该算法还可以对天线的相对带宽参数进行优化, 证明了训练好的 VAE-BPNN-GA 可以代替 CST, 对天线的性能参数进行快速预测和优化; 并且将 VAE-BPNN 与用于 GA 算法中的 NSGA-II 算法相结合, 实现对天线多目标性能的优化, 与 CST 的仿真优化时间相比, 提出的机器学习模型可以在一定程度上提升天线优化设计的效率。

第六章 总结与展望

6.1 全文工作总结

传统的基于理论模型、电磁场数值计算方法或电磁仿真软件设计微波器件,如设计高保真度的天线结构,通常需要在原始设计的基础上进行参数扫描,以选出性能最优的结构参数或达到设计目标,因此,通常需要耗费很长的优化时间或占用很多计算资源。近年来,随着机器学习以及深度学习理论不断发展,GPU性能不断提升,其已被广泛运用于其他领域。机器学习和深度学习常用的一些算法和模型已经运用到天线的性能分析和设计中。首先,基于 CST, HFSS 等电磁仿真软件得到一部分样本并用于训练机器学习或深度学习模型;其次,将训练好的机器学习模型作为代理模型,可以以较高的预测精度和较短的预测时间对天线性能进行分析,进而结合一些智能优化算法对天线的某些性能实现快速优化,避免了基于电磁仿真软件通过参数扫描优化天线结构时耗费的大量时间和计算成本。对于类似于二维图像处理的可编码超表面单元或阵列天线的辐射方向图的分析,或根据设计要求来逆向设计超表面单元或天线阵列的过程,可以基于图像处理领域中常用的 CNN 或 GAN 方法,建立输入的二维平面结构与输出的二维数据结构或一维数据结构之间非线性映射关系。本文围绕基于机器学习算法对天线性能进行分析和优化,深度学习算法在类似图像处理的电磁问题加速求解中的应用展开了研究,对所设计的机器学习模型在已有天线结构,新型天线结构的性能分析和优化设计中的应用,主要包括训练好的机器学习模型对天线性能的预测精度,预测时间以及结合优化算法对性能的优化时间。对所设计的机器学习模型与其他机器学习算法的预测优化性能进行对比研究,验证了设计的机器学习模型的有效性和可行性,并总结了对天线性能进行分析和优化设计的整体框流程。本文的研究成果如下:

首先,设计新的机器学习模型,即将 GRNN 与 PCA 相结合,对所设计的,CPW 馈电的加载 Ψ 形缝隙结构的八边形单极子天线的 S_{11} 和 MaxGain 性能曲线进行分析,并与其他简单的机器学习模型的预测精度进行比较;将集成学习的思想运用于机器学习模型的架构中,即设计一种将集成 BP 神经网络与 PCA 相结合模型,并用于对由 CPW 馈电的分形八边形单极子天线的 S_{11} 曲线和 MaxGain 曲线进行预测,并与其他机器学习方法关于预测精度进行比较,证明了设计的机器学习模型的有效性和可行性。

其次,首次将 CGAN 算法用于求解静电场中的二维泊松方程,二维有限区域内的电势由该区域内的相对介电常数分布和源电荷分布,以及采用的边界条件决定。设置了九个不同的

计算场景,并基于 FDM 算法得到训练样本用于训练 CGAN,与基于 CNN 求解该方程相比,训练好的 CGAN 具有更高的预测精度和更短的预测时间,且具有更强的泛化性能。该项工作的意义在于将 CGAN 运用于类似图像处理的电磁场问题的求解中,并且其具有比 CNN 更高的预测精度,有望以后更多地用 CGAN 代替 CNN 分析超表面单元或阵列的性能分析中。

最后,基于新设计的机器学习模型,即将 VAE 与 BPNN 相结合,预测天线的 S_{11} 曲线,并结合 GA 算法对 S_{11} 参数进行优化,得到最优结构参数。由于 VAE 具有比一般 AE 如 PCA,更好的数据重构性能,因此,VAE-BPNN-GA 能很好地实现对双 T 形单极子天线的性能优化;并且将 VAE-BPNN 与多目标优化算法 NSGA-II 相结合,实现对具有单陷波频带特征的单极子天线的性能进行多目标优化。优化结果以及与 PCA-BPNN 的对比表明,VAE-BPNN 具有更好的预测性能,总结了基于机器学习算法对天线性能进行分析和优化的整体流程框图。

本文的研究工作重点在于根据不同的天线结构,来设计合理的机器学习模型,在保证预测精度的同时,通过合理的数据采集方式,尽可能以较少的样本数据集,建立可以代替 CST 或 HFSS 等的代理模型,实现对天线优化范围内的参数性能的快速预测。训练好的机器学习模型结合智能优化算法,缩小待优化参数的迭代步长,进行快速的精细化仿真和优化。在一定程度上能减少传统的迭代优化所需的仿真时间以及计算机资源。这对于大型天线阵列以及复杂天线的优化设计,有一定的研究价值。但本文重在研究对于单个性能曲线参数的分析与优化,对于需要满足一定工程需要的大型阵列的设计有待于进一步的研究。

6.2 后期工作展望

尽管本文的工作取得了一些进展,主要是关于新型机器学习模型的设计,但是受作者水平以及时间所限,还有非常大的改善空间,还有大量的工作有待后续的研究,作者认为在以下方面有待进一步的研究和改进:

1. 本文在设计机器学习模型方面做了较多工作,但这些设计的模型基本用于预测天线的 S_{11} 曲线,而决定天线性能好坏的参数还包括:天线增益、天线辐射效率、天线相对带宽等。因此,后续可以基于设计的机器学习模型分析天线的多个性能参数,并结合多目标优化算法如 Pareto 遗传算法对天线的多个目标性能参数进行同时优化。

2. 在对设计的机器学习模型进行训练的过程中,仍然需要基于 CST 等电磁仿真软件获得大部分的训练样本,获得训练样本的这一过程仍然是计算成本较高的,如何设计更好的机器学习模型,运用何种样本采集方法在保证预测精度的同时,能降低所需的训练样本数量,进一步提高优化效率有待于进一步研究。

3. 本文的研究对象基本为单个天线结构,而如何将设计的机器学习模型推广到电大尺寸天线以及天线阵列的性能分析和设计中,即建立更高的天线设计维度与其性能参数,如辐射方向图,辐射效率之间的非线性映射关系需要进行更深层的研究。

参考文献

- [1] Balanis C A . Antenna theory : analysis and design[J]. IEEE Antennas & Propagation Society Newsletter, 2003, 24(6):28-29.
- [2] Sheng X , Wei S . Method of Moments[M]. Wiley-IEEE Press, 2012.
- [3] Sullivan, Dennis M . Electromagnetic Simulation Using the FDTD Method[M]. IEEE Press, 2013.
- [4] Reddy J N J N . An Introduction To The Finite Element Method[M]. John Wiley & Sons, Ltd, 2013.
- [5] Pathak P H , Carluccio G , Albani M . The Uniform Geometrical Theory of Diffraction and Some of Its Applications[J]. IEEE Antennas & Propagation Magazine, 2013, 55(4):41-69.
- [6] 曹逸. 机器学习辅助优化与天线设计技术研究[D]. 东南大学.
- [7] 杨振超. 新型手机天线的研究及设计[D]. 电子科技大学, 2011.
- [8] Qi, Wu, Yi, et al. Machine-Learning-Assisted Optimization and Its Application to Antenna Designs: Opportunities and Challenges[J]. 中国通信: 英文版, 2020, 17(4):13.
- [9] Wang Z , Fang S , Wang Q , et al. An ANN-Based Synthesis Model for the Single-Feed Circularly-Polarized Square Microstrip Antenna With Truncated Corners[J]. IEEE Transactions on Antennas & Propagation, 2012, 60(12):5989-5992.
- [10] Liu B , Akbarian H A , Vandenbosch G , et al. An efficient method for antenna optimization based on evolutionary computation and machine learning techniques[J]. IEEE Transactions on Antennas & Propagation, 2014, 62(1):7-18.
- [11] Robustillo P , Zapata J , Encinar J A , et al. ANN Characterization of Multi-Layer Reflectarray Elements for Contoured-Beam Space Antennas in the Ku-Band[J]. IEEE Transactions on Antennas & Propagation, 2012, 60(7):3205-3214.
- [12] Feng, Zhang, Chao, et al. Parametric Modeling of EM Behavior of Microwave Components Using Combined Neural Networks and Pole-Residue-Based Transfer Functions[J]. IEEE Transactions on Microwave Theory & Techniques, 2016.
- [13] Jin J , Zhang C , Feng F , et al. Deep Neural Network Technique for High-Dimensional Microwave Modeling and Applications to Parameter Extraction of Microwave Filters[J]. IEEE Transactions on Microwave Theory and Techniques, 2019, 67(10):4140-4155.
- [14] Qiu T , Shi X , J Wang, et al. Deep Learning: A Rapid and Efficient Route to Automatic Metasurface Design[J]. Advanced Science, 2019.
- [15] He, Ming, Yao, et al. Machine-Learning-Based PML for the FDTD Method[J]. IEEE Antennas & Wireless Propagation Letters, 2018.
- [16] Yeo B K , Lu Y . Fast detection and location of failed array elements using the fast SVM algorithm. IEEE, 2010:1-4.
- [17] Moghaddam E S . Design of a Printed Quadrifilar-Helical Antenna on a Dielectric Cylinder by Means of a Genetic Algorithm [Antenna Applications Corner][J]. IEEE Antennas & Propagation Magazine, 2011, 53(4):262-268.
- [18] Li Y L , Shao W , You L , et al. An Improved PSO Algorithm and Its Application to UWB Antenna Design[J]. IEEE Antennas & Wireless Propagation Letters, 2013, 12:1236-1239.
- [19] M. Xue, D. Shi, Y. He and C. Li, "A Novel Intelligent Antenna Synthesis System Using Hybrid Machine Learning Algorithms," 2019 International Symposium on Electromagnetic Compatibility - EMC EUROPE, 2019, pp. 902-907, doi: 10.1109/EMCEurope.2019.8871996.
- [20] Thakare V V , Singhal P K . BANDWIDTH ANALYSIS BY INTRODUCING SLOTS IN MICROSTRIP ANTENNA DESIGN USING ANN[J]. Progress in Electromagnetics Research M, 2009, 9:107-122.

- [21] Xiao L Y , Shao W , Jin F L , et al. Multi-Parameter Modeling with ANN for Antenna Design[J]. IEEE Transactions on Antennas and Propagation, 2018:1-1.
- [22] Prado D R , Lopez-Fernandez J A , Barquero G , et al. Fast and Accurate Modeling of Dual-Polarized Reflectarray Unit Cells Using Support Vector Machines[J]. IEEE Transactions on Antennas and Propagation, 2018, PP(99):1-1.
- [23] Prado, Daniel R , Lopez-Fernandez, et al. Support Vector Regression to Accelerate Design and Crosspolar Optimization of Shaped-Beam Reflectarray Antennas for Space Applications[J]. IEEE Transactions on Antennas and Propagation, 2019.
- [24] Ma J , Huang Y , Pu M , et al. Inverse Design of Broadband Metasurface Absorber Based on Convolutional Autoencoder Network and Inverse Design Network[J]. Journal of Physics D Applied Physics, 2020, 53(46).
- [25] Zhaocheng, Liu, Dayu, et al. Generative Model for the Inverse Design of Metasurfaces.[J]. Nano Letters, 2018.
- [26] Shan T , Li M . Coding Programmable Metasurfaces Based on Deep Learning Techniques[C]// 2019 IEEE International Symposium on Antennas and Propagation and USNC-URSI Radio Science Meeting. IEEE, 2019.
- [27] Patnaik A , Choudhury B , Pradhan P , et al. An ANN Application for Fault Finding in Antenna Arrays[J]. IEEE Transactions on Antennas & Propagation, 2007, 55:775-777.
- [28] Q. Chen, H. Ma and E. -P. Li, "Failure Diagnosis of Microstrip Antenna Array Based on Convolutional Neural Network," 2019 IEEE Asia-Pacific Microwave Conference (APMC), 2019, pp. 90-92, doi: 10.1109/APMC46564.2019.9038656.
- [29] 陈先昌. 基于卷积神经网络的深度学习算法与应用研究[D]. 浙江工商大学, 2014.
- [30] Hou Y C , Su D L , Ma J P . Analysis and design of Ultra Wide Band Planar monopole antenna[C]// International Symposium on Antennas. IEEE, 2008.
- [31] Liang J , Lu G , Chiau C C , et al. CPW-fed circular disc monopole antenna for UWB applications[C]// IEEE International Workshop on IEEE Antenna Technology: Small Antennas & Novel Metamaterials. IEEE, 2005.
- [32] Oktafiani F , Wahyu Y , Wijayanto Y N . Broadband octagonal patch antenna for cognitive radio applications[C]// 2015 IEEE Asia Pacific Conference on Wireless and Mobile (APWiMob). IEEE, 2016.
- [33] Ruchandani K , Kumar M . A novel CPW fed octagonal aperture antenna with back patch for UWB applications[C]// International Conference on Nascent Technologies in the Engineering Field. IEEE, 2015:1-5.
- [34] Ibrahim A A , Abdalla M A . Compact size UWB antenna with multi-band notched characteristics for wireless applications[C]// 2016 IEEE International Symposium on Antennas and Propagation & USNC/URSI National Radio Science Meeting. IEEE, 2016.
- [35] Tarbouch M , Amri A E , Terchoune H . Compact CPW-Fed microstrip octagonal patch antenna with H slot for WLAN and WIMAX applications[C]// International Conference on Wireless Technologies. IEEE, 2017.
- [36] Weng W C , Hung C L . An H-Fractal Antenna for Multiband Applications[J]. IEEE Antennas & Wireless Propagation Letters, 2015, 13:1705-1708.
- [37] Tarbouch M , Amri A E , Terchoune H . Compact CPW-Fed microstrip octagonal patch antenna with H slot for WLAN and WIMAX applications[C]// International Conference on Wireless Technologies. IEEE, 2017.
- [38] Singh B K . Design of rectangular microstrip patch antenna based on Artificial Neural Network algorithm[C]// 2015 2nd International Conference on Signal Processing and Integrated Networks (SPIN). IEEE, 2015.
- [39] Rolph S . Fractal Geometry: Mathematical Foundations and Applications[J]. Mathematical Gazette, 1990, 74(469):288-317.
- [40] Yang S , Browne A . Neural network ensembles: combining multiple models for enhanced performance using a multistage approach[J]. Expert Systems, 2010, 21(5):279-288.

- [41] Hansen L K , Salamon P . Neural network ensembles[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2002, 12(10):993-1001.
- [42] Wold S , Esbensen K , Geladi P . Principal component analysis[J]. Chemometrics & Intelligent Laboratory Systems, 1987, 2(1-3):37-5.
- [43] Zenko B , Todorovski L , Dzeroski S . A Comparison of Stacking with Meta Decision Trees to Bagging, Boosting, and Stacking with other Methods. IEEE, 2001.
- [44] Gu J, Wang Z, Kuen J, et al. Recent advances in convolutional neural networks. 2015, arXiv preprint arXiv:1512.07108.
- [45] Ohnishi R , Wu D , Yamaguchi T , et al. Numerical Accuracy of Finite-Difference Methods[C]// 2018 International Symposium on Antennas and Propagation (ISAP). IEEE, 2019.
- [46] Cui R , Wei M . Research and application of Successive Over-Relaxation Iterative Algorithm[C]// International Conference on Electronic & Mechanical Engineering & Information Technology. IEEE, 2011.
- [47] Shan T , Tang W , Dang X , et al. Study on a Fast Solver for Poisson's Equation Based On Deep Learning Technique[J]. IEEE Transactions on Antennas and Propagation, 2020, PP(99):1-1.
- [48] Mirza M, Osindero S. Conditional Generative Adversarial Nets. 2014, arXiv: 1411.1784. [Online]. Available: <https://arxiv.org/abs/1411.1784>
- [49] Kingma DP, Ba J. Adam: A Method for Stochastic Optimization. 2014, arXiv: 1412.6980. [Online]. Available: <https://arxiv.org/abs/1412.6980>
- [50] Bengio, Yoshua, Courville, et al. Representation Learning: A Review and New Perspectives[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2013, 35(8):1798-1828.
- [51] Kingma DP, Welling M. Auto-encoding variational bayes. arXiv.org:1312.6114v10, 2014.
- [52] Kuo Y L , Wong K L . Printed double-T monopole antenna for 2.4/5.2 GHz dual-band WLAN operations[J]. IEEE Xplore, 2003.
- [53] Sharma Y , Zhang H H , Xin H . Machine Learning Techniques for Optimizing Design of Double T-Shaped Monopole Antenna[J]. IEEE Transactions on Antennas and Propagation, 2020, 68(7):5658-5663.
- [54] Madsen K, Nielsen HB, Tingleff O. Methods for non-linear least squares problems. Society for industrial & applied mathematics 2004.
- [55] Naseri P , Hum S V . A Generative Machine Learning-Based Approach for Inverse Design of Multilayer Metasurfaces[J]. IEEE Transactions on Antennas and Propagation, 2021, PP(99):1-1.
- [56] Kiarashinejad Y , Abdollahramezani S , Adibi A . Deep learning approach based on dimensionality reduction for designing electromagnetic nanostructures[J]. 计算材料学(英文), 2020(1):12.
- [57] Sharma Y , Wu J , Hao X , et al. Sparse linear regression for optimizing design parameters of double T-shaped monopole antennas[C]// 2017 IEEE International Symposium on Antennas and Propagation & USNC/URSI National Radio Science Meeting. IEEE, 2017.
- [58] Xiao L Y , Shao W , Jin F L , et al. Multi-Parameter Modeling with ANN for Antenna Design[J]. IEEE Transactions on Antennas and Propagation, 2018:1-1.
- [59] Ching-Shih. Deb, K. Pratap, A. Agarwal, S. and Meyarivan, T. (2002), " A fast and elitist multiobjective genetic algorithm: NSGA-II", IEEE Transactions on Evolutionary Computation, 6(2), 182-197.
- [60] Li G , Yang S , Feng Q , et al. Dual-polarized Differential-fed Phased Array Antenna with Sidelobe Suppression Based on NSGA-II for 5G Millimeter Wave Application[C]// 2020 International Conference on Microwave and Millimeter Wave Technology (ICMMT). 2020.

附录 1 程序清单

第三章:

基于 GRNN-PCA 预测 CPW 馈电的加载 ψ 形缝隙的八边形单极子天线的性能曲线
(CPW_PSI_Slot_Octagonal_Monopole_Antenna_GRNN_PCA1 文件夹)

ML_Solve: 基于 GRNN-PCA 预测天线性能曲线主函数

Performance_Comparison: 比较不同天线的性能曲线 (S_{11} 和 MaxGain)

Dataset_Generation: 生成用于训练和测试 GRNN-PCA 的数据 (S_{11} 和 MaxGain)

Dataset_Reduction: 基于 PCA 对训练样本输出数据 (S_{11} 和 MaxGain) 进行降维

Dataset_Normalization: 对 GRNN 模型的输入输出数据进行归一化

Dataset_GRNN_Training: 训练 GRNN 模型

Dataset_GRNN_Testing: 测试 GRNN 模型

Different_Machine_Learning_Methods_Comparison: 比较不同机器学习模型的预测性能

基于 BPNN-Ensemble-PCA 预测 CPW 馈电的混合分形单极子天线的性能曲线
(CPW_Koch_Octagonal_Fractal_Monopole_Antenna_Analysis_Machine_Learning 文件夹):

ML_Solve: 基于 BPNN-Ensemble-PCA 预测天线性能曲线主函数

Generating_Dataset: 生成用于训练和测试 BPNN-Ensemble-PCA 的数据 (S_{11})

Dataset_PCA: 基于 PCA 对天线的高维数据向量进行降维 (S_{11})

Dataset_Normalization: 归一化 BPNN 的输入输出数据 (S_{11})

Training_Dataset_BP_Ensemble_PCA: 训练 BPNN-Ensemble-PCA 模型 (S_{11})

Testing_Dataset_BP_Ensemble_PCA: 测试 BPNN-Ensemble-PCA 的预测性能 (S_{11})

Comparison_Different_Machine_Learning: 不同机器学习方法性能的对比 (S_{11})

Plot_Test_Sample_Prediction_Performance: 基于 BPNN-Ensemble-PCA 对测试样本 S_{11} 性能
的预测结果 (S_{11})

Generating_Dataset_Gain_Expand: 生成用于训练和测试 BPNN-Ensemble-PCA 的数据
(MaxGain)

Dataset_PCA_Gain_Expand: 基于 PCA 对天线的高维数据向量进行降维 (MaxGain)

Dataset_Normalization_Gain_Expand: 归一化 BPNN 的输入输出数据 (MaxGain)

Training_Dataset_BP_Ensemble_PCA_Gain_Expand: 训练 BPNN-Ensemble-PCA 模型

(MaxGain)

Testing_Dataset_BP_Ensemble_PCA_Gain_Expand: 测试 BPNN-Ensemble-PCA 的预测性能 (MaxGain)

Comparison_Different_Machine_Learning_Gain_Expand: 不同机器学习方法性能的对比 (MaxGain)

Plot_Test_Sample_Prediction_Performance_Gain_Expand: 基于 BPNN-Ensemble-PCA 对测试样本 S11 性能的预测结果 (MaxGain)

第四章:

基于 CGAN 求解 2D Poisson's Equation 程序 (NM_Poisson_Equation_CGAN_Analysis 文件夹):

Solving_Poisson_Equation_with_CGAN: 基于 CGAN 求解二维泊松方程主函数

define_problem_parameters: 定义 9 个待求解二维有限区域的基本参数

calculating_permittivity_distribution_in_scenario_1: 基于 FDM 计算场景 1 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_2: 基于 FDM 计算场景 2 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_3: 基于 FDM 计算场景 3 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_4: 基于 FDM 计算场景 4 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_5: 基于 FDM 计算场景 5 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_6: 基于 FDM 计算场景 6 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_7: 基于 FDM 计算场景 7 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_8: 基于 FDM 计算场景 8 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_9: 基于 FDM 计算场景 9 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

generating_CGAN: 生成用于训练和测试 CGAN 的数据

define_generator_network: 定义生成器

define_discriminator_network: 定义判别器

define_model_gradients_and_loss_functions: 定义模型梯度和损失函数

training_CGAN: 训练 CGAN

calculating_training_relative_error: 计算训练样本的预测误差

calculating_testing_relative_error: 计算测试样本的预测误差

calculating_relative_error_tenth: 计算 CGAN 对区域中心为三角形的样本预测误差

calculating_relative_error_eleventh: 计算 CGAN 对区域中心为四边形的样本预测误差

calculating_relative_error_twelfth: 计算 CGAN 对区域中心为五边形的样本预测误差

Potential_Distribution_Prediction: 基于 CGAN 预测 9 个场景测试样本区域内的电位分布

Potential_Distribution_Prediction_OutScene: 基于 CGAN 预测区域中心为三角形、四边形、五边形场景的电位分布

Probability_Distribution_Prediction_Error_Testing_Sample: 基于 CGAN 绘制所有测试样本预测误差的概率分布图

基于 CNN 求解 2D Poisson's Equation 程序(NM_Poisson_Equation_CNN_Analysis 文件夹):

Solving_Poisson_Equation_CNN: 基于 CNN 求解二维泊松方程主函数

define_problem_parameters: 定义 9 个待求解二维有限区域的基本参数

calculating_permittivity_distribution_in_scenario_1: 基于 FDM 计算场景 1 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_2: 基于 FDM 计算场景 2 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_3: 基于 FDM 计算场景 3 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_4: 基于 FDM 计算场景 4 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_5: 基于 FDM 计算场景 5 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_6: 基于 FDM 计算场景 6 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_7: 基于 FDM 计算场景 7 对应的相对介电

常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_8: 基于 FDM 计算场景 8 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

calculating_permittivity_distribution_in_scenario_9: 基于 FDM 计算场景 9 对应的相对介电常数、源电荷分布、以及观测区域内的电位分布

generating_dataset_CNN: 生成用于训练和测试 CNN 的数据

define_convolution_neural_network: 定义卷积神经网络

define_model_gradients_and_loss_functions: 定义模型梯度和损失函数

training_CNN: 训练 CNN

calculating_training_relative_error: 计算 CNN 对训练样本的预测误差

calculating_testing_relative_error: 计算 CNN 对测试样本的预测误差

calculating_triangular_relative_error: 计算 CNN 对区域中心为三角形测试样本的预测误差

calculating_square_relative_error: 计算 CNN 对区域中心为四边形测试样本的预测误差

calculating_pentagon_relative_error: 计算 CNN 对区域中心为五边形测试样本的预测误差

Potential_Distribution_Prediction: 基于 CNN 预测 9 个场景测试样本区域内的电位分布

Potential_Distribution_Prediction_OutScene: 基于 CNN 预测区域中心为三角形、四边形、五边形场景的电位分布

Probability_Distribution_Prediction_Error_Testing_Sample: 基于 CNN 绘制所有测试样本预测误差的概率分布图

第五章:

基于 VAE-BPNN-GA 预测并优化双 T 形单极子天线性能程序
(Dual_T_Monopole_Antenna_VAE_BPNN2 文件夹):

ML_Solve: 基于 VAE-BPNN-GA 预测并优化天线性能主函数

Dataset_Generation: 生成用于训练和测试 VAE-BPNN 模型的数据

Dataset_Reduction: 训练 VAE

Dataset_Normalization: 归一化 BPNN 的输入输出数据

Dataset_BPNN_Training: 训练 VAE-BPNN 模型

Dataset_BPNN_Testing: 测试 VAE-BPNN 模型的预测重构性能

Dataset_S11_GA_Optimization: 基于 VAE-BPNN-GA 优化天线的 S11 性能

Antenna_S11_Design_VAE_BPNN: 基于 VAE-BPNN 预测的最优设计结果

Dataset_FractionBandWidth_GA_Optimization: 基于 VAE-BPNN-GA 优化天线的相对带宽性能

Antenna_FractionBandWidth_Design_VAE_BPNN: 基于 VAE-BPNN 预测的最优设计结果
基于 PCA-BPNN-GA 预测并优化双 T 形单极子天线性能程序
(Dual_T_Monopole_Antenna_PCA_BPNN_GA 文件夹):

ML_Solve: 基于 PCA-BPNN-GA 预测并优化天线性能主函数

Dataset_Generation: 生成用于训练和测试 PCA-BPNN 模型的数据

Dataset_Reduction: 训练 PCA

Dataset_Normalization: 归一化 BPNN 的输入输出数据

BPNN_Training: 训练 PCA-BPNN 模型

BPNN_Testing: 测试 PCA-BPNN 的预测重构性能

Antenna_Design_GA_Optimization: 基于 PCA-BPNN-GA 优化天线的 S11 性能

Antenna_Design_Test: 基于 PCA-BPNN 预测的最优设计结果

基于 VAE-BPNN-GA 预测并优化具有带陷特征的超宽带单极子天线的性能程序
(Single_Notch_Band_Monopole_Antenna 文件夹):

Dataset_Generation: 生成用于训练和测试 VAE-BPNN-GA 的数据

Dataset_Reduction: 训练 VAE 模型

Dataset_Normalization: 归一化 BPNN 输入和输出数据

Dataset_BPNN_Training: 训练 VAE-BPNN 模型

Dataset_BPNN_Testing: 测试 VAE-BPNN 的预测重构性能

Multi_Objective_Design_Optimization: 基于 VAE-BPNN-NSGAI 实现对天线性能的多目标优化

Antenna_Multi_Objective_Optimization: 基于 VAE-BPNN 预测的最优设计结果

Performance_Comparison: VAE-BPNN-NSGAI 所得最优设计结果与参考文献最优设计结果对比

附录 2 攻读硕士学位期间撰写的论文

- [1] K. N. Peng and F. Xu, "Analysis of CPW-Fed Octagonal Patch Antenna with ψ Slot based on GRNN and PCA," 2021 International Conference on Microwave and Millimeter Wave Technology (ICMMT), 2021, pp. 1-3, doi: 10.1109/ICMMT52847.2021.9618221.;
- [2] K. N. Peng and F. Xu, "Solving 2D Poisson's Equation Based on Conditional Generative Adversarial Network," International Journal of Numerical Modelling: Electronic Networks, Devices and Fields (doi: 10.1002/jnm.3020;)
- [3] K. N. Peng and F. Xu, "Optimization of Antenna Performance based on VAE-BPNN-PCA", 2022 International Conference on Microwave and Millimeter Wave Technology(ICMMT), 2022 (EI early access)

致谢

在研究生学习的三年时间中，我得到了导师许锋教授的悉心指导，在他的指导和启发下顺利地完成了研究生课程的学习以及本文所做的各项研究工作，最后完成了自己的学位论文。许老师在科研工作中严谨的治学态度、渊博的知识、敏锐的洞察力、丰富的工程经验一直是我的学习榜样。在生活中，许老师给予我很多无私的帮助和关心，帮助我渡过各个难关；同时他以丰富的人生阅历和经验对我今后的规划提出了许多宝贵的建议。在此，谨向许老师对我的培养和教诲表示最诚挚的感谢。

另外，感谢南京邮电大学射频集成与微组装国家地方联合工程实验室的张明教授、程勇教授、王正斌教授、刘芫健教授、李波教授、刘蕾蕾教授、徐立勤副教授、陈董副教授、黄晓东副教授、韩叶副教授、储鹏副教授等。他们或在课堂上，或在科研中，或在实验室中对我热情指导，热情帮助，使我受益匪浅。

同时，感谢许老师课题组的邓森岫博士、刘水博士、杨玲博士、羌静霞博士、张雅梅博士、赵晓飞硕士、陈方君硕士、张笑硕士、周亮硕士、李茂娅硕士等师兄师姐，对我在学习生活中的许多帮助。特别感谢刘水博士，带我学习，在研究和写作方面给予了我很多指导性的意见和建议，感谢赵晓飞硕士在我学习天线过程中对我的帮助。感谢余佳、高培才、周佳丽、闻婉婉等同门和我一起同甘共苦，一同学习科研，感谢左治、吴桐、张亚丽、杜斐斐、司萌萌等师弟师妹。感谢舍友李雪峰、徐含静、韩旭、张月华、谭文婧、倪梦媛、余敏、刘小曼、陈怡慧、马佳三年来给予的鼓励与陪伴。

特别感谢我的父母在生活和学习上对我的全力支持，永远相信我，永远是我坚强的后盾，是我最温暖的港湾，希望日后我能成为你们的骄傲。

最后，向论文评阅专家和答辩委员会的专家学者表示我最衷心的感谢！