

基于深度学习与代理模型的天线优化设计研究进展

□文 / 汤昊臻¹, 吴季航¹, 张伟^{1,2*}

(1. 北京邮电大学 电子工程学院, 北京 100876; 2. 信息光子学与光通信国家重点实验室, 北京 100876)

摘要: 随着现代无线通信的快速发展, 通信系统正在对天线设计提出宽带、高增益、小型化等一系列要求。高性能的要求往往需要复杂的天线结构, 这将带来一系列挑战, 如参数高维化、计算成本高昂和研发周期延长等。为应对不断增长的高性能天线需求, 本文聚焦于人工神经网络与机器学习在天线设计方面的应用现状与发展趋势, 系统总结了深度神经网络、基于知识的神经网络、逆向网络和自适应进化网络等核心算法原理, 探讨了结合神经网络或深度学习进行天线设计的可行性、优势和所面临的问题。之后, 本文展示了基于神经网络空间映射技术的超表面圆极化天线优化实例, 该实例结果表明, 采用空间映射策略仅需 4 次迭代即可收敛, 成功实现了 1.98 GHz ~ 2.2 GHz 频段内回波损耗优于 -20 dB、轴比小于 3 dB 的优化目标。相较于耗时 34 小时的传统遗传算法与耗时 6.8 小时的传统神经网络, 该方法的计算效率分别提升了约 10 倍、2 倍。基于深度学习与代理模型的天线优化技术正推动着天线设计从传统仿真试错向模型快速预测转变, 为天线设计提出了新的解决方案和技术路径。

关键词: 天线设计; 人工神经网络; 机器学习; 代理模型; 空间映射; 拓扑优化

中图分类号: TP18; TN820 **文献标志码:** A **文章编号:** 2096-5036(2026)01-0049-17

DOI: 10.16453/j.2096-5036.202606

0 引言

随着无线通信的快速发展, 一些复杂结构的天线(如超宽带天线、可重构天线, 异形天线等)的设计周期和设计难度也随之增加^[1-3]。天线设计已不满足单一的阻抗匹配, 需同时兼顾增益、轴比、旁瓣电平和交叉极化等多项指标^[4-8]。这种多目标大大增加了设计的自由度。

从传统天线的几个几何结构变量到多层叠、多耦合的新型天线, 或者周期排列的复杂超表面单元, 甚至拓扑优化中的高维数像素点状态, 这些结构一方面确实丰富了天线的创新, 但是同时也带来了计算成本大、设计周期长的问题。当前, 天线设计的性能验证主要是基于传统的有限元法、矩量法或时域有限差分法等电磁计算方法^[9-11]。尽管这些方法能够提供准确的电

磁场解，但仿真耗时确实也很长，尤其是对于复杂的天线结构，或者对于精密的网格剖分。当结合遗传算法或粒子群优化等全局优化算法进行设计空间搜索时，往往需要调用长时间的全波仿真进行试错，这进一步增加了设计的成本^[12-15]。

为缓解天线设计中的计算成本问题，基于深度学习与代理模型的天线优化技术提出了新的解决方案和技术路径^[16-18]。神经网络与机器学习的拟合能力为建立天线结构参数与电磁响应之间的非线性映射提供了新的数学工具。区别于传统插值方法，训练完备的神经网络能够学习高维参数空间中的复杂电磁规律，作为高精度的代理模型，替代昂贵的全波仿真求解器。一个构建完成的代理模型，其预测速度大大缩短，能够以极低的计算成本支持大规模优化迭代。其中的逆向设计方法可根据目标S参数或远场性能指标直接预测出最优几何结构，从而实现目标到结构的反向解决方案^[19-24]。同时，对于模型样本获取难、高精度仿真代价高等问题，业界正提出越来越多的解决方案。比如，

结合先验知识的空间映射技术，将优化分步骤进行，先进行粗略模型搭建，然后以少量高精度数据校正粗略模型，减少高精度数据的依赖^[25,26]；或者通过结合主动学习与迁移学习的策略，实现样本集的复用，一个样本支持多类天线设计，能够有效缓解电磁数据获取成本高的难题。

1 神经网络与算法模型基础

1.1 前馈神经网络

前馈神经网络是指神经元之间的连接不形成循环的人工神经网络，通常被用于解决非动态建模问题。其中，多层感知器是较常用的前馈神经网络结构，被广泛应用于微波建模，包括无源元件（如天线、滤波器等）结构参数优化和有源器件（如二极管、三极管等）输出特性预测^[27,28]，这里重点关注其在天线领域的应用。主要是利用多层感知器构建从输入空间，如天线的几何尺寸、结构参数，到输出空间，如S参数、增益、轴比的非线性映射。




图 1 典型多层感知器的神经网络概念图

一个典型的全连接多层感知器由输入层、若干隐藏层和输出层构成,各层之间通过权重连接,一个最简单的三层感知器如图1所示。对于一个包含 L 层的网络,第 l 层神经元的输出向量 $\mathbf{h}^{(l)}$ 可表示为前一层输出的线性变换经非线性激活函数处理后的结果:

$$\mathbf{h}^{(l)} = \sigma(\mathbf{W}^{(l)} \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}) \quad (1)$$

其中, $\mathbf{W}^{(l)}$ 、 $\mathbf{b}^{(l)}$ 分别为第 l 层的权重矩阵与偏置向量矩阵, $\sigma(\cdot)$ 为Sigmoid、Tanh或ReLU等非线性激活函数。

在天线设计中,前馈神经网络的训练可以看作是对权重 $\mathbf{w}$ 的优化,利用仿真软件得出天线的性能作为训练集,通过反向传播调整权重 $\mathbf{w}$,最小化预测响应 y_k 与全波仿真真值 d_k 之间的损失函数 $E(\mathbf{w})$:

$$E(\mathbf{w}) = \frac{1}{2} \sum_{k=1}^K \|y_k(\mathbf{x}_k, \mathbf{w}) - d_k\|^2 \quad (2)$$

但是,对于一些具有急剧变化的响应曲线,多层感知器往往表现出训练难、精度低的问题。针对这一点,常选用更针对局部优化的径向基函数网络。设计中一般采用具有局部特征的函数,比如,可以使用高斯函数 $\phi_j(\mathbf{x}) = \exp(-\beta_j |\mathbf{x} - \mathbf{c}_j|^2)$ 作为激活函数,输出 $y(\mathbf{x}) = \sum_{j=1}^J \mathbf{w}_j \phi_j(\mathbf{x}) + \mathbf{b}$ 为这些响应的线性组合。相比于采用全局逼近方式的多层感知机,建模效果更好,训练过程也更为简便。这主要得益于网络结构对输入输出映射中的局部非线性行为拟合,有利于缓解响应曲线急剧变化的问题。此外,一些其他的网络结构同样能达到这种效果,比如小波神经网络主要就是针对高度非线性或存在突变的响应曲线拟合。同样,如果对准确度要求宽松一些,极限学习机作为单隐藏层前馈神经网络的典型,可以在有限的训练数据集下,快速完成电磁参数的粗略建模^[29]。

得益于其强大的表征能力,前馈神经网络适用于处理高维输入数据,这在微波器件建模中的效果是很可观的^[30]。

1.2 基于知识的神经网络

尽管多层感知器对非线性问题可以做到良好的拟合预测,但它同样存在着训练集依赖问题,数据集的优劣将直接决定预测效果的好坏,这与想要减少高精度训练集的初衷不合。为了有效利用已有的微波物理知识,Feng等提出基于知识的神经网络(KBNN),将先验知识与数据驱动模型集合,提升模型的数据利用效率,减少数据依赖^[31]。

基于知识的神经网络一般包含“粗糙模型”与“精细模型”两部分。粗糙模型 $\mathbf{R}_{\text{coarse}}$ 通常基于经验公式、等效电路模型或低精度快速仿真算法,能够提供天线响应的物理趋势,为天线优化指明方向,但其精度有限,无法直接作为最终模型预测输出响应;精细模型 $\mathbf{R}_{\text{fine}}$ 则是一个神经网络,用于学习粗糙模型与高精度全波仿真真值之间的偏差或映射函数。一种典型的加法型基于知识的神经网络输出如图2(a)所示,其数学表达式为:

$$\mathbf{R}_{\text{KBNN}}(\mathbf{x}) = \mathbf{R}_{\text{coarse}}(\mathbf{x}) + \mathbf{R}_{\text{fine}}(\mathbf{x}, \mathbf{w}) \quad (3)$$

基于这种将物理先验知识与神经网络融合,校正粗细模型差异的思想,主要实施方法可分为四类^[32-35]。

1) 差分方法:数学表达为 $\mathbf{R}_{\text{KBNN}}(\mathbf{x}) = \mathbf{R}_{\text{coarse}}(\mathbf{x}) + \mathbf{R}_{\text{fine}}(\mathbf{x}, \mathbf{w})$,类同加法型基于知识的神经网络,模型的核心思想在于校正粗糙模型的误差。首先,利用粗模型提取主要物理非线性,然后基于神经网络开始拟合残差函数,基于先验知识保证了残差函数具有小动态范围和平滑曲面特性,这种做法可以让神经网络易于收敛,可以减少训练样本的需求。




图 2 基于知识的神经网络模型图

2) 多知识嵌入方法: 将多个粗糙模型 $\{F_{\text{coarse}}^{(1)}, F_{\text{coarse}}^{(2)}, \dots, F_{\text{coarse}}^{(K)}\}$ 的预测同时嵌入网络, 神经网络充当融合器, 学习其自适应加权融合, 从而获得比任何单一先验模型更广的有效覆盖空间:

$$F_{\text{em}}(\mathbf{x}) \approx F_{\text{nn}}(\mathbf{x}, F_{\text{coarse}}^{(1)}(\mathbf{x}), \dots, F_{\text{coarse}}^{(K)}(\mathbf{x})) \quad (4)$$

这里的粗糙模型能够探索更为广阔的设计空间, 粗细模型集成学习, 可以有效加快模型的训练过程, 同时保证了模型的鲁棒性。

3) 先验知识输入方法: 主要思想就是利用粗糙模型输出与真实响应之间的相关性为训练提供指引, 粗糙模型的输出 $F_{\text{coarse}}(\mathbf{x})$ 将作为神经网络的附加输入, 这可以对输入空间作出扩展。

$$F_{\text{em}}(\mathbf{x}) \approx F_{\text{nn}}(\mathbf{x}, F_{\text{coarse}}(\mathbf{x})) \quad (5)$$

利用粗细模型的相关性简化神经网络的映射复杂度, 将一部分的复杂度移交给更为简单的粗糙模型完成, 通过先验知识的相关程度与精细模型的数据量在仿真精度和训练难易程度上做出平衡。

4) 空间映射神经网络: 空间映射技术是微波工程领域的经典优化算法。该技术被引入作为神经网络先验模型, 在基于知识的神经网络框架下, 神经网络被训练用于寻找一个从精细参数空间 $\mathbf{x}$ 到粗糙参数空间 $\mathbf{p}$ 的非线性映射 $\mathbf{P}$:

$$\mathbf{p} = F_{\text{nn}}(\mathbf{x}) \quad (6)$$

使得在该映射空间下, 粗糙模型的响应能够复现精细模型的行为:

$$F_{\text{em}}(\mathbf{x}) \approx F_{\text{coarse}}(F_{\text{nn}}(\mathbf{x})) \quad (7)$$

同样地, 映射模型训练完后, 设计迭代将在粗糙模型中完成, 之后以少量高精度数据完成粗糙模型到细模型的误差校正, 由于粗糙模型仿真获取难度低, 优化迭代速度快, 这有利于大幅提升设计与优化的效率空间, 如此一来, 复杂的电磁优化问题就转化为寻找空间映射函数的问题^[36]。

基于先验知识的神经网络就是通过在网络训练过程中或者在网络训练之前引入相关的经验公式或者粗糙模型的物理约束, 从而减少高精度样本的依赖, 能够在数据需求、模型精度和鲁棒性上取得平衡, 这对于需要高成本的电磁仿真模型是一个行之有效的解决途径^[37-39]。

1.3 逆向神经网络结构

一个完整的天线设计要能够根据预期性能指标设计所对应的天线结构, 与正向代理模型不同, 逆向神经网络致力于根据目标找到合适的天线输入参数。但是, 在天线设计中, 往往需要多目标一起满足, 这就对优化方法作出了

要求,因为一对多的映射往往会使网络难以收敛。为应对多目标设计需求,逆向神经网络常采用多分支并行结构。一个需要同时满足 S 参数、增益和远场性能的设计任务,其映射关系可描述为:

$$\mathbf{y}_{\text{geom}} = \mathcal{F}_{\text{merge}}(\mathcal{F}_S(\mathbf{x}_S), \mathcal{F}_{\text{Gain}}(\mathbf{x}_{\text{Gain}}), \mathcal{F}_{\text{Pattern}}(\mathbf{x}_{\text{Pattern}})) \quad (8)$$

其中, $\mathcal{F}_i$ 代表针对第 i 类物理指标进行特征提取的子网络, $\mathcal{F}_{\text{merge}}$ 为特征融合与回归网络。在这里,网络输入层被解耦为多个独立的并行分支进行处理。




图3 使用正向神经网络获取先验知识的正逆向神经网络结合模型

此外,为解决逆向训练数据获取难题,结合高精度的正向网络作为先验知识产生大量可靠的虚拟样本,成为在低成本下充分训练逆向网络的有效策略^[40]。图3即为一种正逆向神经网络结合模型。

1.4 自适应与进化神经网络

自适应与进化神经网络吸收了原来传统优化设计中的思想,引入动态演化机制,将神经

网络的训练与遗传算法、粒子群优化等优化算法结合^[41],这可以减少数据集的浪费,将大规模训练样本获取改为了先小样本训练,再结合优化算法判断样本范围需求,之后再生成样本进行训练,这常常用在神经网络缺乏某些先验数据或设计空间未知的情况下。具体而言,就是借助闭环演化思想,利用两个合作协同的网络,在这里,一个网络用于生成设计参数,这可能是一个训练好的逆向网络;一个用于快速评估性能,一般引入传统优化算法,通过梯度下降更新权重,或者利用进化策略动态调整网络的权重参数。这将使得网络能够同步进行学习、判断和生成,即系统利用当前预测结果指导新的全波仿真采样,并将新样本实时加入训练集用以更新网络。这种思想是以最小的仿真代价实现设计收敛,但是有可能会局部最优的情况。

1.5 高斯过程与降维模型

前述神经网络常用于天线设计领域的参数优化问题,即拓扑结构已知,优化参数。不过,为了探索天线设计的极限问题,现在有高维数拓扑优化的天线设计,这就需要统计学习的方法与降维技术。其中,高斯过程回归常被提及,其得益于非参数化的思想,可以应用于小样本条件下的代理建模。高斯过程不再是传统确定性预测的思想,而是选择提供预测值的概率分布。对于输入 $\mathbf{x}$,其输出 $f(\mathbf{x})$ 服从高斯过程:

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')) \quad (9)$$

其中, $m(\mathbf{x})$ 为均值函数, $k(\mathbf{x}, \mathbf{x}')$ 为协方差核函数。

当前,像素化天线越来越多被提及,而且一些复杂超表面结构或者一些高自由度的天线拓扑,它们的变量维度往往不再是几个特定的几何结构参数,而是通过数字比特的思想转化为了高维像素阵列。传统方法在这里完全不再

适用，结构不再是手动可调的规则几何，直接构建代理模型不可行^[42]。为了解决这种复杂几何与计算模型之间的矛盾，这就需要采用降维技术将高维离散的拓扑结构映射到低维连续的像素流。此时，一些具有统计规律（也就是结构相似）的几何群首先被捕捉，利用线性特征提取这种结构作为整体结构的主成分，之后这些主成分，可以通过正交变换（如旋转、平移、重叠等）将复杂的高维几何拓扑映射为包含主要特征的低维几何主成分。

$$x_h \approx \mu + \sum_{i=1}^d \alpha_i v_i \quad (10)$$

其中， v_i 是从几何样本中提取的基函数， α_i 是低维设计系数， μ 是误差补偿量。通过这种方式，优化过程仅需针对少量的系数 α 进行，从而大幅压缩搜索空间。

而针对更复杂的非线性拓扑特征，引入了非线性流形学习思想，具体借助深度自动编码器的强大降维能力，将几何结构降维由编码器

Enc、解码器Dec两部分完成。其中，编码器负责将高维像素化或网格化几何 x_h 压缩为低维潜在向量 z ：

$$z = \text{Enc}(x_h) \quad (11)$$

解码器则负责从潜在向量重构几何结构：

$$x_{\text{rec}} = \text{Dec}(z) \quad (12)$$

在此框架下，神经网络代理模型构建在低维潜在空间 z 与电磁响应 y 之间（即 $y \approx F_m(z)$ ）。优化算法在光滑、连续且维数较低的潜在空间 z 中寻找最优解，最后通过解码器将其还原为物理可实现的复杂拓扑结构。这不仅降低了计算复杂度，还能够通过潜在空间的正则化约束保证生成结构的平滑性与可加工性。

基于知识的神经网络通过在学习过程中引入物理约束，成功在模型精度、训练成本和泛化能力之间取得了平衡；而结合几何降维技术，进一步拓展了其在处理高维、复杂微波器件拓扑优化问题上的能力，是现代电磁辅助设计的重要发展方向。




图 4 文献 [43] 提出的用于滤波器拓扑优化的卷积神经网络拓扑优化架构与模型示例

2 机器学习驱动的天线优化关键技术

本章探讨了具体的代理模型应用于天线设计中的效果,借助神经网络和机器学习的非线性拟合能力,用以缓解参数复杂性、仿真高成本、多目标高性能的需求所带来的一系列挑战。通过列举实际案例,分析解决思路及方法效果,概述了其中的算法原理和网络架构设计,并指出了其应用的天线模型。

2.1 高保真代理模型与几何特征提取

在处理大型非均匀阵列或相控阵设计时,常利用深度神经网络替代全波电磁仿真的计算,解决传统数值计算方法耗时过长的问题^[44]。在这里,神经网络架构通常包含输入层、隐藏层,以及输出层。其中,输入层为阵列的几何分布参数,如天线相位馈电或位置坐标,这将影响单元间距,隐藏层通过训练,调整权重系数 w ,使网络拟合输入参数与电磁响应之间的非线性映射关系,输出层一般为 S 参数、有源单元方向图或其他远场性能指标。在具体实施中,可以结合传统进化算法,如粒子群优化、遗传算法,进行适应度评估并生成下一次迭代所需的样本,从而提升阵列综合的效率。

例如,针对大型非均匀阵列设计中的互耦问题,文献[45]提出了一种结合机器学习辅助代理模型与有源单元方向图技术的解决方案。网络输入为目标阵元与其前后邻域单元的几何向量,借助有源单元方向图思想以解构整体阵列,大大减少了训练的复杂度。之后利用两个并行的深度神经网络分别建立子阵列几何参数,这里就是前文的邻域几何向量与中心阵元矢量有源单元方向图(Vec. AEP)的非线性映射。为了进一步简化训练,提取有源单元方向图的特征向量,即正交的 E_ϕ 与 E_θ 作为输出。这

种做法打破了传统思想直接将整个阵列几何作为输入,巧妙地利用了有源单元方向图,在考虑互耦的情况下简化了训练难度,这主要是阵元互耦具有局部衰减特性,远处的阵元对中心阵元的影响足以忽略,构建了以子阵列特征为核心的输入机制。文中还有一大创新,即引入了异构迁移学习策略,实现一个数据集多类天线设计复用的思想,大大缓解了不同规模阵列需重复生成数据集,占用昂贵的仿真资源等问题。对于不同单元数量的大规模阵列性能,文章利用在小规模阵列数据集上训练好的模型,直接进行大规模的阵列预测,并且对于不等间距排列的阵列,同样具有良好的远场性能预测。实验表明,在128单元的圆极化交叉偶极子阵列综合中,该方法将全波仿真所需的6小时计算时间压缩至0.235秒,同时能够保持预测精度,达到了旁瓣电平误差 <0.5 dB,轴比误差 <0.1 dB。这种将整体结构拆分为局部特征,利用局部特征预测整体,充分结合了有源单元方向图的思想,成功将计算复杂度由 $O(N^2)$ 降低至 $O(N)$ 。这一方法不仅实现了对非均匀阵列低旁瓣、低交叉极化和宽角扫描特性的快速预测,同时也为大规模阵列预测提出了新的解决思路。文献[45]提出的网络架构与模型优化示例如图5所示。

2.2 基于深度神经网络的多目标逆向设计

天线设计已不满足单一的阻抗匹配,需同时兼顾增益、轴比、旁瓣电平和交叉极化等多项指标。这种多目标大大增加了设计的自由度,直接构建从响应空间到几何参数空间的逆向映射网络容易收敛困难。为此,提出了多分支并行架构与知识辅助策略,以解耦多目标优化中不同物理量(如 S 参数、增益、方向图)在输入要求上的差异性,这同样是一种整体到局部的




图 5 机器学习辅助的天线阵列优化架构与优化结果示例 [45]

简化思想，因为多目标综合复杂度总是大于单目标综合的。具体而言，采用了独立的并行分支分别提取特征，不再仅仅关注单一层的传统设计，各分支的目标综合将再引入深层的神经网络进行训练，最终各目标在深层网络进行融合，有效缓解了多目标间的特征干扰、难以收敛的问题。同样地，为了减少训练成本，采用先验知识辅助，缓解全波电磁仿真耗时导致的高精度训练集难以获取问题。具体实施为训练一个高精度的正向神经网络作为快速替代模型，并利用该正向神经网络扩展数据集，即再生成海量的虚拟数据。此操作扩充了训练集，有利于平滑训练过程，提高逆向网络的泛化能力与精度。

以文献[46]为例，针对超宽带天线多目标难优化的问题，Xiao等提出了多分支逆向神

经网络架构。文献主要设计了三个独立的特征提取子网络，分别对这三类目标进行独立训练，缓解了多目标下S参数、增益，以及辐射方向图的复杂性提高，训练难收敛的问题。三个分支提取的异构特征将采用深层神经网络进行融合，最终直接预测给出输出天线的几何结构参数。实验结果表明，文中成功实现了给定目标下，快速预测给出几何尺寸，这有效解决了多目标的特征冲突，且预测的准确率优于传统的单分支网络。

此外，文献[47]在3D打印介质透镜天线的设计中，验证了知识型神经网络的高效性。针对透镜天线几何复杂、单次全波仿真极为耗时等挑战，文章采用了先验知识嵌入策略，利用CST仿真软件结合拉丁超立方采样获取少量




图 6 文献 [46] 中用于验证多目标多分支神经网络优化算法的多模共振天线模型与预测结果对比




图 7 3D 打印透镜天线模型与仿真实测对比结果 [47]

高保真样本，训练基础前馈神经网络，随后利用该网络作为生成器构建了包含数万组“几何-性能”映射的增强数据集。这种做法显著降低了对仿真数据的依赖，样本效率提升，大幅降低了高性能定制化介质天线的设计门槛。

2.3 基于物理知识的空间映射优化

传统的空间映射技术通过建立“粗糙模型”与“精细模型”之间的线性或简单非线性关联来加速优化。但是，在处理涉及电磁-热-应

力耦合的复杂微波器件时，这种映射关系已无法采用某一函数代替，因为简单函数无法跨拟合多物理场之间的高维非线性偏差。为了解决这个问题，文献[48]中提出了多保真度传输函数网络，通过引入分层递进的映射，将复杂问题分布处理，缓解多物理场带来的复杂度增加。

该方法不再试图一步到位地学习从低精度模型到多物理场模型的映射，而是构建了双层空间映射框架。第一层映射用于建立“粗网格电磁模型”与“细网格单物理场电磁模型”之间的关联。第二层映射用于建立“细网格单物理场电磁模型”与“高保真多物理场模型”（包含电-热-力耦合，计算最慢）之间的关联。在此框架中，神经网络被参数化为非线性传输函数，分别学习各层级模型之间的输入空间映射和输出校正参数。数学上，这种级联映射可表示为：

$$R_{\text{multi}} \approx R_{\text{em, fine}}(P_{\text{ANN2}}(x)) \approx R_{\text{em, coarse}}(P_{\text{ANN1}}(P_{\text{ANN2}}(x))) \quad (13)$$

这种架构有效地将复杂的多物理场计算负担分解，利用中间层级（单物理场em）作为“桥梁”，降低了神经网络对昂贵多物理场训练数据的依赖。




图 8 文献 [48] 中的验证双层多保真度空间映射算法的压电贴片天线模型与优化结果对比

例如，文献[48]提出了一种基于人工神经网络的双层多保真度空间映射算法，利用神经网络作为映射算子，训练神经网络学习从“粗网格em”到“细网格em”，以及从“细网格


em”到“多物理场”的非线性偏差。这种算法可以在低成本的粗模型空间中进行快速搜索，扩展参数优化的空间，其中，关键节点选择调用少量多物理场仿真进行校正。实验验证表明，该方法在保证设计精度的同时，显著减少了昂贵的多物理场仿真次数。其天线结构与结果如图8所示。

2.4 基于机器学习的天线几何拓扑演化与多物理场协同优化


现在，像素化天线越来越被提及，其变量的维度往往不再是几个几何结构参数，而是利用数字比特的思想转化为了高维数的像素阵列。进行这种非规则的天线拓扑优化，其思路就是在输入层采用像素化网格或二进制矩阵以表征天线表面的金属分布，数字化天线结构。之后，利用卷积神经网络的平移不变性以及局部特征提取能力，捕捉天线几何拓扑中的边缘耦合及电流路径，旨在提取出结构的主成分或者典型结构，之后将整体映射为低维的特征向

量。为了在预测精度与计算效率之间取得平衡，架构中通常会集成卷积神经网络构成的分类器，快速判别生成的拓扑结构是否满足连通性，是否物理可实现，从而剔除大量无效解；同时，集成高斯过程回归或深度神经网络的回归器，对拓扑结构进行精细的性能预测，筛除不符合预期的无效结构，同时提供预测的不确定性估计以指导采样。

该类方法的具体实施通常嵌入在进化算法的迭代循环中，需要边学习边预测边筛选。机器学习模型替代全波电磁仿真或流体动力学仿真对离散化为像素矩阵的设计个体进行适应度预评估，因为像素化的结构在传统仿真中将极大耗费时间。关键的实施策略在于模型的序列化与模型的实时更新。文献[49]的思路就是采用分步优化策略，先利用流体仿真数据训练代理模型优化接地结构的拓扑以降低风阻，固定该最优拓扑后再针对辐射单元进行电磁性能的拓扑演化；为了指导优化方向、减少成本高昂的精细模型仿真数据，同时采用主动学习策



(a) 优化前后的 5G 基站天线模型对比



(b) 优化前后的抗风阻效果对比

图 9 机器学习辅助拓扑设计的天线模型与效果对比 [50]

略, 仅对代理模型预测表现优异或不确定性较高的拓扑结构调用真实物理仿真进行验证, 边筛选边预测边仿真验证, 之后将新生成的仿真数据实时回馈至训练集, 通过不断修正代理模型的决策边界, 以最小的仿真代价逼近全局最优拓扑, 这在保证精度的同时, 能大大缓解数据依赖性。

具体而言, 文献[49]为了解决像素化天线设计的效率问题, 提出采用机器学习辅助天线几何设计。文中针对一款用于互耦降低的E形贴片天线及多频天线, 采用了卷积神经网络作为分类器筛选无效几何, 高斯过程回归作为回归器预测S参数, 其中, 网络的输入为高分辨率的二进制像素矩阵, 以0/1二进制编码代替金属/非金属的拓扑。相比于传统的遗传算法, 该方法通过代理模型能够过滤大部分无效的全波仿真计算, 实验表明, 其不仅成功设计出了满足多频段指标的复杂像素结构, 且收敛速度比传统方法快3倍以上, 有效提升了在超高维设计空间中的寻优能力。文献[50]则进一步将机器学习拓扑优化扩展至低风载基站天线的多物理场设计中, 如图9所示, 针对Sub-6 GHz频段的大规模阵列风荷

载过大问题, 研究者提出了一种序列多物理场机器学习辅助优化方法。金属接地结构转为像素化拓扑, 利用深度神经网络训练风阻预测模型, 优化出一种具有低风阻特性的创新拓扑结构; 随后, 在此基础上, 对偶极子辐射臂的几何形状进行了电磁优化。最终设计的 4×4 双极化阵列在保持优异电磁性能的同时, 通过拓扑优化实现了73%的风荷载降低, 同时考虑了多物理场与天线性能, 这为传统天线优化提供了新的方向。

3 基于神经网络空间映射技术的天线优化具体实践

3.1 算法原理与网络代理模型架构

针对全波电磁仿真在复杂天线优化中计算成本过高的问题, 在之前的研究工作^[51]中提出了一种结合输入空间映射与神经网络的代理模型优化策略。该模型采用超表面与圆极化天线的粗网格剖分求解器作为粗略模型, 具有更快收敛、更快迭代速度, 但准确度欠缺的响应结果, 采用细网格剖分求解器作为精细模型, 具有更好的收敛精度、更长的仿真时间和高保真




图 10 空间映射神经网络的概念化模型与具体应用模型

性的响应结果。核心思想就是构建一个计算廉价的“粗糙模型”以探究更为广阔的设计空间，以及为精细模型提供优化方向；之后高保真的“精细模型”用于保证预测的精度，由于粗模型带来的先验知识，这里只需使用少量数据以完成粗细模型之间的误差校正。如图 10 所示，空间映射神经网络由一个训练好的神经网络映射模块与一个使用粗网格剖分结果训练的粗糙模型级联结合而成。

在数学表述上，设 $\mathbf{x}_f$ 为精细模型的设计变量空间， $R_f(\mathbf{x}_f)$ 为其对应的电磁响应（如 S 参数、轴比）；同理，设 $\mathbf{x}_c$ 与 $R_c(\mathbf{x}_c)$ 分别为粗糙模型的变量与响应。粗模型计算成本低廉，但结果常会产生“错位现象”，导致结果出现一定程度上的失真。为减少超表面圆极化天线精细模型与粗略模型之间因网格划分差异导致的响应错位现象，这种差异可以表示为 $|R_f(\mathbf{x}) - R_c(\mathbf{x})| > \varepsilon$ ，文中引入神经网络作为非线性映射的代理模型 P_{NN} ，建立从精细空间到粗糙空间的映射关系：

$$\mathbf{x}_c = P_{NN}(\mathbf{x}_f, \mathbf{w}) \quad (14)$$

其中， $\mathbf{w}$ 为神经网络的权重参数。通过训练神经网络，使得映射后的整体模型能够准确反映精细模型的响应关系。

$$R_{\text{surrogate}}(\mathbf{x}_f) = R_c(P_{NN}(\mathbf{x}_f)) \approx R_f(\mathbf{x}_f) \quad (15)$$

这一步需要建立的是粗细模型的校准项，给定的精细模型几何参量可以通过空间映射函数得到校准后的粗模型输入，进而得到校准后的天线性能响应。同样地，该部分神经网络模型采用常用的多层感知器神经网络模型，包含输入层、隐藏层和输出层。隐藏层采用非线性的 sigmoid 函数作为激活函数。由于粗细模型之间的映射关系通常较为简单，且非线性程度比较低，因此可以采用较少数量的隐藏神经元构建该映射。

在该架构中，粗网格剖分全波求解器的仿真结果作为训练集 1，用于构建反映圆极化天线基础响应及其大致优化方向的粗模型代理模型；而精细网格剖分求解器的仿真结果则作为训练集 2，用于学习因网格剖分差异所引起的频率偏移与幅度误差，通过少量样本即可保证精细模型的精度。即，粗网格数据能够提供广泛广阔的设计空间探索，并为高精度准确响应的模型提供全局优化的指导，而细网格数据则确保最终解的保真度和准确性。

3.2 超表面加载圆极化天线设计实例

为验证上述算法的工程有效性，选取了超表面加载圆极化交叉偶极子天线作为优化对象。如图 11 所示，基于传统交叉偶极子天线进




图 11 优化所使用的超表面圆极化天线仿真模型与实物模型

行了蛇形蜿蜒线加载、末端弯折、不等长切割等操作。不等长蛇形蜿蜒线,有效延长了电流路径,既能够降低谐振频率,又能够缩小天线辐射体尺寸;双分支不等长切割的偶极子拓扑与末端加载的非对称箭头尾端可以达到双频展宽的目的;背面反射器可实现较宽的轴比波束宽度,并为天线辐射提供了良好的前向增益。整体结构由顶层的印刷交叉偶极子辐射单元与底层的超表面反射板组成。圆极化辐射是通过交叉偶极子的空心四分之一波长($\lambda_g/4$)延迟环以形成关键的 90° 相位差,而偶极子拓扑形成相等的正交幅度。底部的超表面阵列用电磁带隙结构替代传统金属反射板,利用其对反射相位的操控,可以在目标频段内得到随频率变化的相位,以补偿只能满足单一频率(中心频率 f_c)下的反射板高度 H ,从而优化相位敏感的圆极化性能;同时,亚波长的基本结构也有利于尺寸的缩减,通过精心设计的电磁带隙基本结构,在维持或提升天线辐射性能的同时,将反射板面积压缩至半波长(对应于中心频率 f_c)以下。不仅作为反射地平面,还通过其独特的相位响应改善天线的轴比带宽与增益特性,实现整体小型化的目的。

基于实际的设计需求,超表面圆极化天线的优化指标设定在L/S波段,具体要求在1.98 GHz至2.2 GHz的频带范围内,同时满足回波损耗 S_{11} 小于-20 dB以及轴比AR小于3 dB。由于结合超表面的天线设计复杂度高,参数扫描或直接优化方法难以快速收敛,仿真时间长,优化成本高,采用空间映射神经网络作为代理模型进行天线设计优化。对于粗粒度模型,设定收敛精度为0.04,在HFSS中仅需2~4次网格划分迭代即可。相比之下,设定精细模型的收敛精度为0.01,这就需要更多网格迭代次数与计算时间,也能够获得更精确的结果。粗

网格剖分的等效替代模型采用三层前馈神经网络结构,并设置sigmoid激活函数,输入输出分别为由HFSS得到的粗模型响应以及给定的几何参量。同样地,输入映射函数也采用三层感知机模型,激活函数为sigmoid函数。文中精细模型采用高精度的自适应网格剖分,以确保结果作为精度的可靠性;粗模型低剖分网格密度以快速获取响应结果,其单次仿真耗时仅为精细模型的几分之一,虽然精度有差异,但是其保留了关键的响应趋势与物理规律。

3.3 优化实施流程与仿真加工验证

实验设计阶段采用了实验设计法进行正交取点,生成81组粗网格样本用于对粗模型的代理模型进行训练,49组精细网格样本用于对输入神经网络进行训练,兼顾广阔的设计空间探索与局部误差校准。此外,测试集采用另外的随机的20组样本仿真数据构建,用于泛化性能评估。粗网格剖分求解器的替代模型以及输入映射的代理模型性能的评估,通过测试集与代理模型预测之间的均方根误差进行量化。

模型精度的量化评估采用均方根误差作为核心指标。在第四次即最终优化迭代中,粗网格替代模型的训练误差、测试误差分别为1.46%、1.95%;完整基于空间映射神经网络代理模型的训练误差、测试误差在最终迭代中达到1.5%、2.06%。经过四个优化周期,也就是四次完整的迭代过程后,预测结果出现收敛,最终优化后的设计参数为 $\mathbf{x}=[32.5, 32, 4.06869, 4.0, 4.0, 46.0609]^T$ 。HFSS仿真结果、基于空间映射神经网络的预测结果与实物测量的结果如图12所示,同时该图展示了加工的实物图及暗室测量图。如图12所示,仿真结果与预测结果吻合良好,且都满足了预先设定的优化目标,说明了方法的有效性。




图 12 基于空间映射神经网络的天线 HFSS 仿真、模型预测、加工实测对比图

最终，超表面加载的圆极化交叉偶极子天线在 1.98 ~ 2.2 GHz 目标频段实现了 S_{11} 小于 -20 dB（实测小于 -18.4 dB）、轴比小于 3 dB 的性能指标，圆满达成了预期的设计目标。实际上， S_{11} 在 1.78 ~ 3.03 GHz 范围内（相对带宽 51.9%）始终保持小于 -10 dB，3 dB 轴比带宽覆盖 1.96-2.23 GHz（相对带宽 12.9%）。

此外，为进一步阐明模型的优势，评估计算效率，表 1 将提出的空间映射神经网络方法与遗传算法（GA）及传统人工神经网络优化进行了对比。通过采用空间映射技术，代理模型能够在保持相当精度的同时，以更少的迭代次数及 CPU 耗时实现了更优的收敛速度。总体而言，

从计算总耗时看，传统的遗传算法进行了约 100 次迭代，并行计算总时间为 34 小时，其结果仍出现不完全收敛的情况。传统的神经网络优化耗时大大降低，约为 6.8 小时，但是需要 9 次迭代才能完成最终收敛。而基于空间映射的优化策略，尽管用了更多的数据（粗模型数据），而且一次迭代的耗时更多，但是其仅需 4 次迭代即可收敛，时长再次降低为 3.4 小时。粗模型探索广阔的设计空间并为精细模型提供设计指导，精细模型少量但精确，用于校正响应的差异，每次迭代的计算负担有很大一部分转移到了廉价的粗模型上。这大大降低了神经网络对精细模型的依赖，大大减少了优化所需时间，为天线优化设计提出了切实可行的解决途径。

表 1 使用不同优化方法优化超表面圆极化天线的性能比较

优化方法	遗传算法	传统神经网络优化	基于空间映射神经网络优化
迭代次数	100	9	4
每次迭代所需的粗网格样本数	—	—	81
每次迭代所需的细网格样本数	1	49	49
每次迭代粗网格计算时间	—	—	7 min 30 s
每次迭代细网格计算时间	20.4 min	36.7 min	36.7 min
HFSS 仿真评估所需的总时间	20.4 min×100	36.7 min×10	(36.7 + 7.5)min×5
代理模型训练和优化所需的时间	—	4.4 min×9	5.2 min×4
并行计算所需要的总时间	34 h*	6.8 h	3.4 h

注：* 表示设计目标尚未满足。

4 面临的挑战与未来展望

基于神经网络与机器学习代理模型进行的天线设计仍面临着许多挑战。未来的一大重要方向是发展物理信息神经网络。物理神经网络不再是简单地将模型的输入输出响应给到网络，而是嵌入电磁场的麦克斯韦方程，这将使得预测不再是无边界的，可能违反实际的设计，网络在给出预测的同时能判断这些结果是否满足基本物理定律，有利于在少样本甚至无典型数据的情况下，确保预测结果满足物理一致性^[52]。这样不仅能够大幅降低网络的数据依赖性，还能够提高模型的鲁棒性及快速预测能力，为电磁场的计算提供一种可以替代传统数值算法的解决思路。另外，目前越来越多的天线设计不满足于对传统拓扑进行优化，而是利用生成对抗网络及扩散模型构建新型拓扑，这有利于逼近天线设计的极限性能^[53]，目前也已经成为天线优化的一大热门方向。这将带来非常高的设计自由度，一些传统设计难以达到的结构已经在超表面、滤波器、天线等领域得以验证^[54]。此外，针对神经网络的数据问题，高精度电磁仿真数据获取成本高昂，这衍生了

减少数据依赖、平衡精度和训练量的方向，目标是开发一种通用的预训练模型，使其能作为一个有利的粗模型或先验知识来对各种具体天线做出设计指导^[55]。

5 结语

随着无线通信技术发展，对天线的需求将越来越高，天线将更加复杂，将面临计算成本高、设计周期长等新问题。本文系统性地总结了深度学习与代理模型在天线优化领域的相关研究、所具有的优势，以及所面临的问题。文章从基础的神经网络架构到应用于天线设计中的实际案例，分析了具体应用中如何在预测精度和数据需求之间做出平衡，以及如何借助策略来简化训练，加快优化进程。本文用实例说明了数据驱动结合物理先验知识是解决高维、非线性、高复杂度天线设计的有力途径，能够在保证精度的前提下将设计周期大大缩短。

参考文献

- [1] Liu Fulai, Zhou Wu, Qin Dongbao, et al. CAWE-ACNN

- algorithm for coprime sensor array adaptive beamforming[J]. Sensors, 2024, 24(17): 5454.
- [2] Xue Cong, Zhu Hairui, Zhang Shurui, et al. Broadband beamforming weight generation network based on convolutional neural network[J]. IEEE Geoscience and Remote Sensing Letters, 2024, 21: 4501105.
- [3] Marzetta T L. Noncooperative cellular wireless with unlimited numbers of base station antennas[J]. IEEE Transactions on Wireless Communications, 2010, 9(11): 3590-3600.
- [4] Sievenpiper D F, Dawson D C, Jacob M M, et al. Experimental validation of performance limits and design guidelines for small antennas[J]. IEEE Transactions on Antennas and Propagation, 2012, 60(1): 8-19.
- [5] Li Qianqian, Zhang Haifeng. A high-gain circularly polarized antenna array based on a chiral metastructure[J]. IEEE Transactions on Antennas and Propagation, 2023, 71(4): 3033-3041.
- [6] Li Weiran, Guo Huankun, Wang Xiaoyi, et al. A 2-bit reconfigurable metasurface with real-time control for deflection, diffusion, and polarization[J]. IEEE Transactions on Antennas and Propagation, 2024, 72(2): 1521-1531.
- [7] Wang Jiafu, Li Yue, Jiang Zhi hao, et al. Metantenna: when metasurface meets antenna again[J]. IEEE Transactions on Antennas and Propagation, 2020, 68(3): 1332-1347.
- [8] Venkateshwaran S, Rao K K, Kumbha S R. Design and implementation of circular polarized patch antenna using EBG structure[C]//2022 IEEE Microwaves, Antennas, and Propagation Conference, December 12-16, 2022, Bangalore, India. IEEE, 2022: 1792-1797.
- [9] Garg A, Sharma A, Zheng Weiguang, et al. A review on artificial intelligence-enabled mechanical analysis of 3D printed and FEM-modelled auxetic metamaterials[J]. Virtual and Physical Prototyping, 2025, 20: e2445712.
- [10] Alhaj Hasan A, Nguyen T M, Kuksenko S P, et al. Wire-grid and sparse MoM antennas: past evolution, present implementation, and future possibilities[J]. Symmetry, 2023, 15(2): 378.
- [11] David D S K, Jeong Y, Wu Yin chao, et al. An analytical antenna modeling of electromagnetic wave propagation in inhomogeneous media using FDTD: a comprehensive study[J]. Sensors, 2023, 23(8): 3896.
- [12] Rahmat-Samii Y, Gies D, Robinson J. Particle swarm optimization (PSO): a novel paradigm for antenna designs[J]. URSI Radio Science Bulletin, 2003, 2003(306): 14-22.
- [13] El Misilmani H M, Naous T, Al Khatib S K. A review on the design and optimization of antennas using machine learning algorithms and techniques[J]. International Journal of RF and Microwave Computer-Aided Engineering, 2020, 30(10): e22356.
- [14] Cha Haotian, Fallahi H, Dai Yuchen, et al. Multiphysics microfluidics for cell manipulation and separation: a review[J]. Lab on a Chip, 2022, 22(3): 423-444.
- [15] Zhu Yi, Schenk M, Filipov E T. A review on origami simulations: from kinematics, to mechanics, toward multiphysics[J]. Applied Mechanics Reviews, 2022, 74(3): 030801.
- [16] Sarker N, Podder P, Mondal M R H, et al. Applications of machine learning and deep learning in antenna design, optimization, and selection: a review[J]. IEEE Access, 2023, 11: 103890-103915.
- [17] Khan M M, Hossain S, Mozumdar P, et al. A review on machine learning and deep learning for various antenna design applications[J]. Heliyon, 2022, 8(4): e09317.
- [18] Katkevičius A, Plonis D, Damaševičius R, et al. Trends of microwave devices design based on artificial neural networks: a review[J]. Electronics, 2022, 11(15): 2360.
- [19] Gadhafi R, Copiaco A, Himeur Y, et al. Exploring the potential of deep-learning and machine-learning in dual-band antenna design[J]. IEEE Open Journal of the Computer Society, 2024, 5: 566-577.
- [20] Gosal G, Almajali E, McNamara D, et al. Transmitarray antenna design using forward and inverse neural network modeling[J]. IEEE Antennas and Wireless Propagation Letters, 2016, 15: 1483-1486.
- [21] Waqar N, Wong K K, Tong K F, et al. Deep learning enabled slow fluid antenna multiple access[J]. IEEE Communications Letters, 2023, 27(3): 861-865.
- [22] Lin Yi Lu D, Maman L, Earls J, et al. Optimization of antenna array configurations using deep learning[J]. IEEE Open Journal of Antennas and Propagation, 2025, 6(5): 1367-1374.
- [23] Yao Yifan, Park J, Jin Xianglan. Deep learning detection on multi-antenna quantize-forward relay channel based on maximum likelihood[J]. IEEE Transactions on Cognitive Communications and Networking, 2026, 12: 1978-1991.
- [24] Shao Xiaodan, Hu Limei, Sun Yulong, et al. Hybrid near-field 6D movable antenna design exploiting directional sparsity and deep learning[PP/OL]. V1. arXiv (2025-06-18) [2026-01-20]. <https://doi.org/10.48550/arXiv.2506.15808>.
- [25] Koziel S, Ogurtsov S. Antenna design by simulation-driven optimization[M]. Cham: Springer International Publishing, 2014.
- [26] Bandler J W, Cheng Q S, Dakrouy S A, et al. Space mapping: the state of the art[J]. IEEE Transactions on Microwave Theory and Techniques, 2004, 52(1): 337-361.
- [27] Zhang Q J, Gupta K C. Neural networks for RF and microwave design[M]. Boston: Artech House, 2000.
- [28] Zhang Wei, Feng Feng, Jin Jing, et al. Parallel multiphysics optimization for microwave devices exploiting neural network surrogate[J]. IEEE Microwave and Wireless Components Letters, 2021, 31(4): 341-344.
- [29] Zhang Wei, Feng Feng, Liu Wenyuan, et al. Advanced parallel space-mapping-based multiphysics optimization for high-power microwave filters[J]. IEEE Transactions on Microwave Theory and Techniques, 2021, 69(5): 2470-2484.
- [30] Feng Feng, Na Weicong, Jin Jing, et al. Artificial neural networks for microwave computer-aided design: the state of the art[J]. IEEE Transactions on Microwave Theory and Techniques, 2022, 70(11): 4597-4619.
- [31] Feng Feng, Zhang Jianan, Zhang Wei, et al. Coarse- and fine-mesh space mapping for EM optimization incorporating mesh deformation[J]. IEEE Microwave and Wireless Components Letters, 2019, 29(8): 510-512.
- [32] Watson P M, Gupta K C. EM-ANN models for microstrip vias and interconnects in dataset circuits[J]. IEEE Transactions on Microwave Theory and Techniques, 1996, 44(12): 2495-2503.

- [33] Watson P M, Gupta K C, Mahajan R L. Applications of knowledge-based artificial neural network modeling to microwave components[J]. International Journal of RF and Microwave Computer-Aided Engineering, 1999, 9(3): 254-260.
- [34] Wang Fang, Zhang Qi Jun. Knowledge-based neural models for microwave design[J]. IEEE Transactions on Microwave Theory and Techniques, 1997, 45(12): 2333-2343.
- [35] Na Weicong, Feng Feng, Zhang Chao, et al. A unified automated parametric modeling algorithm using knowledge-based neural network and l1 optimization[J]. IEEE Transactions on Microwave Theory and Techniques, 2017, 65(3): 729-745.
- [36] Jin Jing, Zhang Chao, Feng Feng, et al. Deep neural network technique for high-dimensional microwave modeling and applications to parameter extraction of microwave filters[J]. IEEE Transactions on Microwave Theory and Techniques, 2019, 67(10): 4140-4155.
- [37] Liu Zhijun, Hu Xin, Liu Ting, et al. Attention-based deep neural network behavioral model for wideband wireless power amplifiers[J]. IEEE Microwave and Wireless Components Letters, 2020, 30(1): 82-85.
- [38] Zhang Sun, Hu Xin, Liu Zhijun, et al. Deep neural network behavioral modeling based on transfer learning for broadband wireless power amplifier[J]. IEEE Microwave and Wireless Components Letters, 2021, 31(7): 917-920.
- [39] Simsek M, Zhang Q J, Kabir H, et al. The recent developments in knowledge based neural modeling[J]. Procedia Computer Science, 2010, 1(1): 1321-1330.
- [40] Ojaroudi M, Bila S, Torrès F. A new approach of multi-parameter UWB antenna modeling based on knowledge-based artificial neural network[C]//12th European Conference on Antennas and Propagation (EuCAP 2018), London, UK. Institution of Engineering and Technology, 2018: 1-5. DOI:10.1049/cp.2018.0497.
- [41] Jin Yaochu. Surrogate-assisted evolutionary computation: Recent advances and future challenges[J]. Swarm and Evolutionary Computation, 2011, 1(2): 61-70.
- [42] Liu Bo, Aliakbarian H, Ma Zhongkun, et al. An efficient method for antenna design optimization based on evolutionary computation and machine learning techniques[J]. IEEE Transactions on Antennas and Propagation, 2014, 62(1): 7-18.
- [43] Yang Yiqi, Zhang Wei, Jin Jing, et al. A cross-channel parametric CNN framework for microwave topology modeling[J]. IEEE Transactions on Microwave Theory and Techniques, 2025(99): 1-17.
- [44] Stanković Z Ž, Olčan D I, Dončov N S, et al. Consensus deep neural networks for antenna design and optimization[J]. IEEE Transactions on Antennas and Propagation, 2022, 70(7): 5015-5023.
- [45] Yang Xin, Zhao Yanwen, Wan Mi, et al. Circularly polarized antenna array synthesis based on machine-learning-assisted surrogate modeling[J]. IEEE Transactions on Antennas and Propagation, 2024, 72(2): 1469-1482.
- [46] Xiao Liye, Shao Wei, Jin Fulong, et al. Inverse artificial neural network for multiobjective antenna design[J]. IEEE Transactions on Antennas and Propagation, 2021, 69(10): 6651-6659.
- [47] Liu Yanfang, Peng Lin, Shao Wei. An efficient knowledge-based artificial neural network for the design of circularly polarized 3-D-printed lens antenna[J]. IEEE Transactions on Antennas and Propagation, 2022, 70(7): 5007-5014.
- [48] Yang Xiao, Wang Zimeng, Hu Haitian, et al. Multifidelity space-mapping-based approach for accelerated multiphysics optimization of microwave devices[J]. IEEE Transactions on Microwave Theory and Techniques, 2025, 73(12): 9902-9919.
- [49] Wu Qi, Chen Weiqi, Yu Chen, et al. Machine-learning-assisted optimization for antenna geometry design[J]. IEEE Transactions on Antennas and Propagation, 2024, 72(3): 2083-2095.
- [50] Han Biying, Wu Qi, Yu Chen, et al. Low-wind-load broadband dual-polarized antenna and array designs using sequential multiphysics machine-learning-assisted optimization[J]. IEEE Transactions on Antennas and Propagation, 2025, 73(1): 135-148.
- [51] Zhai Tong, Tang Haozhen, Liu Zuodong, et al. Advanced space-mapping-based approach for accelerated optimization of metasurface-combined circularly polarized antenna[J]. IEEE Antennas and Wireless Propagation Letters, 2025, 24(11): 3991-3995.
- [52] Raissi M, Perdikaris P, Karniadakis G E. Physics-informed neural networks: a deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. Journal of Computational Physics, 2019, 378: 686-707.
- [53] Hu Yanyan, Jin Yuchen, Wu Xuqing, et al. A theory-guided deep neural network for time domain electromagnetic simulation and inversion using a differentiable programming platform[J]. IEEE Transactions on Antennas and Propagation, 2022, 70(1): 767-772.
- [54] An Sensong, Zheng Bowen, Tang Hong, et al. Multifunctional metasurface design with a generative adversarial network[J]. Advanced Optical Materials, 2021, 9(5): 2001433.
- [55] Meng Yuquan, Dong Zhiqiao, Lu K C, et al. Meta-learning-based domain generalization for cost-effective tool condition monitoring in ultrasonic metal welding[J]. IEEE Transactions on Industrial Informatics, 2025, 21(1): 653-662.

作者简介

汤昊臻 男, 北京邮电大学硕士生在读。主要研究方向为相控阵天线、电磁优化、射频技术等。

吴季航 男, 北京邮电大学博士生在读。主要研究方向为相控阵天线、人工智能、电磁仿真加速等。

张伟 男, 北京邮电大学电子工程学院、信息光子学与光通信国家重点实验室副研究员, 博士生导师。主要研究方向为基于人工智能的电磁器件(射频、微波、毫米波、光波等器件)快速建模与优化设计EDA技术、基于人工智能与机器学习的天线设计、移动机器人运动规划等。
通信作者 email: weizhang13@bupt.edu.cn