

密级： 保密期限：

北京邮电大学

硕士学位论文



题目： 基于智能优化算法和代理模型
的天线优化设计

学 号： 2019110088

姓 名： 范文敏

专 业： 信息与通信工程

导 师： 洪卫军

学 院： 信息与通信工程学院

2022 年 5 月 30 日

中国 · 北京

密级： 保密期限：

北京邮电大学

硕士学位论文



题目： 基于智能优化算法和代理模型
的天线优化设计

学 号： 2019110088

姓 名： 范文敏

专 业： 信息与通信工程

导 师： 洪卫军

学 院： 信息与通信工程学院

2022 年 5 月 30 日

Confidentiality level: Confidentiality period:



BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

Thesis for Master Degree

**Topic: OPTIMIZED DESIGN OF ANTENNAS
BASED ON INTELLIGENT OPTIMIZATION
ALGORITHMS AND SURROGATE MODELS**

Number: 2019110088

Candidate: Wenmin Fan

Major: Information and Communication Engineering

Supervisor: Weijun Hong

Institute: School of Information and
Communication Engineering

May 30th, 2022

基于智能优化算法和代理模型的天线优化设计

摘 要

天线作为通信系统中的关键单元,承担着收发信号的重要任务,其性能直接影响整体的通信质量。技术的迭代更新催生了对于新型天线的需求,传统设计方式在应对日益复杂的天线结构和不断增加的设计自由度时显得捉襟见肘。本文基于智能优化算法和代理模型的新方法,实现了多款微带天线以性能需求为导向的多参数快速优化设计。一方面,要从多维设计空间中迅速搜索到符合需求的天线结构,需要设计一种收敛速度快且不容易陷入局部最优的算法。另一方面,为了进一步提高天线优化设计效率,避免大规模的全波仿真,还需要研究小样本代价下代理模型的构建。

主要工作包括以下几个方面:

(1) 提出改进鲸鱼优化算法(IWOA),通过实施四种改进策略更好地平衡了算法局部开发和全局搜索两种能力,进而提高整体寻优性能,在23个测试函数上的仿真对比实验证明了这一点。引入传递函数离散化处理得到的二进制改进鲸鱼优化算法(BIWOA),能够解决二进制变量下的优化问题。

(2) 基于IWOA和BIWOA分别开展了两款微带天线的高效优化设计。一款是矩形切角超宽带天线,四次结构参数优化实验得到的天线,带宽均覆盖3.1~10.6GHz,且工作频段内回波损耗表现良好。另一款是具有24个开关的频率可重构天线,通过选择开关状态成功使其工作于不同频段,且谐振点处反射系数尽可能小。

(3) 基于上述研究基础,通过嵌入代理模型进一步降低了优化过程中对全波仿真次数的需求,从而提高了工作效率。针对传统代理模型设计中的难点,提出结构选择、阈值切换和在线更新策略构建自学习代理模型。基于本文提出的算法和模型,分别完成了一款不规则多边形超宽带天线和一款具有12个开关的可重构天线的优化设计。该方案与没有引入代理模型的方案相比,大幅降低了优化过程中耗费的成本。

超宽带天线和可重构天线是现代通信领域中的研究热点,具有广阔应用前景,本文提出的方案解决了传统方法的部分难点,成功实现了上述两类天线的自动优化设计,对于其他类型天线的智能化

设计进程也具有参考意义。

关键词：天线设计 鲸鱼优化算法 代理模型 超宽带天线 可重构天线

OPTIMIZED DESIGN OF ANTENNAS BASED ON INTELLIGENT OPTIMIZATION ALGORITHMS AND SURROGATE MODELS

ABSTRACT

The Antenna, as a key component in the communication system, is responsible for transmitting and receiving signals, and its performance directly affects the communication quality. The iterative update of technology has brought about a demand for novel antennas, while the traditional design methods are unable to cope with the increasing complex antenna structures and high design freedom. In this paper, based on the new method of intelligent optimization algorithms and surrogate models, a fast multiparameter optimization design of microstrip antennas guided by performance requirements is realized. On the one hand, it is necessary to design an algorithm that converges fast and is not easy to trap into local optimum to quickly search for the antenna structure that meets our requirements in multidimensional design space. On the other hand, in order to further improve the efficiency and avoid large-scale full-wave electromagnetic simulations, it is necessary to study the construction of surrogate models with small samples.

The main work includes the following aspects:

(1) Proposed the improved whale optimization algorithm (IWOA). Four improved strategies are proposed to balance the two capabilities of local exploitation and global exploration of the algorithm to further improve the optimization ability. This is demonstrated by comparison experiments on 23 benchmark functions. The binary improved whale optimization algorithm (BIWOA) can solve optimization problems with binary variables by introducing transfer function processing.

(2) The efficient optimization design of two kinds of microstrip antennas is carried out respectively based on IWOA and BIWOA. The

bandwidth of ultra-wideband (UWB) antennas with rectangular cuts obtained in four structural parameters optimization experiments all cover 3.1 to 10.6GHz, and the return loss in the working band meets our requirements. The other is a frequency reconfigurable antenna with 24 switches, which can operate in different frequency bands with a low reflection coefficient in the resonance frequency by selecting switching states.

(3) Based on the research described above, the number of electromagnetic simulations in the optimization process is further reduced by embedding surrogate models and the work efficiency is improved. Aiming at the difficulties of traditional surrogate model design, structure selection, threshold switching, and online updating strategies are proposed to construct the self-learning surrogate model. Based on the proposed algorithms and models, the optimization design of irregular polygonal UWB antennas and reconfigurable antennas with 12 switches are completed respectively, which significantly reduces the cost in the optimization process compared with the scheme without surrogate models.

UWB antennas and reconfigurable antennas are the research hotspots in the field of modern communication and have a broad prospect of application. The scheme proposed in this paper solves some difficulties of traditional methods and successfully realizes the automatic optimization design of the above two kinds of antennas, which has reference significance for the intelligent design of other types of antennas.

KEY WORDS antenna design, whale optimization algorithm, surrogate model, ultra-broadband antenna, reconfigurable antenna

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 面向天线优化设计的智能优化算法研究	2
1.2.2 面向天线优化设计的代理模型研究.....	3
1.3 本文研究内容与结构安排	4
1.3.1 主要研究内容.....	4
1.3.2 论文结构安排.....	6
第二章 基础理论概述	7
2.1 微带天线相关理论.....	7
2.1.1 微带天线基本结构.....	7
2.1.2 天线常用性能参数.....	7
2.2 智能优化算法相关理论.....	9
2.2.1 优化理论基础.....	9
2.2.2 优化算法分类.....	10
2.2.3 对比算法简介.....	11
2.3 代理模型相关理论.....	12
2.3.1 设计流程.....	12
2.3.2 抽样策略.....	14
2.3.3 模型分类.....	15
2.3.4 评价指标.....	15
2.4 HFSS 联合仿真	16
2.5 本章小结.....	18
第三章 基于改进鲸鱼优化算法的天线优化设计	19
3.1 鲸鱼优化算法原理.....	19
3.2 鲸鱼优化算法改进.....	21
3.2.1 非线性收敛因子	21
3.2.2 自适应权重系数.....	22
3.2.3 混合变异策略	22
3.2.4 边界约束策略	24
3.3 优化算法性能对比.....	25
3.3.1 基准测试函数.....	25
3.3.2 实验设置.....	27
3.3.3 仿真结果.....	28

3.3.4 对比分析.....	32
3.3.5 离散化设计.....	33
3.4 基于 IWOA 的连续型变量天线优化设计	36
3.4.1 天线结构.....	36
3.4.2 优化结果.....	38
3.5 基于 BIWOA 的离散型变量天线优化设计	40
3.5.1 天线结构.....	40
3.5.2 优化结果.....	41
3.6 本章小结.....	44
第四章 结合代理模型预测的天线自动优化设计	45
4.1 方案模块划分.....	45
4.2 代理模型方法改进.....	46
4.2.1 传统代理模型方法.....	46
4.2.2 代理模型改进策略.....	47
4.2.3 天线优化设计流程.....	50
4.3 基于 IWOA 和代理模型的天线优化设计	51
4.3.1 天线结构.....	51
4.3.2 样本采集.....	52
4.3.3 寻优设置.....	54
4.3.4 优化结果.....	54
4.4 基于 BIWOA 和代理模型的天线优化设计	57
4.4.1 天线结构.....	57
4.4.2 样本采集.....	57
4.4.3 寻优设置.....	59
4.4.4 优化结果.....	59
4.5 本章小结.....	62
第五章 总结与展望	63
5.1 论文总结.....	63
5.2 工作展望.....	64
参考文献.....	65

第一章 绪论

1.1 研究背景及意义

俄国科学家波波夫 1894 年在金属屑检波器实验中受到启发发明了天线，迄今已有一百余年。天线作为辐射和接收无线电信号的关键单元，可以看作是传输线上有界导行波和自由空间中无形电磁波之间状态切换的一道大门，在移动通信、雷达、卫星等领域中应用广泛，其性能直接影响着整个系统信息传递的质量。天线设计依赖于电磁场理论，Computer Simulation Technology (CST) 和 High Frequency Structure Simulator (HFSS) 等电磁仿真软件已经成为当前天线设计领域的首选工具，具备可靠的仿真能力和友好的操作界面，大大提高了天线设计者的工作效率^[1]。在这些电磁仿真软件指导下进行天线设计的一般流程如图 1-1 所示，首先通过参数调整使得仿真结果满足要求，然后再进行实体加工和测试，很大程度上避免了设计制作的盲目性。




图 1-1 电磁仿真软件辅助下的天线设计流程

无线通信系统技术的不断革新和频谱资源的日益紧张，促进了新型天线的诞生，也对天线设计提出了更高要求。为满足不同业务需求，在设计前对目标天线的性能和尺寸等设置了指标限制。方向图、增益、谐振频率、带宽等性能参数随着天线结构参数改变而产生非线性变化，其优化问题往往涉及大量参数，可能是连续的，也可能是离散的。仅依靠电磁仿真软件的传统设计方法在实际应用中存在的一些不足开始不容忽视，例如：（1）依赖于人工操作和经验性；（2）设计流程中计算量大且优化效率低；（3）内置的优化算法种类单调且容易

陷入局部最优；(4) 无法应对日益复杂的天线设计需求。

天线综合问题可以归属为黑箱优化问题，智能优化算法的出现使得非遍历寻求最优解成为可能。智能优化算法也称为元启发式算法，对于优化问题自身连续、可微等性质没有限制，在设计空间中通过多点并行同时搜索向着全局最优解收敛，与 HFSS 等仿真软件中集成的传统优化算法相比，在鲁棒性、通用性、寻优性能等方面具有优势，有能力应对多参数复杂结构的天线优化设计这种黑箱问题。基于智能优化算法的方案降低了对基础理论和工作经验的要求，把设计师从枯燥繁重的调参工作中解放了出来。

另一方面，算法迭代过程中需要不断调用电磁仿真软件进行全波求解，随之而来的是高昂的时间成本和资源代价，这一点限制了智能优化算法在天线优化设计领域的落地应用。为了提高优化效率，降低试验成本，结合代理模型的优化方法受到了国内外学者的关注。代理模型在天线优化过程中，能以较小成本代价拟合天线结构和反射系数、方向图、增益等特性之间的非线性关系，通过训练使得预测偏差控制在可接受范围内，然后嵌入优化算法中完成新个体对应响应的预测，从而降低优化过程中对全波仿真次数的需求，极大地提高天线优化效率。

综上所述，本文旨在运用具有强大全局搜索能力的智能优化算法和低成本低耗时的代理模型，再结合高精度电磁仿真工具实现微带天线在设定目标下的自动优化设计，以工程中具有广阔应用前景的超宽带天线和可重构天线为主要设计对象。这一研究对于天线优化设计来说，能够提高求解质量，减少资源耗费和时间代价，提高优化效率，而且有能力应对传统方法无法处理的复杂结构问题，在该领域中具有重要研究意义。

1.2 国内外研究现状

1.2.1 面向天线优化设计的智能优化算法研究

自 20 世纪 60 年代以来，人们就开始探索并模拟自然界中各种智能行为或规律归纳形成智能优化算法，其中提出时间较早的遗传算法（Genetic Algorithm, GA）、差分进化（Differential Evolution, DE）以及粒子群优化（Particle Swarm Optimization, PSO）等算法已被广泛应用，是当之无愧的经典算法。各种新型算法和改进算法相继提出，在各领域中的应用还有待进一步研究。天线设计中待优化结构参数相对较多，传统的试错法无法满足复杂的工程需求，国内外研究者尝试引入各种智能优化算法来解决天线优化问题。

遗传算法是受到自然进化规律的启发提出的^[1]，通过选择、交叉和变异等

系列操作在历次迭代中寻求问题的最优解。加州大学学者在 1994 年应用遗传算法优化天线辐射方向图,开创了基于智能优化算法设计天线的先河^[3],之后又基于遗传算法和矩量法分别实现了以端口反射系数和有效带宽为目标的天线优化设计^[4]。基于经典智能优化算法完成不同类型的天线优化已有大量研究,例如基于遗传算法实现带宽为 1.8~2.3GHz 的同轴馈电 E 型微带天线^[5]以及适用于 WCDMA 和 WiMAX 的三频段天线^[6],应用粒子群算法设计了带宽达到 5.5GHz 的不规则花键形状贴片天线^[7]和孔径耦合馈电的宽带天线^[8]。除了这些经典优化算法,近年来提出的新型算法在天线优化设计领域也发挥了作用。蜘蛛猴优化算法被用于天线阵阵列因子以及一款贴片天线结构的优化中^[9]。蚁狮优化算法在与粒子群、蚁群、猫群以及生物地理学四种先进优化算法的对比实验中展露了优势,在天线阵列综合问题中实现了旁瓣电平和零值深度控制^[10]。基于入侵杂草优化算法优化得到了谐振频率在 6.4GHz,带宽覆盖 2~11GHz 的超宽带印刷天线^[11]。基于灰狼优化算法 (Grey Wolf Optimizer, GWO) 优化设计了一款双频天线和一款宽带磁电偶极子天线,与 GA、PSO 和 DE 相比更加具有竞争力^[12]。

与单一的标准智能优化算法相比,改进算法和混合算法在性能方面更加具有优势。融合了新搜索机制的果蝇优化算法被用于优化一款 U 型槽微带阵列天线,合成后阻抗带宽为 3.38GHz,与原始结构相比带宽提升了 181.6%^[13]。改进后的骆驼算法实现了智能天线系统的抗干扰设计^[14]。Liang 等将 GA 和 PSO 两种经典优化算法的机制结合,得到的混合算法在测试中表现优于原始单一算法,将混合算法用于优化阵列中每个单元的幅度和相位,最终合成后增益达到了 16.2dBi 的良好效果^[15]。Ustun 等基于 ABC 和 DE 的混合算法实现了一款在 WiMAX 和 WLAN 频段具有陷波特性和覆盖超宽带其他频率范围的天线^[16]。上述案例中多为单目标优化,或者将多个目标通过加权和等方式转化为单目标问题。算法的另一个发展方向是直接实现多目标,非支配排序遗传算法^[17]、多目标粒子群算法^[18]、多目标差分进化算法^[19]等在天线优化场景中兼顾多个目标,找到性能相当的解集再进行取舍。

以上研究充分说明智能优化算法已经广泛应用于天线设计优化中,国内外研究学者一方面在不断探索新型的智能优化算法,另一方面努力对现有算法进行改进或融合。算法种类繁多,在归纳总结和仿真对比的基础上着眼于各个角度以提升算法性能,来满足天线设计中日益复杂的优化需求是本文进一步研究的方向。

1.2.2 面向天线优化设计的代理模型研究

代理模型能够在高计算成本问题中拟合输入输出之间的关系以便后续进行

估值,避免在优化过程中持续性调用代价高昂的原模型进行精确计算。基本结构包括多项式回归、高斯过程、反向传播神经网络(Back Propagation Neural Network, BPNN)等一系列元模型及其变体。为了进一步提升预测精度,一些研究人员将多种元模型通过各种策略集成来使用。面对天线优化设计中智能优化算法带来的海量电磁计算工作,陆续有学者应用代理模型来解决这一问题。

克里金模型在天线设计领域使用频率很高。郭欣欣等基于差分进化算法和克里金模型实现了双层贴片天线驻波比和主瓣增益的优化^[20]。Hassan 等将克里金模型引入新型天线设计中,实现了一款具有两种辐射模式的纳米天线^[21]。Tomasson 等基于精度可调整的克里金模型优化了宽带单极子和三波段平面偶极子天线^[22]。

结构多样的人工神经网络也被用于天线代理模型的构建。Varma 等应用径向基神经网络实现了一款加载了矩形槽的微带天线设计,输出天线结构对应的谐振频率与预期之间平均误差为 0.36%^[23]。Kaur 等将人工神经网络引入多频带分形天线的设计中,结合遗传算法优化得到的天线能够工作于 L、S、C 三个波段^[24]。Dong 等在之前研究基础上提出了一种基于稀疏连接的高精度 BPNN 模型,结合 PSO 算法对三频段平面单极子天线进行优化^[25]。Gampala 等基于机器学习模型实现了可用于全球定位系统的开槽贴片天线优化^[26]。洪涛等构建了新型代理模型应用于标签天线走线的延伸设计,其原理是双向的长短期记忆神经网络^[27]。

此外,还有各种其他类型的天线代理模型。例如, Mahouti 等构建支持向量回归(Support Vector Regression, SVR)模型优化了一款 Vivaldi 天线^[28], Cui 等基于改进的 K 近邻模型实现了低维设计变量下小样本模型构建,并完成了四款天线的优化设计^[29]。

通过国内外研究现状总结发现,基于智能优化算法的方案能够应对不同场景下的设计需求,而结合代理模型的天线优化设计方案在提高效率方面是切实有效的。基于现有研究存在的问题,本文从优化算法、代理模型和设计对象三个角度出发,探索设计优化能力和适用性更强的智能优化算法,平衡代理模型训练中成本和精度的矛盾,实现不同变量类型下的天线优化设计。

1.3 本文研究内容与结构安排

1.3.1 主要研究内容

本文主要研究了天线智能优化设计方案,基于提出的智能优化算法,结合联合仿真完成了两款微带天线的设计,在此基础上引入自学习代理模型完成了

另外两款微带天线的设计，并通过电磁仿真次数证明了第二种方案在效率上的优势。

(1) 首先研究了多种经典以及新型智能优化算法的原理并在仿真中一一实现，通过初步对比选择了结构较为简单且优化性能不错的新型算法——鲸鱼优化算法 (Whale Optimization Algorithm, WOA)。从实现原理出发，提出四种改进策略来提升算法寻优性能。在 23 个基准测试函数上的数值仿真实验，证实了改进后的算法和原始算法以及其他多种算法相比，在收敛速度、寻优精度以及稳定性等方面都存在着显著优势。改进后的算法可以应用于连续变量优化问题，通过引入传递函数进行处理，算法能够解决离散变量下的优化问题。

(2) 基于改进后的鲸鱼优化算法完成了一款矩形切角超宽带天线的优化设计，分别进行了 4 次实验均得到了满足预期目标的天线结构，阻抗带宽完全覆盖超宽带频段且回波损耗表现良好。从八种传递函数中选择了适用于当前场景的传递函数，并应用离散化处理的算法实现了一款有 24 个开关的频率可重构天线设计，在优化得到的开关状态序列下，天线分别可以工作在 L、S、C、X 波段，且谐振点处反射系数非常小。

(3) 为了提高设计效率引入代理模型辅助策略，首先抽样构建优化变量样本集并通过联合仿真得到目标响应，然后训练代理模型备选集中的模型，选择预测精度最高的模型加入优化流程，代替电磁仿真软件大部分的工作。对达到设定阈值且样本库中不存在的“潜力解”进行精确求解并加入样本库。优化过程中新增样本达到设定值时重新启动模型训练，以充分利用优势个体携带的信息。

(4) 结合改进后的鲸鱼优化算法和自学习代理模型，分别实现了一款不规则多边形超宽带天线和一款 12 开关的频率可重构天线的优化设计，在优化结果达到同一目标时，通过比较电磁仿真次数证明了引入代理模型的设计方案在设计效率上的提升。

研究过程中的创新之处主要包括以下几点：

(1) 提出改进鲸鱼优化算法 (IWOA)，针对鲸鱼优化算法在优化问题中存在的缺陷给出了四种改进策略，与原算法和另外五种算法的对比实验证明了其优越性。基于 IWOA 完成了矩形切角超宽带天线的连续型结构参数优化，得到了 4 款满足超宽带通信需求的天线。

(2) 离散化处理得到二进制改进鲸鱼优化算法 (BIWOA)，基于 BIWOA 完成了 4×4 贴片可重构天线的二进制开关状态序列设计，实现了同一天线工作频率的多样化选择，从而减少通信系统中天线的数量。

(3) 提出自学习代理模型并嵌入天线优化设计流程，通过初始小样本学习

完成结构选择，设定阈值来控制代理模型和原高复杂度模型的切换，并利用优化过程中产生的新个体实现模型动态更新，提高预测精度的同时减少设计盲目性。基于该方案实现了多边形超宽带天线的结构参数优化和 3×3 贴片可重构天线开关状态探索，均大幅度提升了设计效率。

1.3.2 论文结构安排

全文共包括五个章节，每个章节内容安排如下：

第一章为绪论，首先阐述了研究背景及意义，然后综述了天线设计领域智能优化算法和代理模型的国内外研究现状，接着对论文主要研究内容和创新点加以阐述，最后是对论文的基本结构进行介绍。

第二章概述了研究相关的理论，划分为微带天线、智能优化算法、代理模型以及联合仿真四个部分。

第三章基于改进鲸鱼优化算法实现天线优化设计，介绍了算法基本原理以及四种改进策略和离散化处理，通过数值实验进行了性能对比验证，然后基于改进后的算法完成了优化变量分别为连续型和离散型的两款天线设计。

第四章提出了结合代理模型进行天线优化设计的方案，阐述了代理模型的设计流程，在此基础上完成了两款天线的优化设计，与第三章提出方案相比提高了效率。

第五章对当前工作做出总结，并对后续研究方向进行展望。

第二章 基础理论概述

2.1 微带天线相关理论

2.1.1 微带天线基本结构

了解微带天线^[30]的结构和原理，有助于在理论指导下进行优化设计工作，并用天线指标对设计结果进行评估。微带天线一般由辐射贴片、介质基板和导体接地板组成，由馈电在形状各异的辐射贴片和接地板之间激励起高频电磁场，经四周缝隙向外辐射。一般情况下，要求介质基板的介电常数不超过 10，而且材料厚度远小于工作波长。按照结构特征一般可分为贴片天线和缝隙天线，具有重量轻、体积小、剖面低、易共形且成本低等优势，被广泛应用于各种场景。

微带天线最常见的分析方式有传输线模型、谐振腔模型和全波分析法，可以看作是一维到二维到三维的转化，前面两种物理意义比较清晰，全波分析法物理意义不明显但是求解非常精确。微带天线的馈电方式，根据有无接触可划分为直接馈电和间接馈电。直接馈电包括常用的微带线侧馈和同轴线背馈，前者中微带线与贴片直接相连且共面，便于统一制作和后期集成，但是馈线自身的辐射会产生一定的干扰，后者将馈线外导体安装在接地板上，内层金属导体穿过介质层与上层贴片连接，与微带线相比减少了附加辐射，增加了插入损耗和制作复杂度。间接馈电一般基于电磁作用实现，比较常见的方式有电磁耦合、缝隙耦合和共面波导馈电等。无论选择何种方式，需要着重考虑的都是辐射结构与馈电结构之间的阻抗匹配。

2.1.2 天线常用性能参数

(1) 阻抗匹配

S 参数即散射参数，是基于端口入射波和反射波关系建立的，可以表征射频器件传输通道几乎全部的特性，N 端口的设备需要 N^2 个 S 参数来描述。以图 2-1 所示的双端口网络为例，电流和电压归一化处理后呈线性关系，记端口 1 入射波为 a_1 ，反射波为 b_1 ，端口 2 入射波反射波为 a_2 和 b_2 ，它们满足：

$$\begin{bmatrix} b_1 \\ b_2 \end{bmatrix} = \begin{bmatrix} S_{11} & S_{12} \\ S_{21} & S_{22} \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} \quad (2-1)$$

端口 2 匹配时，端口 1 的反射系数 $S_{11}(dB) = 20 \lg |S_{11}|$ 经常被用于衡量天线与馈线的阻抗匹配程度。




图 2-1 双端口 S 参数

输入阻抗是天线自有的性质，在测量时可以通过馈电口输入电压和输入电流间的比值表示，实数项 R_{in} 是输入电阻，虚数项 X_{in} 是输入电抗。天线设计中需要尽可能让天线输入阻抗与传输线特征阻抗匹配，提高传输效率。

$$Z_{in} = \frac{U_{in}}{I_{in}} = R_{in} + jX_{in} \quad (2-2)$$

实际工程中传输线特征阻抗 Z_0 一般为 50Ω 或 75Ω ，反射系数 Γ 计算公式为：

$$\Gamma = \frac{Z_{in} - Z_0}{Z_{in} + Z_0} \quad (2-3)$$

电压驻波比是馈线连接处波腹电压和波节电压之比，

$$VSWR = \frac{U_{max}}{U_{min}} = \frac{1 + |\Gamma|}{1 - |\Gamma|} \quad (2-4)$$

回波损耗 RL 是射频输入信号所反射回的功率与原输入信号功率之间的比，通常使用分贝值形式，

$$RL = -20\lg|\Gamma| = -S_{11} \quad (2-5)$$

以上几种参数都可以用来表征天线与馈线的匹配程度，当输入阻抗与 Z_0 完全匹配时，天线输入端口不会产生反射波，反射系数 $\Gamma=0$ ，电压驻波比 $VSWR=1$ ，回波损耗 RL 趋向于正无穷。一般，在天线设计中至少要求驻波比 $VSWR < 2$ ， $S_{11} < -10dB$ 。

(2) 带宽

带宽 BW 用来描述天线正常辐射和接收信号的频率范围，由阻抗带宽、轴比带宽和方向图带宽等共同限定。

绝对带宽由工作频率上下限之差决定，

$$BW = f_{up} - f_{lp} \quad (2-6)$$

相对带宽是指绝对带宽与中心频率之比，

$$bw = \frac{f_{up} - f_{lp}}{f_c} \times 100\% \quad (2-7)$$

美国联邦通信委员会于 2002 年公布的标准中规定，绝对带宽超过 500MHz 或相对带宽大于 20% 被界定为超宽带天线，这一标准后来被提升至 25%，另外还将频段 3.1GHz-10.6GHz 划分为超宽带民用频段。

(3) 增益

根据辐射特性可以分为全向天线和定向天线，前者向外部空间均匀辐射，后者将大部分能量集中于某一个方向。天线远场区距离原点距离 r 处某场点辐射场可以基于方向性函数 $f(\theta, \varphi)$ 建立如下等式：

$$E(r, \theta, \varphi) = \frac{\exp(-j\beta r)}{r} f(\theta, \varphi) E_0 \quad (2-8)$$

$$F(\theta, \varphi) = \left| \frac{f(\theta, \varphi)}{f_{\max}(\theta, \varphi)} \right| \quad (2-9)$$

为了更加直观显示，将方向性函数归一化处理后即可绘制三维方向图和曲线形式的波瓣图，应用中常常会关注特定平面的方向图来了解大致的辐射情况。

天线增益 G 是当输入功率相同时，实际功率密度和理想全向辐射单元的功率密度在同一处的比值，被用来定量描述天线朝某个特定方向的辐射能力。

$$G = \eta D \quad (2-10)$$

$$D = \frac{S_{\max}}{S_0} = \frac{E_{\max}^2}{E_0^2} = \frac{4\pi}{\int_0^{2\pi} \int_0^\pi F^2(\theta, \varphi) \sin \theta d\theta d\varphi} \quad (2-11)$$

上述式中 θ 和 φ 是方位角， D 是方向性系数， η 是天线效率， $S_{\max}$ 、 $E_{\max}$ 是最大辐射方向上功率密度和电场强度， S_0 、 E_0 是在同一辐射功率下无向点源天线辐射的功率密度和电场强度。方向图主要用来表征单个天线在不同方向上辐射强度，方向性系数则是为了实现不同天线辐射集中程度间定量比较而引入的概念。可以看出，增益由辐射定向性和对能量的转化能力共同决定。

2.2 智能优化算法相关理论

2.2.1 优化理论基础

优化是在一定的约束条件下，从有限或无限多的备选搜索中搜索出最合适或满足要求的选项，在人们生活各方面都有应用。优化问题首先需要考虑三个基本要素，分别是目标函数、定义域和约束条件。根据目标函数的个数可将问题区分为单目标优化和多目标优化，根据优化所面对的参数是否连续能够分为连续问题和离散问题，根据约束条件的有无可以分为约束问题和非约束问题。通常，需要根据以上三点从种类繁多的优化算法中选择出最适合当前问题的算法。

(1) 单目标优化

对于单目标优化问题，以最小化问题为例，在由等式、不等式约束条件以及变量定义域共同确定的可行域中寻找使目标函数值最小的有效解。

$$\begin{aligned} & \min f(x) \\ & h_m(x) = 0, \quad m = 1, 2, \dots, p \\ \text{s.t. } & g_n(x) \leq 0, \quad n = 1, 2, \dots, q \\ & x_{i_min} \leq x_i \leq x_{i_max}, \quad i = 1, 2, \dots, D \end{aligned} \quad (2-12)$$

(2) 多目标优化

对于多目标优化问题而言，目标函数个数不少于 2，不同目标之间可能存在冲突，无法同时达到最优状态，因此需要均衡考虑所有目标函数。通常有两种求解方式，一是通过加权和等策略转换为单目标问题，二是直接求解多目标下的帕累托集合 (Pareto)。

2.2.2 优化算法分类

优化算法大致可以分为传统优化算法和智能优化算法。前者是确定性算法，例如动态规划、牛顿法、共轭梯度法、单纯形法等广泛应用的算法都属于该类别，理论成熟且计算效率高，适用于简单优化问题，但是面对天线多参数优化这种目标函数不明确的复杂问题就显得捉襟见肘了。后者是一种概率算法，不需要依赖优化问题建立精确的模型进行求解，对于目标函数和约束条件没有限制，适用于这种传统优化算法无法应对的场景，在可接受的计算时间内找到满足要求的近似最优解。

在过去的几十年中，各种各样的智能优化算法被提出并应用于各领域的优化问题上。智能优化算法模拟自然界中生物、物理等现象构造搜索机制，结合随机性和启发式信息在可行域中实现高效搜索。其中基于群体智能的算法迭代速度最快，新的算法层出不穷。群智能优化算法通常是对自然界中的鱼虫鸟兽等群体的某种团体行为进行模拟，从中抽象出数学模型形成算法，群体中成员不仅学习自身经验，而且通过互相交流来调整搜索方向。

种类繁多的智能优化算法综合来看，都需要在局部开发和全局探索之间做折中处理，专注于提升局部开发能力容易陷入局部最优无法跳出，不对全局探索设限则算法无法收敛失去寻优的意义，本质上需要重点考虑的就是迭代方向和迭代步长。它们的区别在于来源不同，需要人为设置的超参数不同，平衡开发和探索的策略不同，导致最终处理优化问题时的能力各有强弱。

国内外学者经过多年研究提出了各种智能优化算法，可以按照不同角度进

行分类。本文从算法起源角度进行了简单分类，分为进化机制算法、物理现象算法、动物群体算法、仿植物学算法和仿人智能算法 5 类，如表 2-1 中所示，每个类别列举了一些算法作为代表。

表 2-1 智能优化算法分类

分类	示例
进化机制	遗传算法、进化策略、遗传规划、进化规划
物理现象	模拟退火算法、大爆炸算法、射线优化算法、黑洞算法
动物群体	果蝇优化算法、蝙蝠算法、人工蜂群算法、萤火虫算法
仿植物学	模拟植物生长算法、入侵杂草优化算法、花朵授粉算法
仿人智能	神经网络算法、头脑风暴算法、帝国主义竞争算法、群搜索算法

2.2.3 对比算法简介

在天线优化设计研究中，遗传算法、粒子群算法和差分进化算法由于产生时间较早，应用更为广泛和成熟，具有较优性能的新型算法则还有着广阔的探索空间。本文选用经典智能优化算法和近年来提出的新型智能优化算法共 11 种进行对比分析，包括前文提到过的粒子群算法、引力搜索算法和灰狼优化算法，还有飞蛾扑火优化算法（Moth-flame Optimization, MFO）和樽海鞘群算法（Salp Swarm Algorithm, SSA），下面对用到的一些算法原理进行简单介绍。另外对比中用到的还有蚁狮优化算法、蜻蜓优化算法、蝗虫优化算法、多元宇宙优化算法、正弦余弦算法等。由于单次优化耗时长且优化能力一般，或者优化能力与已经选中的其他算法相近不具有代表性等原因，在初步对比中被淘汰，此处不再一一介绍。

（1）粒子群算法

粒子群算法是 Kennedy 等在 1995 年从鸟群觅食行为中抽象出来的全局搜索算法^[31]，将粒子位置看作是可行解，食物位置看作是优化问题的最优解，位置的优劣程度由适应度值判定。粒子会将自身到达过的最优位置记录下来，种群会综合所有个体到过的最优位置获得全局最优并持续更新，粒子在下一次迭代中的位置取决于当前位置以及自身的速度矢量，速度的更新综合考虑了自身携带信息以及记录的局部和全局最优信息。惯性权重用于平衡算法全局搜索和局部开发能力，两个学习因子参数控制了粒子自身认知能力和社交能力。在迭代过程中充分利用个体和群体经验，更新自身位置和速度直到满足终止条件。

（2）引力搜索算法

受到天体之间相互作用的启发，Rashedi 等基于牛顿万有引力定律以及运动

定律提出了引力搜索算法^[32]。每个物体有位置、速度、加速度和质量四种状态变量，物体位置与问题的可行解相对应，用质量来评价个体当前所处位置的优劣程度。物体彼此之间引力的作用决定了运动方式，在同等引力作用下质量大的物体获得的加速度小，更能保持自身优势位置，小质量物体移动速度更快，种群整体朝着质量较大的物体方向移动，可以看作是粒子群算法的改进版。

（3）灰狼优化算法

灰狼优化算法是在 2014 年提出的算法^[33]，灰狼种群内部严格遵守等级支配制度，所有个体分为 4 个不同等级，其中 α 狼是种群中的领导者，居于最高等级，在狩猎行动中负责发号施令； β 狼代表的从属狼属于第二级，辅助头狼完成种群的管理工作，作为头狼的第一替补存在； δ 是第三级，其余的属于最底层。在每次迭代过程中保存了当前适应度表现最佳的三只灰狼个体，来指导其他个体位置更新。

（4）飞蛾扑火算法

飞蛾扑火算法是 2015 年提出的算法^[34]，受到了飞蛾在夜间横向定位导航机制的启发。最初设置相同数量的飞蛾和火焰两类个体，在迭代过程中对两种个体的更新方式不同。首先飞蛾选择一个火焰并围绕着后者以螺旋线的方式进行飞行搜索，之后将两种个体按照适应度优劣统一排序，并移动火焰以保证其占据了整个群体中最优的几个位置，在原始算法中设置火焰的个数随迭代而线性递减。

（5）鲸鱼优化算法

鲸鱼优化算法是 2016 提出的算法^[35]，其搜索过程模仿了座头鲸群体独特的捕食策略，包括搜索、包围和攻击各阶段的行为。通过收缩环绕和螺旋上升机制实现局部开发，通过随机学习完成全局探索。

（6）樽海鞘群算法

樽海鞘群算法是 Mirjalili 等在 2017 年基于海洋中樽海鞘觅食活动而提出的算法^[36]，这是一种类似于水母的透明生物，通常会集结成链式共同完成觅食。群体中的个体可以分为领导者和追随者两种身份，在迭代过程中追随者在领导者提供的信息下以链式向食物移动，领导者和追随者分别承担全局探索和局部开发的角色。

2.3 代理模型相关理论

2.3.1 设计流程

智能优化算法指导的优化设计中要达到预期目标，需对大量不同组合的天

线结构参数进行建模仿真，同时还要保证求解精度，一次仿真少则数十秒，多则需要几十分钟甚至更久，产生了很大的计算负荷。代理模型能够根据样本点信息拟合实验中输入变量和输出变量之间映射关系，与真实模型差异足够小时，可以在优化过程中代替耗时的仿真计算对新的输入数据进行预测，从而提高计算效率。假设输入集为 $[X^1, X^2, X^3, \dots, X^n]$ ， n 是样本点数，其中 $X^i = (x_1, x_2, \dots, x_D)$ 是 D 维设计空间优化变量的一组取值，实际的输出响应 $Y(X)$ 与代理模型预测响应 $\hat{Y}(X)$ 之间的近似误差记为 ξ 。

$$Y(X) = \hat{Y}(X) + \xi \quad (2-13)$$




图 2-2 构建代理模型的一般流程

代理模型构建步骤一般包括：

(1) 确定自变量和因变量：根据具体工程问题确定输入输出，当输入变量维度过高或特征之间具有相关性时需要降维，筛选出对输出影响较大的变量。在天线设计优化中即确定待优化的天线结构参数及其取值范围，确定优化目标对应的电磁响应；

(2) 构建样本集：根据具体问题确定抽样策略及样本规模，计算样本点对应的响应构建数据集；

(3) 训练代理模型：确定模型初始结构，基于处理过的数据集进行训练确定模型参数，对模型预测精度进行测试评估。若不能满足要求则通过加点丰富数据集或更换代理模型结构再次进行训练。

2.3.2 抽样策略

数据集和模型结构对最终预测效果至关重要。面对昂贵代价问题的求解，训练代理模型的目标是以尽可能少的样本规模达到设定的精度^[37]。合理分布的样本点能够提供更多有效信息，常见的抽样策略有拉丁超立方抽样^[38]、蒙特卡洛抽样^[39]、正交设计^[40]、部分因子或全因子设计^[41]等。其中拉丁超立方抽样（Latin Hypercube Sampling, LHS）最早是由 McKay 等在 1979 年提出的，通过分层充分保障了样本点在设计空间中分布的全面性和均匀性，而且该方法适应性很强，对于变量维度和样本数目没有限制，广泛应用于各领域。

完成一次抽样的主要步骤有：

- （1）确定设计变量维度 D 和取值范围，确定抽样点数目 n ；
- （2）将每一个维度取值范围划分为大小相等且不重复的 n 个子区间；
- （3）按照分布函数在每个子区间内随机取一个值；
- （4）将每个维度取值随机无替换组合 n 次确定样本点位置。

采样点 $X^i = (x_1, x_2, \dots, x_D)$ 的第 j 维采样值可以用公式 (2-14) 表示^[42]：

$$x_j^i = \frac{\pi_j^i + u_j^i}{n} \mid i \in [1, n], j \in [1, D] \quad (2-14)$$

其中， π 是序列 $\{0, 1, 2, \dots, n-1\}$ 的一种独立随机排列，决定了样本点落在哪个子空间中， u 是取值在 $[0, 1]$ 上的随机数，决定了样本点在子空间中的具体位置。

整个设计空间被划分为 n^D 个超立方体，每个超立方体内随机仅取一点，保证了样本在每个维度上的投影均匀分布在不重合的子区间。由于具有随机性，并不能保证样本集在整个设计空间的分布情况，在极端差的情况下所有样本点可能落在同一条直线上，根据这些样本点采集得到的信息无法反映整体设计空间中响应情况。在此基础上按照一定的准则改进可以进一步提升 LHS 选取样本点的均布性，例如最大最小距离准则^[43]。

以二维空间 50 点抽样为例，图 2-3 中是简单随机抽样和基于最大最小距离准则的 LHS-maximin 抽样结果分布情况。肉眼就可以看出，左图中部分区域样本非常集中，甚至出现了重合的情况，部分区域又大面积留白，右图中样本点分布明显更加均匀。




图 2-3 二维采样对比图 (1) 简单随机抽样; (2) LHS-maximin

2.3.3 模型分类

基本的代理模型被称为元模型, 根据方法可以分为插值模型和回归模型两类。插值模型基于对样本点的无偏差预测进行, 以二维平面为例要求训练得到的近似曲线经过所有已知数据点, 常见的有克里金模型、高斯过程模型、径向基函数模型等; 回归模型是在一定条件下使模型预测值和真实值之间的误差尽可能小, 而且可以不经过初始样本点, 常见的有响应面模型、支持向量回归、人工神经网络等。

2.3.4 评价指标

对回归代理模型的预测性能进行评估通常使用的指标有:

(1) 均方误差 (Mean Squared Error, MSE): 取值范围为 $[0, +\infty)$, 是一种用于评估模型对样本点的预测值与其对应真实值之间平均误差的指标。

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \quad (2-15)$$

(2) 均方根误差 (Root Mean Squared Error, RMSE): 对均方误差 MSE 进行开方处理, 便于在数量级上更加直观的评价回归效果。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (2-16)$$

(3) 平均绝对误差 (Mean Absolute Error, MAE): 定义为绝对误差在所有样本点上的平均值, 可以解决正负相消的问题, 但是由于绝对值的存在导致函数不光滑无法求导。

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (2-17)$$

(4) 决定系数 (R^2): 基于残差平方和与总体偏差平方和计算用来量化模型表现情况, 值越接近于 1 表示当前模型预测的精度越高。

$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2-18)$$

上述公式中, n 是测试集样本数量, $\hat{y}_i$ 是样本 i 代理模型预测值, y_i 是样本 i 对应真实响应值, $\bar{y}$ 是测试集上真实响应的平均值。

2.4 HFSS 联合仿真

使用优化算法探索天线结构时, 为了对当前可行解进行评估, 需要借助电磁仿真软件求解电路及辐射性能参数, 再根据返回响应计算得到的适应度来评判个体优劣, 进而执行下一步优化探索。




图 2-4 HFSS 天线设计一般流程

本文选用基于有限元数值分析原理的 ANSYS HFSS 电磁仿真软件对天线进行仿真求解^[44], HFSS 是第一款商业化的全波电磁场仿真软件, 其自适应网格剖

分技术成熟。HFSS 将待求解的模型离散处理为单独的四面体网格，在每个小单元中分别进行计算，通过与初始设定的最大剖分次数及收敛标准的比较来判断求解进程是否停止，能够实现天线各种性能参数的精确计算。基于 HFSS 实现天线设计的一般流程如图 2-4 所示。

为了应对复杂结构天线多参数全局最优化问题，与各种寻优能力更强的优化算法融合，实现整个过程自动化，本文选择通过脚本来控制整个建模求解过程的实现。HFSS 预留了宏命令接口，在可视化操作界面进行的任何操作都可以对应成脚本语言并记录下来。应用该接口实现天线自动化设计主要有两种方式，一种在 HFSS 中先进行一次手动建模并记录下每一步操作，生成 VBScript 脚本文件，在下一次需要重复操作时读取该文件完成建模求解；另一种是利用函数工具箱按照图 2-4 中的流程编写建模程序，按照设计参数控制软件完成建模求解。第一种方式不要求关注脚本文件具体内容，适合简单模型的重复操作。第二种方式要求掌握工具箱的使用和特定功能函数的书写，适用场景更加广泛，尤其适用于复杂结构模型的创建以及需要不断改变天线结构参数的场景。

本文选择第二种方式实现智能优化算法和自动化仿真的嵌合。目前使用较广泛的函数工具箱是 Viay Ramasami 发布的 HFSS-MATLAB-API，经后续研究者的改进和补充其功能更加完善，能够直接调用函数生成脚本控制文件并实现自动运行，完成 HFSS 中建模、求解、数据后处理等大部分操作，生成的结果能够完美嵌入优化算法进行适应度计算。对于操作中缺少的功能，可以通过脚本记录新增功能函数进行补充完善。

将本文中微带天线仿真求解中用到的功能函数按照步骤划分，主要包括：

(1) 创建工程：hfssNewProject 新建工程文件；hfssInsertDesign 插入设计文件；

(2) 天线结构 3D 建模：hfssRectangle 绘制矩形面；hfssCircle 绘制圆形面；hfssPolyline 绘制折线；hfssBox 创建长方体模型；hfssCylinder 创建圆柱体模型；hfssAssignMaterial 分配材料属性；hfssSetColor 设置颜色；hfssSetTransparency 设置透明度；hfssSubtract 布尔相减；hfssUnite 布尔合并；hfssSetSolveInside 设置是否对内部进行求解；

(3) 设置边界条件和激励方式：hfssAssignPE 分配理想导体边界；hfssAssignRadiation 设置辐射边界条件；hfssAssignFiniteCond 设置有限导体边界；hfssAssignWavePort 用于设置波端口激励；hfssAssignLumpedPort 设置集总端口激励；

(4) 求解设置：hfssInsertSolution 向工程插入求解；hfssInterpolatingSweep 插值扫频；hfssFastSweep 快速扫频；hfssSolveSetup 进行求解；

(5) 数据后处理与结果输出: hfssInsertFarFieldSphereSetup 创建远场辐射表面; hfssExportNetworkData 将运行的矩阵写入指定文件; hfssCreateReport 生成多种形式的数值结果报告; hfssExportToFile 将数据保存到指定文件;

(6) 工程管理: hfssSaveProject 保存工程; hfssCloseActiveProject 关闭当前运行工程; hfssExecuteScript 控制软件的启动和关闭, 运行指定路径下的脚本文件。

2.5 本章小结

本章对论文中用到的一些技术进行了重点概述, 以便后续工作的进行。首先简单介绍了微带天线基本结构以及天线设计中经常需要考虑到性能参数, 重点包括阻抗、带宽、增益等。然后基于传统优化方法的不足引出智能优化算法, 并对常见的智能优化算法按照起源进行了简单归类, 并且简单概述了后文算法性能对比用到的几种算法。接下来概述了代理模型的相关理论, 包括构建代理模型的一般步骤、采集样本时常用到的抽样策略、代理模型类型划分以及代理模型精度评估常用的几项指标。最后介绍了本文选用的电磁仿真软件进行天线建模求解的设计流程以及自动化联合仿真的实现。

第三章 基于改进鲸鱼优化算法的天线优化设计


为了更好地实现目标天线的优化设计,本章首先完成了智能优化算法的设计与改进,然后通过不同类型基准函数上的仿真对比实验,验证了改进后鲸鱼优化算法在性能方面的优势,在此基础上通过离散化处理赋予算法处理二进制变量优化问题的能力。最后,针对天线设计领域中超宽带天线和可重构天线的广泛需求,完成了一款矩形切角超宽带天线的多结构参数优化设计和一款频率可重构天线的开关状态优化设计。

3.1 鲸鱼优化算法原理

在基于智能优化算法的天线优化设计流程中,每一次调整参数后都需要调用电磁仿真软件进行求解,进而根据返回的电磁响应计算适应度来指导算法迭代方向。因此,从效率出发希望设计一种寻优能力强、收敛速度快的算法来减少仿真次数。

智能优化算法种类繁多且各有优劣,算法常见的问题有收敛速度慢以及容易陷入局部最优等,如何更好地平衡全局探索和局部开发两种能力来提升其性能是算法改进的研究方向。通过文献调研分析,本文共选取了领域中 11 种智能优化算法,包括粒子群算法这种经典的优化算法,也包括问世时间不久但性能已经过工程验证的新型优化算法。基于各种算法的原理结构编程实现其迭代搜索策略,经过初步仿真对比实验,从中筛选出了 6 种运行速度较快且优化能力更加具有代表性的算法进入后续实验流程,在上一章第 2.2.3 小节中已经对这 6 种算法进行了概述。最终,确定了鲸鱼优化算法作为本文后续改进的目标算法,选择的主要原因有:(1) 鲸鱼优化算法提出年限较短,在天线优化设计领域中的应用几乎处于空白,具有待开发的研究价值;(2) 该算法原理清晰,易于实现,且运算速度快;(3) 该算法在测试函数实验中表现出了不错的寻优能力。

鲸鱼是一种具有高智商和情感的哺乳动物,在自然界中的行为存在着明显的群体性。其中,座头鲸有着特殊的捕食方式,能够在逐渐缩小的包围圈中沿着向上螺旋线朝目标猎物游动,同时沿着圆形或者“9”形产生独特的气泡网^[45],如图 3-1 所示。Goldbogen 等在 2013 年对座头鲸的捕食行为进行了持续性观测,通过传感器采集到的案例总结出螺旋上升和环绕收缩两种机制^[46]。受这种行为的启发,澳大利亚研究者于 2016 年提出了鲸鱼优化算法。该算法原理简单清晰、需调整的控制参数较少,且具有不错的寻优能力,其有效性在多种数学优化问题和工程优化问题中都得到了验证。

图 3-1 座头鲸气泡网觅食示意图^[35]

鲸鱼优化算法是受到座头鲸的捕食行为启发提出的算法，为了将这种行为抽象成数学语言，将其划分为包围猎物、随机搜索、气泡网攻击三个阶段。在 D 维解空间中，每只鲸鱼个体所在的位置 $P(t) = (x_1, x_2, \dots, x_D)$ 代表一个可行解，记当前迭代次数为 t ，最大迭代次数为 T 。

(1) 包围猎物

在此阶段，鲸鱼个体基于回声定位的原理对猎物方位进行判断，鲸鱼向着最优个体游去进行局部开发从而包围猎物，数学模型为：

$$P(t+1) = P^*(t) - A|CP^*(t) - P(t)| \quad (3-1)$$

其中， $P^*(t)$ 为当前最优鲸鱼个体的位置向量， $A = 2a \cdot r_1 - a$ 和 $C = 2r_2$ 是确定包围步长的系数向量，收敛因子 $a = 2 - \frac{2t}{T}$ 随着迭代次数从 2 线性递减到 0， r_1 、 r_2 均是在 $[0,1]$ 中均匀分布的随机数。基于以上设定，系数 A 随着收敛因子的变化在 $[-a, a]$ 的范围中出现波动。

当 $|A| < 1$ 时，下一时刻鲸鱼个体的位置处于该个体当前位置与迭代产生的最优个体位置之间，因此可以看作是收缩包围猎物的过程。

(2) 随机搜索

当 $|A| \geq 1$ 时，鲸鱼跳出包围圈向种群中的随机个体游走进行全局探索，数学模型为：

$$P(t+1) = P_{rand}(t) - A|CP_{rand}(t) - P(t)| \quad (3-2)$$

其中， P_{rand} 是被随机选择的个体。

(3) 气泡网攻击

鲸鱼使用气泡网驱赶猎物时，自身位置按照螺旋线不断更新，公式为：

$$P(t+1) = P^*(t) + |P^*(t) - P(t)| \cdot e^{bl} \cos(2\pi l) \quad (3-3)$$

其中, b 常数能够确定对数螺旋线形状, 本文中设定为 1, l 是 $[-1,1]$ 中均匀分布的随机数。每只鲸鱼等概率 ($p=0.5$) 选择向其他个体游动或是发起攻击, 对当前个体每个维度进行更新。参数 A 的绝对值决定了游动朝向的个体为当前最优解或种群中的随机个体, 向着最优个体前进加速了算法收敛, 体现了算法的局部开发能力; 向着随机个体前进有利于种群扩大当前搜索范围, 跳出局部陷阱, 提高算法的全局探索能力。

3.2 鲸鱼优化算法改进

在实验测试中, 鲸鱼优化算法具有较强的局部开发能力, 但是仍然比较容易陷入局部最优, 发生早熟收敛。针对这种情况基于以下四种策略对算法进行改进得到 IWOA, 以更好平衡全局探索和局部开发之间的矛盾, 提高算法寻优能力。

3.2.1 非线性收敛因子

分析 WOA 算法原理, 可以看出参数 A 协调算法在搜索和开发之间的转换, 而 A 又服从 $[-a,a]$ 上的均匀分布, 参数 a 越大全局搜索能力越强, a 越小局部开发能力越强。WOA 算法中收敛因子 a 随着迭代次数线性递减, 在复杂问题寻优中表现不佳, 因此考虑在算法中引入非线性变化的参数 a 。




图 3-2 收敛因子对比图

相关研究表明, 余弦收敛因子在各种类型的收敛因子中表现优异^[47]。在鲸鱼优化算法中引入不同类型的收敛因子, 包括线性、正弦、余弦、正切、对数和次幂函数, 其中余弦因子在对比实验中展现了更加优异的性能。本文选取的收敛因子随迭代次数变化如图 3-2 所示, 在最大值 2 与最小值 0 之间产生非线性

变化。前期减小速度较缓，系数 A 有更大概率取得超过 1 的绝对值，便于进行充分的全局搜索，后期减小速度加快，有利于局部开发加快收敛速度。

$$a(t) = (a_{\max} - a_{\min}) \cdot \cos\left(\frac{\pi}{2} \cdot \frac{t}{T}\right) \quad (3-4)$$

3.2.2 自适应权重系数

WOA 算法未考虑到迭代过程中猎物吸引力的变化，引入如下随迭代次数变化的权重。

$$\omega(t) = (\omega_{\max} - \omega_{\min}) \cdot \frac{2}{\pi} \cdot \tan\left(\frac{t}{T}\right) \quad (3-5)$$

其中， $\omega_{\max}$ 和 $\omega_{\min}$ 取值分别为 1 和 0。在包围猎物和随机搜索两个阶段，权重随着迭代次数非线性增加，迭代前期对目标依赖性不强，迭代后期权重增大，目标吸引力增强，更好平衡了算法局部开发能力和全局探索能力。加入了自适应权重系数之后，新的位置更新公式如下：

$$\begin{cases} P(t+1) = \omega(t)P^*(t) - A|CP^*(t) - P(t)|, & p < 0.5, |A| < 1 \\ P(t+1) = \omega(t)P_{rand}(t) - A|CP_{rand}(t) - P(t)|, & p < 0.5, |A| \geq 1 \\ P(t+1) = P^*(t) + |P^*(t) - P(t)| \cdot e^{bl} \cos(2\pi l), & p \geq 0.5 \end{cases} \quad (3-6)$$




图 3-3 权重系数随迭代次数变化曲线图

3.2.3 混合变异策略

在搜索过程中鲸鱼个体容易过早陷入局部最优，错失收敛至全局最优解的机会。针对这个问题，考虑通过混合策略为当前鲸群引入新个体来提高种群多样性，提供跳出早熟继续进化的动力。在第 t 次迭代过程中，值得关注的是当前

轮次中适应度居于领导地位的解 $P_{best}(t)$ 和适应度差携带有效信息少的解 $P_{worst}(t)$ 。

针对前者, 综合考虑最优解和次优解, 在各个维度引入变异生成新个体进行位置更新, 高斯变异和柯西变异两种最常用的扰动方式^[48]。随机变量 X 服从正态分布时记为 $X \sim N(\mu, \sigma^2)$, 其概率密度函数为:

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] \quad (3-7)$$

标准正态分布 $N(0,1)$ 服从:

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \quad (3-8)$$

随机变量 X 服从柯西分布时记为 $X \sim C(t, \gamma)$, 其概率密度函数为:

$$f(x; t, \gamma) = \frac{1}{\pi\gamma \left[1 + \frac{(x-t)^2}{\gamma^2}\right]} \quad (3-9)$$

其中, t 是确定峰值位置的参数, γ 是描述一半宽度的尺度参数。标准柯西分布 $C(0,1)$ 的密度函数为:

$$f(x) = \frac{1}{\pi(1+x^2)} \quad (3-10)$$

图 3-4 中给出了标准高斯分布 $N(0,1)$ 和柯西分布 $C(0,1)$ 的概率密度函数曲线, 分析曲线走势可得: 从垂直方向上来看, 在峰值及附近区域柯西分布曲线略低于高斯分布, 在水平方向往两侧延伸时, 柯西分布能够更平滑地趋近 x 轴。因此, 柯西分布有较大概率产生远离局部最优的个体, 和基于高斯分布的变异算子相比更加有利于加强算法的全局搜索能力。本文将标准 Cauchy 变异算子引入鲸鱼优化算法, 以较大的步长产生新的解, 对新产生个体每个维度坐标根据可行解空间域进行边界约束, 与当前轮次中表现最优异的个体进行比较更新, 从而帮助算法跳出局部最优解和早熟收敛。假设当前迭代轮次中, 表现最优异的个体记为 P_{best}^1 , 次优解记为 P_{best}^2 , 以二者为基础生成一个具有潜力的最优解备选集合记为 P_{re} , 如公式 (3-11) 所示, 集合中的元素为四个待选个体的位置坐标, 通过适应度比较选择其中表现最优异的个体取代当前种群中的最优解。

$$\begin{cases} P_{re}^1(t) = P_{best}^1(t) \\ P_{re}^2(t) = P_{best}^1(t)[1 + \text{cauchy}(0,1)] \\ P_{re}^3(t) = P_{best}^2(t)[1 + \text{cauchy}(0,1)] \\ P_{re}^4(t) = \frac{1}{2}[P_{best}^1(t) + P_{best}^2(t)] \end{cases} \quad (3-11)$$

$$Cauchy(0,1) = \tan[\pi \times (rand - 0.5)] \quad (3-12)$$

其中, $Cauchy(0,1)$ 是标准的柯西算子, $rand$ 产生 0 到 1 之间均匀分布的随机数。

对于种群中一些停滞不前的劣质解 $P_{worst}(t)$, 在鲸鱼种群觅食过程中设置一个计数器, 每经过 M 次迭代之后对随机选中的 N_d 个维度进行变异, 生成新的个体取而代之, 每轮被选中的变异个体数 N_p 随着迭代次数增加而减少, 来进一步平衡算法全局搜索能力和收敛速度之间的矛盾。

$$N_p = \left\lceil N_0 \exp\left(-\frac{st}{T}\right) \right\rceil \quad (3-13)$$

$$N_d = \lceil \varepsilon D \rceil \quad (3-14)$$

其中, N_0 是预先设置的变异个数, s 是种群变异规模, ε 是维度变异规模。参数根据优化问题和种群规模进行调整, 本文中设置 M 为 5, s 为 1.7, ε 为 0.4。




图 3-4 标准高斯分布与柯西分布概率密度曲线

3.2.4 边界约束策略

正常迭代及变异产生新的鲸鱼个体 $P(t) = (x_1, x_2, \dots, x_D)$, 若游出搜索空间则会产生无效解, 标准鲸鱼优化算法在检查之后选择将超出边界的个体直接拉回到边界上进行修正。为了提高算法的全局搜索能力, 本文采用公式 (3-15) 中的方法对鲸鱼个体进行边界约束, 在受限区域中对鲸鱼位置中超出解空间的维度进行随机重置, 与原始方法相比增加了种群的多样性。

$$x_i = \begin{cases} x_{i_min} + 0.25r(x_{i_max} - x_{i_min}) & x_i < x_{i_min} \\ x_i & x_{i_min} \leq x_i \leq x_{i_max} \\ x_{i_max} - 0.25r(x_{i_max} - x_{i_min}) & x_i > x_{i_max} \end{cases} \quad (3-15)$$

其中 x_{i_min} 和 x_{i_max} 分别是搜索空间第 i 维的下边界和上边界, r 在 $[0,1]$ 间随机取值。

3.3 优化算法性能对比

3.3.1 基准测试函数

基准测试函数 (Benchmark Functions) 经常被用来评价智能优化算法的可行性以及有效性, 本文选择求解常用的 23 个标准 CEC 测试函数对 IWOA 性能进行验证。每个基准函数有着不同的属性, 这 23 个函数按照极值点数目和变量维度可以分为三种类型^[49]。表中给出了每个基准测试函数名称、具体表达式、变量维度、取值范围以及最小值, 表达式中的参数依照初始标准进行设置。表 3-1 中是 7 个单峰多维度测试函数, 表 3-2 中 6 个为多峰多维度测试函数, 这两种类型的测试函数对变量维度没有限制, 综合考虑本文中待优化的天线设计变量维度, 在此处数值仿真实验中设置为 30。表 3-3 中是 10 个固定维度的多峰测试函数, 每个函数自身定义时就指定了解空间维度。

表 3-1 单峰多维度测试函数

函数名	表达式	维度	范围	最小值
Sphere	$F_1(x) = \sum_{i=1}^n x_i^2$	30	$[-100,100]$	0
Schwefel2.22	$F_2(x) = \sum_{i=1}^n x_i + \prod_{i=1}^n x_i $	30	$[-10,10]$	0
Schwefel1.2	$F_3(x) = \sum_{i=1}^n \left(\sum_{j=1}^i x_j \right)^2$	30	$[-100,100]$	0
Schwefel2.21	$F_4(x) = \max \{ x_i , 1 \leq i \leq n \}$	30	$[-100,100]$	0
Rosenbrock	$F_5(x) = \sum_{i=1}^n \left[100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2 \right]$	30	$[-30,30]$	0
Step	$F_6(x) = \sum_{i=1}^n ([x_i + 0.5])^2$	30	$[-100,100]$	0
Quartic	$F_7(x) = \sum_{i=1}^n ix_i^4 + random[0,1)$	30	$[-1.28,1.28]$	0

表 3-2 多峰多维度测试函数

函数名	表达式	维度	范围	最小值
Schweffel2.26	$F_8(x) = \sum_{i=1}^n -x_i \sin(\sqrt{ x_i })$	30	[-500,500]	-418.9829n
Rastrigin	$F_9(x) = \sum_{i=1}^n [x_i^2 - 10 \cos(2\pi x_i) + 10]$	30	[-5.12,5.12]	0
Ackley	$F_{10}(x) = -20 \exp\left(-0.2 \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}\right) + 20 + e$ $-\exp\left(\frac{1}{n} \sum_{i=1}^n \cos(2\pi x_i)\right)$	30	[-32,32]	0
Griewank	$F_{11}(x) = \frac{1}{4000} \sum_{i=1}^n x_i^2 - \prod_{i=1}^n \cos\left(\frac{x_i}{\sqrt{i}}\right) + 1$	30	[-600,600]	0
Penalized1	$F_{12}(x) = \frac{\pi}{n} \left\{ \sum_{i=1}^{n-1} (y_i - 1)^2 [1 + \sin^2(\pi y_{i+1})] + (y_n - 1)^2 + 10 \sin(\pi y_1) \right\} + \sum_{i=1}^n u(x_i, 10, 100, 4)$ $y_i = 1 + \frac{x_i + 1}{4}$ $u(x_i, a, k, m) = \begin{cases} k(x_i - a)^m & x_i > a \\ 0 & -a < x_i < a \\ k(-x_i - a)^m & x_i < -a \end{cases}$	30	[-50,50]	0
Penalized2	$F_{13}(x) = \left\{ \sin^2(3\pi x_1) + \sum_{i=1}^n (x_i - 1)^2 [1 + \sin^2(3\pi x_i + 1)] \right\} (x_n - 1)^2 [1 + \sin^2(2\pi x_n)] \times 0.1 + \sum_{i=1}^n u(x_i, 5, 100, 4)$	30	[-50,50]	0

虽然单峰多维度测试函数在整个寻优范围内只有一个全局极小值，但是其中部分函数由于自身特性很难收敛到极值，可以用来验证算法的开发能力和收敛能力；多峰多维度测试函数在整个解空间范围内有两个或两个以上局部极小值，极值点之间的距离较小，很容易陷入局部最优解，该类函数可以用来验证算法跳出局部最优的探索能力；多峰固定维度测试函数限定了变量的维数，同样也存在多个局部极值点且难被找到，可以进一步验证算法的全局探索能力。上述测试函数种类丰富，其理论上的最小值和最优解不局限于零，在这些函数上进行的数值仿真实验能够在很大程度上体现优化算法的性能优劣。

表 3-3 多峰固定维度测试函数

函数名	表达式	维度	范围	最小值
Shekel's Foxholes	$F_{14}(x) = \left(\frac{1}{500} + \sum_{j=1}^{25} \frac{1}{j + \sum_{i=1}^2 (x_i - a_{ij})^6} \right)^{-1}$	2	[-65, 65]	1
Kowalik	$F_{15}(x) = \sum_{i=1}^n \left[a_i - \frac{x_1(b_i^2 + b_1x_2)}{b_i^2 + b_1x_3 + x_4} \right]^2$	4	[-5, 5]	0.0003
SixHum Camel Back	$F_{16}(x) = 4x_1^2 - 2.1x_1^4 + \frac{1}{3}x_1^6 + x_1x_2 - 4x_2^2 + 4x_2^4$	2	[-5, 5]	-1.0316
Branin	$F_{17}(x) = \left(x_2 - \frac{5.1}{4\pi^2}x_1^2 + \frac{5}{\pi}x_1 - 6 \right)^2 + 10 \left(1 - \frac{1}{8\pi} \right) \cos x_1 + 10$	2	[-5, 5]	0.398
Goldstein Price	$F_{18}(x) = \left[1 + (x_1 + x_2 + 1)^2 (19 - 14x_1 + 3x_{12}^2 - 14x_2 + 6x_1x_2 + 3x_2^2) \right] \times \left[30 + (2x_1 - 3x_2)^2 \times (18 - 32x_1 + 12x_1^2 + 48x_2 - 36x_1x_2 + 27x_2^2) \right]$	2	[-2, 2]	3
Hartman3	$F_{19}(x) = -\sum_{i=1}^4 c_i \exp \left(-\sum_{j=1}^3 a_{ij} (x_j - p_{ij})^2 \right)$	3	[1, 3]	-3.86
Hartman6	$F_{20}(x) = -\sum_{i=1}^5 c_i \exp \left(-\sum_{j=1}^6 a_{ij} (x_j - p_{ij})^2 \right)$	6	[0, 1]	-3.32
Shekel5	$F_{21}(x) = -\sum_{i=1}^5 \left[(X - a_i)(X - a_i)^T + c_i \right]^{-1}$	4	[0, 10]	-10.1532
Shekel7	$F_{22}(x) = -\sum_{i=1}^7 \left[(X - a_i)(X - a_i)^T + c_i \right]^{-1}$	4	[0, 10]	-10.4028
Shekel10	$F_{23}(x) = -\sum_{i=1}^{10} \left[(X - a_i)(X - a_i)^T + c_i \right]^{-1}$	4	[0, 10]	-10.5364

3.3.2 实验设置

为了验证 IWOA 算法性能, 本文基于上述 3 种类型的 23 个测试函数进行仿真实验, 从收敛速度、收敛精度和稳定性等方面对算法性能进行了对比。选择的对比算法除了 WOA 和 IWOA, 还有前文中介绍的初筛后留下的 PSO、GSA、GWO、MFO 和 SSA 五种算法, 算法中超参数均参照原论文进行设置。在仿真中设置每种算法种群规模皆为 30, 最大迭代次数为 1000。为了避免随机搜索算法结果的偶然性影响算法排名, 让每种算法在 23 个函数下独立重复运行 30 次并取平均值。分别对收敛曲线、均值和标准差进行分析, 观察收敛曲线可以整体判断算法迭代中的收敛速度和最后达到的收敛精度, 均值指标可以用于具体评估算法收敛精度, 标准差指标能够衡量算法稳定性以及鲁棒性。

3.3.3 仿真结果

(1) 收敛曲线




图 3-5 单峰测试函数 F1-F7 收敛曲线




图 3-6 多峰测试函数 F8-F13 收敛曲线




图 3-7 多峰固定维度测试函数 F14-F15 收敛曲线




图 3-8 多峰固定维度测试函数 F16-F23 收敛曲线

(2) 均值和标准差

将上述 7 种算法 30 次独立重复实验之后计算得到的均值和标准差按照表 3-4 到 3-6 中所示进行汇总, 根据算法缩写首字母的先后顺序分列排布。每一个基准测试函数下, 第一行数据是最终搜索到的最优函数值的平均值, 第二行数据是 30 次实验优化实验中搜索结果的标准差, 在表格中已经将每一行中的最优值加粗表示。

表 3-4 单峰多维度 (30) 测试函数寻优均值和标准差

F	GSA	GWO	IWOA	MFO	PSO	SSA	WOA
1	1.06E-16	8.79E-59	1.65E-319	2.33E+03	3.26E-07	1.21E-08	2.59E-147
	5.25E-17	1.76E-58	0	4.30E+03	8.83E-07	2.60E-09	1.42E-146
2	5.44E-08	9.24E-35	1.72E-168	3.70E+01	3.33	1.07	8.43E-104
	1.51E-08	9.88E-35	0	1.97E+01	6.06	7.97E-01	3.90E-103
3	4.09E+02	3.98E-15	1.55E-258	1.90E+04	1.16E+03	3.49E+02	2.24E+04
	1.40E+02	1.17E-14	0	1.30E+04	1.85E+03	2.42E+02	1.01E+04
4	1.42	1.82E-14	4.37E-147	6.84E+01	3.70	7.07	3.18E+01
	1.31	2.04E-14	2.27E-146	8.48	7.37E-01	4.10	2.91E+01
5	4.32E+01	2.73E+01	2.63E+01	5.34E+06	1.23E+04	2.84E+02	2.69E+01
	5.28E+01	7.92E-01	3.43E-01	2.03E+07	3.10E+04	4.38E+02	4.94
6	1.03E-16	5.33E-01	2.60E-02	2.00E+03	3.00E-06	1.15E-08	7.24E-02
	4.27E-17	3.45E-01	1.25E-02	4.07E+03	1.45E-05	2.74E-09	7.08E-02
7	6.07E-02	9.57E-04	5.26E-05	6.76	2.50E-02	8.57E-02	1.66E-03
	3.12E-02	5.58E-04	4.27E-05	1.13E+01	8.42E-03	2.87E-02	1.68E-03

表 3-5 多峰多维度 (30) 测试函数寻优均值和标准差

F	GSA	GWO	IWOA	MFO	PSO	SSA	WOA
8	-2.58E+03	-6.11E+03	-1.24E+04	-8.74E+03	-8.95E+03	-7.77E+03	-1.09E+04
	4.49E+02	8.33E+02	3.93E+02	9.00E+02	6.15E+02	7.52E+02	1.80E+03
9	2.63E+01	5.93E-01	0	1.72E+02	5.65E+01	6.08E+01	7.58E-15
	6.52	1.50	0	3.99E+01	2.04E+01	2.20E+01	2.47E-14
10	7.13E-09	1.62E-14	8.88E-16	1.41E+01	9.36E-02	1.91	4.44E-15
	1.39E-09	3.86E-15	0	7.99	3.61E-01	8.95E-01	2.64E-15
11	8.92	5.86E-03	0	1.21E+01	1.49E-02	9.84E-03	7.42E-03
	3.57	1.29E-02	0	3.12E+01	1.48E-02	1.39E-02	2.30E-02
12	2.08E-01	3.42E-02	1.90E-03	4.75E-01	8.32E-02	5.77	6.39E-03
	3.19E-01	1.42E-02	1.07E-03	7.83E-01	2.83E-01	2.94	5.06E-03
13	1.49E-01	4.93E-01	6.12E-02	8.61E-02	9.11E-03	2.18	1.75E-01
	3.92E-01	2.11E-01	4.50E-02	1.21E-01	1.15E-02	6.36	1.14E-01

表 3-6 多峰固定维度测试函数寻优均值和标准差

F	GSA	GWO	IWOA	MFO	PSO	SSA	WOA
14	4.01	4.78	1.26	2.48	9.98E-01	9.98E-01	2.96
	2.58	4.37	6.35E-01	1.95	4.12E-17	2.24E-16	3.62
15	2.88E-03	4.32E-03	3.72E-04	3.04E-03	2.41E-03	9.14E-04	6.64E-04
	1.62E-03	8.16E-03	9.05E-05	5.89E-03	6.09E-03	2.88E-04	4.47E-04
16	-1.03	-1.03	-1.03	-1.03	-1.03	-1.03	-1.03
	5.05E-16	5.73E-09	2.95E-10	6.78E-16	6.65E-16	8.08E-15	4.27E-10
17	3.98E-01	3.98E-01	3.98E-01	3.98E-01	3.98E-01	3.98E-01	3.98E-01
	0	1.80E-07	6.22E-06	0	0	3.39E-15	2.73E-06
18	3.00	3.00	3.00	3.00	3.00	3.00	3.00
	2.74E-15	9.63E-06	4.34E-05	2.18E-15	9.69E-16	1.88E-13	1.58E-04
19	-3.86	-3.86	-3.86	-3.86	-3.86	-3.86	-3.86
	2.39E-15	2.02E-03	4.94E-03	2.71E-15	1.44E-03	3.04E-14	2.28E-03
20	-3.32	-3.28	-3.22	-3.23	-3.28	-3.23	-3.25
	1.46E-15	7.19E-02	9.87E-02	6.54E-02	6.40E-02	5.17E-02	8.76E-02
21	-6.68	-9.57	-1.01E+01	-7.06	-6.30	-8.15	-9.47
	3.59	1.83	1.72E-02	3.46	3.34	3.18	1.76
22	-1.02E+01	-1.04E+01	-1.04E+01	-8.63	-8.01	-8.28	-8.45
	1.06	2.02E-04	1.29E-02	3.04	3.48	3.12	3.15
23	-1.05E+01	-9.91	-1.05E+01	-6.64	-8.26	-9.75	-7.98
	2.21E-15	1.96	2.19E-02	3.77	3.56	2.40	3.25

3.3.4 对比分析

(1) 收敛曲线

图 3-5 到图 3-8 中是 7 种算法在 23 个测试函数下的收敛曲线对比图，图中横坐标为优化算法迭代次数，纵坐标为寻优所得函数最优值。为了使算法结果显示更加直观，图中纵坐标采用对数刻度，其中由于函数 F8、F16 以及 F19~F23 寻优结果为负数，收敛曲线的坐标轴仍使用线性刻度。

首先对比改进后鲸鱼优化算法 IWOA 和标准版鲸鱼优化算法 WOA 的性能，收敛曲线图中圆圈标记的曲线是 WOA 收敛曲线，上三角标记的曲线是 IWOA 收敛曲线。从曲线走势来看，在 23 个测试函数下 IWOA 曲线收敛速度和最终实现的收敛精度都明显优于 WOA，且在 WOA 陷入局部最优的情况下，IWOA 仍然具有跳出早熟陷阱的能力，这一点在 F3、F8、F11 等多个函数的收敛曲线图中表现明显。

然后对比 IWOA 与筛选留下的其他 5 种算法。纵向分析收敛曲线，在相同迭代次数下 IWOA 可以取得更高的求解精度。横向比较，达到同一收敛精度时 IWOA 经过的迭代次数最少。IWOA 不管是在单峰测试函数还是多峰测试函数

上, 收敛速度和求解精度都表现突出, 有力证明了本文提出的改进策略有效提升了鲸鱼优化算法在全局搜索和局部开发之间的平衡能力, 实现了一种性能方面具有优势的优化算法。

(2) 均值和标准差

表 3-4、表 3-5 和表 3-6 中分别是 3 种类型测试函数下 30 次独立重复实验得到的均值和标准差, 其中加粗表示的是每个测试函数下 7 种算法取得的最优均值和最小标准差。

比较鲸鱼优化算法标准版和本文改进版, 数据表现与收敛曲线中获得的直观感受一致, IWOA 在 23 个函数上都搜索到了比 WOA 更优的解。与 WOA 相比, IWOA 在除了 F17、F19 和 F20 以外的 20 个函数上标准差都更小。在没有取得最小的这 3 个函数上, 30 次寻优得到的标准差也是同一数量级的, 说明了改进后的算法与原算法相比寻优性能更加稳定。

总结表格中 7 种算法的优化结果, 分析均值可以得到 IWOA 在 19 个测试函数上都取得了最优解, 且在 F6、F13、F14 和 F20 这 4 个测试函数中也能够取得较接近最优值的解, 因此综合来看 IWOA 寻优精度比其他六种优化算法高, 具有更好的全局寻优能力。分析标准差可以得到 IWOA 在 13 个测试函数上均方差最小, 证明了改进后算法的在稳定性方面也具有优势。

通过上述分析, 本文改进后的鲸鱼优化算法面对测试案例中多种不同优化问题时, 在收敛速度、收敛精度以及稳定性方面都有着明显优势, 因此考虑将 IWOA 引入本文研究的天线优化设计中, 更高效地完成设计空间中天线最佳结构的探索。

3.3.5 离散化设计

改进后的鲸鱼优化算法适合用于解决连续变量优化问题, 为了应对离散变量下的优化需求, 例如微带天线网格化“开窗”设计或者基于开关的可重构天线优化设计等应用场景, 考虑引入传递函数实现鲸鱼位置向量从连续到离散的映射。以二进制为例, 将离散化处理的 IWOA 算法记为 BIWOA。文献[50]中介绍了 4 种 S 型和 4 种 V 型传递函数, 应用于粒子群算法的离散化。其中 S 型传递函数以 Sigmoid 函数为原型, 通过改变指数项系数实现不同变种, 4 种传递函数值随自变量变化曲线如图 3-9 所示。V 型传递函数曲线变化趋势与 S 型不同, 如图 3-10 所示, 4 种 V 型传递函数区别在于从零点往两端延伸时曲线的斜率和所达到的饱和值不同。将上述 8 种传递函数分别引入 IWOA 进行对比试验, 从而选择出更加适用的离散化方法。

$$\begin{cases} S_1(x) = \frac{1}{1 + \exp(-2x)} & S_2(x) = \frac{1}{1 + \exp(-x)} \\ S_3(x) = \frac{1}{1 + \exp\left(-\frac{1}{2}x\right)} & S_4(x) = \frac{1}{1 + \exp\left(-\frac{1}{3}x\right)} \end{cases} \quad (3-16)$$

$$\begin{cases} V_1(x) = \left| \operatorname{erf}\left(\frac{\sqrt{\pi}}{2}x\right) \right| & V_2(x) = |\tanh(x)| \\ V_3(x) = \left| \frac{x}{\sqrt{1+x^2}} \right| & V_4(x) = \left| \frac{2}{\pi} \arctan\left(\frac{\pi}{2}x\right) \right| \end{cases} \quad (3-17)$$




图 3-9 S 型传递函数曲线




图 3-10 V 型传递函数曲线

对比八种传递函数下 BIWOA 算法的性能，以测试函数 F1、F3、F5、F7 为例进行说明，分别在维度 30 和维度 60 的情况下进行 30 次独立实验取平均值。图 3-11 到图 3-14 是对应情况下的收敛曲线，综合来看，在较低维度 30 情况下，

基于传递函数 S_1 的算法收敛速度和寻优精度表现最佳。在较高维度 60 情况下，V 型函数虽然前期收敛速度慢，但后期寻找全局最优解更有优势。本文中需要完成设计的天线，待优化变量维度均低于 30，且只需找到满足预期目标的天线结构，不局限于一定要找到全局最优解，因此选用 S_1 函数进行离散化。




图 3-11 测试函数 F1 收敛曲线；(1) 维度 30；(2) 维度 60




图 3-12 测试函数 F3 收敛曲线；(1) 维度 30；(2) 维度 60




图 3-13 测试函数 F5 收敛曲线；(1) 维度 30；(2) 维度 60




图 3-14 测试函数 F7 收敛曲线: (1) 维度 30; (2) 维度 60

3.4 基于 IWOA 的连续型变量天线优化设计

3.4.1 天线结构

高速率大容量的通信场景催生了对于超宽带天线的广泛需求,超宽带通信系统中,平面结构天线因其低剖面、低成本等优点常常被采用。本小节应用改进后的鲸鱼优化算法 IWOA,对连续型变量的微带贴片天线进行优化设计,找到满足预期目标的结构参数。传统的矩形贴片天线工作频带较窄,为了获得更大的阻抗带宽,可以考虑在贴片两端切去对称的矩形槽口。通过图 3-16 中切角前后回波损耗曲线对比图可以看出,切角之后天线的-10dB 带宽明显增加,证明该措施能够有效扩展天线频带宽度,为后续超宽带天线的设计提供了思路。




图 3-15 天线切角前后俯视图对比

本小节待优化的天线为矩形切角超宽带天线,几何结构如图 3-17 所示,印制在厚度 H 为 1mm 的 FR4 介质基板上,通过宽度为 2mm 的 50Ω 微带线进行馈电,背面为部分接地板,除了待优化参数 $[X1, X2, X3, X4, X5]$ 外,其他固定参数初始值参见表 3-7 进行设置。

(1) 待优化变量及取值范围

设计空间维度 D 为 5,待优化参数为金属贴片宽度 $X1$ 以及长度 $X2$,切角

的宽度 X3 以及长度 X4，还有部分接地板的长度 X5，变化范围如表 3-8 中所示。




图 3-16 天线切角前后反射系数曲线对比




图 3-17 矩形切角超宽带天线示意图

表 3-7 天线部分固定参数

变量名称	L	W	L1	W1	H
取值(mm)	31	24	10	2	1

表 3-8 优化变量及取值范围

变量名称	X1	X2	X3	X4	X5
优化范围 (mm)	[12, 24]	[10, 21]	[1, 5]	[1, 5]	[5, 10]

(2) 适应度函数

优化目标为回波损耗和带宽，IWOA 算法中的适应度函数如公式 (3-18) 所示，其中权重系数 k_1 和 k_2 取值分别为 1 和 2， $S_{11}(i)$ 为频段 3.1~10.6GHz 内各采

样点处反射系数的加权值， BW 为 S_{11} 小于 -10dB 的输入阻抗带宽。优化设计中设置种群大小为 20，最大迭代次数 200。

$$Fitness = \frac{k_1}{n} \sum_{i=1}^n S_{11}(i) - k_2 BW \quad (3-18)$$

$$S_{11} = \begin{cases} |S_{11}|, & S_{11} > -10\text{dB} \\ S_{11}, & -20\text{dB} < S_{11} \leq -10\text{dB} \\ -20, & S_{11} \leq -20\text{dB} \end{cases} \quad (3-19)$$

3.4.2 优化结果

运用本章改进后的鲸鱼优化算法，对矩形切角微带天线分别进行了四次优化实验，兼顾工作带宽和回波损耗平均值，每次都得到了满足优化目标的天线结构。优化得到的天线结构参数及对应的工作带宽汇总到了表 3-9 中，每种结构下天线带宽都覆盖了 $3.1\sim 10.6\text{GHz}$ 的超宽带工作频段要求。

表 3-9 超宽带天线优化结果汇总

序号	X1(mm)	X2(mm)	X3(mm)	X4(mm)	X5(mm)	频段(GHz)
天线 1	17.50	20.20	3.11	4.20	8.90	3.09~11.91
天线 2	17.00	18.00	3.00	4.68	8.73	3.10~11.65
天线 3	17.82	20.31	2.94	4.25	8.85	3.05~11.68
天线 4	20.52	19.15	4.33	4.78	8.69	3.05~10.83




图 3-18 四次优化得到的天线反射系数对比

优化后回波损耗曲线图对比如图 3-18 所示，图中标注了判断频率和反射系数是否满足要求的边界线，从图中可以看出，四次优化设计得到的天线回波损耗与带宽均实现了优化目标。超宽带天线除了频带宽，还具有全向辐射特性。以带宽最宽的天线 1 为例，图 3-19 到图 3-21 分别是 3GHz、6GHz 和 9GHz 频率下的二维辐射方向图，其中虚线是 XOZ 截面，实线是 YOZ 截面。从中可以看出天线方向图在 XOZ 面近似为圆形，YOZ 面近似数字“8”的形状，在高频处产生了一些畸变，符合预期要求。




图 3-19 3GHz 下 XOZ 和 YOZ 截面辐射方向图




图 3-20 6GHz 下 XOZ 和 YOZ 截面辐射方向图




图 3-21 9GHz 下 XOZ 和 YOZ 截面辐射方向图

3.5 基于 BIWOA 的离散型变量天线优化设计

3.5.1 天线结构

现代信息通讯系统需要集成多种业务，不同工作频率的天线集成增加了系统设计的难度和成本。本小节对基于开关的 $m \times n$ 频率可重构天线进行优化设计，通过调整 RF 开关组合的状态改变拓扑结构，辐射贴片上的有效电流长度发生变化，使得天线能够满足不同场景下的通信需求。如图 3-22 所示，正方形铜制小贴片以 m 行 n 列排布，贴片之间通过开关彼此连接，常用的开关类型有微电子机械系统（Micro Electro Mechanical System, MEMS）开关、PIN 开关等，相对来说 MEMS 开关导通电阻更低、开路隔离度更高，且具有低损耗、小尺寸等优点，更适合用于可重构天线制作。参考文献[51]中可重构天线的结构参数进行建模，小方形贴片印制在材料为 Rogers RT/duriod 5880 的介质基板上，通过同轴电缆从背部进行馈电。




图 3-22 可重构天线贴片结构示意图

$$D = m(n-1) + n(m-1) \quad (3-20)$$

优化变量为开关的开闭状态，用“0”表示断开，“1”表示闭合，行列开关总数即为鲸鱼位置向量的维度 D ，可以按照公式 (3-20) 计算。在仿真中假设开关为理想模型，用连接相邻两个贴片的理想导体表示开关闭合。以 m 、 n 均等于 4 为例，正方形贴片边长为 9.4mm，相邻间隙 5.6mm，连接开关宽度 1.2mm。通过联合仿真在 HFSS 中完成天线的自动化建模以及求解，正方形贴片以 4 行 4 列均匀排布，贴片之间的行列开关按照优化算法传递过来的鲸鱼个体位置向量进行设置。

(1) 待优化变量

待优化变量的维度就是行列开关总数，在 4×4 可重构天线优化中为 24，每一维的值代表开关状态，取值只为 0 或 1。

(2) 适应度函数

优化目标是指定频点的回波损耗， ε 是可以接受的频率误差，预设值为 0.1。优化算法种群大小设置为 20，最大迭代次数 200。

$$Fitness = S_{11}(f) \Big| f_{obj} - \varepsilon \leq f \leq f_{obj} + \varepsilon \quad (3-21)$$

3.5.2 优化结果

改变开关组合的状态实现天线在不同工作频率之间的切换，本文在 5 种不同的预设目标频率下分别进行了实验，成功得到工作在不同频段的 5 种天线开关状态。表 3-10 中汇总了寻优得到的天线开关状态序列以及对应仿真结果，图 3-23 到图 3-27 分别是五次优化得到的天线开关结构俯视图和回波损耗曲线图，在图中用星号标注了谐振频率点和对应的 S_{11} 值。

最终得到的开关状态序列下：(1) 天线 1 设定的目标频率为 1.50GHz，实际谐振频率为 1.52GHz，在该频点处反射系数达到 -34.39dB，反射系数小于 -10dB 的频率范围在 1.48GHz-1.56GHz，工作在 L 波段；(2) 天线 2 设定的目标频率为 3.90GHz，实际谐振频率为 3.94GHz，在该频点处反射系数达到 -28.43dB，工作于 3.90GHz-3.98GHz，属于 S 波段；(3) 天线 3 优化前设定的目标频率为 4.80GHz，实际谐振频率为 4.70GHz，在该频点处反射系数达到 -32.76dB，工作于 4.66GHz-4.74GHz，属于 C 波段；(4) 天线 4 设定的目标频率为 8.50GHz，实际谐振频率为 8.50GHz，在该频点处反射系数达到 -36.97dB，工作于 8.44GHz-8.58GHz，属于 X 波段较低频率；(5) 天线 5 设定的目标频率为 10.20GHz，实际谐振频率为 10.25GHz，在该频点处反射系数达到 -46.56dB，工作于 9.67GHz-11.06GHz，属于 X 波段较高频率。


应用 BIWOA 算法实现了频率可重构天线中二进制开关状态序列的寻优，多次实验中控制谐振频率在设置范围内的同时，探索找到使得回波损耗表现优

异的开关状态。实验结果证明了该款频率可重构天线通过开关状态切换，能够实现在不同波段不同频率之间的切换，有能力应对不同场景下的通信需求，在实际应用中能够减少系统中集成天线的种类和数量。


表 3-10 频率可重构天线优化结果

序号	开关状态序列	目标频率(GHz)	谐振频率(GHz)	$S_{11\min}(\text{dB})$
天线 1	010100110110000111001110	1.50	1.52	-34.39
天线 2	000011011011100001100011	3.90	3.94	-28.43
天线 3	110010111001001110101111	4.80	4.70	-32.76
天线 4	010001110011000111010111	8.50	8.50	-36.97
天线 5	100010101100010001101010	10.20	10.25	-46.56


(1)




(2)

图 3-23 (1) 天线 1 的开关结构；(2) 天线 1 的 S_{11} 曲线图

(1)



(2)

图 3-24 (1) 天线 2 的开关结构；(2) 天线 2 的 S_{11} 曲线图




图 3-25 (1) 天线 3 的开关结构; (2) 天线 3 的 S_{11} 曲线图




图 3-26 (1) 天线 4 的开关结构; (2) 天线 4 的 S_{11} 曲线图




图 3-27 (1) 天线 5 的开关结构; (2) 天线 5 的 S_{11} 曲线图

3.6 本章小结

本章首先完成了智能优化算法的设计，从近年来常用的 11 种优化算法出发，确定鲸鱼优化算法作为基本算法进行研究。然后分析了基础鲸鱼优化算法的原理，针对其存在的缺点提出一系列改进策略。接着将改进后的鲸鱼优化算法与其他几种常见的智能优化算法在基准测试函数下进行对比测试，仿真结果证明了改进后的鲸鱼优化算法寻优性能的优势。在此基础上，引入传递函数实现改进鲸鱼优化算法的离散化。最后，基于改进后的鲸鱼优化算法完成了连续型变量下的超宽带天线设计，多次实验获得的天线均能够覆盖超宽带通信频段且反射系数平均值表现良好。基于离散化处理的改进鲸鱼优化算法完成了具有 24 个开关的频率可重构天线的优化设计，多次实验分别获得了工作在不同波段的开关状态，且回波损耗性能良好。本章中设计的算法和方案能够切实有效地实现不同类型天线的优化设计，得到的超宽带天线和频率可重构天线均具有实际应用价值。

第四章 结合代理模型预测的天线自动优化设计

为了进一步提高天线优化设计工作的效率，本章在智能优化算法方案的基础上引入代理模型实现对天线电磁响应的预测。基于改进后的方案开展了两款天线的高效优化设计，一种是不规则多边形超宽带天线，另一种是基于开关的频率可重构天线，通过电磁仿真次数对比证明了改进后方案在效率上的提升。

4.1 方案模块划分

智能优化算法辅助下的天线结构设计，只需要给定寻优空间边界限制和算法初始参数，就可以同时对多个参数进行自动化调整，直到满足预设条件停止寻优，与传统方法相比避免了手动调试的过程。在上一章的天线设计实例中，每一次完成天线结构优化都接近上千次地调用电磁仿真软件来计算适应度，一次仿真至少需要消耗 1 到 2 分钟，这也就意味着高昂的时间和资源代价。在本章中将代理模型引入上述过程，从小样本中获取信息，训练模型捕获输入和输出之间复杂的非线性映射关系，代替全波仿真软件大部分的工作，从效率的角度对方案进行优化。

代理模型从原理上考虑，是在统计学理论指导下通过样本学习获得某种映射关系，从而以尽可能小的误差估计新输入参数对应的响应。在天线设计领域中通常有两种对应关系。一种是以天线谐振频率、增益等性能参数为输入特征，以天线具体的结构参数为输出构建代理模型，更加贴近实际工程中从需求到结果的设计流程，给定性能指标直接输出天线结构。另一种则是以性能为目标，把结构参数作为输入特征进行训练，更贴近电磁仿真软件中高精度模型的逻辑，给定天线结构输出对应响应。前者对模型精度要求高，且天线的性能参数多是精确的数值，后者更适合与智能优化算法结合，充分地探索设计空间使得性能表现更佳。本文选择第二种对应关系来训练代理模型，结合上一章改进后寻优能力更强的鲸鱼优化算法 IWOA 和 BIWOA，完成以性能需求为向导的天线结构优化设计。基于智能优化算法和代理模型实现微带天线的自动优化设计，模块划分如图 4-1 所示。




图 4-1 天线自动优化设计模块划分

（1）智能优化算法模块

前期的工作包括智能优化算法的选择、改进以及评估，这些在第三章已经完成。在本章的整个天线设计流程中，智能优化算法模块的主体为 IWOA 算法和 BIWOA 算法，具体再根据优化问题中自变量的类型选择。该模块中，以天线多维结构参数为位置坐标的鲸鱼种群，在待优化变量上下界构成的设计空间中，迭代执行一系列搜索策略，直到找到适应度最佳的个体，满足初始设置的性能标准，其坐标就对应着本次优化得到天线的结构参数，或者达到最大迭代次数停止整个搜索过程。

（2）适应度函数计算模块

适应度函数基于天线设计中对于性能的需求建立，作为沟通的桥梁实现其他模块间信息的传递。适应度计算模块从智能优化算法模块获得当前个体位置向量，也就是天线待优化结构参数，将其传递到代理模型或联合仿真模块获得对应的目标响应。根据响应完成适应度值计算并返回到优化算法中，作为种群中鲸鱼个体位置优劣的判断依据，指导下一步优化行进方向。

（3）联合仿真模块

联合仿真模块运用 2.4 小节中介绍的工具箱中的功能函数生成 VBS 脚本，自动完成 HFSS 软件的调用，构建当前结构参数下的天线模型并求解，将计算得到的 S_{11} 、增益、方向图等电磁特性返回到适应度计算模块。

（4）代理模型模块

为了进一步提高效率，训练代理模型来代替电磁仿真软件的工作。在参数迭代寻优过程中，代理模型根据当前个体的结构参数对目标响应进行预测，并将预测值传递到适应度模块进行计算。

4.2 代理模型方法改进

4.2.1 传统代理模型方法

结合代理模型进行天线优化设计，主要目的在于提高效率，模型的预测精

度和构建模型耗费的成本格外受到关注。预测精度表征着模型的优劣，直接影响收敛结果的质量，成本则直接影响工作效率，而这两者之间是存在矛盾的，构建一个完全与原模型相当的高精度模型需要大量样本点的支撑，也就违背了提高效率的初衷。因此，以规模尽量小的样本构建一个误差可接受的模型是代理模型方法的主要研究点，样本集的构建和代理模型结构的选择是解决问题的关键。

传统代理模型多为静态模型，面临的难点主要有：

（1）样本规模难以确定

一些学者在样本规模大小选择方面进行了一些研究。Jones 等经过实验对比建议样本规模设置为 $10D$ ，其中 D 为待解决问题变量的维度^[52]。Forrester 等认为样本规模应该小于问题维度的 20 倍^[53]。这些研究只能作为样本规模确定时的参考，不同的应用场景、不同的问题维度、不同的模型结构、不同的精度要求都会影响样本规模的选择。没有完善的理论进行指导，我们无法确定初始构建的样本集能否训练得到预期的模型。静态模型建立过程中一次性完成样本采集，如果不能满足精度要求，需要重新采样来保持样本点在设计空间中分布规律的一致性，这就造成了前期采样工作的浪费，抑制了效率提升的空间。

（2）模型结构难以确定

构建代理模型可选用的结构众多，由于原理层面的差异导致其在不同拟合关系中表现各有优劣。国内外学者在模型的适用性方面进行了对比研究，总体来说代理模型应根据处理问题的类型进行选择，不存在某种模型应对各种问题都具有最佳性能。在工程应用中，对于关系未知的拟合问题无法根据经验选择最适合的模型结构。

（3）模型精度难以确定

静态代理模型在优化过程中始终保持不变，训练得到的模型在后续实验中完全代替原模型。如果在整个设计空间中对预测精度要求很高，就造成了模型构建成本上的负担；如果降低对精度的要求，那么在寻优后期模型很可能跟不上种群的搜索精度，导致最终无法找到满足要求的天线结构。

4.2.2 代理模型改进策略

针对以上难点，从代理模型的构建流程出发提出以下策略进行改进：

（1）结构选择

代理模型在不同应用场景下的性能表现与数据集密切相关，无法断言某种结构一定优于其他结构。本文从天线优化问题非线性、小样本等特征出发，综合考虑领域中不同类型的代理模型结构，从中选择了 4 种具有代表性和潜力的

模型构成备选集，获取样本集之后分别完成训练，选择在测试集上预测表现最好的模型嵌入智能优化算法中。

(a) 克里金模型

克里金模型^[54]最早应用于地质学领域，其目标响应函数可以分成实现全局近似的线性回归和局部近似的随机过程两部分，以估计方差最小化为原则构造对样本无偏估计的模型。为了方便表示，将样本集记为 $X = (x_1, x_2, \dots, x_n)^T$ ，对应的响应集合记为 $Y = (y_1, y_2, \dots, y_n)^T$ 。

$$y(x) = p(x) + z(x) = f^T(x)\beta + z(x) \quad (4-1)$$

$$\text{cov}[z(x_i), z(x_j)] = \sigma^2 R(\theta, x_i, x_j) \quad (4-2)$$

$$R(\theta, x_i, x_j) = \prod_{k=1}^D R_k(\theta_k, d_k) \quad (4-3)$$

其中， $p(x)$ 是 p 阶多项式， $z(x)$ 是均值为 0、方差为 σ^2 的随机过程， β 是回归系数。空间相关函数 $R(\theta, x_i, x_j)$ 可以用核函数 $R_k(\theta_k, d_k)$ 表示，常用的核函数有高斯函数、自然指数函数等， D 是样本点的维度， d 是数据集样本之间的距离，参数 θ 体现了 d 对相关性的影响程度。经过一系列推导，对于新样本点其预测值可以通过以下公式计算：

$$\hat{y}(x_{new}) = f^T(x_{new})\beta^* + r^T(x_{new})R^{-1}(Y - F\beta^*) \quad (4-4)$$

$$F = [f^T(x_1), f^T(x_2), \dots, f^T(x_n)]^T \quad (4-5)$$

其中， β^* 是对 β 的最小二乘估计， $r(x)$ 是预测点与其他 n 个样本点之间的相关矩阵。

利用极大似然估计求解相关函数矩阵得到结果仅与 R 有关，因此超参数调节的目标就是选择 θ 使得对数似然估计最大。

$$L(\theta) = -\frac{n}{2} \ln(\sigma^2) - \frac{1}{2} \ln(|R|) \quad (4-6)$$

在实际应用中，克里金模型需根据具体情况确定线性回归中的基函数类型和随机过程中的相关函数类型。

(b) 支持向量回归模型

支持向量回归是一种特殊的支持向量机^[55]实现，可以分为线性 SVR 和非线性 SVR，在处理非线性问题时通过核函数转化为更高维空间中的线性问题^[56]。如图所示，假设预测值和真实值之间可以接受的最大偏差是 ε ，相当于构建了一个以预测曲线 $f(x)$ 的不敏感间隔区，误差小于 ε 就被认为是 0。SVR 回归函

数可以表示为:

$$f(x) = \sum_{i=1}^n (a_i - a_i^*) K(x_i, x) + b \quad (4-7)$$

其中 a_i , a_i^* 和 b 是拟合得到的参数, $K(x_i, x)$ 是对特征进行映射的核函数, x_i 是不同的初始样本点, x 是当前被模型评价的点。




图 4-2 支持向量回归示意图

(c) 反向传播神经网络模型

人工神经网络模型模拟了人类脑部结构特征，简单的多输入单输出神经元作为信息处理单元，按照一定的拓扑结构集结形成复杂网络，实践中广泛应用的反向传播神经网络是其中一种。BPNN 结构一般包括输入层、输出层和隐藏层，每层之间以权重和阈值为桥梁互联，理论上具有逼近任意复杂非线性函数的能力，能够自学习和适应未知系统。BPNN 是一种泛化能力很强的前馈神经网络模型，按照 Kolmogorov 定理，工程应用中多采用单隐藏层结构^[57]。在训练过程中数据信息先从输入层正向传递到输出层，若输出误差没有达到设定目标，则沿着该通道逐层反向传播实现对连接权值、阈值参数的修正，反复进行上述过程直到满足要求。

(d) 随机森林回归模型

随机森林^[58]属于一种集成算法，由多棵彼此之间没有关联的未剪枝决策树单元组合而成。在训练阶段，使用 bootstrap 重抽样从初始训练集中有放回的抽取多个子样本集，样本和样本输入特征的选取都是随机的。基于分类回归树算法为每个子样本集分别建立对应的回归树模型。测试阶段预测结果为所有回归树输出平均值，其输出由多个基本单元共同决定，误差平摊避免了单棵决策树造成的结果偏差。

(2) 阈值切换

从平衡模型精度和设计成本的角度出发，设置阈值切换实现优化过程中代

理模型和 HFSS 仿真模型的选择。代理模型首先对种群中的个体进行初步评估,若该个体适应度达到了设置的阈值,则有可能成为满足设计要求的解,记为“潜力解”。首先将其位置坐标,也就是天线结构参数与数据库中的样本集进行比较,如果有重复个体则直接调用数据库中响应作为下一步判断依据。如果样本集中不存在该个体,则通过联合仿真调用 HFSS 进行精确求解,判断对应的响应是否满足性能指标,来决定优化工作继续还是停止。与代理模型完全取代原模型相比,这一措施降低了对于代理模型精度的要求。

(3) 在线更新

为了充分利用优化过程中每一次电磁仿真求解携带的信息,首先判断初始样本中是否有满足设计要求的天线结构参数,如果存在则直接输出,没有再进行后续的模型训练以及搜索优化等工作。对于优化过程中产生的新数据点,将其结构参数和对应响应加入样本集数据库,当新增样本数目达到设定值时重新进行模型训练,精细化模型在“潜力解”周围区域的预测精度来匹配优化后期种群搜索精度。

4.2.3 天线优化设计流程

基于智能优化算法和代理模型方案的天线优化设计流程如图 4-3 所示,优化方案实施过程如下:

(1) 确定天线模型大致结构类型以及待优化参数维度和取值范围,明确优化目标;完成 IWOA 或 BIWOA 算法参数以及种群初始化;

(2) 确定初始样本规模,基于 LHS-maximin 方法划分设计空间完成采样,联合仿真计算每个样本点对应的精确电磁响应加入样本集数据库,判断数据库中天线是否满足设置的优化目标,不满足则进行下一步;

(3) 基于样本集数据库完成备选模型训练,选择在测试集上均方根误差最小的模型加入优化流程;

(4) 调用训练好的代理模型对种群中个体依次进行预测并迭代产生新的个体,根据预测响应计算适应度并判断是否接近优化目标,若达到设定的阈值则切换到 HFSS 电磁仿真软件对该个体进行精确求解,将个体加入样本集数据库并计算适应度;

(5) 判断数据库中新增样本点是否触发新一轮模型训练,如果触发就用更新后局部精度更高的模型替代上一个模型,反之模型不变;

(6) 判断当前最优解是否满足优化目标,若满足就结束参数优化流程,输出天线结构参数及对应响应,否则返回步骤(4)。若达到最大迭代次数则停止优化进程。




图 4-3 基于智能优化算法和代理模型的天线自动优化设计流程

4.3 基于 IWOA 和代理模型的天线优化设计

4.3.1 天线结构

(1) 不规则多边形超宽带天线结构

在矩形、三角形等规则形状贴片天线的基础上扩大设计自由度,对一种不规则的多边形天线进行优化设计,提高了应对更多场景的可能性^[59]。刻有部分接地板的天线俯视图如图 4-4 所示,该天线贴片部分可以看作是由 12 个顶点确定的不规则多边形,印制在 $30 \times 30 \times 1.5 \text{ mm}^3$ 的 FR4 介质基板上,通过同一平面上长度 L_1 为 12.5mm,宽度 W_1 为 3mm 的微带线进行馈电。由于天线左右对称,只需要确定其中一半的形状,本文以右侧顶点 P_1 到 P_5 为基准构建天线模型贴片部分。




图 4-4 多边形不规则超宽带天线结构示意图

(2) 待优化变量及取值范围

待优化参数为接地板长度和多边形贴片顶点的位置，其中 x_i 是点 P_i 的横坐标， y_i 是相邻两点 P_i 与 P_{i-1} 纵坐标之差。参数设计空间维度是 11，每一维变量的取值范围如表 4-1 中所示。

$$X = (x_1, x_2, x_3, x_4, x_5, y_1, y_2, y_3, y_4, y_5, L_g) \quad (4-8)$$

表 4-1 待优化结构参数及取值范围

变量名称	$x_1 \sim x_5$	$y_1 \sim y_5$	L_g
优化范围(mm)	[3, 14.5]	[0.1, 5]	[10.5, 12]

4.3.2 样本采集

(1) 优化目标

优化目标为频带宽度 BW 和超宽带工作频带内 S_{11} ，适应度函数如公式 (4-9) 和 (4-10) 所示，其中权重系数 $k_1 = 1$ ， $k_2 = 2$ ，兼顾了工作带宽覆盖范围尽可能大和 3.1~10.6GHz 频带内反射系数平均值尽可能小两个目标。

$$Fitness = \frac{k_1}{n} \sum_{i=1}^n S_{11}(i) - k_2 BW \quad (4-9)$$

$$S_{11} = \begin{cases} S_{11}, & -20dB < S_{11} \leq -10dB \\ -20, & S_{11} \leq -20dB \end{cases} \quad (4-10)$$

(2) 样本采集

代理模型的训练首先需要构建数据集作为训练和测试的对象, 样本质量直接影响最后模型的精度。确定样本集输入特征为天线 11 维结构参数, 输出响应为带宽和反射系数均值。为了保证样本点能够均匀全面地分布在整個设计空间, 采用 2.3.2 小节中介绍的 LHS-maximin 方法完成待优化结构参数在各自取值范围限制下的采样。调用联合仿真模块从文件中依次读取样本点天线结构参数, 自动完成建模求解返回对应的响应, 完成样本集的构建。在本设计案例中设置初始样本规模为 100, 表 4-2 中列举了部分样本作为示例。

表 4-2 部分样本数据示例

参数	序号									
	1	2	3	4	5	6	7	8	9	10
$x_1(\text{mm})$	7.69	13.00	10.98	4.35	5.42	6.23	9.16	7.25	8.74	9.39
$x_2(\text{mm})$	10.31	12.31	7.65	11.58	10.58	14.22	4.31	7.51	11.86	7.32
$x_3(\text{mm})$	14.20	9.78	14.15	6.27	7.72	12.77	7.85	13.72	6.63	8.45
$x_4(\text{mm})$	14.34	4.18	11.83	13.26	12.40	13.57	4.75	12.71	10.50	9.20
$x_5(\text{mm})$	11.33	3.58	9.43	5.39	7.42	6.61	9.56	6.90	13.28	12.40
$y_1(\text{mm})$	1.84	1.69	1.57	1.01	0.37	2.76	1.17	0.30	4.26	1.27
$y_2(\text{mm})$	4.26	3.66	4.73	2.16	4.98	3.73	0.88	2.64	0.82	2.73
$y_3(\text{mm})$	4.41	3.44	1.11	4.33	2.51	2.90	2.84	4.96	4.90	4.75
$y_4(\text{mm})$	3.02	0.59	4.43	4.73	4.79	2.73	2.89	2.82	2.50	2.37
$y_5(\text{mm})$	2.92	1.73	4.91	5.00	3.55	3.43	0.47	1.09	3.83	3.63
$L_g(\text{mm})$	11.79	11.22	11.71	11.58	10.99	11.09	11.67	11.27	10.64	11.96
BW (GHz)	6.20	2.90	5.20	3.30	6.20	3.50	4.15	7.00	1.05	5.45
$S_{11\text{mean}}$ (dB)	-14. 50	-7.08	-13. 02	-10. 43	-13. 48	-8.77	-11. 58	-11. 81	-8.05	-12. 19

为了便于后续进行训练, 对采集到的样本数据进行预处理, 通过规范化消除量纲和取值范围不同带来的不良影响。由于输入数据是在指定范围内采集的天线结构参数, 适合采用最小-最大原则进行处理:

$$x_{\text{norm}} = \frac{x - lb}{ub - lb} \quad (4-11)$$

其中, ub 和 lb 分别为各维变量取值范围上下界。

4.3.3 寻优设置

(1) 结合 IWOA 算法和代理模型对不规则多边形天线的结构参数进行优化设计, 设置优化算法初始种群规模为 20, 最大迭代次数为 200。

(2) 将上述联合仿真构建的初始样本集划分为训练集和测试集, 占比分别为 80%和 20%, 通过交叉验证训练备选集中的代理模型。按照适应度函数权重系数, 综合考虑工作带宽和反射系数的预测均方根误差, 确定了克里金模型作为初始模型加入到算法适应度评估中。

(3) 整个优化流程在满足适应度 $Fitness < -35$ 或达到最大迭代次数的情况下停止, 给出当前找到的天线最优结构和对应响应值。

(4) 当天线性能参数预测值接近预设目标时, 也就意味着当前个体有成为满足要求个体的希望。设置代理模型和仿真软件切换条件为 $Fitness < -25$, 对于满足该条件且不与数据库中现有样本结构参数重复的个体, 通过联合仿真调用原电磁仿真软件进行精确计算, 将对应的输入输出作为新样本点加入数据库并判断是否已经满足设计要求。

(5) 当数据库中新增样本数目达到 8 时更新代理模型, 将新模型加入到之后的优化流程中。

4.3.4 优化结果

将基于 IWOA 算法的设计流程记为方案一, 结合 IWOA 算法和代理模型的设计流程记为方案二, 在两种方案下分别进行实验, 优化得到满足要求的天线结构。表 4-3 和表 4-4 中分别汇总了两种方案下得到天线的结构参数以及对应的适应度值。从图 4-5 中 S_{11} 曲线来看, 方案一优化得到的天线工作频段为 3.25~12GHz, 反射系数在 6.45GHz 处达到最小值-30.60dB, 根据频带宽度和 3.1~10.6GHz 频段内的反射系数平均值计算得适应度为-35.01。方案二优化得到的天线工作频段为 3.2GHz~12GHz, 反射系数在 6.65GHz 处取得最小值-48.69dB, 适应度值为-35.30。综合来看, 方案二优化得到的天线在带宽和回波损耗方面稍有优势, 可以看作是性能相当的结果, 进而能够通过仿真代价比较两种方案的优化效率。

由于调用电磁仿真软件进行建模求解是最耗时的环节, 其他流程耗费的时间相对来说可以忽略, 因此, 选择以仿真软件调用次数为指标评价方案效率。方案一中对种群每一代产生的个体都调用了电磁仿真软件进行求解, 调用次数为 1276 次, 方案二中仅对数据库中不存在的“潜力解”个体进行精确求解, 调用次数为 79 次。不考虑初始样本采集耗费的次数时, 方案二电磁仿真软件调用

次数仅为方案一的 6.19%，加上初始样本采集次数后方案二调用次数为方案一的 14.03%，通过调用次数的对比证明了结合代理模型的方法大大提高了开关状态的搜索效率。

表 4-3 方案一优化得到的天线结构参数

变量名称	x_1	x_2	x_3	x_4	x_5	L_g
取值 (mm)	7.65	9.08	10.34	8.33	6.45	11.83
变量名称	y_1	y_2	y_3	y_4	y_5	BW
取值 (mm)	1.53	4.70	3.83	2.46	4.13	8.75GHz

表 4-4 方案二优化得到的天线结构参数

变量名称	x_1	x_2	x_3	x_4	x_5	L_g
取值 (mm)	7.71	8.88	10.23	8.13	6.49	11.91
变量名称	y_1	y_2	y_3	y_4	y_5	BW
取值 (mm)	1.49	4.74	3.83	2.38	4.14	8.8GHz




图 4-5 两种方案下多边形超宽带天线 S_{11} 曲线图




图 4-6 方案二寻优适应度收敛曲线

以方案二为例，图 4-7 和 4-8 中分别是对应天线结构的俯视图以及 6.65GHz 下的二维辐射方向图，其中虚线是 XOZ 截面，实线是 YOZ 截面。从中可以看出天线 XOZ 面的方向图近似为圆形，YOZ 面近似数字“8”的形状，具有良好的全向辐射特性。




图 4-7 方案二优化得到天线结构




图 4-8 6.65GHz 处 XOZ 和 YOZ 截面辐射方向图

4.4 基于 BIWOA 和代理模型的天线优化设计

4.4.1 天线结构

以 3.5 小节中 $m \times n$ 频率可重构天线为例，在 $m = n = 3$ 情况下正方形贴片和开关排列如图 4-9 所示。待优化结构参数即为开关 S1~S12 的状态，闭合为“1”，断开为“0”，维度为 12。开关的组合状态有 $2^{12} = 4096$ 种，为了快速找到指定谐振频率下天线开关状态，引入 BIWOA 算法和自学习代理模型实现高效搜索。

$$X = (S1, S2, S3, S4, S5, S6, S7, S8, S9, S10, S11, S12) \quad (4-12)$$




图 4-9 可重构天线贴片及开关排列示意图

4.4.2 样本采集

(1) 优化目标

优化目标为指定谐振频率和对应的回波损耗值，以开关状态为变量生成 VBScript 脚本，自动调用 HFSS 创建模型进行求解，处理返回的报告得到谐振频

率和该点处对应 S_{11} 。在 BIWOA 算法优化过程中适应度值计算如下：

$$Fitness = \begin{cases} |f - f_{obj}|, & |f - f_{obj}| > \varepsilon \\ S_{11}, & |f - f_{obj}| \leq \varepsilon \end{cases} \quad (4-13)$$

允许实际谐振频率和目标谐振频率之间存在 ε 的误差，超过限制范围时适应度设置为两频率之间的差值，在给定误差范围内设置适应度值为谐振频率点对应的 S_{11} 值，上述目标函数兼顾了谐振频率准确性和反射系数尽可能小两方面的考虑。

(2) 样本采集

确定样本集输入变量为开关状态序列，输出变量为谐振频率和反射系数 S_{11} 最小值。由于每一维度变量仅有两种取值，不适合直接用 12 维拉丁超立方方法对每个维度进行区间划分。为了让采集样本点尽量均匀分布于设计空间，首先将开关全部断开到全部闭合的二进制状态序列转换为十进制大区间，然后将大区间划分为 $N/10$ 个不重合的小区间，在每个小区间随机采样得到 10 个不重复的点再转换为 12 维的二进制开关序列， N 为初始样本规模。在本设计案例中设置初始样本规模为 80，按照上述抽样策略完成输入特征集的构建，调用联合仿真模块实现每种开关状态下的建模求解，得到对应的谐振频率和 S_{11} 最小值作为响应集汇总到样本集数据库，表 4-5 中是随机抽取的部分样本示例。

表 4-5 部分样本数据示例

序号	开关状态序列	谐振频率 f (GHz)	$S_{11\min}$ (dB)
1	111111010001	9.25	-24.99
2	000010010010	10.40	-26.24
3	110110010110	10.44	-20.09
4	101011011100	8.80	-19.26
5	111011110001	9.49	-15.75
6	110000011111	11.15	-16.46
7	001111100001	8.83	-23.87
8	011100100110	11.59	-14.95
9	001111000001	9.11	-37.23
10	001100111011	8.38	-25.05

4.4.3 寻优设置

(1) 结合 BIWOA 算法和代理模型进行天线开关状态探索设计, 设置种群规模为 10, 最大迭代次数为 200。

(2) 将上述开关状态序列和对应谐振频率以及谐振点处反射系数构成的初始样本集划分为训练集和测试集, 占比分别为 80%和 20%。在频率可重构天线开关状态切换过程中, 谐振频率的准确性优先度更高, 以该项误差作为确定模型结构的主要标准确定了随机森林回归模型为初始模型。

(3) 优化算法停止条件为适应度 $Fitness < -40$ 或达到了预设的最大迭代次数。

(4) 代理模型和精确仿真模型切换的触发条件设置为适应度函数值小于 -25, 对于满足触发条件且数据库中不存在的开关状态调用 HFSS 进行精确求解, 将新样本点加入样本集数据库并判断是否满足停止条件。

(5) 数据库中新增样本计数器达到 5 时将计数器置 0, 基于更新后的数据库重新训练代理模型供下次所用。

4.4.4 优化结果

基于 BIWOA 算法的优化设计记为方案一, 结合 BIWOA 算法和代理模型的优化设计记为方案二, 在两种不同目标频率下分别进行了实验。

(1) 目标频率 1

设置目标谐振频率为 8.70GHz, 允许误差 ε 为 0.1。在两种方案下分别进行天线开关状态寻优。图 4-10 中是两种方案优化得到的天线结构俯视图, 开关状态序列分别为 [1 1 0 0 0 1 1 0 1 0 1 0]和 [0 0 0 1 0 0 1 1 1 1 1 0]。





图 4-10 (1) 方案一天线结构; (2) 方案二天线结构

图 4-11 两种方案下可重构天线 S_{11} 曲线图

如图 4-11 所示，两种方案下的 S_{11} 曲线几近重合，谐振频率均实现了设定目标 8.70GHz，-10dB 阻抗带宽为 8.61~8.81GHz。方案一得到天线 S_{11} 最小值达到 -41.91dB，方案二天线 S_{11} 最小值达到 -59.52dB。两种方案优化得到的天线性能相当，在不考虑初始样本采集代价情况下，方案二电磁仿真软件调用次数仅为方案一的 3.60%，加上样本采集方案二调用次数为方案一的 20.55%，调用次数的对比证明了结合代理模型的方法大大提高了开关状态的搜索效率。

表 4-6 优化结果

序号	开关序列	f_{obj} (GHz)	f (GHz)	S_{11min} (dB)	仿真次数
方案一	110001101010	8.70	8.70	-41.91	472
方案二	000100111110	8.70	8.70	-59.52	17




图 4-12 方案二寻优适应度收敛曲线（频率 1）

(2) 目标频率 2

设置目标谐振频率为 10.40GHz，允许误差 ε 为 0.1，在方案一和方案二下分别进行天线开关状态寻优。




图 4-13 方案一与方案二天线结构




图 4-14 两种方案下可重构天线 S11 曲线图

两种优化方案得到同一天线结构，开关状态序列为[1 1 1 0 0 0 0 1 0 0 0 1]，谐振频率为 10.43GHz，与设定目标 f_{obj} 之间的差距在允许误差范围内。有效阻抗带宽为 9.68~11.46GHz，与目标频率 1 下的工作频段没有重合，天线 S_{11} 最小值达到-44.84dB。

在不考虑初始样本采集代价情况下，方案二电磁仿真软件调用次数仅为方案一的 2.67%，加上初始样本采集的调用次数方案二为方案一的 17.90%。而实际上初始样本采集工作仅进行了一次，训练的代理模型可在多种不同目标优化过程中发挥作用，进一步体现了方案二效率上的优势。

表 4-7 优化结果

序号	开关序列	f_{obj} (GHz)	f (GHz)	S_{11min} (dB)	仿真次数
方案一	1 1 1 0 0 0 0 1 0 0 0 1	10.40	10.43	-44.84	525
方案二	1 1 1 0 0 0 0 1 0 0 0 1	10.40	10.43	-44.84	14




图 4-15 方案二寻优适应度收敛曲线（频率 2）

4.5 本章小结

本章从传统代理模型构建出发，提出一种自学习代理模型，该模型通过结构选择、代理模型与原模型阈值切换以及加入优势个体后在线更新等策略，一定程度上平衡了模型预测精度和构建成本之间的矛盾。结合 IWOA 算法和代理模型完成了一款不规则多边形超宽带天线结构参数的优化设计。结合 BIWOA 算法和代理模型完成了具有 12 个开关的频率可重构天线开关状态的探索。优化得到天线的性能均满足预期要求，且通过电磁仿真软件调用次数对比，证明了结合代理模型的方案与单纯使用优化算法的方案相比，在优化效率上有大幅度提升。

第五章 总结与展望

5.1 论文总结

本文将智能优化算法和代理模型技术引入以性能为向导的天线设计中,实现了天线连续型和离散型变量结构参数的自动优化设计,与传统方法相比减少了人工操作,提高了优化效率。本文在广泛调研的基础上,进行了原理分析、算法改进、仿真对比、实例验证等工作,对目前研究的内容和结论总结如下:

(1) 智能优化算法的改进设计。首先对经典的以及近年来出现的各种智能优化算法进行了广泛研究,按照算法主要策略的起源进行分类,从中选择了 11 种较有代表性的算法进行了仿真验证,接着确定了鲸鱼优化算法作为本文研究点,选择的原因主要有:算法提出年限较短,具有待开发的研究价值;算法原理清晰,运算速度快;算法在测试函数中表现出了不错的寻优能力。然后从 WOA 算法原理和不足出发,提出非线性收敛因子、自适应权重系数、混合变异、边界约束四种策略进行改进。在 23 个不同类型的基准测试函数上进行数值验证,证明了 IWOA 算法相比原 WOA 和其他几种算法在收敛速度、稳定性和结果精度方面具有明显优势。最后引入多种 S 型和 V 型传递函数对 IWOA 算法进行离散化处理得到 BIWOA,使其有能力应对二进制参数优化问题。

(2) 基于上述两种算法和联合仿真实现天线自动优化设计。基于 IWOA 算法实现了矩形切角超宽带天线以带宽和回波损耗为目标的结构参数优化,优化得到的 4 款天线均覆盖了 3.1~10.6GHz 频段,频带内回波损耗表现良好,且具有全向辐射特性。基于 S_1 传递函数处理后的 BIWOA 算法完成了开关式可重构天线设计,优化变量为方形贴片之间的 24 个行列开关状态序列,优化目标为指定的谐振频率点和该点处的回波损耗值,得到在 5 种不同开关状态下天线分别谐振于 1.52、3.94、4.70、8.50、10.25GHz,工作在 L、S、C、X 不同波段,实现了频率可重构且控制了谐振点处反射系数小。

(3) 结合自学习代理模型实现天线自动优化设计。在天线设计方案中引入自学习代理模型代替 HFSS 软件实现结构参数到性能响应的映射。首先利用改进的 LHS 方法构建结构参数样本集,调用 HFSS 联合仿真计算得到响应,通过初始训练进行模型结构选择。然后在优化过程中引入模型完成对鲸鱼个体适应度的预测,对新产生的“潜力解”切换到 HFSS 进行精确求解并加入数据库,新增样本数达到设定值时启动模型训练,进一步提升优化后期“潜力解”周围区域模型预测精度。在本章中,结合 IWOA 算法和代理模型实现了一款不规则多边形超宽带天线,以阻抗带宽和频带内反射系数为目标的连续型结构参数优

化；结合 BIWOA 算法和代理模型完成了一款频率可重构天线，以谐振频率和反射系数为目标的二进制行列开关状态搜索。与不使用代理模型方案相比，在找到性能相当的天线结构时电磁仿真次数大大减少。

综上所述，本文通过智能优化算法以及智能优化算法结合代理模型两种方案实现了多种微带天线的优化设计，以较有应用前景的超宽带天线和可重构天线为主。智能方法的引入实现了设计空间的自动探索，减少了人工操作需求，提高了优化速度，最后得到的天线性能也更加优异，在天线设计领域具有实际应用价值。

5.2 工作展望

本文在微带天线自动优化设计领域进行了一些研究，但是由于时间和水平有限，工作中还存在着一些不足，未来可再进一步深入和完善：

（1）优化算法层面：本文改进了鲸鱼优化算法，在后续研究中可以考虑：从更多的新型优化算法中进行筛选、针对具体应用场景提出更有效的改进策略、吸收不同算法的优势进行融合等措施找到更加适合于天线设计的算法。本文设计实例中将不同优化目标转化为单目标后再进行下一步工作，后续可以继续研究多目标优化的平衡策略。

（2）代理模型层面：本文模型建立在元代理模型基础上，后续可以考虑引入更多改进模型、混合模型，还可以在样本规模和抽样策略上进行改进，追求以更小的代价获得更高的预测精度。

（3）天线层面：本文主要对微带天线 S_{11} 曲线相关的性能指标进行优化，后续可以考虑尺寸、方向图、极化等更多优化方向，深入探索不同类型结构参数与天线性能表现之间的关系，或者完成某具体通信场景所需天线的设计并制作实物完成测量。

（4）平台自动化层面：本文初步实现了微带天线的自动优化设计，将不同的算法、模型集成为软件平台以应对各种类型的天线设计是可继续研究的方向。

参考文献

- [1] 董健, 晋凡, 钦文雯等. 融合智能算法和代理模型的天线快速优化平台设计[J]. 电讯技术, 2019, 59(4): 462-467.
- [2] Holland J H. Adaptation In Natural And Artificial Systems[M]. Cambridge: MIT Press, 1975: 100-120.
- [3] Johnson J M, Rahmat-Samii, Y. Genetic algorithm optimization and its application to antenna design[C], Antennas and Propagation Society International Symposium, 1994. AP-S. Digest. IEEE, 1994, 1: 326-329.
- [4] Johnson J M, Rahmat-Samii Y. Genetic algorithms and method of moments (GA/MoM): A novel integration for design[C], Antennas and Propagation Society International Symposium, 1997. IEEE, 1997 Digest. IEEE, 1997, 3: 1664-1667.
- [5] Sun S, Lv Y, Zhang J, et al. Optimization based on genetic algorithm and HFSS and its application to the semiautomatic design of antenna[C]// 2010 International Conference on Microwave and Millimeter Wave Technology. IEEE, 2010: 892-894.
- [6] Orankitanun T, Yaowiwat S. Application of Genetic Algorithm in Tri-band U-slot Microstrip Antenna Design[C]// 2020 17th International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology (ECTI-CON). 2020.
- [7] Lizzi L, Viani F, Azaro R, et al. Optimization of a spline-shaped UWB antenna by PSO[J]. IEEE Antennas & Wireless Propagation Letters, 2007, 6(11):182-185.
- [8] Kovaleva M, Bulger D, Esselle K P. Comparative Study of Optimization Algorithms on the Design of Broadband Antennas[J]. IEEE Journal on Multiscale and Multiphysics Computational Techniques, 2020, PP (99):1-1.
- [9] Al-Azza A A, Al-Jodah A A, Harackiewicz F J. Spider Monkey Optimization: A Novel Technique for Antenna Optimization[J]. IEEE Antennas and Wireless Propagation Letters, 2015.
- [10] Saxena P, Kothari A. Ant Lion Optimization algorithm to control side lobe level and null depths in linear antenna arrays[J]. AEUE - International Journal of Electronics and Communications, 2016, 70(9):1339-1349.
- [11] Dastranj, Aliakbar. Optimization of a Printed UWB Antenna Application of the invasive weed optimization algorithm in antenna design[J]. IEEE Antennas & Propagation Magazine, 2017: 2-11.
- [12] Li X, Luk K M. The Grey Wolf Optimizer and Its Applications in

- Electromagnetics[J]. IEEE Transactions on Antennas and Propagation, 2020, 68(3):2186-2197.
- [13] Darvish A, Ebrahimzadeh A. Improved Fruit-Fly Optimization Algorithm and Its Applications in Antenna Arrays Synthesis[J]. IEEE Transactions on Antennas and Propagation, 2018, 66(4):1756-1766.
- [14] 任春慧,刘升,张伟康,张微微. 柯西变异的骆驼算法优化与应用[J]. 计算机工程与应用, 2021, 57(21):8.
- [15] Liang Z, Ouyang J, Yang F. A hybrid GA-PSO optimization algorithm for conformal antenna array pattern synthesis[J]. Journal of Electromagnetic Waves & Applications, 2018:1-15.
- [16] Ustun D, Akdagli A. Design of band-notched UWB antenna using a hybrid optimization based on ABC and DE algorithms[J]. AEU - International Journal of Electronics and Communications, 2018, 87.
- [17] Deb K, Agrawal S, Pratap A, et al. A Fast Elitist Non-dominated Sorting Genetic Algorithm for Multi-objective Optimization: NSGA-II[J]. Lecture Notes in Computer Science, 2000, 1917:849--858.
- [18] Coello C, Ing D, Lechuga M S. MOPSO: A Proposal for Multiple Objective Particle Swarm. 2003.
- [19] Xue F, Sanderson A C, Graves R J. Pareto-based multi-objective differential evolution[C]. Canberra: Congress on Evolutionary Computation, 2003.
- [20] 郭欣欣, 陈晓辉, 裴进明. 一种基于代理模型和差分进化的天线高维快速优化算法[J]. 安徽工程大学学报, 2017, 32(01):63-67.
- [21] Hassan A K S, Etman A S, Soliman E A. Optimization of a Novel Nano Antenna with Two Radiation Modes using Kriging Surrogate Models[J]. IEEE Photonics Journal, 2018, 10(4): 1-17.
- [22] Tomasson J A, Pietrenko-Dabrowska A, Koziel S. Expedited Globalized Antenna Optimization by Principal Components and Variable-Fidelity EM Simulations: Application to Microstrip Antenna Design[J]. Electronics, 2020, 9(4):673.
- [23] Varma R, Ghosh J. Design of electromagnetically-coupled microstrip antennas using neural networks[C]// 2016 2nd International Conference on Contemporary Computing and Informatics (IC3I). IEEE, 2016.
- [24] Kaur G, Rattan M, Jain C. Design and Optimization of PSI (Ψ) Slotted Fractal Antenna Using ANN and GA for Multiband Applications[J]. Wireless Personal Communications, 2017.

- [25] Dong J, Qin W, Wang M. Fast Multi-Objective Optimization of Multi-Parameter Antenna Structures Based on Improved BPNN Surrogate Model[J]. IEEE Access, 2019, 7:77692-77701.
- [26] Gampala G, Reddy C J. Fast and Intelligent Antenna Design Optimization using Machine Learning[C]// 2021:1350-1351.
- [27] 洪涛, 贺则昊, 王翠,等. 基于 BiLSTM 代理模型的 RFID 标签天线快速多目标设计[J]. 微波学报, 2021, 37(1):7: 21-27.
- [28] Mahouti P, Kızılay A, Tari O, A, et al. Design Optimization of Ultra-Wide Band Vivaldi Antenna Using Artificial Intelligence. ACES, 2021, pp.1-4.
- [29] Cui L, Zhang Y, Zhang R, et al. A Modified Efficient KNN Method for Antenna Optimization and Design[J]. IEEE Transactions on Antennas and Propagation, 2020, PP(99):1-1.
- [30] 赵越. 微带天线的宽频带与小型化技术研究[D]. 西南交通大学, 2020.
- [31] Kennedy J, Eberhart R C. Particle Swarm Optimization[C]. Proceedings of the IEEE International Conference on Neural Networks. Piscataway, 1995:1942- 1948.
- [32] Rashedi E, Nezamabadi-Pour H, Saryazdi S. GSA: A Gravitational Search Algorithm[J]. Information Sciences. 2009, 179(13): 2232-2248.
- [33] Mirjalili S, Mirjalili S M, Lewis A. Grey Wolf Optimizer[J]. Advances in Engineering Software, 2014, 69(3):46–61.
- [34] Mirjalili S. Moth-flame optimization algorithm: A novel nature-inspired heuristic paradigm[J]. Knowledge-Based Systems, 2015, 89:228-249.
- [35] Mirjalili S, Lewis A. The Whale Optimization Algorithm[J]. Advances in Engineering Software, 2016, 95: 51-67.
- [36] Mirjalili S, Gandomi A H, Mirjalili S Z, et al. Salp swarm algorithm: a bio-inspired optimizer for engineering design problems[J]. Advances in Engineering Software, 2017, 114: 163-191.
- [37] Giunta A A, Wojtkiewicz S F, Eldred M S. Overview of modern design of experiments methods for computational simulations[C]//Proceedings of the 41st AIAA aerospace sciences meeting and exhibit, AIAA-2003-0649. 2003.
- [38] McKay M D, Beckman R J, Conover W J. Comparison of three methods for selecting values of input variables in the analysis of output from a computer code[J]. Technometrics, 1979, 21(2): 239-245.
- [39] Metropolis N C, Ulam S M. The Monte Carlo Method[J]. Journal of the American Statistical Association, 1949, 44(247):335-341.

- [40] Zhang Y S, Li W G, Zheng M Z. Orthogonal arrays obtained by generalized difference matrices with g levels[J]. SCIENCE CHINA Mathematics, 2011, 54(1).
- [41] Saltelli A, Andres T H, Homma T. Sensitivity analysis of model output. Performance of the iterated fractional factorial design method[J]. Computational Statistics & Data Analysis, 1995, 20(4): 387-407.
- [42] 张德虎, 高正红, 李焦赞, 等. 代理模型选样准则研究[J]. 空气动力学学报, 2011, 29(06): 719-725+732.
- [43] Johnson M E, Moore L M, Ylvisaker D. Minimax and maximin distance designs[J]. Journal of Statistical Planning & Inference, 1990, 26(2): 131-148.
- [44] Maini, Surita, Marwaha, et al. Modeling and simulation of novel antenna for the treatment of hepatocellular carcinoma using finite element method.[J]. Electromagnetic Biology & Medicine, 2013, 32(3).
- [45] Watkins W A, Schevill W E. Aerial Observation of Feeding Behavior in Four Baleen Whales: *Eubalaena glacialis*, *Balaenoptera borealis*, *Megaptera novaeangliae*, and *Balaenoptera physalus*[J]. Journal of Mammalogy, 1979(1): 155-163.
- [46] Goldbogen J A, Friedlaender A S, Calambokidis J, et al. Integrative approaches to the study of baleen whale diving behavior, feeding performance, and foraging ecology[J]. BioScience. 2013, 63: 90-100.
- [47] Zhong M, Long W, Xu B, et al. Whale optimization algorithm with nonlinear control parameter[J]. MATEC Web of Conferences, 2017, 139:00157.
- [48] 苏福清, 匡洪海, 钟浩, 等. 基于柯西变异改进粒子群算法的无功优化[J]. 电气工程学报, 2021, 16(1): 55-61.
- [49] 陈亚环. 混合群智能算法及其在聚类分析中的应用研究[D]. 陕西: 西安电子科技大学, 2018.
- [50] Mirjalili S, Lewis A. S-shaped versus V-shaped transfer functions for binary Particle Swarm Optimization[J]. Swarm & Evolutionary Computation, 2013, 9(Complete): 1-14.
- [51] Weedon W H, Payne W J, Rebeiz G M. MEMS-switched reconfigurable antennas[C]. Antennas & Propagation Society International Symposium. IEEE, 2001.
- [52] Jones D R, Schonlau M, Welch W J. Efficient Global Optimization of Expensive Black-Box Functions[J]. Journal of Global Optimization, 1998, 13(4): 455-492.
- [53] Forrester A, Sobester A, Keane A J. Engineering Design Via Surrogate Modelling:

- A Practical Guide[M]. DBLP, 2008.
- [54]Oliver M A, Webster R. Kriging: a method of interpolation for geographical information systems[J]. International Journal of Geographical Information System, 1990, 4(3): 313-332.
- [55]Brereton R G, Lloyd G R. Support Vector Machines for classification and regression[J]. ANALYST, 2010, 135(2):230-0.
- [56]Amari S, Wu S. Improving support vector machine classifiers by modifying kernel functions[J]. Neural Networks, 1999, 12(6):783-789.
- [57]Kolmogorov A N. On the representation of continuous functions of several variables by superposition of continuous functions of one variable and addition[J]. Doklady Akademii nauk SSSR, 1957, 114:369-373.
- [58]Breiman. Random forests[J]. MACH LEARN, 2001, 2001,45(1):5-32.
- [59]Mahmoud K R. UWB Antenna using Gravitational Search Algorithm[J]. Journal of engineering ences, 2013, 41(5): 1890-1903.